

TEKNOFEST

HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

ULAŞIMDA YAPAY ZEKA YARIŞMASI

KRİTİK TASARIM RAPORU

BigBrainNet

417063

TEKNOFEST
İSTANBUL HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

İÇİNDEKİLER

ŞEKİL LİSTESİ	3
TABLO LİSTESİ	4
1. TAKIM ŞEMASI	5
2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ	5
3. ALGORİTMALAR VE SİSTEM MİMARİSİ	6
3.1 Veri Setleri	6
3.2 Algoritmalar	6
3.2.1 Yolo V5	6
3.2.2 Non-Maximum Suppression (Maksimum Olmayanı Bastırma) Algoritması	7
3.2.3 Sistem Mimarisi	8
4. ÖZGÜNLÜK	9
5. SONUÇLAR VE İNCELEME	11
6. KAYNAKÇA	13



ŞEKİL LİSTESİ

Şekil 1. Takım Şeması.....	5
Şekil 2. Özgün frame görüntüsü	5
Şekil 3. Görsel tahmin sonucu	6
Şekil 4. YOLOv5 Mimarisi [5]	7
Şekil 5. Non-Maximum Suppression Algoritmasının Etkisi [10]	7
Şekil 6. Sistem Mimarisi.....	8
Şekil 7. Sentetik oluşturulan görüntüler.....	9
Şekil 8. Sentetik oluşturulan görüntüler.....	10
Şekil 9. Görsel tahmin sonuçları	11
Şekil 10. Görsel tahmin sonuçları	12




TABLO LİSTESİ

Tablo 1. YOLOv5 modelinin versiyonları [6] 8



1. TAKIM ŞEMASI

BigBraNet takımı, 7 kişiden oluşmaktadır (Şekil 1). 6 üye Samsun Üniversitesinde eğitimine devam etmekte olup, 2 üye yazılımı mühendisliği, 2 üye elektrik-elektronik mühendisliği ve 2 üye havacılık ve uzay mühendisliği lisans eğitimine devam etmektedir. Takımdaki bu üyeler, yazılım geliştirme sorumlusu, veri tabanı sorumlusu ve raporlama sorumlusu olarak görev yapmaktadırlar. Ayrıca, takım danışmanı görüntü işleme ve yapay öğrenme alanında uzun yıllar akademik deneyime sahiptir ayrıca bu alanda çeşitli projeler yürütmektedir.



Şekil 1. Takım Şeması

2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ


Sistemin eğitilmesi için kullanılması planlanan COCO ve VisDrone veri setleri indirildi. Ayrıca kendi İnsansız Hava Aracımız (İHA) ile yapılan uçuşlar sonrasında elde edilen görseller indirilen veri setleri ile birleştirildi (Şekil 2). Toplanan bu verilerden maksimum verim elde edilebilmesi için veri setlerinin içerisinde bulunan video ve görsellerin kontrast ve parlaklık gibi ayarlamaları yapılarak görüntüler daha yüksek bir performans için iyileştirildi. Videoların içerisinde hareket bulanıklığı olan frame'ler süzgeç ve filtreler yardımı ile netleştirildi. Etiketsiz verilerin etiketlenmesi için kullanılması planlanan Labellmg açık kaynak kodlu yazılım işlevsellik, kullanım kolaylığı ve performans açısından test edildi. El ile etiketleme sırasında program arayüzünün basitliği ve işlevselliği nedeniyle Labellmg yazılımı el ile işaretleme işlemlerinde kullanılmaya devam edilecektir. Elde edilen veri setlerinin genişletilmesi ve özgün bir veri seti elde edilmesi için süreç devam etmektedir.



Şekil 2. Özgün frame görüntüsü

Ön tasarım raporunda kullanılması planlanan YOLOv5 modelinin versiyonları kullanılarak kapsamlı deneysel çalışmalar gerçekleştirilmiştir. Bu versiyonlar arasından en yüksek performans YOLOv5l6 modeli ile elde edilmiştir. Bu deneysel çalışmalarda, özgün olarak elde edilen frame'lerin yanı sıra COCO ve VisDrone veri setlerinde yarışma için paylaşılan veri kümesindekilere benzeyen görüntülerin çıkartılarak kullanılmıştır. Bu sayede, veri çeşitliliği artırılarak geliştirilen modelin öğrenme performansı artırılması amaçlanmıştır.

Bu projede, özgünlük bölümünde detaylı olarak sunulan NXN'lik bölme yaklaşımına dayalı geliştirilen YOLOv5l6 modeli kullanılarak performans 0.918 mAP@0.5 elde edilmiştir. Ayrıca, geliştirilen model, TEKNOFEST tarafından sağlanan video kullanılarak test edilmiştir. Sonuç olarak, %96 ortalama kesinlik elde edilmiştir. Görsel tahmin sonucu ile ilgili örnek bir frame Şekil 3'de verilmiştir.



Şekil 3. Görsel tahmin sonucu

3. ALGORİTMALAR VE SİSTEM MİMARİSİ

3.1 Veri Setleri

Projede nesne tespiti için veri kümesi olarak COCO [1] ve VisDrone [2] veri setleri kullanılmıştır. Bu veri setleri ile geliştirilen modelin eğitim aşamasında kullanılmıştır. Fakat veri setlerinde etiketli insan/taşıtlarının az olmasından dolayı, kendi İnsansız Hava Aracımız (İHA) ile çekilen görüntüler etiketleme işlemi yapılarak veri seti genişletilmesi yapılmıştır. Etiketleme işlemi için LabelImg [3] açık kaynak kodlu yazılım kullanıldı. Ayrıca, iniş-kalkış alanlarının tespiti görevi için gerekli logolar, drone yardımı ile elde edilen görüntülere yerleştirilerek oluşturulan veri kümesi de eğitim setine katılmıştır.


3.2 Algoritmalar

YOLO algoritmasına dayalı modelleri detaylı olarak araştırdıktan sonra, gerçek zamanlı çalışma hızı yüksek ve küçük obje tespitindeki yüksek performansından dolayı PyTorch temelli YOLOv5 [6] mimarisi kullanıldı.

3.2.1 Yolo V5

YOLO (You Only Look Once), nesne tespiti için Evrişim Sinir Ağını kullanan tek aşamalı bir derin öğrenme algoritmasıdır [4]. Diğer derin öğrenme modellerinin aksine, YOLO algoritması, algılamayı bir sinir ağı aracılığıyla tek bir ileri yayımda yapmaktadır [5]. Buna ek olarak, bu algoritma tespit edilen nesnelerin konum bilgilerini verir ve böylece nesnelerin konumlarından üst üste olup olmadıklarını anlamamızı sağlar. YOLO algoritmasının çalışma prensibi genel olarak görüntüyü bölgelere ayırır ve ardından her bölgedeki nesneleri çevreleyen Bounding Box (Kapsayıcı Kutu) ile çizer. Daha sonra, her bir bölgede nesne bulunma olasılığını hesaplar. Bu hesaplanan güven skorlarına bağlı olarak nesneleri tahmin etmektedir [4-5].


Şekil 4'de belirtildiği üzere, bu mimari giriş modülü, omurga ağı, boyun ağı ve tahmin ağı olmak üzere dört ana bölümden oluşmaktadır. Ayrıca, YOLOv5 mimarisi, Darknet53 mimarisi yerine CSPDarknet53 özellik çıkarım modelini kullanmaktadır [5,7].



Şekil 4. YOLOv5 Mimarisi [5]

3.2.2 Non-Maximum Suppression (Maksimum Olmayanı Bastırma) Algoritması

YOLO algoritması, öncelikle görüntüyü $N \times N$ 'lik ızgaralara böler. Bu ızgara boyutları görselin boyutuna ya da farklı diğer değişkenlere bağlı olarak değişebilir (5x5, 9x9, vs.). Her ızgara kendisine belirlenen alan içerisinde nesne olup olmadığını kontrol eder. Kendi alanı içerisinde nesne olduğunu düşünen ızgaralar bu nesnenin merkez noktasının da kendi ızgarası içinde olup olmadığını kontrol eder. Merkez noktasının kendi içinde olduğunu düşünen ızgaralar nesnenin çevresini bounding box ile çizer. Fakat bir nesne için birden fazla ızgaranın kendisinin merkez nokta olduğunu düşünerek bounding box çizmesi durumunda ekranda gereksiz bounding box lar oluşur. Bu sorunu çözmek için "Non-Maximum Suppression Algoritması" kullanılır (Şekil 5). Bu algoritma, her bir bounding box için bir güven skoru hesaplanmasını ve en yüksek güven skoruna sahip olan bounding box'ın seçilmesini sağlar. Sonuç olarak, en doğru ve en az hataya sahip çerçeve çizilmiş olunur [8-10].



Şekil 5. Non-Maximum Suppression Algoritmasının Etkisi [10]


ÖTR'de İHA ile çekilmiş görüntülerde nesnelerin tespiti için YOLOv5 algoritması kullanmaya karar verilmişti. Bu model içerisinde çeşitli katman yapılarına sahip birçok versiyonu bulunmaktadır. Bu versiyonlar ile ilgili detaylı bilgiler Tablo 1'de verilmiştir. Bu projede, bu modelin her bir versiyonu, problemimize uyarlanıp. Daha sonra, her bir versiyon için eğitim ve test işlemi gerçekleştirilmiştir. Yapılan işlemlerden sonra alınan sonuca göre YOLOv5l6 versiyonu kullanılmaya karar verilmiştir.

Tablo 1. YOLOv5 modelinin versiyonları [6]

Versiyon	Boyut (piksel)	mAP ^{val} (0.5)	Hız (ms)	Parametreler (M)	FLOPs (B)
YOLOv5s	640	55.4	2.0	7.3	17.0
YOLOv5m	640	63.1	2.7	21.4	51.3
YOLOv5l	640	66.9	3.8	47.0	115.4
YOLOv5x	640	68.8	6.1	87.7	218.8
YOLOv5s6	1280	61.9	4.3	12.7	17.4
YOLOv5m6	1280	68.7	8.4	35.9	52.4
YOLOv5l6	1280	71.1	12.3	77.2	117.7
YOLOv5x6	1280	72.0	22.4	141.8	222.9

3.2.3 Sistem Mimarisi

BigBrainNet Takımı olarak yarışma sırasında kullanacağımız algoritma ve mimarinin şeması Şekil 6.'da gösterilmiştir.



Şekil 6. Sistem Mimarisi

Yarışma isterlerini karşılayacak sistem mimarisi tasarlanırken çalışmalar parçalar halinde yürütülmüştür. Bu aşamalar şöyledir:

Veri Setinin Eldesi: Öncelikle yapay zeka modelinin eğitimi baz alınmış, bu eğitim için veri seti eldesi ve elde edilen veri setlerinin iyileştirilmesi yapılmıştır. Proje kapsamında kullanılacak veri setlerinin eldesi için VisDrone ve COCO veri setleri kullanılmış ve bu veri setlerinin haricinde kendi İHA'mızın çekmiş olduğu görüntüler ile veri seti özgünleştirilmiştir.

Veri Setinin Organizasyonu: Elde edilen veri seti içerisinde işleme uygun olmayan verilerin elenmesi ve ayıklanması işlemi uygulanmış, bu uygulama sonrasında daha verimli ve performanslı bir set eldesi yapılmıştır.

Veri Etiketleme: Elde edilen veri setlerine UAP ve UAİ şekillerinin eklendiği yeni veriler Labellmg açık kaynak kodlu yazılım aracı ile etiketlendikten sonra oluşan etiketli yeni veriler eklenmiştir.

Veri Çoğaltma: Veri setlerinin içerisinde bulunan video ve görsellerin kontrast ve parlaklık, kırpma, pozlama gibi ayarlamaları yapılarak görüntüler daha yüksek bir performans için iyileştirildi.

Yapay Zeka Modelinin Eğitimi: Elde edilen nihai veri seti yine aynı şekilde belirlenen en uygun optimum hiper parametreler baz alınarak eğitildi. Projenin eğitim aşamasında, 2xIntel Xeon


Silver4114(20Core) (2.20GHz, 3.00GHz Turbo, 13.75MB), 64GB DDR4 2666MHz RAM, Quadro P4000 8GB ekran kartına sahip iş istasyonu kullanılmıştır.

Yarışma Sırasında Kullanılacak Eğitilmiş Yapay Zeka Modeli: Yukarıda belirtilen aşamalar sonrasında oluşan ve yarışma sırasında kullanılmaya hazır olan eğitilmiş yapay zeka modeli şartnamede belirtilen formata uygun olarak bize verilen JSON dosyasından verilerin alınması ile başlar. Yarışma esnasında (Test Aşamasında) ise NVIDIA RTX 2080 GPU, 32 GB RAM ve Intel Core i7 işlemciye sahip bir bilgisayar kullanılacaktır. Alınan veriler önceden eğitilmiş yapay zeka modelinde işlenerek yine aynı dosya formatına sahip bir çıktı oluşturulur. Oluşturulan çıktı yarışma sunucusuna yüklenir.

4. ÖZGÜNLÜK

Bu projenin özgün yönleri şunlardır:

- Projede geliştirilen modelin eğitim aşaması için COCO [1] ve VisDrone [2] gibi veri setlerinde benzer görüntüler çıkartılarak kullanılmıştır. Bu veri setlerinin yanı sıra kendimiz döner kanatlı İHA kullanılarak özgün bir veri seti elde edilmiştir. 2000 frame içeren bu veri seti için etiketleme işlemleri gerçekleştirilmiştir (Şekil 2). Ayrıca Uçan Araba Park (UAP) Alanı ve Uçan Ambulans İniş (UAI) Alanı sınıfları için sentetik veriler oluşturulmuştur (Şekil 7). Bu şekilde geliştirilecek modelin tespit performansı artırılmıştır.



Şekil 7. Sentetik oluşturulan görüntüler

- Teknik şartnamede de yer aldığı üzere yarışmacılara sunulan görüntüler değişken hava koşulları ve parlaklık/kontrast gibi gürültüler içermektedir. Bu yüzden, İnsan, taşıt, Uçan Araba Park (UAP) Alanı ve Uçan Ambulans İniş (UAI) Alanı sınıflarını içeren nesnelerin tespiti için yansıtma, döndürme ve bulanıklaştırma gibi veri artırma (Data Augmentation) yöntemleri kullanılarak veri setinin genişletilmesi sağlanmıştır. Böylece, veri kümesinin çeşitliliği ve kalitesi artırılmış ve kullanılması planlanan modelin performansının artırılması amaçlanmıştır.
- Bu projede, giriş görüntüsünü NXN'lik matrislere bölünmesi ve ardından her bir bölge için geliştirilen derin öğrenme model kullanılarak tahmin sonuçları elde edilmiştir. Daha sonra, her bir bölge için elde edilen tahmin sonuçları, bir birleştirme algoritmasına tabi tutularak orijinal boyuttaki görüntü üzerinde yeniden yerleştirilmiştir (Şekil 8). Önerdiğimiz bu model kullanılarak küçük boyuttaki nesneleri yüksek performans ile tespit edilmiştir. İlgili görsel sonuçları Şekil 9'da verilmiştir.



Şekil 8. Sentetik oluşturulan görüntüler

Şekil 8'de, görüntüyü 3x3 boyutunda dilimlere ayrılmış ve 9 farklı bölge elde edilmiştir. Daha sonra, her bir bölge için geliştirilen derin öğrenme modeli uygulanmış ve ardından tüm tahmin sonuçları birleştirilmiştir.

- Bu projede, İHA ile çekilmiş görüntülerde nesnelerin tespiti için YOLOv5 modelinin versiyonlarının her biri için eğitim (%80) ve test aşaması (%20) uygulanmıştır. Bu versiyonlar arasında en iyi performansı, 0.918 mAP@0.5 olarak YOLOv5l6 modeli ile elde edilmiştir. Ayrıca, diğer YOLOv4, YOLOv3 gibi modeller de kullanılmış ve performansları karşılaştırılmıştır.

KTR aşamasında sonra yapılması planlananlar şunlardır:


- Geliştirilen derin öğrenme modelinin giriş görüntü boyutları yükseltilerek nesne tespiti başarımına etkileri gözlemlenecektir. Böylece, en iyi performansa sahip giriş boyutu seçilecektir.
- Projede geliştirilen modelin eğitim aşaması için VisDrone-2019 gibi farklı veri setleri araştırılacak ve Teknofest Ulaşım'da Yapay Zeka yarışmasındakine benzer görüntülerin çıkarılması gerçekleştirilecektir. Ayrıca, döner kanatlı İHA kullanılarak özgün bir veri seti daha fazla genişletilecektir. Bu sayede, veri çeşitliliği artırılarak önerilen modelin eğitim/öğrenme performansının artırılması hedeflenmektedir.

- YOLOv5 versiyonları arasında belirlenen en iyi performansa sahip modellere dayalı hibrit bir sistem geliştirilmesi planlanmaktadır. Bu sistem her iki algorithmadan elde edilecek sonuçları etkili bir şekilde birleştirmeye dayanmaktadır. Bu birleştirme işlemi için çoğunluk oylayıcı yöntemi kullanılacaktır. Bu doğrultuda, farklı modellerden elde edilen tahmin kapsayıcı kutularının ağırlık değerleri dikkate alınarak birleştirme işlemi uygulanacaktır.

5. SONUÇLAR VE İNCELEME

Bu kısımda geliştirilen sistemin yarışmacılar tarafından elde edilmiş sonuçları paylaşılır ve bu sonuçlar üzerine sistemin performansı üzerine inceleme sunulur. Uygulanan test senaryoları ve sonuçları hakkında bilgi verilir. Yapılan testlerin sonuçları ile uygulanan yöntemlerin ne kadar uyumlu olduğu karşılaştırılır. Tüm aşamalarında yaşanan sorunlar, yapılan hatalar ve bunların üstesinden nasıl gelindiği, edinilen tecrübeler hakkında bilgi verilir.


Bu projede, elde edilen veri seti, eğitim ve test kümeleri, rastgele %80-%20 olarak ayrılmıştır. Daha sonra, YOLOv5 model versiyonları ayrı ayrı uygulanmıştır. Bu versiyonlar arasında en iyi performansı, 0.87 mAP@0.5 olarak YOLOv5l6 modeli ile elde edilmiştir. Ayrıca, özgünlük bölümünde (Bölüm 4) belirtilen giriş görüntüsünü NXN'lik matrislere bölünmesine dayalı geliştirilen yaklaşım kullanılarak eğitim ve test işlemleri tekrarlanmıştır. Sonuç olarak, YOLOv5l6 modeli 0.918 mAP@0.5 elde edilmiştir. Önerilen yaklaşım kullanılarak yaklaşık %4'lük bir artış sağlanmıştır. İlgili görsel tahmin sonuçları Şekil 9'da verilmiştir.



Şekil 9. Görsel tahmin sonuçları

Şekil 9 (a)'da YOLOv5 modelinin direk uygulanarak elde edilen tahmin sonucu verilirken, Şekil 9 (b)'de ise önerilen bölme yaklaşımına dayalı YOLOv5 kullanılarak elde edilen tahmin sonucu gösterilmiştir. Bu sonuçlara göre, önerilen yaklaşım kullanılarak daha iyi tespit performansı sağladığı gözlenmiştir.

TEKNOFEST tarafından sağlanan video verisinin 30 saniyesi için etiketleme işlemleri gerçekleştirilmiştir. Daha sonra, geliştirilen model, bu videoda test edilmiştir. Sonuç olarak, %96 ortalama kesinlik elde edilmiştir. Görsel tahmin sonucu ile ilgili örnek bir frame Şekil 10'da verilmiştir. Son olarak, özgünlük bölümünde (Bölüm 4) belirtilen KTR aşamasından sonra planladığımız veri setinin genişletilmesi sağlanacak ve geliştirilen model için farklı yaklaşımlar kullanılacaktır. Bu sayede, daha yüksek performanslı bir derin model elde edilmesi hedeflenmektedir.



Şekil 10. Görsel tahmin sonuçları

TEKNOFEST
İSTANBUL HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

6. KAYNAKÇA

- [1] Lin, T.Y., et al. (2014). Microsoft COCO: Common Objects in Context. arXiv preprint arXiv: 1405.0312.
- [2] Zhu, P., Wen, L., Du, D., Bian, X., Hu, Q., and Ling, H. (2020). Vision Meets Drones: Past, Present and Future. CoRR, vol. abs/2001.06303, <https://arxiv.org/abs/2001.06303>.
- [3] Tzutalin. Labellmg. Git code, 2015, <https://github.com/tzutalin/labellmg>.
- [4] Redmon, J., Divvala, S., Girshick, R., and Farhadi, A. (2016). You only look once: Unified, real-time object detection. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 779-788).
- [5] Lei, F., Tang, F., and Li, S. (2022). Underwater Target Detection Algorithm Based on Improved YOLOv5. Journal of Marine Science and Engineering, 10(3), 310.
- [6] Jocher, G., Stoken, A., Borovec, J., Christopher, S.T., and Laughing, L.C. (2021) Ultralytics/yolov5: V4.0-nn.SILU() Activations, Weights & Biases Logging, Pytorch Hub Integration. (GitHub: <https://github.com/ultralytics/yolov5>)
- [7] Nepal, U., and Eslamiat, H. (2022). Comparing YOLOv3, YOLOv4 and YOLOv5 for Autonomous Landing Spot Detection in Faulty UAVs. Sensors, 22(2), 464.
- [8] Hosang, J., Benenson, R., and Schiele, B. (2017). Learning non-maximum suppression. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 4507-4515).
- [9] Rothe, R., Guillaumin, M., and Gool, L. V. (2014, November). Non-maximum suppression for object detection by passing messages between windows. In Asian conference on computer vision (pp. 290-306). Springer, Cham.
- [10] Song, Y., Pan, Q. K., Gao, L., and Zhang, B. (2019). Improved non-maximum suppression for object detection using harmony search algorithm. Applied Soft Computing, 81, 105478.