

TEKNOFEST

**HAVACILIK, UZAY VE TEKNOLOJİ
FESTİVALİ**

**ULAŞIMDA YAPAY ZEKA YARIŞMASI
KRİTİK TASARIM RAPORU**

TAKIM ADI

DetectionByAI

BAŞVURU ID

412556

İÇİNDEKİLER

İÇİNDEKİLER	2
ŞEKİL LİSTESİ.....	3
1. TAKİM ŞEMASI	3
2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ	3
3. ALGORİTMALAR VE SİSTEM MİMARİSİ.....	4
3.1. Veri Setleri	4
3.2. Algoritmalar	5
4. ÖZGÜNLÜK	8
5. SONUÇLAR VE İNCELEME.....	8
6. KAYNAKÇA	12



ŞEKİL LİSTESİ

Şekil 1. Manipüle edilmiş örnek bir kare	5
Şekil 2. Ekibimizin çekimlerinden örnek bir kare	5
Şekil 3. YOLOv4-Large modellerinin mimarisi (Bochkovskiy, 2021)	6
Şekil 4. YOLOR mimarisi (Wang, 2021)	7
Şekil 5. Sistem Şeması	7
Şekil 6. Eğitim grafikleri	9
Şekil 7. YOLOR-E6 modelinin örnek çıktıları	10
Şekil 8. YOLOv4-P5 modelinin örnek çıktıları	10
Şekil 9. YOLOv4 modelinin örnek çıktıları	11
Şekil 10. a) Kesilmiş UAP fotoğrafı b) Mavi renk kanalına Otsu eşiklemesi uygulanmış fotoğraf c) Morfolojik kapama uygulanmış fotoğraf d) İkili görüntüdeki konturun yeşil ile işaretlendiği fotoğraf.....	11
Şekil 11. Tüm modellerin ortak çıktılarını içeren örnek fotoğraflar	12

1. TAKIM ŞEMASI

Takımımız danışman hariç 5 üyeden oluşmaktadır. Üyeler belirlenen görev dağılımı ve takvim kapsamında çalışmakta, bulgularını ortak açılan bulut hesabı üzerinde birleştirmektedirler.

KAPTAN (ÜYE 1), aynı zamanda 2021 Sağlıkta Yapay Zekâ Yarışması'nda finalist takım kaptanı olma görevini üstlenmiştir. Yer aldığı FRC (FIRST Robotics Competition) takımının kamera görüntüsünü kullanarak robotun otonom hareketinden sorumlu üyesidir. TÜBİTAK Lise Öğrencileri Araştırma Projeleri Yarışması'nda görüntü işleme temelli projesi ile katılmış, bölgede derece almıştır. **ÜYE 2**, Etik Hacker'dır ve "TryHackMe: Advent Of Cyber Security 3" sertifikası sahibidir. Kablosuz sensör ağları ve görüntü işleme temelli projesi ile TÜBİTAK Lise Öğrencileri Araştırma Projeleri Yarışması'na katılmış, bölge ve ulusalda derece almıştır. **ÜYE 3**, TÜBİTAK Lise Öğrencileri Araştırma Projeleri Yarışması'na kablosuz sensör ağları, görüntü işleme ve otonom akıllı tarım teknolojileri alanındaki projeleriyle katılmış, bölgede ve ulusalda dereceler almıştır. **ÜYE 4**, TÜBİTAK Bilgisayar Olimpiyatları genç kız takımı üyesidir. **ÜYE 5**, yazılımın farklı alanlarında kendini geliştirmektedir. **DANIŞMAN**, graf teorisi ve optimizasyon teknikleri gibi konularda akademik çalışma sahibi bir matematikçidir. Danışmanlığını yaptığı öğrenciler Tübitak Lise Öğrencileri Araştırma Projeleri Yarışmaları ve TEKNOFEST gibi birçok yarışmada bölge, ulusal ve uluslararası dereceler almışlardır.

KAPTAN ve **ÜYE 2**, denenmek üzere tespit edilen algoritmalar üzerinde çalışmakta, en uygun modelin geliştirilmesi için çaba harcamaktadır. **ÜYE 3** literatür taramalarına devam etmekte, güncel yaklaşımları ve muhtemel iyileştirmeleri takım üyelerine aktarmaktadır. Ayrıca testlerde elde edilen sonuçları analiz ederek, algoritmaların iyileştirilmesi için gereken önlemleri araştırmaktadır. **ÜYE 4** ve **ÜYE 5**, Üye 3 ile eşgüdümlü çalışarak, yapılan testlerin sonuçlarına bağlı olarak farklı veri setleri araştırmakta, bulunan veri setlerini manipüle ederek genişletmekte, kameralı drone çekimleri yaparak eğitimi destekleyecek yeni veri setleri oluşturmaktadırlar. **DANIŞMAN**; bu yarışmada, iş bölümü, takvimleme, takım içi iletişim ve planlamadan sorumludur. Ayrıca, tüm üyelerin çalışmalarından hareketle raporlama sürecini takip etmektedir.

2. Proje Mevcut Durum Değerlendirmesi

Ön tasarım raporundan bu yana yapılan çalışmaları "veri seti" ve "kullanılacak yöntem" açısından iki ayrı başlıkta değerlendirebiliriz.

VERİ SETİ

Ön tasarım raporunda komite tarafından paylaşılan ham görüntülerin, bu görüntülere uygulanacak filtrelerle elde edilecek görüntülerin ve VisDrone2021 veri setinin kullanılacağı; gereği halinde de drone ile kendi çekimlerimizin yapılacağı ifade edilmişti.

Öncelikle komite tarafından paylaşılan görüntüler ile VisDrone2021 veri seti eğitim ve test için uygun formatlara dönüştürülmüştür. UAP ve UAİ alanlarının renk kodlarına ve büyüklüklerine uygun

olarak maketler hazırlanmış, uygun açı ile DJI Tello Drone ile havadan fiziki çekimleri yapılmıştır. Daha sonra tüm bu görüntülere çeşitli hava durumu efektleri (yağmur, kar, sis) uygulanarak veri seti olabildiğince genişletilmiştir. Sonra olarak elde edilen tüm görüntüler takım üyeleri tarafından etiketlenmiştir.

KULLANILACAK YÖNTEM

Ön tasarım raporunda, YOLOv5, Scaled YOLOv4, YOLOR, VGG16, Faster R-CNN ve EfficientDet yöntemleri üzerinde araştırmalar ve denemeler yapılacağı, buna göre en verimli yöntemin seçilerek çalışmaların bu yöntemi iyileştirmek amacıyla devam edeceği ifade edilmişti. Yaptığımız ek literatür taramalarında yer alan bilgilere ve komite tarafından paylaşılan görüntüler üzerinde yaptığımız denemelere göre YOLOR ve Scaled YOLOv4 yöntemlerinin saydığımız diğer tüm yöntemlere göre hız ve doğruluk oranı bakımından daha verimli olduğu değerlendirilmiştir. Bu bakımdan bu yarışmada YOLOR ve YOLOv4 yöntemleri ile ilerleyecektir.

Ön tasarım raporunda bahsedilen algoritmalar ve yöntemler incelemeye ve değerlendirmeye başlanmıştır. Yapılan değerlendirmeler ve incelemeler sonucunda YOLOv5 ve Faster R-CNN'nin Scaled YOLOv4, YOLOR gibi makine öğrenmesi modellerine kıyasla yavaş ve düşük doğrulukta kaldığı görülmüştür. Bundan dolayı YOLOv5 ve Faster RCNN'nin kullanılmasından vazgeçilmiştir. Yapılan araştırmalar sonucunda veri seti üzerinde eğitip performanslarını karşılaştırmak amacıyla YOLOR ve Scaled YOLOv4 yöntemlerinin kullanılmasına karar verilmiştir.

Ön tasarım raporunda, UAP-UAİ tespiti ile taşıt-yaya tespitinin tek modelle mi yoksa ayrı modellerle mi yapılacağına dair bir karar verilmemişti. Veri setlerinde UAP-UAİ sayısı, taşıt ve yaya sayısına göre oldukça azdır. Bu yüzden, kullanılacak tek bir modelin, UAP-UAİ tespitinde farklı taşıt-yaya tespitinde farklı doğruluk oranlarına sahip olabileceği öngörülmüştür. Buna göre yöntem aynı bile olsa bile farklı parametrelerle eğitilecek iki farklı modelin kullanılmasına karar verilmiştir. Böylece hem UAP-UAİ konum tespitinde hem taşıt-yaya tespitinde tek bir modelle ortalama bir doğruluk payı elde edilmesi yerine, her biri için kullanılacak farklı modellerle yüksek doğruluk payı elde edilmesinin önü açılmıştır.

Taşıt ve yaya algılama alanında YOLOR ve Scaled YOLOv4 modelleri eğitilmiş ardından bu modellerin performansları test veri seti üzerinde karşılaştırılmıştır. Karşılaştırmalar sonucunda YOLOR-E6 modelinin kullanılması kararlaştırılmıştır. UAP ve UAİ algılayan modelin sonuçları yeterli görüldüğünden bu alanda karşılaştırmak amacıyla birden fazla model eğitilmemiştir.

UAP ve UAİ alanlarının inişe uygun olup olmadığını anlamak amacıyla klasik görüntü işleme yöntemlerinden otsu eşikleme, morfolojik kapama ve kontur bulma kullanan bir algoritma geliştirilmiştir.

Sonuç olarak konum tespiti yapan iki model ve uygunluk tespiti yapan algoritma birleştirilmiştir. Şu anda modellerimiz simülasyon yarışması için hazırdır. Bundan sonraki süreçte, doğruluğu daha yüksek modeller ve algoritmalar elde edilmeye çalışılacak, sistemin performansını yükseltebilecek yöntemlerin araştırılmasına devam edilecektir.

3. Algoritmalar ve Sistem Mimarisi

3.1 Veri Setleri

UAP-UAİ tespiti ile taşıt-yaya tespiti farklı modellerle yapılacağından sadece UAP ve UAİ alanlarından oluşan bir veri seti ile sadece taşıt ve yayalardan oluşan iki farklı veri seti oluşturulmuştur. UAP ve UAİ alanlarından oluşan veri seti 225 karelik bir veri setidir. Teknofest komitesi tarafından paylaşılmış örnek videoların işaretlenmiş halleri, ekibimizin kendi çektiği videolar ve bu iki veri setinin de sis, kar efekti kullanılarak manipüle edilmiş versiyonlarından oluşmaktadır. Örnek videodaki UAP ve UAİ içeren karelerin sayısının az olmasından dolayı ekibimiz kendi videosunu çekme kararı almıştır. Bunun dışında yağmur, kar, sis gibi farklı durumlarda oluşabileceğinden dolayı kar, sis, yağmur efektleri kullanarak bazı kareleri manipüle edilmiştir. Manipüle edilmiş bir kare örnek olarak şekil 1'de verilmiştir.



Şekil 1. Manipüle edilmiş örnek bir kare

Kendi çektiğimiz video için ekibimiz UAP ve UAİ alanlarının kopyasını yazıcıdan çıkartmış ve ardından DJI Tello Drone ile video altına almışlardır. Bu videolardan örnek bir kare şekil 2'de verilmiştir.



Şekil 2. Ekibimizin çekimlerinden örnek bir kare

Taşıt ve yayalardan oluşan veri seti ise VisDrone ve Teknofest komitesi tarafından paylaşılmış örnek videoların işaretlenmesi ile oluşturulmuştur. VisDrone veri setinin seçilme sebebi drone görüntülerinden oluşan en kapsamlı ve büyük veri seti olmasıdır. VisDrone veri seti etiketleri yarışma formatına uygun olmadığı için veri setinin etiketleri ve formatı düzeltilmiştir. Bu veri seti toplamda 10.768 görüntüden oluşmaktadır. Veri setinde toplam 195.368 taşıt ve 90.393 yaya bulunmaktadır. Her iki veri seti de %75'i eğitim %25'i test olmak üzere 2'ye bölünmüştür. Teknofest tarafından verilen örnek video ve ekibimiz tarafından çekilmiş videolar makesense.ai web sitesi kullanılarak etiketlenmiştir

3.2 Algoritmalar

Yarışmadaki görevimiz verilen karedeki taşıtı yaya ve özel iniş alanlarını tespit etmek, ayrıca iniş alanlarının inişe uygun olup olmadığını bulmaktır. Bu problem üç aşamada ele alınacaktır. Taşıt ve yayaların tespiti için ayrı UAP-UAİ iniş alanlarının tespiti için ayrı bir yapay zekâ modeli eğitilecektir. İniş alanlarının inişe uygun olup olmadığını bulmak için de klasik görüntü işleme algoritmaları kullanılacaktır.


Yarışmada taşıt, yaya ve iniş alanlarının tespit edilip en küçük sınırlayıcı kutu ile işaretlenmesi gerekmektedir. Bu problem bir nesne algılaması problemi ve bu alanda geliştirilmiş birçok yapay zekâ modeli bulunmaktadır. Fakat yarışmadaki zaman kısıtlamasından dolayı hızlı çalışan modellere ihtiyaç duyulmaktadır. Hızlı bir şekilde nesne algılaması yapabilen modellerin en popülerlerden bir tanesi YOLO model ailesidir. Bu modeller hız ve performans bakımından en önde gelmektedirler. YOLO model ailesi Redmon ve arkadaşları tarafından 2016 yılında yayınlanan YOLOv1 ile başlamıştır (Redmon, 2016). Ardından Redmon ve Farhadi 2017 yılında YOLOv2, 2018 de ise YOLOv3 ü yayınlamalarıyla bu model ailesini geliştirmeyi sürdürmüşlerdir (Redmon, 2017; Redmon, 2018). Bu model ailesinin sonraki

modelleri olan YOLOv4 ise Bochkovskiy ve arkadaşları tarafından 2020'de, Scaled YOLOv4 ise 2021'de yine aynı grup tarafından yayınlanmıştır (Bochkovskiy, 2020; Bochkovskiy, 2021).

YOLOv4, YOLO serisini ortaya çıkaran Redmon ve arkadaşlarından farklı olarak Bochkovskiy ve arkadaşları tarafından geliştirilmiştir. YOLOv4 özellik çıkarımı için CSPDarknet53, özellik toplayıcısı (feature aggregation) olarak SPP (Spatial Pyramid Pooling) ve PAN (Path Aggregation Network) modellerini ve en son çıktılar için YOLOv3'ü kullanmaktadır. Bunlar dışında YOLOv4 Mish aktivasyon fonksiyonunu ve Bag of Freebies denen çeşitli veri artırımı metotlarını kullanmaktadır. Bunlar sayesinde YOLOv3'e göre yaklaşık 10% bir doğruluk artışı elde etmişlerdir (Bochkovskiy, 2020).


Scaled YOLOv4 ise YOLOv4'ün geliştirilmiş versiyonudur. Scaled YOLOv4, YOLOv4 modelinin CSP katmanları eklenmiş, Tiny ve Large olmak üzere farklı boyutları oluşturulmuş ve çeşitli iyileştirilmiş yapılmış halidir. Scaled YOLOv4 modelleri üç adet model türünden oluşmaktadır: YOLOv4-Tiny, YOLOv4-CSP, YOLOv4-Large. Bu modeller katman ve parametre sayısı açısından farklılık göstermektedirler. YOLOv4-Tiny modeli telefonlar veya gömülü sistemlerde çalıştırılmak için hazırlanmış hafif bir modeldir. YOLOv4-CSP ise YOLOv4-Tiny'den daha ağır ama doğruluğu daha yüksek, YOLOv4-Large'dan ağırlık bakımından daha hafif fakat doğruluğu daha düşüktür.

YOLOv4-Large modelleri Scaled YOLOv4 model ailesinin en ağır ve doğruluğu en yüksek modelleridir. YOLOv4-Large YOLOv4-P5, YOLOv4-P6 ve YOLOv4-P7 olmak üzere üç adet modelden oluşmaktadır. YOLOv4-P5 bu modeller arasında en hafifi YOLOv4-P7 ise en ağırıdır. YOLOv4-Large modelleri tasarlanırken öncelikle YOLOv4-P5 modeli tasarlanmış ve sonra bu modelin üstüne katmanlar eklenerek YOLOv4-P6 ve YOLOv4-P7 modelleri oluşturulmuştur. Şekil 3'te YOLOv4-Large modellerinin mimarileri gösterilmiştir.



Şekil 3. YOLOv4-Large modellerinin mimarisi (Bochkovskiy, 2021)


Bu modellerden sonra YOLOX, YOLOv5 ve YOLOR olmak üzere farklı kişiler tarafından farklı modeller öne sürülmüştür. Tüm bu modeller arasında YOLOR hız ve performans bakımından en iyi sonucu vermektedir. YOLOR Chien-Yao Wang ve arkadaşları tarafından öne sürülmüştür (Wang, 2021). YOLOR (You Only Look Once Representation) önceki nesne algılama modellerinin aksine açık bilgi (explicit knowledge) ve örtük bilgi (implicit knowledge) kavramlarını kullanmaktadır. İnsanlarda örtük bilgi önceki anıları ifade ederken açık bilgi ise görüntü, duyma gibi duyularla elde edilen bilgileri ifade eder. İnsan zekasından esinlenen YOLOR modelinde örtük bilgi sinir ağının derin katmanlarından elde edilirken açık bilgi modelin başlangıç katmanlarından elde edilir. Elde edilen bu bilgiler birleştirilir. Bu işlem şekil 4'te gösterilmiştir.



Şekil 4. YOLOR mimarisi (Wang, 2021)

YOLOR gerçek zamanlı nesne algılaması yapan modeller arasında COCO veri setinde en iyi sonucu vermiştir. YOLOR dört farklı modelden oluşmaktadır. Bu modeller doğrulukları ve ağırlıkları azdan çoğa olacak şekilde YOLOR-P6, YOLOR-W6, YOLOR-E6 ve YOLOR-D6'dır. Taşıt ve yaya algılamada Scaled YOLOv4 modellerinden YOLOv4-P5 ve YOLOR modellerinden YOLOR-E6 modelleri eğitilmiş ve test veri seti üzerinde performansları karşılaştırılmıştır.

UAP ve UAI iniş alanlarının algılanması için YOLOv4 modeli eğitilmiştir. Eğer karede UAP veya UAI algılanırsa bu alanın inişe uygun olup olmadığının anlaşılması için klasik görüntü işlemlerinden oluşan bir algoritma kullanılmaktadır. Öncelikle algılanan UAP ve UAI alanlarının içinde herhangi bir insan veya taşıt olup olmadığı kontrol edilir. Bunun için taşıt ve yaya algılayan modelden yayaların ve taşıtların koordinatları alınır ve YOLOv4 modelinin çıktıları ile çakışıp çakışmadığı tespit edilir. Eğer çakışma varsa alan inişe uygun değil diye kaydedilir. Eğer ki çatışma yoksa alanda insan veya taşıt dışında bir nesne var mı diye kontrol edilir. Bu algorithmada öncelikle fotoğraf sadece UAP veya UAI'yi içerecek şekilde kırılır. Ardından kırılmış alan üzerinde eğer ki alan UAI ise kırmızı, eğer alan UAP ise mavi renk kanalı üzerinde otsu eşikleme uygulanır. Eşikleme sonucunda elde edilen ikili görüntü (binary image) üzerindeki gürültüyü yok etmek için morfolojik işlemlerden kapama uygulanır. İkili görüntüdeki gürültü temizlendikten sonra görüntü üzerinde OpenCV kontur bulma algoritması uygulanarak ikili görüntüde iniş alanı bulunur. Ardından ikili görüntüde algılanan konturun içindeki siyah piksel sayısı kontrol edilir. Eğer ki piksel sayısı 15'ten fazla ise alan iniş için uygun değildir. Şekil 5'te geliştirilen sistemin şeması verilmiştir.



Şekil 5. Sistem Şeması

Tüm modeller eğitilirken COCO veri seti üzerinde önceden eğitilmiş ağırlıkları kullanılarak transfer öğrenmesi ile eğitilmişlerdir. Modeller eğitilirken CIoU veya GloU, nesneler (objectness) ve sınıflandırma (classification) kayıp fonksiyonları kullanılmıştır. GloU (Generalized Intersection over Union), Rezatofighi ve arkadaşları tarafından 2019 yılında CIoU (Complete Intersection over Union) ise Zheng ve arkadaşları tarafından 2021 yılında geliştirilmiştir (Zheng, 2021). GloU nesne algılaması gibi problemlerde sıklıkla kullanılan IoU (Intersection over Union) kayıp fonksiyonunun geliştirilmiş halidir (Rezatofighi, 2019). IoU fonksiyonu modelin tahmini ile kesin referansın kesişimini birleşimlerine

bölünerek bulunur. Fakat IoU fonksiyonu tahmin ile kesin referansın kesişimleri yok ise 0 döndürür ve negatif değer döndüremez. Bu durum IoU fonksiyonunun tahminin referanstan yakında mı olduğunu yoksa uzakta mı olduğunu yansıtmamasını engeller. Bu sorunu çözmek amacıyla Rezatofighi ve arkadaşları GloU fonksiyonunu önermiştir. Fakat GloU'nun yavaş olması ve çeşitli sebeplerden dolayı Zheng ve arkadaşları 2021 yılında CloU kayıp fonksiyonunu ileri sürmüşlerdir. Bu kayıp fonksiyonu IoU ve GloU'nun süregelen bir sürü sorununu çözmektedir.

Cisimlilik (objectness) kayıp fonksiyonu modelin tahminin nesne olup olmadığını belirten bir kayıp fonksiyonudur. Model bir nesne için birden fazla tahmin yapabilir. Her tahmin için cisimlilik skoru hesaplanır. Diğer kayıp fonksiyonlarını bu tahminlerden sadece en yüksek cisimlilik skoruna sahip olanlar için hesaplanırken cisimlilik kayıp fonksiyonu tüm tahminler için hesaplanır (Redmon, 2018). Sınıflandırma (classification) kayıp fonksiyonu modelin algıladığı nesnenin için tahmin ettiği sınıfın doğruluğunu gösterir. (Redmon, 2018).

Modellerin testlerinde keskinlik, duyarlılık, mAP@.5 ve mAP@.5:.95 metrikleri kullanılmıştır. Keskinlik, modelin seçimlerinin yüzde kaçının doğru olduğunu verir. Duyarlılık ise seçimlerin yapılması gereken tüm işaretlemelerin yüzde kaçının yapıldığını verir. (Shung, 2018). mAP hesaplanırken sıfırdan bire kadar 0.1'er şeklinde artan duyarlılık (recall) değerleri için kesinlik (precision) değerleri işaretlenerek bir duyarlılık-keskinlik grafiği oluşturulur (Yohanandan, 2020). Toplamda 11 tane olan duyarlılık değerleri için kesinlik (precision) değerleri toplanır ve ortalaması alınır, yani 11'e bölünür. Bu değer tüm veri türleri için tekrarlanır. Tüm türlerin AP değerlerinin ortalaması mAP değerini verir. mAP@.5 IoU eşik değerinin 0.5 halindeki değeri iken mAP@.5:.95 0.5'ten 0.95'e kadar her seferinde 0.05 artacak şekilde olan IoU eşik değerleri ile elde edilen sonuçların ortalamasıdır.

Tüm modeller eğitilirken mozaik artırma, mixup, HSV değerlerini değiştirme, döndürme, kırma, yakınlaştırma, uzaklaştırma, fotoğrafın bir kısmını siyaha boyama gibi veri artırımı metotları uygulanmıştır.


4. Özgünlük

Yarışmada kullanmak üzere standart alışkanlıklardan farklı olarak üç aşamalı bir sistem geliştirdik. Taşıt-yaya algılamasını ayrı bir model, UAP - UAİ algılamasını ayrı bir model, inişe uygunluk için ise klasik görüntü işleme algoritmalarını kullandık. Böylece üç aşamalı sistemde hem yapay zekâ temelli yöntemleri hem de klasik görüntü işleme yöntemleri hibrit bir şekilde kullanmış olduk.

Bu sayede UAP ve UAİ iniş alanlarının algılanma doğruluğunu arttırdık. UAP ve UAİ alanlarının inişe uygun olup olmadığını anlamak için öncelikle bu alanları yapay zekâ modeliyle tespit ettik ardından tespit edilmiş alanlar üzerinde otsu eşikleme, morfolojik kapama, kontur bulma algoritmaları ile sonuçlar elde ettik. Taşıt ve yayaların algılamasında gerçek zamanlı nesne algılaması alanında geliştirilmiş en yeni ve iyi olan YOLOR modelini tercih ettik. Bu modeli CloU, cisimlilik ve sınıflandırma kayıp fonksiyonları ve mozaik, mixup, HSV değerlerini değiştirme, döndürme, yakınlaştırma gibi veri artırımı metotlarını kullanarak eğittik. Modellerimizi eğitirken COCO veri seti üzerinde önceden eğitilmiş ağırlıklarını kullanarak transfer öğrenmesi ile eğittik. Bu sayede model eğitimi için gerek zamanı ve veri sayısını azaltmış olduk. Bu da modellerin doğruluğunu artırdı. UAP ve UAİ iniş alanları için kendi veri setimizi oluşturduk. Bu veri setini oluştururken UAP ve UAİ alanlarının çıktılarını alıp drone ile görüntüledik ve etiketledik. Veri setini farklı hava şartlarına uyarlamak için fotoğraflar üzerinde çeşitli efektler uyguladık. Farklı veri setlerini birleştirerek hibrit bir veri seti elde ettik ve elimizdeki veri sayısını arttırdık.

5. Sonuçlar ve İnceleme

Taşıt ve yaya algılama kısmında YOLOR-E6 ve YOLOv4-P5 modelleri denenmiştir. YOLOR-E6 modeli 90 devir (epoch) boyunca 832'lik fotoğraf boyutunda eğitilmiştir. 8'lik grup boyutu (batch) kullanılmıştır. Eğitimler Tesla P100 16 GB GPU üzerinde Kaggle platformunda gerçekleştirilmiştir. Model toplamda 16150 eğitim 5386 test fotoğrafı üzerinde eğitilmiştir. Optimizatör olarak SGD kullanılmıştır. Eğitim oranı (learning rate) 0.01 ile başlanmış fakat model eğitime devam ettikçe aşama aşama azaltılmıştır. Modelin eğitim sırasındaki değerlerinin grafiği şekil 6'da gösterilmiştir. Grafikte CloU, eğitim sırasındaki CloU kayıp fonksiyonu değerini, objectness nesnelik kayıp fonksiyonunu, classification sınıflandırma kayıp fonksiyonunu, precision keskinliği ve recall duyarlılığı ifade etmektedir.




Şekil 6. Eğitim grafikleri

YOLOR-E6 modeli test veri seti üzerinde keskinlikte (precision) 0.6 duyarlılıkta (recall) 0.59, mAP@.5'te 0.6 ve mAP@.5:.95'te 0.33 skorlarını elde etmiştir. Modelin örnek fotoğraflar üzerindeki tahminleri şekil 7'de verilmiştir.

YOLOv4-P5 modeli 90 devir (epoch) boyunca 864'lük fotoğraf boyutunda eğitilmiştir. 8'lik grup boyutu (batch) kullanılmıştır. Eğitimler Tesla P100 16 GB GPU üzerinde Kaggle platformunda gerçekleştirilmiştir. Model toplamda 16150 eğitim 5386 test fotoğrafı üzerinde eğitilmiştir. Optimizatör olarak SGD kullanılmıştır. Eğitim oranı (learning rate) 0.01 ve 0.937'lik momentum ile başlanmış fakat model eğitime devam ettikçe eğitim oranı aşama azaltılmıştır. YOLOv4-P5 modeli test veri seti üzerinde keskinlikte (precision) 0.42 duyarlılıkta (recall) 0.68, mAP@.5'te 0.62 ve mAP@.5:.95'te 0.3 skorlarını elde etmiştir. Modelin örnek fotoğraflar üzerindeki tahminleri şekil 8'de verilmiştir.


YOLOR ve YOLOv4-P5 modellerinin çıktıları incelenmiş ve test veri seti üzerindeki metrikleri karşılaştırılmıştır. Her ne kadar YOLOv4-P5 modelinin duyarlılık ve mAP@.5 değeri YOLOR'dan daha yüksek olsa da keskinliği YOLOR'a göre çok daha düşük kalmıştır. Ayrıca modellerin çıktıları incelendiğinde YOLOR'un genelde daha iyi sonuçlar verdiği görülmüştür. Bunlara ek olarak YOLOR YOLOv4-P5'e göre daha hızlı çalışmaktadır. Bu sebeplerden dolayı sistemde kullanılacak model olarak YOLOR seçilmiştir. UAP ve UAI iniş alanlarının algılanması için YOLOv4 modeli eğitilmiştir. Model 3600 adım (step) boyunca 416'lık fotoğraf boyutunda eğitilmiştir. 64'lük grup boyutu (batch) ve 16'lık alt grup (subdivision) kullanılmıştır. Eğitimler Tesla P100 16 GB GPU üzerinde Kaggle platformunda gerçekleştirilmiştir. Model toplamda 180 eğitim 45 test fotoğrafı üzerinde eğitilmiştir. Optimizatör olarak SGD kullanılmıştır. Eğitim oranı (learning rate) 0.0013 olarak seçilmiştir. IoU kayıp fonksiyonu olarak CloU kullanılmıştır. Model test veri seti üzerinde mAP@.5 metriğinde 0.968 mAP@.5:.95 metriğinde 0.62 skorlarını elde etmiştir. Modelin örnek çıktıları şekil 9'da verilmiştir.



Şekil 7. YOLOR-E6 modelinin örnek çıktıları




Şekil 8. YOLOv4-P5 modelinin örnek çıktıları



Şekil 9. YOLOv4 modelinin örnek çıktıları

YOLOv4 modelinden alınan UAP ve UAI konum bilgileri bu alanın inişe müsait olup olmadığının tespitinde kullanılır. Öncelikle fotoğraf sadece modelin verdiği konumları içerecek şekilde kırpılır. Bu fotoğrafın örneği şekil 10a'da verilmiştir. Ardından kırılan fotoğrafın kırmızı veya mavi renk kanalının üzerinde Otsu eşiklemesi uygulanır. Otsu eşiklemesi yapılacak kanalın hangisi olduğuna karar vermek için tespit edilen alanın türüne bakılır. Eğer alan UAP'sa eşikleme mavi kanala eğer alan UAI ise eşikleme kırmızı kanala yapılır. Bunun sebebi UAP'ın renginin mavi, UAI'nin renginin kırmızı olmasıdır. Eşikleme uygulanmış fotoğraf şekil 10b'de verilmiştir. Eşikleme işleminin ardından elde edilen ikili görüntüdeki (binary image) gürültünün temizlenmesi için görüntü üzerinde morfolojik işlemlerden kapama kullanılır. Bu işlemin ardından elde edilen ikili görüntü şekil 10c'de görülebilir. Kapama uygulanmış ikili görüntü üzerinde OpenCV kütüphanesinde bulunan findContours fonksiyonu çağırılır. Bu fonksiyon görüntüdeki konturları bulur. Görüntüdeki en büyük konturun fotoğrafta işaretlenmiş hali şekil 10d'de verilmiştir. Sonraki aşamada görüntüdeki en büyük konturun içinde herhangi bir siyah piksel bulunup bulunmadığına bakılır. Eğer siyah piksel sayısı 15 pikselden büyük ise alan inişe uygun değil olarak işaretlenir.



Şekil 10. a) Kesilmiş UAP fotoğrafı b) Mavi renk kanalına Otsu eşiklemesi uygulanmış fotoğraf c) Morfolojik kapama uygulanmış fotoğraf d) İkili görüntüdeki konturun yeşil ile işaretlendiği fotoğraf

Tüm modellerin çıktılarının birleştirildiği örnek fotoğraflar şekil 11’de verilmiştir.



Şekil 11. Tüm modellerin ortak çıktılarını içeren örnek fotoğraflar

6. Kaynakça

Bochkovskiy, A., Wang, C. Y. ve Liao, H. Y. M. (2020). Yolov4: Optimal speed and accuracy of object detection. arXiv preprint arXiv:2004.10934.

Bochkovskiy, A., Wang, C. Y. ve Liao, H. Y. M. (2021). Scaled-yolov4: Scaling cross stage partial network. In Proceedings of the IEEE/cvf conference on computer vision and pattern recognition (pp. 13029-13038).

Redmon, J., Divvala, S., Girshick, R. ve Farhadi, A. (2016). You only look once: Unified, real-time object detection. Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 779-788).

Redmon, J. ve Farhadi, A. (2017). YOLO9000: better, faster, stronger. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 7263-7271).

Redmon, J. ve Farhadi, A. (2018). Yolov3: An incremental improvement. arXiv preprint arXiv:1804.02767.

Rezatofighi, H., Tsoi, N., Gwak, J., Sadeghian, A., Reid, I. ve Savarese, S. (2019). Generalized intersection over union: A metric and a loss for bounding box regression. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition (pp. 658-666).

Wang, C. Y., Yeh, I. H., & Liao, H. Y. M. (2021). You only learn one representation: Unified network for multiple tasks. arXiv preprint arXiv:2105.04206.

Yohanandan, S. (2020). mAP (mean Average Precision) might confuse you!, Erişim tarihi: 29 Mayıs 2022, <https://towardsdatascience.com/map-mean-average-precision-might-confuse-you-5956f1bfa9e2>

Zheng, Z., Wang, P., Ren, D., Liu, W., Ye, R., Hu, Q., & Zuo, W. (2021). Enhancing geometric factors in model learning and inference for object detection and instance segmentation. IEEE Transactions on Cybernetics.