



TEKNOFEST

**HAVACILIK, UZAY VE TEKNOLOJİ
FESTİVALİ**

**ULAŞIMDA YAPAY ZEKA YARIŞMASI
KRİTİK TASARIM RAPORU**

BAŞVURU ID: 409740

TAKIM ADI

AI-LE

İçindekiler


1. Takım Şeması	1
2. Proje Mevcut Durum Değerlendirmesi	1
3. Algoritmalar ve Sistem Mimarisi	2
3.1. Veri Setleri	2
3.1.1. COWC (Cars Overhead With Context)	2
3.1.2. DOTA (Dataset for Object Detection in Aerial Images)	2
3.1.3. VisDrone	2
3.1.4. Tiny Person	2
3.1.5. AU-AIR	2
3.1.6. Vehicle Detection in Aerial Imagery (VEDAI)	2
3.1.7. Stanford Drone Dataset	2
3.1.8. People on grass(POG)	2
3.2. Algoritmalar	2
3.2.1. Derin Öğrenme Modelleri	2
TPH-Yolov5	3
3.2.2. Takip Algoritmaları ve Yardımcı Algoritmalar	4
3.2.2.1. Kalman Filtresi	4
3.2.2.2. DeepSort	5
3.2.2.3 Sınırlayıcı Kutu Algoritmaları	5
3.2.3. Sistem Mimarisi	6
4. Özgünlük	6
4.1. TPH-Yolo-Modeli:	6
4.2. Birden Fazla Model Kullanım:	6
4.3. Probleme Özgü Veri Setleri:	7
4.4. Etiket Dönüştürme Algoritmaları:	7
4.5. Sınırlayıcı Kutu Algoritmaları:	7
5. Sonuçlar ve İnceleme	7
Kaynakça	9

Şekil Tablosu

Şekil 1 Takım Şeması	1
Şekil 2 Takım Görev Dağılımı	1
Şekil 3 Nense tespiti modelleri özet mimarisi [6]	3
Şekil 4 TPH YOLOv5 Modeli Mimarisi	3
Şekil 5 CSPDarkNet53 [7] Mimarisi	4
Şekil 6 CBAM Katmanı [8]	4
Şekil 7 Kalman Filtresi	4
Şekil 8 SORT ve DeepSort'un farklı veri setlerinde karşılaştırılması [14]	5
Şekil 9 Sistem Mimarisi	6
Şekil 10 Tek Sınıf Etiketlenmiş Veri Örneği	6
Şekil 11 Düşük (Sol) ve Yüksek (Sağ) Çözünürlük Test Sonuçları	7
Şekil 12 Park Durumu Tespiti	8
Şekil 13 mAP ve Hata Değerleri	8



1. Takım Şeması



Şekil 1 Takım Şeması

AI-LE takımı derin öğrenme alanına meraklı 3 öğrenciden oluşmaktadır. Takım kaptanı, takım organizasyonu ve görev takibinden sorumludur. Takım üyeleri veri keşfi, analizi ve derin öğrenme model geliştirilmesinden sorumludur.

Takım Kaptanı	Takım Üyesi	Takım Üyesi
➤ Derin öğrenme model tasarım ve eğitimi ➤ Proje takviminin oluşturulması ve takibi	➤ Veri tabanı oluşturulması ve güncellenmesi, sentetik veri üretilmesi ➤ Rapor tasarımı, düzenlenmesi ve takibi	➤ Probleme uygun derin öğrenme modeli seçilmesi ve tasarlanması ➤ Takımın iletişimi sorumlusu

Şekil 2 Takım Görev Dağılımı

2. Proje Mevcut Durum Değerlendirmesi

Ön tasarım raporunda tek aşamalı obje algılama modellerinden biri olan Yolov4 modelini kullanması planlanmıştır. Ancak bu modelin yerine, kuşbakışı nesne tespiti yapılan senaryolarda doğruluk oranını artırma amacıyla katmanları modifiye edilmiş olan Yolov5 tabanlı TPH-Yolov5'nin kullanılmasına karar verilmiştir. Bu sayede havadan alınan görüntülerde mesafe ve açı gibi değişkenleri daha iyi tolere edebilmiştir. Model hakkında detaylar bilgiler ilerleyen bölümlerde bulunmaktadır.

Modeller örnek video üzerinde test edilirken hızlı sonuç çıkardığı ve bundan dolayı yarışma süresince fazlasıyla ek süre kalacağı fark edilmiştir. Sistemin optimal çalışmasını sağlamak ve aynı zamanda kalan yarışma zamanından faydalanmak için tek model yerine birkaç modeli paralel çalıştırmak üzerine kurulu bir altyapı oluşturulmuştur.

Ön Tasarım raporunda bütün araçlar aynı kategori altına alınmıştı. (Örneğin otobüs ve tren aynı sınıfa aitti). Yapılan testler sonucu farklı objelerin test esnasında aynı sınıf altında alınması modellerin daha önceden öğrenmiş olduğu bazı sınıf özelliklerini kullanmadığı ve bunun sonucunda mAP değerini kötü etkilediğini tespit ettik. Bunun yerine model tüm araç çeşitlerini farklı bir sınıf olarak algılayacak şekilde eğitilir, tespit yapıldıktan sonra JSON formatında aynı sınıf içerisinde gösterilir. (Örneğin model otobüs olarak algılama yapar ancak JSON dosyasında araç yazar).

Özellikle insan sınıfındaki objeler piksel sayısı düşük olduğundan dolayı küçük obje olarak değerlendirilir. Küçük objelerin tespitlerinin yüksek doğruluklar ile yapılması için eğitim ve test hızını

yavaşlatmasına rağmen, bu işlemlerin yüksek çözünürlükte yapılmasına (1536 x 1536) karar verildi. Bu sayede özellikle insan sınıfı tespitinde ciddi bir performans artışı oldu.

3. Algoritmalar ve Sistem Mimarisi

3.1. Veri Setleri

3.1.1. COWC (Cars Overhead With Context)

'Cars Overhead With Context' kuşbakışı araba içeren resim ve videolardan derlenmiş büyük bir veri setidir. Arabaları algılamayı ve/veya saymayı öğrenmek için derin bir sinir ağı gibi bir cihazı eğitmek amacıyla oluşturulmuştur. [1]

3.1.2. DOTA (Dataset for Object Detection in Aerial Images)

DOTA, hava görüntülerinde nesne tespiti için kullanılan büyük ölçekli bir veri setidir. Görüntüler farklı sensörlerden ve platformlardan toplanır. Her görüntü 800 × 800 ila 20.000 × 20.000 piksel aralığındadır. [2] Çok çeşitli ölçekler, yönler ve şekiller sergileyen nesneler içerir.

3.1.3. VisDrone

VisDrone, çeşitli önemli bilgisayarlı görme görevleri için detaylı açıklamalı temel gerçekliğe sahip büyük ölçekli bir kıyaslama aracıdır. Karşılaştırmalı veri seti, konum (Çin'de binlerce kilometre ile ayrılmış 14 farklı şehirden alınmış), çevre (kentsel ve kırsal), nesneler (yaya, araçlar, bisikletler vb.) ve yoğunluk (seyrek ve kalabalık sahneler). Veri kümesinin, farklı senaryolarda ve çeşitli hava ve aydınlatma koşullarında çeşitli drone platformları (yani farklı modellere sahip drone'lar) kullanılarak toplanmıştır. [3]

3.1.4. Tiny Person

Tiny Person, uzun mesafelerde ve devasa arka planlara sahip küçük nesnelerin tespiti için bir oluşturulmuş bir veri setidir. Tiny Person'daki resimler ve videolar (50 karede bir örneklem) internette toplanmıştır ve etiketlenmiştir.

3.1.5. AU-AIR

Trafik gözetimi ile ilgili 8 nesne kategorisi, 132,034 obje, 2 saat uzunluğunda videolardan toplam 32,823 etiketlenmiş kare ile otonom hava gözetleme modellerinin gelişmesini hedefleyen bir veri setidir. [4]

3.1.6. Vehicle Detection in Aerial Imagery (VEDAI)

Yerleşim yerlerinin havasal görüntülerinde etiketlenmiş araçlar, küçük obje olmalarına ek olarak çoklu yönelimler, aydınlatma/gölgeleme değişiklikleri, yansımalar veya tıkanıklıklar gibi farklı değişiklikler ile karelerde yer almaktadır. Ayrıca her görüntü birkaç spektral bant ve çözünürlükte mevcuttur. [5]

3.1.7. Stanford Drone Dataset

Stanford Üniversitesi kampüsünde hazırlanan bu veri seti, kampüsün kuşbakışı görüntülerinde araba, insan, bisiklet kullanan insanlar etiketlenmiş objeler olarak bulunmaktadır.


3.1.8. People on grass(POG)

Toplam 2892 resim ve 6000'e yakın etiketlenmiş farklı açılardan ve yükseklikten drone ile çekilmiş karelerden oluşan bir veri setidir. Görüntü çimenler üstünde çeşitli aktiviteler gerçekleştiren insanları içerir.

3.2. Algoritmalar

3.2.1. Derin Öğrenme Modelleri

Nesne tespiti için kullanılan modeller ikiye ayrılabilir. "One-Stage-Detectors" ve "Two-Stage-Detectors". İki aşamalı çalışan modeller ilk önce resmin üzerinde "region of interest"i bulurlar. Ardından bu bölgelerde sınıflandırma yaparlar. Bu modellere örnek olarak Faster-R-CNN ve Retinanet verilebilir. Öte yandan tek katmanlı modeller çok daha hızlı bir şekilde çalışır. Ancak yüksek hızda çalıştıkları için isabet oranından feragat ederler. YOLO modelleri bunlara örnektir. Nesne tespiti için kullanılan mimariler benzer katmanlara sahiptir. Şekil 3'te bu katmanlar gösterilmiştir.




Şekil 3 Nense tespiti modelleri özet mimarisi [6]

Dron ile kuşbakışı görüntü alınan senaryolarda karşılaşılan çeşitli problemler vardır. İlk problem dronun açısına ve yerden yüksekliğine bağlı olarak nesnelerin ölçeğinin sürekli olarak değişmesidir. İkinci problem ise bu görüntülerde çok geniş bir alan kare içinde bulunduğu için bazı objeler göreceli olarak çok küçük kalabiliyor. Bu problemler göz önünde bulundurulduğunda, nesne tespiti görevi için sıradan nesne tespiti modelleri kullanmak yerine spesifik olarak dron görüntüsü üzerinde tespit yapması için hazırlanan TPH-Yolov5 modeli kullanılmıştır.


TPH-Yolov5

Yolov5 tabanlı bu model özellikle küçük nesnelerin tespit edilebilmesi için oluşturulmuştur. Yolov5 modelinden farklı olarak modifikasyon ve geliştirilme baş (head) kısmında yapılmıştır. Bu kısımda farklı ölçekteki nesnelerin tespit edilebilmesi için ekstra bir katman eklenmiştir. Aynı zamanda orijinal Yolov5 head katmanı, modele ismini veren TPH (Transformer Prediction Head) katmanı ile değiştirilmiştir. Bu katmanın kullanılmasının 2 sebebi vardır. Sinir ağının sonundaki özellik haritaları düşük çözünürlüğe sahiptir. TPH katmanı bu kısımdaki “forward- ve back propagation” süresini ciddi miktarda azaltmaktadır. Toplamda 4 adet head katmanı vardır. Model Şekil 4’teki gibi özetlenebilir.




Şekil 4 TPH YOLOv5 Modeli Mimarisi

Backbone olarak, orijinal Yolov5 modelinde kullanılan CPS-Darknet53 mimarisi kullanılmaktadır. Bu mimari Şekil 5’te gösterilmiştir.



Şekil 5 CSPDarkNet53 [7] Mimarisi

Geniş kapsama alanına sahip görüntülerde dikkat bölgesini bulmak için (Region of interest), CBAM adı verilen bir modül kullanılmıştır. Bir özellik haritası verildiğinde, CBAM, dikkat haritasını kanal ve uzamsal olmak üzere iki ayrı boyut boyunca sırayla çıkarır ve ardından uyarlanabilir özellik iyileştirmesi gerçekleştirmek için dikkat haritasını girdi özellik haritasıyla çarpır [8].




Şekil 6 CBAM Katmanı [8]

3.2.2. Takip Algoritmaları ve Yardımcı Algoritmalar

3.2.2.1. Kalman Filtresi

Yarışma esnasında tespit edilecek çeşitli objeler her zaman kare içerisinde görünmez. Örneğin bir yaya ağacın altından geçerse kare içerisinde yayaya ait herhangi bir piksel olmayacağı için nesne tespiti modeli yayayı bulamaz. Bunu engellemek için çeşitli algoritmalar vardır. Tractor++ algoritması bunlara örnek olarak verilebilir. Philipp Bergmann'ın çalışmasında daha düşük fps gerektiren problemlerde daha başarılı olduğu görülmüştür [9].

Kalman filtresi Deepsort ile kullanıldığında daha hızlı senaryolarda çalışabilmektedir. Kalman filtresi özyinelemeli olarak çalışan bir algoritmadır ve tabiri caizse modele kısa süreli bir hafıza kazandıracaktır. Kalman filtre tekniği, konumun bir Gauss tarafından dağıtıldığı varsayılan doğrusal bir sistemin konumunu tahmin etmek için kullanılır [10]. Başka bir deyişle, objenin hızına göre yerini tahmin eder. Tahmin ederken Gauss dağılımını kullanır. Tahmin etme ve doğrulama adımlarından oluşur. Tahmin adımı, mevcut duruma dayalı olarak bir sonraki adımın tahmininin yapar. Düzeltme adımı, elde edilen ölçüm sonuçlarına dayalı olarak tahmin adımıyla sonuçlanan tahmini iyileştirir ve bu sayede yeni bir tahmin elde edilmiş olur [11]. Aşağıdaki Şekil 7 Kalman filtresi algoritmasını basit bir şekilde göstermektedir.



Şekil 7 Kalman Filtresi

3.2.2.2. DeepSort

Derin öğrenme modellerinde nesne takibi problemi verilerin özelliklerine göre farklı yöntemler kullanılarak çözülmektedir. Geleneksel olarak, bir yoğunluk fonksiyonunun maksimumunu bulma tekniği olan Ortalama kaydırma (mean shifting), piksel parlaklığının zaman içinde ekran boyunca nasıl hareket ettiğini tahmin eden Optik akış (optical flow) gibi metotlar kullanılmıştır. Naoya Oshima ve arkadaşlarının yapmış olduğu bu çalışma, mean shifting ve optical flow yöntemlerinin tek bir objeyi gayet hızlı koşullarda takip edebilmesine rağmen, kare içerisinde birden fazla obje olması durumunda yavaş kaldığını göstermiştir [12].

Teknik şartnamede belirtildiği gibi sis, yağmur vs. durumların test videosunda olabileceğini göz önünde bulundurarak geleneksel yöntemlerin istenilen başarıyı vermeyeceği görülmüştür. Daha modern ve gelişmiş bir algoritma olan DeepSort kullanılacak model için uygundur. Deepsort algoritmasını anlamak için SORT [13] algoritmasını incelemekte fayda vardır. SORT 4 adımdan oluşur;

- **Tespit:** Nesne tespiti yapılan bölümdür. Bu bölümde model olarak ekip tarafından TPH-Yolov5 kullanmasına karar kılınmıştır.
- **Tahmin:** “Kalman Filtresi” ile nesne takibinin yapıldığı kısımdır. Kalman filtresinin nasıl çalıştığı önceki bölümde anlatılmıştır.
- **İlişkilendirme:** Mevcut nesneler tespit edilirken, her nesnenin sınır kutu (bounding box) bilgileri, mevcut çerçevedeki (frame) yeni konumu tahmin edilerek tahmin edilir.
- **Benzersiz Kimlik Üretimi ve Yok Edilmesi:** Nesneler görüntüye girip çıktıklarında, benzersiz kimliklerin buna göre yaratılması veya yok edilmesi gerekir. Bu kısım ile birlikte süreç tamamlanmış olur.

SORT, nesne takibi hassasiyeti ve doğruluğu açısından genel olarak iyi bir performans elde ederken, nispeten yüksek sayıda benzersiz kimlik üretir ve yok eder [14]. Bu sebepten ötürü Deepsort algoritması geliştirilmiştir. SORT algoritmasına çok fazla benzemektedir. Aralarındaki en bariz fark Deepsort’un içerisinde bir CNN modelinin çalışmasıdır. Aşağıdaki tabloda Deepsort ve SORT algoritmalarının çeşitli veri setlerinde gösterdikleri performanslar karşılaştırılmıştır.

		MOTA ↑	MOTP ↑	MT ↑	ML ↓	ID ↓	FM ↓	FP ↓	FN ↓	Runtime ↑
KDNT [16]*	BATCH	68.2	79.4	41.0%	19.0%	933	1093	11479	45605	0.7 Hz
LMP_p [17]*	BATCH	71.0	80.2	46.9%	21.9%	434	587	7880	44564	0.5 Hz
MCMOT_HDM [18]	BATCH	62.4	78.3	31.5%	24.2%	1394	1318	9855	57257	35 Hz
NOMTwSDP16 [19]	BATCH	62.2	79.6	32.5%	31.1%	406	642	5119	63352	3 Hz
EAMTT [20]	ONLINE	52.5	78.8	19.0%	34.9%	910	1321	4407	81223	12 Hz
POI [16]*	ONLINE	66.1	79.5	34.0%	20.8%	805	3093	5061	55914	10 Hz
SORT [12]*	ONLINE	59.8	79.6	25.4%	22.7%	1423	1835	8698	63245	60 Hz
Deep SORT (Ours)*	ONLINE	61.4	79.1	32.8%	18.2%	781	2008	12852	56668	40 Hz

Şekil 8 SORT ve DeepSort'un farklı veri setlerinde karşılaştırılması [14]

3.2.2.3 Sınırlayıcı Kutu Algoritmaları

Yarışma içerisinde gerçekleştirilmesi gereken görevlerden biri de UAİ ve UAP alanlarının iniş yapmaya uygun olup olmadığını tespit etmektir. Bu bölgelerin üzerinde (veya yakınında) başka bir nesne olursa veya bu bölgeler frame içerisinde tam görünmezse, algoritma bu alanların iniş yapmaya uygun olmadığını göstermelidir. Bu soruna çözüm olarak 2 ayrı algoritma ekibimiz tarafından yazılmıştır.

Sınırlayıcı Kutu Kesişim Tespiti

Deep Sort algoritması çıktı olarak her çerçevedeki (frame) nesnelerin sınırlayıcı kutularını x, y, w (genişlik), h (yükseklik) cinsinden verir [14]. Nesnelerin kesişim durumları bu koordinatlardan yola çıkarak kolaylıkla bulunabilir. Eğer UAİ veya UAP alanlarının içinde veya yakınında başka nesneler varsa, kesişim tespiti algoritması bu alanlara iniş yapılamaz bilgisini json dosyasına kaydedecektir.

Sınırlayıcı Kutu Sınır Değer Tespiti

Eğer iniş alanları çerçevede tam olarak gözüküyorsa, bu nesnelerin sınırlayıcı kutu koordinatlarından en az 2 tanesi çerçevenin sınır koordinatlarından birinde olacaktır. Bunu tespit etmek için öncelikle x, y, w, h formatında olan sınırlayıcı kutular; x1, x2, y1, y2 formatına dönüştürülür. Elde edilen bu 4 değerden en az 2 tanesi çerçevenin sınır koordinatlarından birinde ise, objenin tamamının çerçevede olmadığı kabul edilir.


3.2.3. Sistem Mimarisi

Veri Önışleme: Geleneksel veri arttırma yöntemlerinin yanında Mosaic [15] metodunu kullandık. Mosaic veri arttırma metodu 4 tane resmi birleştirir. Bu işlem modelin arka planları algılamasında önemli rol oynar.

Model Eğitimi: Her TPH-Yolov5 modeli ayrı veri setleriyle eğitilmiştir.

- Taşıt tahmini için AU-AIR, COWC, DOTA, VEDAI
- İnsan tahmini için POG, Tiny Person, Stanford Drone Dataset, takımın kişisel dronu ile çekilmiş veriler
- UAP ve UAI iniş yerleri tahmini için Teknofest örnek videosundaki verilerden üretilen sentetik yeni veriler

Takip Algoritmaları: Teknofest tarafından verilen örnek videoda takip algoritması kullanmanın önemi çıkarımı yapılmıştır. Bu durumdan dolayı taşıt ve insan tahmini yapan modellerde DeepSort algoritması kullanılmıştır.



Şekil 9 Sistem Mimarisi


4. Özgünlük

4.1. TPH-Yolo-Modeli:

Dronun yüksekliğine bağlı olarak nesnelerin frame içerisindeki boyutu değiştiği için ve bu nesnelerin boyutu frame boyutuna göre çok daha küçük olduğu için, geleneksel nesne tespit modellerinden ziyade spesifik olarak küçük nesnelerin tespit edilmesi için oluşturulmuş TPH-Yolov5 modeli ekibimiz tarafından kullanılmıştır.

4.2. Birden Fazla Model Kullanım:

Sistemimiz 3 TPH-Yolov5 modellerinden oluşmaktadır. Bir model taşıt sınıfını diğer model insan sınıfını, diğer model UAP ve UAI sınıflarını algılar. Her modelin çıkardığı sonuçlar birleştirilerek tek bir sonuç oluşur. Ortaya çıkan bu sonuç box detection algoritmasından geçerek json dosyası oluşturulur. Sistem mimarisinin bu şekilde oluşturulmasının birkaç nedeni vardır. İnternette bulunan bazı büyük veri setleri belli bir sınıfa odaklı olduğu için görüntülerde başka sınıfların var olmasına rağmen sadece istenilen tüm sınıflar etiketlidir. Şekil 10'da görüldüğü gibi veri seti insan içermesine rağmen sadece arabalar etiketlenmiştir. Bu tarz görüntülerin etiketlenmemiş sınıflar içermesi modelin kötü eğitilmesine yol açar.



Şekil 10 Tek Sınıf Etiketlenmiş Veri Örneği

UAP ve UAI sınıflarının ayrı model içinde olması ise bu sınıflara ait verilerin sayıca az ve yetersiz olarak veri seti sınıf dengesini bozmasından dolayıdır. Ayrı model ile eğitildiklerinde bu sorun ortadan kalkmaktadır.

4.3. Probleme Özgü Veri Setleri:

Geliştirdiğimiz farklı modeller ile Teknofest tarafından sağlanan video üzerinde testler yapıldığında bütün modellerimizin küçük nesneleri (çoğunlukla insan objeleri) algılamakta zorlandıkları fark edildi. Bu durumun modellerimizin sonuçlarında istenmeyen etkilerini en aza indirmek için çeşitli yöntemlere başvuruldu.

İnsan objelerinin model tarafından daha iyi bulunabilmesi için Tiny Person ve POG (People On Grass) veri setleri modellerimize beslendi. Tiny Person veri seti karelerde göreceli olarak küçük olan insan objeleri modellerin daha doğru algılamasını sağlayan bir veri setidir. Çoğunlukla geniş bir açıyla yüksekte çekilmiş drone görüntüleri barındırır. POG veri seti çimen üzerindeki çok çeşitli aktiviteler yapan insanları içerdiğinden kullanılması uygun görülmüştür [16]. Bu değişikliklerden sonra modellerimizde insan objelerin algılanmasında iyileşme gözlemlendi. Buna ek olarak derin öğrenme modellerinde küçük objelerin algılanmasında başarısı kanıtlanmış [17] Feature Pyramid Network (FPN) kullanılacaktır.

UAP ve UAI iniş alanlarının algılaması için modellerin daha fazla veriye ihtiyaç duyduğunun fark edilmesi üzerine farklı simülasyon ortamları kullanılarak ve olabildiğince drone çekimlerine yakın bir ortam oluşturarak sentetik UAP ve UAI iniş alanları verileri oluşturuldu.

4.4. Etiket Dönüştürme Algoritmaları:


Modeli geliştirirken kullanılacak olan verileri hazırlarken karşılaşılabilecek en büyük problemler bir tanesi farklı formatlardaki veriler ile çalışmaktır. Açık kaynaklı bulunan ve elle hazırlanan verileri birleştirirken, resimlerdeki nesnelerin etiketlerin formatı aynı olmak zorundadır. Elle veri hazırlanırken nesne etiketleri 'YOLO' formatında oluşturuldu. Fakat modelde kullanmak için internette bulunan verilerin çoğunda etiketlerin formatı YOLO'dan farklıdır. Bazı veri setleri 'json' veya 'Pascal' gibi sık kullanılan formatındayken VisDrone gibi bazı veri setleri kendi etiket formatına sahiptir. Modeli eğitirken veri etiketlerinin hepsinin YOLO formatında olması gerektiğinden farklı formatlardaki koordinat etiketlerini YOLO formatına çevirecek fonksiyonlar hazırlandı. Python üzerinden yazılan fonksiyonlar ile herhangi bir nesne etiketinin YOLO formatına çevrilmesi mümkün hale getirildi. Bu şekilde açık kaynaklı bulunan etiketlenmiş görsellerin hepsini tekrar etiketleme yapmadan modelin eğitimi için kullanılabilir.

4.5. Sınırlayıcı Kutu Algoritmaları:

Önceki bölümde de bahsedildiği üzere nesnelerin birbiri ile iç içe olup olmadığını kontrol eden ve nesnelerin tamamının frame içerisinde gözüküp gözükmediğini tespit eden 2 algoritma ekibimiz tarafından geliştirilmiştir. UAP veya UAI sınırlayıcı kutuları ile insan sınıfının kesişmesini, insan sınıfı ile bisiklet sınıfı sınırlayıcı kutuları kesiştiğinde sadece insan sınıfının görülmesi ve motosiklet ve insan sınıfı kutuları kesiştiğinde ise sadece taşıt sınıfı görülmesi şeklinde 3 metoda sahip bir sınırlayıcı kutu algoritması yazılmıştır. Algoritmalar kısmında detaylı bir şekilde açıklanmıştır.

5. Sonuçlar ve İnceleme

VisDrone veri seti ile önceden eğitilmiş olan TPH-Yolov5 modelinin performansını ölçmek için çeşitli testler yapılmıştır. Yapılan ilk testte modele verilen fotoğrafın boyutu değiştirilmiş ve modelin performansı gözlemlenmiştir. Bunun için aynı çerçeve (frame) üzerinde 640 x 640 ve 1536 x 1536 boyutlarında sonuç çıkarımı (inference) yapılmıştır. Elde edilen sonuçlar, fotoğraf boyutunun modelin performansı üzerinde çok ciddi etkisi olduğunu göstermektedir. Test senaryoları ve sonuçları Şekil 11'de gösterilmiştir.




Şekil 11 Düşük (Sol) ve Yüksek (Sağ) Çözünürlük Test Sonuçları

Diğer test, sınırlayıcı kutu algoritmalarının doğru çalışıp çalışmadığını gözlemlemek için yapılmıştır. Bunun için iniş alanına uygun olan ve uygun olmayan 2 ayrı drone iniş yeri görüntüsü ve nesne koordinatları algoritmaya verilmiştir. Test senaryoları ve çıktıları Şekil 12’de görülmektedir.



Şekil 12 Park Durumu Tespiti

Drone çekimlerinden oluşan ve ekibimiz tarafından hazırlanan veri seti ile modele transfer öğrenmesi yapılmıştır. Aşağıdaki grafikte görüldüğü üzere validasyon setinin mAP değeri kısa bir süre içerisinde %90’a yaklaşmıştır. Ancak grafikteki hata değerleri gözlemlendiğinde overfit durumu görülmektedir. Bunun sebebi hazırlanan veri setindeki fotoğraf sayısının az olması ve benzer ortamlardaki örneklerden oluşmasıdır. Farklı veri setlerinden alınan yeni eğitim örnekleriyle birlikte bu durumun üstesinden gelinecektir.



Şekil 13 mAP ve Hata Değerleri

Kaynakça

- [1] D. Cazzato, C. Cimorelli, J. L. Sanchez-Lopez, H. Voos ve M. Leo, «A survey of computer vision methods for 2D object detection from unmanned aerial vehicles,» *Journal of Imaging*, cilt 6, no. 8, p. 78, 2020.
- [2] G.-S. Xia, X. Bai, J. Ding, Z. Zhu, S. Belongie, J. Luo, M. Datcu, M. Pelillo ve L. Zhang, «Dota: A large-scale dataset for object detection in aerial images,» *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2018.
- [3] P. Zhu, L. Wen, D. Du, X. Bian, H. Fan, Q. Hu ve H. Ling, «Detection and tracking meet Drones Challenge,» *IEEE Transactions on Pattern Analysis and Machine Intelligence*, pp. 1-1, 2021.
- [4] İ. Bozcan ve E. Kayacan, «AU-AIR: A Multi-modal Unmanned Aerial Vehicle Dataset for Low Altitude Traffic Surveillance,» %1 içinde *IEEE International Conference on Robotics and Automation (ICRA)*, 2020.
- [5] S. Razakarivony ve F. Jurie, «Vehicle detection in aerial imagery : A small target detection benchmark,» *Journal of Visual Communication and Image Representation*, no. 34, pp. 187-203, 2016.
- [6] A. Bochkovskiy, C.-Y. Wang ve H.-y. Liao, «YOLOv4: Optimal Speed and Accuracy of Object Detection,» 2020.
- [7] P. Xu, L. Qingyang, B. Zhang, F. Wu, K. Zhao, X. Du, C. Yang ve R. Zhong, «On-board real-time ship detection in HISEA-1 SAR images based on CFAR and lightweight deep learning,» *Remote Sensing*, cilt 13, no. 10, p. 1995, 2021.
- [8] S. Woo, J. Park, J.-Y. Lee ve K. In So, «Cbam: Convolutional block attention module,» *ECCV*, pp. 3-19, 2018.
- [9] P. Bergmann, T. Meinhardt ve L. Leal-Taixe, «Tracking without bells and whistles,» %1 içinde *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019.
- [10] H. A. Patel ve D. G. Thakore, «Moving Object Tracking Using Kalman Filter,» *International Journal of Computer Science and Mobile Computing*, cilt 2, no. 4, pp. 326-332, 2013.
- [11] L. E. Taylor, M. Mirdanies ve R. P. Saputra, «Optimized object tracking technique using Kalman filter,» *Journal of Mechatronics, Electrical Power, and Vehicular Technology*, cilt 7, no. 1, pp. 57-66, 2016.
- [12] N. Oshima, T. Saitoh ve R. Konishi, «Real time mean shift tracking using optical flow distribution,» %1 içinde *2006 SICE-ICASE International Joint Conference*, 2006.
- [13] A. Bewley, Z. Ge, L. Ott, F. Ramos ve B. Upcroft, «Simple online and realtime tracking,» %1 içinde *2016 IEEE International Conference on Image Processing (ICIP)*, 2016.
- [14] N. Wojke, A. Bewley ve D. Paulus, «Simple online and realtime tracking with a Deep Association metric,» %1 içinde *2017 IEEE International Conference on Image Processing (ICIP)*, 2017.

- [15] W. Hao ve S. Zhili, «Improved Mosaic: Algorithms for more Complex,» %1 içinde *Journal of Physics: Conference Series*, 2020.
- [16] B. Kiefer, D. Ott ve A. Zell, «Leveraging Synthetic Data in Object Detection on Unmanned Aerial Vehicles,» 2021.
- [17] M. Zhu, K. Han, C. Yu ve Y. Wang, «Dynamic Feature Pyramid Networks for Object Detection,» 2020.

