

TEKNOFEST

**HAVACILIK, UZAY VE TEKNOLOJİ
FESTİVALİ**

**ULAŞIMDA YAPAY ZEKA YARIŞMASI
KRİTİK TASARIM RAPORU**

TAKIM ADI

AI Tech

BAŞVURU ID

408690

İÇİNDEKİLER

İÇİNDEKİLER	2
ŞEKİL LİSTESİ.....	3
KISALTMALAR.....	3
1. TAKİM ŞEMASI	4
2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ	4
3. ALGORİTMALAR VE SİSTEM MİMARİSİ.....	5
3.1. Veri Setleri.....	5
3.2. Algoritmalar.....	6
4. ÖZGÜNLÜK	9
5. SONUÇLAR VE İNCELEME	11
6. KAYNAKÇA.....	12



ŞEKİL LİSTESİ


ŞEKİL 1: TAKIM ORGANİZASYONU.....	4
ŞEKİL 2: ÖRNEK EĞİTİM VİDEOSUNUN AYRIŞTIRILMASI	5
ŞEKİL 3: İSTENMEYEN KAMERA AÇISI İLE ELDE EDİLMİŞ GÖRÜNTÜ	4
ŞEKİL 4: KARANLIKTA KAYDEDİLMİŞ GÖRÜNTÜ	4
ŞEKİL 5: MOZAİK ARTIRMA İŞLEMİ SONUCUNDA OLUŞAN GÖRSEL	4
ŞEKİL 6: YOLOV5 MİMARİSİ.....	7
ŞEKİL 7: FARKLI VERİ BOYUTLARINDA HAVUZLAMA YAPAN SPP.....	7
ŞEKİL 8: NON-MAX SUPPRESSION ALGORİTMASINI AÇIKLAYAN GÖRSEL	8
ŞEKİL 9 YOLOV5 MODELLERİ	8
ŞEKİL 10: ELDE EDİLEN UAİ GÖRÜNTÜSÜ.....	9
ŞEKİL 11: ELDE EDİLEN UAP GÖRÜNTÜSÜ	9
ŞEKİL 12: UAİ ALANI EKLENMİŞ GÖRSEL.....	9
ŞEKİL 13: GENİŞLETİLMİŞ UAP ALANI	10
ŞEKİL 14: UAP VE UAİ ALANLARIN İNİŞ DURUMUNU KONTROL EDEN ALGORİTMANIN AKIŞ ŞEMASI	10
ŞEKİL 15: TESPİT EDİLEN NESNELERİN SINIFLANDIRMA HİYERARŞİSİ.....	11
ŞEKİL 16: MODELİN EĞİTİM SONUÇLARI	11
ŞEKİL 17: MODELİN DEĞERLENDİRME VERİSİ ÜZERİNDEKİ TAHMİNLERİ.....	12

KISALTMALAR

ÖTR	Ön Tasarım Raporu
YOLO	You Only Look Once
UAP	Uçan Araba Pisti
UAİ	Uçan ambulans iniş pisti
FLOPS	floating-point operations per second
SPP	Spatial Pyramid Pooling
CNN	Convolutional neural network
PANet	Path Aggregation Network
IoU	intersections of union
PNG	Portable Network Graphics

1. TAKIM ŞEMASI

“AI Tech” takımı 1 kaptan ve 4 üye olmak üzere 5 kişiden oluşmaktadır. Takım üyelerinin tamamı lisede eğitim görmektedir. Takım üyeleri birbirleri arasında tam bir iletişim halinde projeyi yürütmektedir. Projenin mevcut durumunun değerlendirilmesi, özgün fikirlerin ortaya atılması ve uygulanması, geliştirilen yapay zeka algoritmasının incelenmesi ve sonuçlarının değerlendirilmesi takım üyelerinin tamamının katıldığı toplantılarda görüşülmektedir. Üyelerin proje kapsamındaki uzmanlık alanları şekil 1’de belirtilmiştir.



Şekil 1 Takım Organizasyonu

2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ

Proje kapsamında ÖTR’de belirtildiği üzere Teknofest Komitesi tarafından yarışmacı sağlanan örnek eğitim videosu ve VisDrone veri seti kullanılmıştır[1]. Bu veri setleri üzerinde yapılan işlemler sonucunda etiketlemeye hazır veriler elde edilmiştir. Veriler online bir platform olan MakeSense sitesinde etiketlenmiştir[2]. Etiketleme yapılırken özgünlük kısmında belirtilen sınıflandırma hiyerarşisi kullanılmıştır. Bu hiyerarşi ÖTR raporundan sonra ekip üyelerince tasarlanmış ve projeye dahil edilmiştir.

Hazırlanan veri seti içerisinde raylı taşıtlar kategorisine ait veri bulunmamaktadır. Yapılan literatür araştırması sonucunda bu kategoriye ait istenilen kriterleri (kamera açısı vb.) karşılayan bir veri setine rastlanmamıştır. Literatür araştırması genişletilerek ve farklı kaynaklar taranarak ilgili kategoriye ait veri seti araştırmasına devam edilmektedir.

Veri etiketleme işleminden sonra elde edilen veriler eğitim (train) ve değerlendirme (validation) verisi olmak üzere 2 gruba ayrılmıştır. Eğitim verileri algoritmayı eğitmek için, değerlendirme verileri eğitilmiş algoritmanın doğruluk değerini ölçmek için kullanılmıştır.

Verilerin ayrılma işlemi tamamlandıktan sonra YOLOv5 algoritması online ortamdan yerel bilgisayara aktarılmıştır[3]. Kullanılan bilgisayarda ÖTR raporundan farklı bir donanım bulunmamaktadır. Aktarılan algoritma etiketli veriler ile eğitimi gerçekleştirmek üzere çalıştırılmıştır. Eğitilen algoritmadan sonuç almak için gerekli yazılımlar hazırlanmıştır. Bu yazılımlar görüntü içerisindeki nesneleri ve nesnelerin koordinatlarını tespit ederek bir listeye atamaktadır. Ayrıca bu yazılım özgünlük kısmında detaylandırılan UAP ve UAİ alanlarının iniş durumunun kontrol edilmesini sağlayan algoritmayı da içermektedir.

Eğitilmiş algoritma önceden belirlenmiş değerlendirme (validation) verisi üzerinde teste tabi tutulmuştur. Test sonuçları sonuçlar ve inceleme kısmında yer almaktadır.


Eğitim süresinin kısaltmak ve sistem performansını artırmak için bu aşamadan sonra yazılım “CUDA” aracılığıyla çalıştırılacaktır. Gerçekleştirilecek olan yarışma simülasyonu ve yarışma esnasında da yine “CUDA” yazılımı kullanılacaktır.

3. ALGORİTMALAR VE SİSTEM MİMARİSİ

3.1. Veri Setleri

3.1.1. Örnek Eğitim Videosu

Teknofest komitesi tarafından tarafımıza sağlanan örnek eğitim videosu 292 saniye uzunluğunda olup yaklaşık olarak 8760 frame içermektedir. Videonun çözünürlüğü 1920x1080 boyutlarındadır. Öncelikle örnek eğitim videosundaki frame'lerin tamamının kullanılması düşünülmüş ancak ardışık frame'lerin birbirinin kopyası niteliğinde olması ve 8760 frame'in tamamının kullanılmasının eğitim süresini oldukça uzatması gerekçeleriyle videodaki framelerin ayrıştırılmasına karar verilmiştir. Videodaki frame'ler 10' lu parçalara ayrılmış daha sonra bu 10'lu parçanın ilk frame'i eğitim verisi olarak kullanılmak üzere belirlenmiştir[Şekil 2].



Şekil 2 Örnek Eğitim Videosunun Ayrıştırılması

Ayrıştırma işleminden sonra örnek eğitim videosundan 876 adet frame elde edilmiştir. Elde edilen görüntüler karlı, güneşli gibi farklı hava durumlarını içerisinde barındırmaktadır. Bu heterojen yapı geliştirilen algoritmanın farklı çeşitteki veriler üzerinde daha yüksek performans sağlamasına sebep olmaktadır.

3.1.2. VisDrone Veri Seti

Algoritmanın eğitiminde kullanılan veri setlerinden bir tanesi de "VisDrone" veri setidir[1]. Bu veri seti train (eğitim), validation (değerlendirme) ve test başlıkları altında yaklaşık 10000 adet görsel içermektedir. Veri seti yağmurlu, güneşli gibi farklı hava durumlarını ve sabah, akşam gibi günün farklı zamanlarını içeren görseller bulundurmaktadır. Veri setindeki bütün görsellerin kullanılmasının işlem yükünü artırması sebebi ile veri seti içerisinde yapılan bir eleme işlemi ile veri setinin küçültülmesine karar verilmiştir. Bu eleme işlemi yapılırken yeni oluşacak veri setinin de heterojen özelliklere sahip olmasına dikkat edilmiştir. Ayrıca veri seti içerisinde bulunan istenmeyen kamera açısı ile elde edilmiş görüntüler ile çok yüksek irtifadan çekilmiş görüntüler veri seti içerisine dahil edilmemiştir. Yine gece vakitlerinde çekilen ve düşük parlaklığa sahip görseller nesnelerin tam olarak ayırt edilmemesi gerekçesiyle veri setine dahil edilmemiştir[Şekil 3-4].



Şekil 3: İstenmeyen Kamera Açısı ile Elde Edilmiş Görüntü



Şekil 4: Karanlıkta Kaydedilmiş Görüntü

Bu eleme işlemi sonucunda 60 adet görsel yapay zekanın eğitiminde kullanılmak üzere belirlenmiştir. Belirlenen görseller yarışma şartnamesinde belirtilen UAP ve UİA alanlarını içermemektedir. Bu eksikliği gidermek için UAP ve UİA alanlarını içeren görseller bu veri seti içerisindeki görsellere eklenmiştir. Bu işlem hakkında detaylı bilgi “özgünlük” kısmında yer almaktadır.

3.2. Algoritmalar


Yarışma şartnamesinde belirtilen görevlerin yerine getirilmesini sağlamak üzere “YOLOv5” algoritmasının kullanılmasına karar verilmiştir[4]. YOLOv5 önceki YOLO versiyonlarının geliştirilmiş halidir. YOLO algoritmaları görüntülerdeki veya videolardaki nesneleri ve bu nesnelerin koordinatlarını aynı anda tespit eder [5]. Bu bağlamda YOLOv5 algoritması bir nesne tespit algoritması olup görüntü sınıflandırma (image classification) algoritmalarından farklı tek bir nesneye ait resimleri tanımlamak değil, birden fazla nesne içeren resimlerde her bir nesneyi ayrı ayrı tespit etmesidir.

Proje ön değerlendirme raporunda belirtildiği üzere algoritmanın farklı nitelikteki verilerle eğitilmesi için “veri artırma (Data Augmentation)” işleminin uygulanmasına karar verilmişti. Veri artırma işlemi sahip olunan veriler üzerinde farklı görüntü işleme teknikleri uygulanarak veri sayısının artırılmasını ifade etmektedir. YOLOv5 algoritması ise eğitim sırasında her eğitim grubu (Batch) için veri artırma işlemini uygulamaktadır. Bu veri artırma işlemleri ölçekleme (scaling), Renk alanı ayarı (Color Space Adjustment) ve Mozaik artırma (Mosaic Augmentation)[6]. Bunlardan en yeni olanı ve en önemlisi olan mozaik artırma aynı eğitim grubu içerisindeki 4 görseli oranlı 4 karoya çevirmektedir[Şekil 5]. Bu işlem sayesinde hem veri sayısı artırılmakta hem de görüntü içerisindeki küçük nesnelerin tespiti daha doğru yapılabilmektedir[6].



Şekil 5: Mozaik artırma işlemi sonucunda oluşan görsel

YOLOv5 mimarisi 1 adet giriş katmanı, 1 adet omurga (backbone) katmanı, 1 adet boyun (neck) katmanı ve 1 adet baş (head) katmanından oluşur[Şekil 6].




Şekil 6: YOLOv5 Mimarisi [7]

Giriş katmanında algoritmada kullanılacak görsellerin algoritma tarafından alınması sağlanır. Algoritmanın eğitimi sırasında algoritmada kullanılacak görsellerin boyutu 480x480 çözünürlüğe sahip olacak şekilde ayarlanmıştır. Resim çözünürlüğünün çok küçük olması resim içerisindeki nesnelerin özelliklerini kaybetmesine sebep olurken çözünürlüğün çok büyük olması eğitim için gereken süreyi ve CPU-GPU kullanımını artırmaktadır. Bu bağlamda çözünürlüğün belirlenmesinde bu iki durum göz önüne alınmıştır.

“Backbone” katmanında resimler üzerinde özellik çıkarımı (feature extraction) işlemi uygulanır. Backbone katmanında CSP modeli kullanılmaktadır. CSP gradyan kaybolması (Vanishing Gradient) sorununu giderir, ağı özellikleri yeniden kullanmaya teşvik eder, parametre ve FLOPS sayısını azaltır[6].

“Backbone” katmanında kullanılan bir diğer yapı ise SPP yapısıdır[8]. Bu yapı bir havuzlama (pooling) katmanı olup ağı sabit boyutlu kısıtlamasını kaldıran bir havuz katmanıdır. Bu katman sayesinde CNN'e sabit boyutlu giriş görüntüsü gerektirmez. Aynı zamanda ağı giriş yapan görseller üzerinde kırma (crop) ve çözgü (Warp) işlemlerinin yapılması ihtiyacını önler.




Şekil 7: Farklı Veri Boyutlarında Havuzlama Yapan SPP [9]

Algoritmanın “Neck” katmanında komşu özellik haritalarından (feature map) daha detaylı bilgilerin çıkarılması sağlanır. Bu kısımda bulunan “PANet” yapısının en önemli özelliği algoritma içerisinde mekânsal bilgiyi korumasıdır[10]. YOLOv3'ten bu yana güncellenen bu yapı büyük nesnelerin sahip


olduğu uzamsal bilginin çok fazla katmana yayılması sorununa çözüm üreterek algoritma içerisinde “kısıyor” oluşturur[11].

“Head” katmanında ise en küçük sınırlayıcı kutular bulunur ve her kutunun sınıfı belirli bir güven skoru ile tahmin edilir. YOLOv5 içerisinde her nesne için ayrı ayrı en küçük sınırlayıcı kutu oluşturmaya yarayan “Anchor Box” yöntemi kullanılmaktadır. Temel olarak Anchor Box yöntemi nesnelerin üzerine binlerce sınırlayıcı kutu çizerek bunlar arasından güven skoru en fazla olanı seçmeye dayalı bir yöntemdir. Güven skoru en fazla olan kutuların seçilmesinde “Non Max Suppression” algoritması kullanılır. Bu algoritma IoU yöntemi ile sınırlayıcı kutu sayısını minimuma indirir[12][Şekil 8].



Şekil 8: Non-Max Suppression Algoritmasını Açıklayan Görsel[13]

YOLOv5 “s, l, m ve x” olmak üzere 4 farklı modele sahiptir. Bu modeller kendi içinde doğruluk ve eğitim süresi açısından avantajlara ve dezavantajlara sahiptir [Şekil 2]. Ekibimiz tarafından doğruluk oranı en yüksek olan “YOLOv5x” kullanılmıştır. Algoritmanın eğitimi sırasında başlangıç ağırlıkları (initial weights) olarak “COCO” veri seti üzerinde eğitilmiş YOLO modelinin ağırlıkları kullanılmıştır. Böylece algoritmanın eğitimi sırasında doğruluk oranının daha hızlı artması sağlanmıştır.




Şekil 9 YOLOv5 Modelleri [14]

4. Özgünlük

4.1. Veriler üzerinde UAP ve UAİ alanlarının çoğaltılması


Veri seti içerisinde bulunan UAP ve UAİ alanlarını içeren verilerin sayısının az olması ve bu alanların tespitinin algoritmanın önemli noktalarından biri olması sebebiyle takımımız tarafından UAP ve UAİ alanlarının çoğaltılması kararlaştırılmıştır. İlk olarak elimizde mevcut olan UAP ve UAİ alanları fotoğraf düzenleme uygulamaları yardımıyla ilgili resimlerden kesilerek arka planı boş matrislerden oluşan bir resim formatı olan “png”ye dönüştürülmüştür[Görsel]. Daha sonra bu görseller içerisinde UAP ve UAİ alanları içermeyen “VisDrone” veri setindeki görseller üzerine eklenmiştir[Görsel]. İlk başta UAP ve UAİ içeren görsel sayısı 112 iken bu işlemten sonra görsel sayısı 173’ya çıkarılmıştır.



Şekil 10: Elde Edilen UAİ Görüntüsü



Şekil 11: Elde Edilen UAP Görüntüsü




Şekil 12: UAİ Alanı Eklenmiş Görsel

4.2. UAP ve UAİ alanlarının iniş durumunun kontrol edilmesinin sağlayan algoritma

Yarışma şartnamesinde belirtilen görevlerden bir tanesi de UAP ve UAİ alanlarının iniş için uygun olup olmadığının kontrol edilmesidir. Takımımız da bu göreve yönelik olarak özgün bir algoritma geliştirmiştir. Algoritma öncelikli olarak değerlendirilen frame(görüntü) içerisinde UAP veya UAİ alanlarının olup olmadığını kontrol etmektedir. Frame içerisinde bu alanların bulunması halinde ilgili alanların koordinatları YOLOv5 algoritması yardımıyla tespit edilmektedir. Belirlenen bu koordinatlar üzerinde genişletme işlemi uygulanmaktadır[Görsel 1-2]. Bu işlemin uygulanmasının amacı ilgili alanların sadece üzerinde değil aynı zamanda yakınında da inişi engelleyecek nesnelerin bulunup bulunmadığının kontrol edilmesidir. Alanların genişletilmesinden sonra geliştirilen algoritma ilgili koordinatların içerisinde başka nesnelerin bulunup bulunmadığını kontrol etmektedir. Bu noktada diğer nesnelerin koordinatları yine YOLOv5 aracılığıyla elde edilmektedir. UAP ve UAİ alanlarının koordinatları içerisinde başka nesnelerin bulunması halinde iniş durumu uygun olarak nitelendirilmektedir. Algoritma çalışma mantığı Şekil 14'deki akış şemasında belirtilmiştir.




Şekil 13: Genişletilmiş UAP Alanı



Şekil 14: UAP ve UAİ Alanların İniş Durumunu Kontrol Eden Algoritmanın Akış Şeması

4.3. Tespit edilecek nesnelerin gruplandırılması

Yarışma şartnamesinde Motorlu Karayolu Taşıtları ve Raylı Taşıtların “Taşıt” olarak sınıflandırılması gerektiği belirtilmiştir. Ancak eğitilecek olan yapay zeka modeline bu taşıtların hepsini bir tür olarak vermek sınıfsal doğruluğu düşürecek ve algoritmanın daha kötü sonuç vermesine sebep olacaktır. Örneğin “Kamyon” taşıtı ile “Motosiklet” taşıtının aynı kategoride sınıflandırılması o sınıfa ait özgün özelliklerin algoritma tarafından öğrenilememesine sebep olacaktır. Ekibimiz de bu sorunun önüne geçmek için tespit edilecek nesne türlerini yeniden sınıflandırmıştır[Şekil]. Bu sınıflandırma sonucunda yapılan tahminler düzenlenerek tekrardan yarışma şartnamesinde belirtilen sınıflandırma formatına uygun hale dönüştürülmüştür.




Şekil 15: Tespit Edilen Nesnelerin Sınıflandırma Hiyerarşisi

5. SONUÇLAR VE İNCELEME

Yapay zeka modelinin eğitimi tamamlandıktan sonra ekibimiz modelin doğruluğunu ve performansını değerlendirmiştir. Yapay zeka modeli 50 epochs değeri için çalıştırılmıştır. 50. epochs değerinden sonra doğruluk oranında önemli bir artış görülmediği için bu değer yeterli görülmüştür. Her bir epochs içerisinde bütün veriler 16'lı grup şeklinde modelden geçmiştir. Bu noktada ilk başta gruptaki veri sayısını belirten parametre (batch size) 32 olarak belirlenmiş fakat yüksek çözünürlükteki çok sayıda resmin sistem donanımının performans özelliklerini aştığı görülünce gruplar 16'lı olacak şekilde düzenleme yapılmıştır.


Algoritmanın 50 epochs değeri için gösterdiği performans grafikleri Şekil 16'da verilmiştir.



Şekil 16: Modelin Eğitim Sonuçları

Grafikler incelendiğinde model mAP_0.5 parametresi için %89 doğruluk oranı gösterdiği belirlenmiştir. Ayrıca modelin kayıp oranının da oldukça düşük olduğu fark edilmektedir. Bu da modelin görüntülerdeki küçük nesneleri de tespit etme yetisine sahip olduğunu göstermektedir. Bu sonuç algoritmada kullanılan SPP yapısının etkisini göstermektedir.

Modelin değerlendirme verisi üzerinde yaptığı bazı tahminler şekil 17’de verilmiştir. Resim üzerine yazı yazdırma işleminde Türkçe karakter problemi yaşanmıştır. En kısa zamanda düzeltilecektir.



Şekil 17: Modelin Değerlendirme Verisi Üzerindeki Tahminleri

6. KAYNAKÇA

[1] Veri Seti Erişim Linki: <http://aiskyeye.com/>

[2] İnternet Sitesi Erişim Linki: <https://www.makesense.ai/>

[3] Kaynak Kod Erişim Linki: <https://github.com/ultralytics/yolov5>

[4] Couturier, R., Noura, H.N., Salman, O., Sider, A., 6 Temmuz 2021, A DEEP LEARNING OBJECT DETECTION METHOD FOR AN EFFICIENT CLUSTERS INITIALIZATION

[5] Akdeniz, A.N., Yolov5 ile Nesne Tespiti, 4 Ağustos 2021, Erişim Adresi: [https://medium.com/@akdenizz7/yolov5-ile-nesne-tespiti-8aa370febfc0#:~:text=Nesne%20Tespiti\(Object%20Detection\)%3B,ile%20ilgili%20bir%20bilgisayar%20teknolojisi](https://medium.com/@akdenizz7/yolov5-ile-nesne-tespiti-8aa370febfc0#:~:text=Nesne%20Tespiti(Object%20Detection)%3B,ile%20ilgili%20bir%20bilgisayar%20teknolojisi)

[6] Solawetz, J., YOLOv5 New Version - Improvements And Evaluation, 29 Haziran 2020, Erişim Adresi: <https://blog.roboflow.com/yolov5-improvements-and-evaluation/>

[7] Görsel Erişim Adresi: https://www.researchgate.net/figure/YOLO-v5-Architecture-Overview-3_fig2_351355008

[8] He, K.; Zhang, X.; Ren, S.; Sun, J.; 18 Haziran 2014; Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition

[9] Görsel Erişim Adresi: https://www.researchgate.net/figure/The-network-structure-with-a-spatial-pyramid-pooling-layer_fig1_329147074

[10] S. Liu, L. Qi, H. Qin, J. Shi and J. Jia, 18 Eylül 2018, Path Aggregation Network for Instance Segmentation

[11] R, M., PANet: Path Aggregation Network In YOLOv4, 3 Temmuz 2020, Erişim Tarihi: 02.06.2022, Erişim adresi: <https://medium.com/clique-org/panet-path-aggregation-network-in-yolov4-b1a6dd09d158>

[12]K, S., 1 Ekim 2019, Non-maximum Suppression (NMS), Erişim Tarihi: 07.06.2022, Erişim Adresi: <https://towardsdatascience.com/non-maximum-suppression-nms-93ce178e177c>

[13] Görsel Erişim Adresi: <https://towardsdatascience.com/non-maximum-suppression-nms-93ce178e177c>

[14] Görsel Erişim Adresi: <https://github.com/ultralytics/yolov5>

