

TEKNOFEST

HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

ULAŞIMDA YAPAY ZEKA YARIŞMASI

KRİTİK TASARIM RAPORU

RACLAB – Turing Mind

400604



İÇİNDEKİLER

İÇİNDEKİLER.....	2
ŞEKİL LİSTESİ.....	3
1. TAKIM ŞEMASI (5 PUAN).....	4
2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ (15 PUAN).....	4
3. ALGORİTMALAR VE SİSTEM MİMARİSİ (25 PUAN)	5
3.1. VERİ SETLERİ (10 PUAN).....	5
3.1.1. VİSDRONE VERİ SETİ.....	5
3.1.2. STANFORD DRONE VERİ SETİ.....	5
3.1.3. UAVDT Veri Seti.....	5
3.2. ALGORİTMALAR (15 PUAN)	6
3.2.1. RetinaNet Algoritması.....	6
3.2.2. YOLOv5 Algoritması	7
3.2.3. CLAHE Algoritması	8
3.2.4. Görüntü Kirlenme Algoritmaları	8
4. ÖZGÜNLÜK (25 PUAN).....	9
5. SONUÇLAR VE İNCELEME (25 PUAN)	10
6. KAYNAKÇA (5 PUAN).....	12



ŞEKİL LİSTESİ

Şekil 1: Takım Organizasyonu.....	4
Şekil 2: Stanford Drone Veri Setindeki Görüntülerin Bir Örneği.....	5
Şekil 3: UAVDT Veri Setindeki Görüntülerin Bir Örneği.....	6
Şekil 4: Farklı piramit türleri.....	6
Şekil 5: COCO Veriseti Üzerinde Test Sonuçları.....	7
Şekil 6: COCO Veriseti Üzerinde Başarım Kıyaslaması.....	7
Şekil 7: Sınırlayıcı Kutular Yardımıyla Nesne Tespit Örneği.....	8
Şekil 8: Orijinal Görüntü.....	8
Şekil 9: CLAHE Uygulanmış Görüntü.....	8
Şekil 10: Kırletme Algoritmalarının Uygulanması.....	9
Şekil 11: Özgünlüğe Yönelik Uygulamalar.....	10
Şekil 12: YOLOv5 Eğitim Modeli Üzerinde Test Çıktısı.....	11
Şekil 13: YOLOv5 Eğitim Modeli Grafik Çıktısı.....	11
Şekil 14: RetinaNet Eğitim Modeli Test Çıktısı.....	12

TABLO LİSTESİ

Tablo tablosu ögesi bulunamadı.


KISALTMALAR

UAP: Uçan Ambulans İniş
UAI: Uçan Ambulans İniş
YOLO: You Only Look Once
RACLAB: Robotics Automation Control Laboratory
UAVDT: Unmanned Aerial Vehicle Detection and Tracking
CNN: Convolutional Neural Network
HE: Histogram Equalization
AHE: Adaptive Histogram Equalization
CLAHE: Contrast Limited Adaptive Histogram Equalization

1. TAKIM ŞEMASI (5 PUAN)

RACLAB (Robotics Automation Control Laboratory) araştırma ve geliştirme laboratuvarı 2014 yılında Doç. Dr. Akif DURDU önderliğinde kurulmuştur.

RACLAB – Turing Mind takımı, Konya Teknik Üniversitesi Elektrik Elektronik Mühendisliği Bölümü Öğretim üyesi Doç. Dr. Akif DURDU danışmanlığında, 5 Bilgisayar Mühendisliği öğrencisiyle birlikte çalışmalarına devam etmektedir. Ulaşımında Yapay Zeka takımı, iki alana ayrılarak çalışmalarını yürütmektedir. Veri Toplama, Veri Analizi ve Algoritma Geliştirme ekibi, hazırladıkları veriseti ve algoritmaları diğer ekip üyeleriyle senkron bir şekilde sağlamaktadır. Bu aşamadan itibaren Görüntü İşleme ve Nesne Tespiti ekibi, geliştirilen algoritmaları ve modeli test ederek yarışma kapsamında çalışma yürütmektedir. Bu organizasyona ilişkin görev dağılımları Şekil 1’de verilmiştir.



Şekil 1: Takım Organizasyonu

2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ (15 PUAN)

Ön tasarım raporu sürecinin ardından ön tasarım raporunda belirtilen veri setleri incelenmiş ve kendi içlerinde sınıflandırılmıştır. Sınıflandırılan veri setleri incelendiğinde bazı veri setlerinin teknik şartnamede belirtilen şartları sağlamadığı kanaatine varılmıştır. Veri setleri içerisinde yarışma şartnamesine uygun olmayan görseller çıkartılmış ve teknik şartnamede belirtilen şartları sağlayan görseller kullanılarak yeni bir veri seti oluşturulmuştur.

Veri seti oluşturulurken bazı faktörler ele alınmıştır. Bu faktörler:

- Veri çeşitliliği,
- Verilerin sınıf bazında eşit sayıda olması,
- Görüntülerin teknik şartnameye uygun açılarda olması,
- Yarışma isterlerini karşılamayan görüntülerin çıkartılmasıyla yeni bir veri seti oluşturulmuştur.

Oluşturulan veri seti üzerinde etiketleme işlemi yapılmış olup ön tasarım raporunda da belirtilmiş olan görüntü kirlenme algoritmaları ve CLAHE algoritması veri setine uygulanmıştır. Uygulanan algoritmalar; gaussian blur, snow, shadow, high gamma, clahe, add brightness ve low brightness olmak üzere yedi adettir. Uygulanan bu algoritmalar hem veri setindeki verilerin çoğaltılmasına hem de farklı ortamlarda nesne tespit modelinin daha verimli olmasına katkı sağlamıştır. Algoritmalarla ilişkin çıktılar, Kısım 3.2.3 ve Kısım 3.2.4’te verilmiştir.

Tüm bu işlemler sonucunda elde edilen veri seti, ön tasarım raporunda açıklanan nesne tespit algoritmalarında eğitilmiştir. YOLOv5 algoritmasında yapılan eğitimlerde çeşitli hazır modeller kullanılmıştır. YOLOv5 nano ve small modellerinin çıktıları incelendiğinde yeterli oranda tespit oranına ulaşamadığı gözlemlenmiştir. Bu doğrultuda YOLOv5 algoritması üzerinde medium ve large modelleri daha uygun olacağı saptanmıştır. RetinaNet algoritmasında ise Resnet-50 temelli bir eğitim gerçekleştirilmiştir. Eğitim sonuçları incelendiğinde YOLOv5 algoritmasının RetinaNet algoritmasına göre daha hızlı olduğu gözlemlenmiş olup YOLOv5 algoritmasının birincil nesne tespit algoritması olarak kullanılmasına karar verilmiştir. Yarışma süresinin değişiklik göstermesi durumunda YOLOv5 algoritmasına alternatif olarak RetinaNet algoritması kullanılacaktır.

Yarışma esnasında kullanılacak haberleşme sistemi, temel olarak hazırlanmış olup TEKNOFEST tarafından yayınlanacak olan haberleşme dökümanına uygun olarak revize edilecektir. Yarışma esnasında kullanılması planlanan algoritmaların testleri, Nvidia RTX2060 ve Nvidia RTX2080 ekran kartlarına sahip iki bilgisayarda yapılmıştır.

3. ALGORİTMALAR VE SİSTEM MİMARİSİ (25 PUAN)

Bu alanda algoritmalar ve sistem mimarileri iki madde halinde incelenmiştir.

3.1. VERİ SETLERİ (10 PUAN)

Ön Tasarım Raporu'nda tanımlanan veri setleri, detaylıca incelenmiştir. Çözünürlük, veri sayısı, teknik şartnameye uygunluk gibi faktörler göz önüne alınmış ve üç adet veri seti belirlenmiştir. Belirlenen veri setlerinden uygun görseller seçilmiş ve etiketlenmiştir. Veri setlerine ilişkin detaylar Kısım 3.1'in alt başlıklarında detaylandırılmıştır.

3.1.1. VISDRONE VERİ SETİ

Bu veri seti, Çin'deki Tianjin Üniversitesi bünyesinde bulunan AISKEYE tarafından hazırlanmıştır. Veri seti, çeşitli koşullarda havadan alınan görüntülerle oluşturulmuştur. 400 videodan oluşan bu veri seti, görüntülere ayrıldığında 265228 görüntüden oluşmaktadır. Veri setinin içerisinde çeşitli araç, motosiklet, bisiklet, kamyonet, kamyon görüntüleri mevcuttur. VisDrone veri seti, yarışmada kullanılacak olan verilerin temelini oluşturmaktadır [1].

3.1.2. STANFORD DRONE VERİ SETİ

Stanford Drone veri seti, Stanford Üniversitesi bünyesinde bulunan Computational Vision & Geometry Lab (Bilgisayarlı Görü ve Geometri Laboratuvarı) tarafından hazırlanmıştır. Veri setinin oluşturulma amacı kalabalık ortamlarda nesne tespiti ve takibidir. Bu veri seti, taşıtlardan çok insan tespiti ve takibine odaklanmıştır. Stanford Drone veri seti, VisDrone veri setine yardımcı olacak şekilde kullanılmış olup insan tespiti verimini artırmıştır [2]. Stanford Drone veri setindeki görüntülerin bir örneği Şekil 2'de verilmiştir.



Şekil 2: Stanford Drone Veri Setindeki Görüntülerin Bir Örneği

3.1.3. UAVDT Veri Seti

UAVDT veri seti, "The Unmanned Aerial Vehicle Benchmark: Object Detection and Tracking" makalesi için hazırlanmıştır. Veri seti, 80000 görüntüden oluşur. Bu veri setinin diğerlerinden farkı, veri çeşitliliğinin ön planda tutulduğu ve her durumun değerlendirilmeye çalışıldığı bir veri seti olmasıdır. Yükseklik olarak 30 metre üstü, 30 metre altı gibi konum çeşitliliğinin yanı sıra gündüz, gece gibi farklı saatler, yağmurlu, sisli, bulutlu gibi farklı hava koşullarında veriler toplanmıştır. UAVDT veri seti, VisDrone ve Stanford Drone veri setlerinin eksiklerini kapatmakta kullanılmıştır [3]. UAVDT veri setindeki görüntülere örnek bir görüntü Şekil 3'te verilmiştir.



Şekil 3: UAVDT Veri Setindeki Görüntülerin Bir Örneği


3.2. ALGORİTMALAR (15 PUAN)

Bu alanda kullanılmış olan algoritmalar hakkında bilgi verilmiştir.

3.2.1. RetinaNet Algoritması

RetinaNet, yoğun ve küçük ölçekli nesnelerde kendini kanıtlamış tek aşamalı nesne tespit modellerinden birisidir. RetinaNet diğer tek aşamalı nesne tespit modellerinin üzerine özellik piramit ağları ve focal loss (odak kaybı) olarak 2 algoritmayı mimarisine eklemiştir.

Özellik Piramit Ağı: Görüntüdeki değişken ölçekte olan görüntüleri algılamak için RetinaNet’de özellik piramit ağı kullanılmaktadır. Bir CNN mimarisinde, öznelik haritalarının çıktı boyutu, her ardışık evrimsel işlem bloğundan sonra azalır ve bir piramidal yapı oluşturur. Bu işlem görüntüyü daha düşük çözünürlüğe ve boyuta indirger. Bu işlem belleği yorduğundan farklı piramit türleri oluşturularak amaca yönelik farklı türler kullanıma sunulmuştur [4]. Piramit yapısını kullanan çeşitli mimariler Şekil 4’te verilmiştir.




Şekil 4: Farklı piramit türleri

YOLOv5 modeline alternatif olarak yedek modeller araştırılmıştır. Araştırmalar sonucunda RetinaNet’in yoğun ve küçük ölçekli nesnelerde başarılı olduğu gözlemlenmiştir. Şekil 5 ve Şekil 6’da COCO veri seti üzerinde test sonuçları paylaşılmıştır. Bu araştırma sonucu RetinaNet’in uygun bir model olduğuna karar verilmiştir.

	backbone	AP	AP ₅₀	AP ₇₅	AP _S	AP _M	AP _L
<i>Two-stage methods</i>							
Faster R-CNN+++ [16]	ResNet-101-C4	34.9	55.7	37.4	15.6	38.7	50.9
Faster R-CNN w FPN [20]	ResNet-101-FPN	36.2	59.1	39.0	18.2	39.0	48.2
Faster R-CNN by G-RMI [17]	Inception-ResNet-v2 [34]	34.7	55.5	36.7	13.5	38.1	52.0
Faster R-CNN w TDM [32]	Inception-ResNet-v2-TDM	36.8	57.7	39.2	16.2	39.8	52.1
<i>One-stage methods</i>							
YOLOv2 [27]	DarkNet-19 [27]	21.6	44.0	19.2	5.0	22.4	35.5
SSD513 [22, 9]	ResNet-101-SSD	31.2	50.4	33.3	10.2	34.5	49.8
DSSD513 [9]	ResNet-101-DSSD	33.2	53.3	35.2	13.0	35.4	51.1
RetinaNet (ours)	ResNet-101-FPN	39.1	59.1	42.3	21.8	42.7	50.2
RetinaNet (ours)	ResNeXt-101-FPN	40.8	61.1	44.1	24.1	44.2	51.2

Şekil 5: COCO Veriseti Üzerinde Test Sonuçları


Yapılan araştırmalar sonucu YOLOv5 algoritmasına ek olarak kullanılabilecek bu algoritmanın avantajları göz önünde bulundurulmuştur. Eğitim aşamasının diğer algoritmalarla göre hızlı olması RetinaNet algoritmasının seçilmesinde öncül bir kriter olmuştur. RetinaNet algoritmasının doğruluk oranları Şekil 6 üzerinde belirtildiği gibi diğer algoritmalarla göre üstünlük sağladığı gözlemlenmiş ve bu algoritmanın da yarışma esnasında ek algoritma olarak kullanılmasına karar verilmiştir.



Şekil 6: COCO Veriseti Üzerinde Başarım Kıyaslaması

3.2.2. YOLOv5 Algoritması

YOLOv5, YOLO (You Only Look Once) temelli nesne tespit algoritmalarının beşinci sürümüdür. YOLOv5 algoritması, Ultralytics firması tarafından geliştirilmiş olup aktif olarak geliştirilmektedir [5]. Bu algoritma, yapı olarak PyTorch kullanmaktadır. YOLO temelli nesne tespit algoritmaları, konvolüsyonel sinir ağları (CNN) temelli olacak şekilde oluşturulmuştur. YOLO algoritmalarında, giriş görüntüsüne bir sinir ağı uygulanır. Sinir ağı yardımıyla giriş görüntüsündeki öznitelikler çıkartılır ve sınırlayıcı kutular tahmin edilir. Sınırlayıcı kutular yardımıyla nesnenin bulunma olasılığı hesaplanır. Her bir sınırlayıcı kutu için güven skoru denilen bir değer hesaplanır. Güven skoru yardımıyla, tespit edilen nesnenin gerçekten o nesne olup olmadığı anlaşılabilir. Örneğin, tespit edilen bir taşıtın güven skoru 0,3 olsun. Güven skorunun 0,3 olması, o taşıtın gerçekten taşıt olma ihtimalinin %30 olduğunu gösterir. Sınırlayıcı kutuların bulunması ve güven skoru hesaplamasından sonra non-max suppression işlemi uygulanır. Non-max suppression işlemi yardımıyla güven skoru düşük sınırlayıcı kutular elenir ve en yüksek güven skoruna sahip kutu seçilir. Sınırlayıcı kutular yardımıyla nesne tespit örneği Şekil 7'de verilmiştir.



Şekil 7: Sınırlayıcı Kutular Yardımıyla Nesne Tespit Örneği

3.2.3. CLAHE Algoritması

Veri seti içerisindeki görüntülerin arasında oluşacak olan istenmeyen farklılıkları ortadan kaldırmak için veya data augmentation (veri çoğaltma) için kullanılır. Bu algoritma, görsellerdeki yerel kontrastı geliştiren bir algoritmadır. Böylelikle, veri setindeki renk farklılıkları azaltılabilmektedir. Bunlarla birlikte histogram eşitleme (HE) teknikleri de kullanılmaktadır. Histogram eşitleme tekniği, görüntünün kontrastını arttırmak için kullanılan yaygın bir yöntemdir. Uyarlanabilir Histogram Eşitleme (AHE) ise görüntünün bazı bölgelerine karşılık gelen birkaç histogramı hesaplayarak yerel kontrastı geliştirip yerel bilgi kaybını azaltmaktadır. CLAHE, HE ve AHE yöntemlerini baz alarak kontrastın limitlenmesini sağlar [8]. Böylece önceden verilen değerde histogramı kırpmasını sağlayarak büyümeyi önlemektedir. CLAHE algoritması, veriler içerisinden daha kaliteli görüntüler elde edilmesini sağlamaktadır [6]. UAP verisine ait orijinal görüntü ve CLAHE algoritması uygulanmış görüntü Şekil 8 ve Şekil 9'da verilmiştir.




Şekil 8: Orijinal Görüntü



Şekil 9: CLAHE Uygulanmış Görüntü

3.2.4. Görüntü Kirlenme Algoritmaları

Görüntü kirlenme, veri setindeki çeşitliliği arttırmak amacıyla kullanılan veri çoğaltma işlemleridir. Karşılaşılabilecek farklı görüntü kirlenmelerinde (gölge, fazla ışık, az ışık vb.) modelin nesne tespitinde kullanılan veri seti çeşitliliğinin artmasıyla modelin tespit yeteneği doğru oranda artacaktır. Kullanılan görüntü kirlenme yöntemleri gaussian gürültüsü, karlandırma, gölgelendirme, gamma artırma, güneş parlaklığını artırma ve ışık oranını azaltma olarak kullanılmıştır [6]. Bunlara ek olarak Kısım 3.2.3.'deki CLAHE algoritması da görüntü kirlenme algoritmalarıyla beraber model eğitimi için kullanılmıştır. Kullanılan kirlenme yöntemleri Şekil 9'da gösterilmiştir.



Şekil 10: Kirlenme Algoritmalarının Uygulanması

4. ÖZGÜNLÜK (25 PUAN)

Bu kısımda, yapılan özgünlük çalışmalarına dair bilgiler maddeler halinde verilmiştir.

- UAP ve UAİ alanlarının tespiti için, modelden gelecek tespit verisinin yanı sıra morfolojik görüntü işleme teknikleri kullanılmıştır. Renk analizi, daire tespiti gibi fonksiyonlar kullanılarak olası UAP, UAİ alanları belirlenecek ve modelden gelen tespit verisiyle karşılaştırma yapılmaktadır. Tespit oranı yüksek çıkan sonuç, yarışma sunucusuna gönderilerek işlem tamamlanmaktadır.
- Bazı görsellerde tespit edilecek nesne küçük gözükabilmektedir. Küçük gözükten nesneler, modelin tespit performansını düşürüp hataya sebep vermektedir. Boyut kaynaklı nesne tespit hatalarını azaltmak ve genel nesne tespit oranını arttırmak için SAHI kütüphanesi kullanılmıştır. SAHI kütüphanesi, Türk geliştiriciler tarafından hazırlanmıştır. Kütüphanenin amacı, büyük ölçekli görsellerde bulunan küçük nesnelerin tespitindeki hataları gidermektir. Kütüphane, kendisine verilen görseli belirlenen sayıda eşit parçalara ayırır ve ayrılan parçalarda tek tek tespit işlemi yapar. Elde edilen sonuçlar, görselin orijinalinde toplanır. Böylelikle küçük nesnelerin tespit edilmesindeki hataların önüne geçilmektedir.
- YOLOv5 modeli üzerinde takım üyelerinin yaptığı testler sonucu çeşitli ince ayarlar ve parametreler bulunmuş ve bu ayarlamaların modelin doğruluğu üzerindeki etkisi analiz edilerek özgün parametre ayarlamaları yapılmıştır.
- İnternette hazır olarak alınan veri setleri üzerinde yapılan testler sonucu doğruluk oranının düşük olduğu gözlemlenmiş olup hava aracı temin edilmiştir. Oluşturulan UAP, UAİ alanları, taşıt ve insanların olduğu bölgelerden veri toplanarak özgün bir veri seti oluşturulmuştur. Oluşturulan ve hazır temin edilen veri setleri birleştirilerek tespit edilen nesne sayısı ve tespit oranında artış sağlanmıştır.
- Deepsort, Kalman filtresini kullanan basit çevrimiçi ve gerçek zamanlı İzleme adlı bir algoritma kullanır. YOLO tarafından algılanan sınırlayıcı kutuları kullanarak, önceki ve sonraki çerçevede benzer boyut ve benzer hareketlere sahip sınırlayıcı kutuları eşleyerek bir sınıf kimliği atar. Bununla birlikte Deepsort, bir kişinin veya bir nesnenin arkasına saklanıp sonra yeniden görünmesi durumunda ona farklı bir kimlik atanması durumunu sınırlar. DeepSort, insanlar ve nesneler arasındaki benzerliği karşılaştıran bir yapay zekâ modeli kullanarak bu sorunu çözer

- YOLOv5 modelinin yanında semantic segmentasyon kullanarak yol, kaldırım ve çimli alan gibi ayırt edici alanların tespit işlemi gerçekleştirilmiştir. Bu şekilde tespit edilen nesnenin hangi alanda kaldığını kontrol ederek nesnenin olması gerektiği bir alanda olup olmadığı kontrol edilmekte ve bu şekilde tespit edilen nesnenin doğruluğu artırılmaktadır.
- CLAHE algoritması kullanılarak, veri seti içerisinde bulunan görüntülerdeki yerel kontrasta iyileştirme işlemleri yapılacaktır. Renk farklılıkları azaltılarak histogram eşitleme teknikleriyle görüntünün bazı bölgelerindeki histogram değerlerinde hesaplama işlemleri yapılacak ve yerel kontrast geliştirilerek bilgi kaybını azaltmak hedeflenecektir. Böylelikle veriler içerisinde daha kaliteli görüntüler elde edilecektir.
- Veri setinde bulunan görüntülerin çoğaltılması amacıyla farklı görüntü işleme teknikleri uygulanarak görüntüler üzerinde resim çoğaltma işlemi yapılacaktır. Bu teknikler güneş efekti, resmin parlaklığının azaltılması ve artırılması, gamma oranı değişikliği, gölgelendirme, kar efektleri gibi özellikleri içerisinde barındırmaktadır [7]. Bu sayede bir fotoğrafa bu teknikler uygulanıp görüntülerde çoğaltma işlemi yapılacaktır. Çoğaltılan bu görüntülerle, veri setinin büyütülmesine katkı sağlamasının yanı sıra, eğitilecek olan modelin çeşitli görüntü kayıplarına karşı tespit oranını arttırmaktadır.
- Yarışma esnasında, sunucudan alınan görüntülere ön işleme yapılacaktır. Ön işlemede amaçlanan, parlaklık değerlerinin eşitlenmesidir. Parlaklık değerleri eşitlendiğinde görüntünün her kısmı aynı parlaklık değerine sahip olacak ve parlaklık kaynaklı nesne tespit hatalarının önüne geçilecektir.
- Gabor filtresi kullanılarak görsel içerisinde yer alan insan tespitinin artırılması amaçlanmıştır. Gabor filtresi, görüntü üzerinde belirli yönlerde uzanan ayrıtları tespit etmek için kullanılmakta olan görüntü işleme filtresidir.


5. SONUÇLAR VE İNCELEME (25 PUAN)

10 / 12

Eğitimin daha optimize hale getirilebilmesi için YOLOv5 algoritmasının hiper parametreleri ve optimizasyon algoritmaları(adam, sgd) üzerinde çeşitli testler yapılmış olup yarışma için en uygun eğitimin çıkarılabilmesi için en optimize parametreler belirlenmiştir. YOLOv5 algoritmasında yapılan eğitime ait örnek bir çıktı Şekil 12'de verilmiştir.



Şekil 12: YOLOv5 Eğitim Modeli Üzerinde Test Çıktısı



Şekil 13: YOLOv5 Eğitim Modeli Grafik Çıktısı

YOLOv5 eğitiminin grafik çıktısı Şekil 13'de verilmiş olup, bu modelin 200 epoch'tan itibaren doğruluk kısmındaki kayıp(loss) değerlerinde aşırı bir sapma olduğu gözlemlenmiştir. Eğitimin 200 epoch'ta en verimli halde olduğu tespit edilmiştir.

RetinaNet algoritması için de eğitim gerçekleştirilmiştir. Bu eğitimin optimize bir şekilde gerçekleştirilebilmesi için epoch(iterasyon) ve step-size(adım sayısı) sayıları büyük önem taşımaktadır. Bu algorithmada 50 epoch kullanılmış olup step-size veri setinin %25'i olarak belirlenmiştir. Bu eğitime ilişkin model üzerinde bir görsel Şekil 14'de verilmiştir.



Şekil 14: RetinaNet Eğitim Modeli Test Çıktısı

6. KAYNAKÇA (5 PUAN)

- [1] <http://aiskyeye.com/>
- [2] https://cvgl.stanford.edu/projects/uav_data/
- [3] <https://arxiv.org/abs/1804.00518>
- [4] <https://developers.arcgis.com/python/guide/how-retinanet-works/>
- [5] <https://arxiv.org/pdf/1506.02640.pdf>
- [6] <https://cdn.t3kys.com/media/upload/userFormUpload/7IMq5LjZtZqzOU7Hy4cbB3CO13cvYkKw.pdf> (2021, Ulaşımda Yapay Zeka Yarışması, RACLAB – Turing Mind KTR)
- [7] <https://www.freecodecamp.org/news/image-augmentation-make-it-rain-make-it-snow-how-to-modify-a-photo-with-machine-learning-163c0cb3843f/>