

TEKNOFEST

**HAVACILIK, UZAY VE TEKNOLOJİ
FESTİVALİ**

**ULAŞIMDA YAPAY ZEKA YARIŞMASI
KRİTİK TASARIM RAPORU**

TAKIM ADI : springnovaAI

BAŞVURU ID : 399817


İÇİNDEKİLER

ŞEKİL LİSTESİ.....	3
TABLO LİSTESİ.....	4
KISALTMALAR.....	5
1.TAKIM ŞEMASI.....	6
2.PROJE MEVCUT DURUM DEĞERLENDİRMESİ.....	6
3.ALGORİTMALAR ve SİSTEM MİMARİSİ.....	7
3.1.VERİ SETLERİ.....	7
3.2.ALGORİTMALAR.....	8
4.ÖZGÜNLÜK.....	8
5.SONUÇLAR ve İNCELEME.....	9
6. KAYNAKÇA.....	13



ŞEKİL LİSTESİ

Şekil 2.1: Oluşturulan Veri Setinden Örnek Görüntüler.....	6
Şekil 4.1: UAP-UAİ iniş alanlarını içeren örnek görüntüler.....	8
Şekil 4.2: UAP-UAİ alanlarına benzer yapılar içeren görüntüler.....	9
Şekil 4.3: İniş durumu tespit algoritması akış şeması.....	9
Şekil 5.1: YOLOv5m6 modelinin test görüntüsü üzerindeki performansı(1).....	10
Şekil 5.2: YOLOv5m6 modelinin test görüntüsü üzerindeki performansı(2).....	10
Şekil 5.3: YOLOv5m6 modelinin test görüntüsü üzerindeki performansı(3).....	11
Şekil 5.4: YOLOv5m6 modelinin test görüntüsü üzerindeki performansı(4).....	11



TABLO LİSTESİ

TABLO 1.1: Takım Şeması.....6

TABLO 5.1: Karşılaşılan sorunlar ve çözümleri.....12



KISALTMALAR

YOLO = You Only Look Once

YOLOR = You Learn One Representation

UAP = Uçan Araba Park

UAI = Uçan Ambulans İniş

TTA = Test Time Augmentation



1. TAKIM ŞEMASI


SpringnovaAI takımı üç tane son sınıf Bilgisayar Mühendisliği öğrencisinden oluşmaktadır.

Takım Üyeleri	Takım Üyelerinin Görev Dağılımları
Kaptan	Nesne tespit ve takip algoritmalarının araştırılması, en optimum algoritmaların belirlenmesi, algoritmaların veri setine göre optimize edilmesi, geliştirilmesi ve eğitimi süreçlerinden ; mevcut aşamada YOLOv5 model eğitimi, mimarisinin geliştirilmesi ve hiperparametre optimizasyonundan, farklı algoritmalar için veri setindeki annotation formatlarının düzenlenmesinden sorumludur.
Üye1	Eğitim için gerekli olan veri setlerinin düzenlenmesi, eğitimi gerçekleştirilecek modele göre ayarlanması, veri artırımı, nesne etiketleme süreçlerinden sorumludur.
Üye2	Modellerin test edilmesi, performanslarının değerlendirilmesi ve optimize edilmesi, sunucu ile kurulacak iletişim ve veri aktarımı için gerekli olan modüllerin hazırlanması süreçlerinden, mevcut aşamada YOLOR, YOLOv4 model eğitimi, hiperparametrelerinin optimizasyonundan, UAP-UAİ iniş alanlarını içeren sentetik görüntüleri üretmede sorumludur.

Tablo 1.1: Takım Şeması

2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ

ÖTR raporunda geniş çaplı olarak ele alınan veri kümeleri üzerinde detaylı incelemeler yapılmış olup kamera açısı, hava olayları, ışıklandırma, yükseklik gibi kriterler dikkatinde görüntüler filtrelenerek yaklaşık 16.000 ham görüntü elde etmiş bulunmaktayız. Bazı veri setlerinde etiketleri bulunmayan nesnelerin (özellikle insan) etiketlenmeleri tarafımızca gerçekleştirilmiştir. Etiketlerimiz varsayılan olarak PASCAL VOC formatında olup eğitimi gerçekleştirilecek algoritmaların istelerine göre dönüştürmeyi sağlayacak betik dosyaları oluşturulmuştur.



Şekil 1.1: Veri Setinden Örnek Görüntüler

Bir diğer tespit edilmesi gereken ve yarışma özeli olan UAP ve UAİ iniş alanları için veri setindeki uygun görüntülere ve çeşitli arka planlar üzerine farklı açılarda ve bazen iniş alanının görüntü üzerinde bir kısmının gözüktüğü şekilde görüntülere sentetik olarak ekleme yapılarak ve etiketlenmeleri sağlanarak veri setine eklenmiştir. Örnek görüntüler 4. başlık altında gösterilmiştir.

ÖTR raporunda temel olarak üç farklı algoritma ele alınmıştır:

- YOLOv5 [1]
- YOLOR [2]
- YOLOX [3]

Bahsedilen bu algoritmalar arasında YOLOv5 ile eğitimler gerçekleştirilmiş olup çeşitli mimari güncellemeleri ve hiperparametre optimizasyonu devam etmektedir. Eğitimler sonucunda taşıt nesnelerinin ve iniş alanlarının iyi derecede tespit edildiği saptanmış olup, insan tespiti konusunda problem yaşandığı görülmüştür. YOLOR üzerinde de eğitim çalışmalarına başlanılmış olup ilerleyen süreçte YOLOv5 ile kıyaslanması gerçekleştirilecektir. YOLOX tarafında model implementasyonu aşamasında sorun yaşandığı için zaman parametresi göz önüne alınarak bu algoritma üzerinde çalışmalara ara verilmiştir ve alternatif algoritmalar araştırılmaktadır. ÖTR tesliminden sonra YOLOv4 algoritması üzerine de çalışmalar gerçekleştirilmiştir. Hazırlanan veri seti YOLOv4 algoritması ile eğitilmiştir. Taşıt konusunda yüksek tespit oranına sahip olsada insan ve iniş kalkış noktalarında yeterince iyi tespit gerçekleştirilememiştir.

3. ALGORİTMALAR ve SİSTEM MİMARİSİ

3.1. VERİ SETLERİ

VisDrone[4] veri seti mevcut veri setimizin yaklaşık olarak 1/5'ini oluşturmaktadır. Veri seti çekim açısı, arka plan ve nesne çeşitliliği açısından oldukça zengindir. Veri setinde toplam 12 adet nesnenin etiketleri mevcuttur. Bu etiketlerden 8'i farklı araç sınıflarını, 2'si (yaya, insan) insan sınıflarını temsil etmektedir. Bu veri kaynağından elde ettiğimiz görüntülerin, tespit edilecek sınıflar arasındaki çeşitliliği, arka plan çeşitliliğini, insan ve taşıt nesnelerinin bir arada olduğu örnekleri artırdığını gözlemlenmiştir.

AU-AIR[5] veri seti mevcut veri setimizin yaklaşık olarak 1/10'unu oluşturmaktadır. Bu veri setinde özellikle UAP-UAİ iniş alanlarını üzerine sentetik olarak ekleyebileceğimiz uygun görüntüler olduğunu tespit ettik. Filtrelediğimiz görüntülerde farklı arka planlar (çim, toprak, yol vb.) üzerine bu iniş alanlarını, farklı açılarda ve çekim yüksekliğine uygun ölçülerde olacak şekilde ekleyerek görüntülerimizi elde ettik.

VAID[6] veri seti mevcut veri setimizin yaklaşık olarak 2/5'ini oluşturmaktadır. Veri setinde 7 farklı araç sınıfının etiketleri mevcuttur. Bu veri setinden kazandığımız avantajlar ; büyük taşıtların set içinde bolca olması, taşıt çeşitliliğinin artırılması ve özellikle çekim mesafesinin diğer veri setlerine oranla biraz daha yüksekten olması tespit edilecek taşıt nesnelerinin tespitini önemli ölçüde iyileştirmektedir.

CARPK (Car Parking Lot Dataset)[7] veri seti mevcut veri setimizin 2/10'unu oluşturmaktadır. Veri seti, otomobil otoparklarında sadece 90 derece kuş bakışı çekim açısıyla çekilmiş görüntülerden oluşmaktadır. Bu kaynaktan elde ettiğimiz avantaj otomobil taşıtları için kuş bakışı çeşitliliğinin artırılmasıdır. Ek olarak veri setinde bulunan fakat etiketleri olmayan insan nesneleri üzerinde elle etiketleme yapılarak veri setimize dahil edilmiştir.

Okumata Action[8] veri seti mevcut veri setimizin 1/5'ini oluşturmaktadır. Veri seti farklı kuş bakışı açılarıyla çekilmiş olup, insan nesnesi içeren görüntülere sahiptir. Mevcut setimizde insan nesnesinin çeşitliliği arttırmak, nesnelerin farklı pozisyonlara (yürüme, koşma, oturma, eşya taşıma gibi) sahip olması bize kazandırdığı avantajlardandır.

UAVDT[9] veri seti mevcut veri setimizin 3/10'unu oluşturmaktadır. Veri seti sadece taşıt nesneleri bulunmaktadır. Üzerinde en çok zaman harcanan settir. Veri setinden filtreleme yaparken özellikle dikkat ettiğimiz ve yarışma isteri olan "tamamı görünmeyen taşıt ve insan nesnelerinin de tespit edilmesi" kuralı dikkate alınarak araçların bir kısmının görüntü üzerinde olduğu resimler filtrelenip etiketlenmeleri sağlanmıştır.

3.2. ALGORİTMALAR

YOLOv5 algoritması üzerinde çalışma yaptığımız ilk algoritmadır. 2020 yılında piyasaya çıkmıştır ve diğer YOLO modellerine göre daha geniş bir topluluğa sahiptir. Öncelikli olarak bu algoritmanın tercih edilmesinin sebebi açık kaynak reposunun daha incelenebilir ve güncellenebilir olmasıdır. Aynı zamanda genetik algoritmaları kullanarak optimum hiperparametre optimizasyonu yapma seçeneği sunmaktadır. Eğitime öncelikli olarak YOLOv5x versiyonu ile başlanılmıştır. Bu versiyonun küçük nesneleri tespit edebilme konusunda yetersiz kaldığı fark edilip YOLOv5m6 versiyonu tercih edilmiştir.


YOLOv4 [10], Nisan 2020'de yayınlanan ve COCO veri setinde son teknoloji performansa ulaşan gerçek zamanlı bir nesne algılama modelidir. YOLOv4 mimarisi darknet üzerinde çalışıldığı için birçok varyasyona sahiptir. Biz eğitimimizde YOLOv4 ün ana modelini tercih ettik. YOLOv3 e göre karşılaştırıldığında hız ve doğruluk açısından daha güçlü bir nesne tespit algılama modeli sunar. EfficientDet ile karşılaştırdığımızda YOLOv4 iki kat daha hızlıdır. YOLOv5 ile karşılaştırıldığında doğruluk açısından birbirlerine çok yakın sonuçlar ile karşılaşılsada performans açısından YOLOv5 daha avantajlıdır. Ayrıca daha hızlı model eğitimi yapmak ve sonuçları değerlendirmek için YOLOv4-Tiny ile de çalışma gerçekleştirilmiştir. YOLOv4-Tiny, YOLOv4'ün sıkıştırılmış versiyonudur. Ağ yapısını daha basit hale getirip, parametreleri azaltarak uzun eğitim süresinin düşürülmesi hedeflenmiştir. YOLOv4-Tiny üzerinde de çalışmalar devam etmektedir.

YOLOR, mimari ve model altyapısındaki farklılıklar nedeniyle YOLOv1-YOLOv5'ten farklı, nesne algılama algoritmasıdır. YOLOR, "Yalnızca Bir Temsil Öğrenirsiniz" anlamına gelir. YOLOR algoritması, karşılaştırmalı algoritmalar için öngörülen ek maliyetlerin bir kısmını kullanarak görevleri gerçekleştirmeyi amaçlar. Dolayısıyla YOLOR, örtük ve açık bilgiyi birlikte işleyebilen ve bu metodoloji nedeniyle rafine edilmiş genel bir temsil üretebilen birleşik bir ağıdır. Hız açısından YOLOv4 e göre daha yüksek bir performans göstermektedir. Aynı zamanda hassasiyet karşılaştırılmasında YOLOv2 den daha yüksek sonuç elde edilmiştir.


4. ÖZGÜNLÜK

ÖTR raporunda ve 3.1 başlığı altında bahsedilen veri setleri detaylı bir şekilde incelenerek yarışma görevini yerine getirecek şekilde harmanlandığımız özgün bir veri seti oluşturulmuştur. Mevcut veri setinde taşıt sınıfı için yaklaşık olarak 200.000, insan sınıfı için ise yaklaşık olarak 75.000 etiket mevcuttur.

Yarışma özeli olan ve veri setlerinde bulunmayan UAP-UAİ iniş alanları, çekim açısı ve yüksekliğine uygun olarak görüntüler üzerine eklenmiş olup, bu alanları içeren görüntüler elde edilmiştir. Ek olarak bu alanlar için FP (False Positive) hatasından kaçınmak amacıyla iniş alanlarına benzer yapılarla sahip görüntüler veri setine eklenmiştir.




Şekil 4.1: UAP-UAİ iniş alanlarını içeren örnek görüntüler



Şekil 4.2: UAP-UAİ alanlarına benzer yapılar içeren görüntüler

Yarışma kuralınca UAP ve UAİ alanlarının üzerinde herhangi bir cisim olması durumunda iniş uygun olamayacağı şeklinde bildirilmesi gerekmektedir. İstenmeyen bu cisimler taşıt ya da insan harici olması durumunda, algoritmanın bu cisimleri tespit edemeyeceğinden dolayı iniş durumunun uygun olup olmadığı tarafımızca oluşturulan algoritma ile tespit edilecektir. Algoritmanın çalışma şeması aşağıda görülmektedir.




Şekil 4.3: İniş durumu tespit algoritması akış şeması

Veri setindeki örnek miktarının az olması durumunda veri artırımı yöntemleri kullanılmaktadır. Buradan yola çıkılarak ve bilgisayarlı görü alanında önemli bir teknik olan TTA (Test Süresi Artırımı)[11] tespit aşamasında veri artırımı yöntemleri kullanarak model doğruluğunu arttırmaya çalışır. Çalışmamızda elimizdeki veri setine en uygun TTA modeli oluşturularak eğitimi gerçekleştirdiğimiz modellere ekleyerek başarı oranını artırılması planlanmaktadır.

5. SONUÇLAR ve İNCELEME

Eğitimler sonucu 0.79 mAP@0.50 skoru ile en iyi performansı aldığımız YOLOv5m6 modelinin, test görüntüleri üzerindeki performansını görebiliriz. Aynı veri seti üzerinde YOLOv4 modeli ile de 0.77 mAP@0.50 skoru elde edildi. YOLOv4 modelimiz başarı oranına kıyasla YOLOv5'den daha iyi sonuç vermektedir. Özgünlük başlığı altında bahsedilen oluşturulacak veri setine özgün TTA tekniği her iki algoritmaya uygulayarak nihai sistemimizi belirleyeceğiz.



Şekil 5.1: YOLOv5m6 modelinin test görüntüsü üzerindeki performansı(1)



Şekil 5.2: YOLOv5m6 modelinin test görüntüsü üzerindeki performansı(2)

Yukarıdaki test görüntülerinde görüldüğü üzere modelin taşıt tespiti konusunda son derece iyi performans gösterdiği gözükmemektedir. Bazı taşıtların fotoğraf üzerinde sadece bir kısmının gözükmesi model tarafından öğrenilmiş olup başarılı sonuçlar elde edilmiştir.



Şekil 5.3: YOLOv5m6 modelinin test görüntüsü üzerindeki performansı(3)

Veri setimizde bulunan sisli, dumanlı vb. arka plana sahip görüntüler sayesinde, modelin bu arka plana sahip alanlarda iyi derecede tespit yapabildiği görüşmüştür.



Şekil 5.4: YOLOv5m6 modelinin test görüntüsü üzerindeki performansı(4)

Modelin yakın ve 90 derece açı ile çekilmiş görüntüler üzerinde insan tespitini başarılı bir şekilde yaptığı gözlemlenmiştir. Aşağıdaki tabloda eğitim boyunca karşılaşılan sorunların kaynakları ve çözümleri belirtilmiştir.

Problem	Problem Kaynağı	Çözüm Önerisi
90 derece kuş bakışı, uzak çekim görüntüler üzerinde insan tespitinin yetersiz olması	Veri setinde ki örnek görüntülerin yetersizliği, sınıf dengesizliği.	Veri artırım yöntemlerinin kullanılması
Taşıt sınıfı için az seviyede FP (False Positive) hatalarının olması	Veri seti içerisinde aynı arka plana sahip ama taşıt içermeyen görüntülerin eksikliği	Aynı arka plana sahip fakat taşıt içermeyen görüntülerin veri setine eklenmesi
UAP-UAİ tespit başarımının düşük olması	Veri setindeki örnek eğitim görüntülerinin yetersizliği	Bu alanlara sahip daha fazla oluşturulması ve veri artırım yöntemlerinin uygulanması

Tablo 5.1: Karşılaşılan sorunlar ve çözümleri



6. KAYNAKÇA

- [1] You Only Look Once: Unified, Real-Time Object Detection "<https://arxiv.org/abs/1506.02640>"
- [2] You Only Learn One Representation: Unified Network for Multiple Tasks Chien-Yao Wang, I-Hau Yeh, Hong-Yuan Mark Liao "<https://arxiv.org/abs/2105.04206>"
- [3] YOLOX: Exceeding YOLO Series in 2021 "arxiv.org/abs/2107.08430"
- [4] <http://aiskyeye.com/>
- [5] AU-AIR: A Multi-modal Unmanned Aerial Vehicle Dataset for Low Altitude Traffic Surveillance "arxiv.org/pdf/2001.11737.pdf"
- [6] Aerial Image Dataset for Vehicle Detection "<https://vision.ee.ccu.edu.tw/aerialimage/>"
- [7] Car Parking Lot Dataset "<https://lafi.github.io/LPN/>"
- [8] Okumata-Action "<http://okutama-action.org>"
- [9] UAVDT "<https://sites.google.com/view/grli-uavdt/%E9%A6%96%E9%A1%B5>"
- [10] YOLOv4: Optimal Speed and Accuracy of Object Detection "<https://arxiv.org/abs/2004.10934>"
- [11] Better Aggregation in Test-Time Augmentation "<https://arxiv.org/abs/2011.11156>"

