

TEKNOFEST

HAVACILIK, UZAY VE TEKNOLOJİ

FESTİVALİ

ULAŞIMDA YAPAY ZEKA YARIŞMASI

KRİTİK TASARIM RAPORU



AprIkod

#399006

İçindekiler

1. Takım Şeması.....	2
2. Proje Mevcut Durum Değerlendirmesi	2
3. Algoritmalar ve Sistem Mimarisi	3
3.1 Veri Setleri	3
3.2 Algoritmalar.....	4
4. Özgünlük.....	5
5. Sonuçlar ve İnceleme	7
6. Referans	10

Şekiller

Şekil 1: Makine Öğrenimi Yaşam Döngüsü.....	2
Şekil 2: Proje Çözümü İçin Takip Edilecek Aşamalar.....	3
Şekil 3: YOLOv4 ve Türev Modellerinin Karşılaştırılması [4]	4
Şekil 4: Yolo Algoritmasının Izgara Hücresinde Çalışma Prensipleri.....	5
Şekil 5: YOLOv4 Yapısı [7].....	5
Şekil 6: Örnek Montajlı Görüntüler	6
Şekil 7: Oluşturulan Algoritma Yapısı	6
Şekil 8: Sahi Algoritma Yapısı	7
Şekil 9: IoU Yapısı	8
Şekil 10: Modelin Test Sonuçları	9
Şekil 11: UAP ve UAI İçin Oluşturulan Algoritmanın Çıktısı.....	9

Tablolar

Tablo 1: Veri Setindeki Sınıfların Boyutu.....	4
Tablo 2: Eğitime Sokulacak "Eğitim" ve "Test" Veri Setlerinin Oranları	4
Tablo 3: Eğitim Sonuçları	7
Tablo 4: Karışıklık Matrisi	8
Tablo 5: Eğitilen Modelin Sınıflandırma Raporu	8

Kısaltmalar

YZ Yayıncı Zeka

UAI Uçan Araç İniş

UAP Uçan Araç Park

YOLO You Only Look Once

IoU Intersection over Union


AP Average Precision

mAP mean Average Precision

1. Takım Şeması

Aprikod takımı, deneyimli öğretim elemanları ile hem proje anlamında hem akademik anlamda tecrübeli kişilerden oluşmaktadır. Takım, yapay zeka (YZ) ile beraber gelişen teknolojinin insanlık yararına daha iyi hale getirilebilmeyi, hayatımızı kolaylaştıracak teknolojiler, yazılımlar üretmek ve bunları sağlık, ulaşım, güvenlik, eğitim vb. alanlarda kullanmayı hedeflemektedir. Takımda bulunan üyeler, proje ve makale gibi alanlarda tecrübeli olmasının yanında sahada da tecrübeli kişilerden oluşmaktadır. Takımda bir yüksek lisans ve iki lisans derecesinde üyeler bulunmaktadır. Bu üyeler, biyomedikal, elektrik elektronik ve bilgisayar mühendisliği alanında öğrenim görmektedir. Böylece multidisipliner arası çalışmalar yürütülmektedir.

Takımın hedefi, bu yarışmada “çözüm için yazılım” ilkesini benimseyerek bilgisayarlı görüyle YZ tabanlı nesne tespiti ile uçan araç için yazılım ortamı oluşturmak, YZ destekli yazılımda Uçan Araba Park (UAP), Uçan Ambulans İniş (UAI), insan ve motorlu taşıtların tespit edilmesi gerekmektedir. YZ modelini aşağıda bulunan ve Şekil 2’de şeması gösterilmiş “Makine Öğrenimi Yaşam Döngüsü [1]” ne uygun olarak geliştirilmesi planlanmaktadır. Her üye bu döngü içerisinde bulunan alanlarda görev alacaktır.




Şekil 1: Makine Öğrenimi Yaşam Döngüsü

2. Proje Mevcut Durum Değerlendirmesi

Bu yarışma kapsamında 2020 yılında yarışmacılara verilen görüntülerin etiketleri JSON formatından kullanılacak model formatına uygun hale getirilmiştir. Yarışmacılara verilen geçen sene ve bu senenin örnek videolarının içerisinde her bir kareyi(frame) .jpg uzantılı görüntü dosyasına dönüştürülmüştür ve dönüştürülen bu görüntüler tek tek etiketlenmiştir. Aprikod takımına ait olan drone ile toplu alanlarda görüntüler alınmıştır ve toplanan görüntüler tek tek etiketlenmiştir. VisDrone[7] veri setinden alınan görüntüler yarışma kapsamında istenilen metriklere göre temizlenmiştir ve etiketleri kullanılacak model formatına uygun hale getirilmiştir. UAP ve UAI alanları yetersiz olduğu tespit edilip bu alanların olmadığı görüntülere montajlanarak sentetik veri çoğaltması yapılmıştır. Veri setinin içerisinde açısal sorunları olan görüntüler bulunmaktadır, bu görüntüleri yarışma şartnamesinde istenen “kamera açısı 60-90 derece aralığında değişken olacaktır” maddesine uygun olacak şekilde temizlenmiştir. Düzenlenen veri seti YOLOv4, YOLOv4-tiny, YOLOv4-p5 modelleri ile eğitilmiştir. Bu modeller kendi arasında başarımları ve hız açısından karşılaştırılmıştır. Karşılaştırılan modeller arasında en yüksek metriklere sahip model seçilmiştir.

UAP ve UAI alanları tespit edilirken iniş durumunun da bildirilmesi gerekmektedir. Bunun için tespit edilen nesnenin sınırlayıcı kutusunu(bounding box) çizerken yeni bir algoritma oluşturulmuştur. UAP ve UAI alanlarının sınırlayıcı kutusunun alt tarafına, alan üzerinde her hangi bir nesne yoksa “uygundur” yazısı, her hangi bir nesne varsa “uygun değildir” yazısı yazılmaktadır.

Genel olarak ÖTR’de bahsedilen “Makine Öğrenimi Yaşam Döngüsü[1]” ve Şekil 5’de bulunan “Proje Çözümü İçin Takip Edilecek Aşamalar” şemasına uygun bir şekilde ilerleyiş gerçekleştirilmiştir.



3. Algoritmalar ve Sistem Mimarisi

Derin öğrenme algoritmaları üç başlık altında incelenebilir. Bunlar sınıflandırma, nesne tespiti ve segmentasyon modelleri olarak düşünülebilir. Bu çalışma süresince nesne tespit modellerinden yararlanılacaktır. Nesne tespitinin amacı, modele bir görüntü sunulduğunda tespit edilmek istenen nesneye ait sınıf bilgisinin ve bölgesel olarak konumunun etrafına çerçeve çizerek tahminde bulunmasıdır [2]. Çalışmada kullanılan algoritma ve yazılım mimarileri ayrıntılı olarak ele alınmıştır.

3.1 Veri Setleri

Derin öğrenme modellerinde veri boyutu büyük bir etkidir. Veri ne kadar çok olursa model o kadar iyi performans sergilemektedir. Bu sebepten dolayı veri setinin büyütülmesi gerçekleştirilmiştir.

- Yarışma kapsamında yarışmacılara verilen video üzerinden kod ile görüntü karelerine (frame) ayrılmıştır. Toplamda kullanılabilecek 8.000 adet görüntü elde edilmiştir.
- Teknofest 2021 ulaşım yapay zeka yarışması final aşamasında modelin test edilmesi için dağıtılan görüntüler kayıt edilmiştir. 14.700 adet görüntü etiketlenip bu yarışma kapsamında eğitim veri setine dahil edilecektir.
- Teknofest 2020 ulaşım yapay zeka yarışmasında verilen etiketli veriler JSON formatından modele uygun hale getirilmiştir. 4.000 adet görüntü bu yarışma kapsamında eğitim veri setine dahil edilecektir.
- Takıma ait drone ile görüntüler toplanıp eğitim veri setine eklenmesi planlanmaktadır.
- İnternet üzerinden veriler bulunmuştur örneğin VisDrone[3] data seti. VisDrone veri setinde bulunan görüntü etiketleri format olarak modele uygun değildir ve bu formata uyması için algoritma geliştirilmiştir. Ayrıca VisDrone veri setindeki sınıf etiketlerinin içerisinde kamyon, motorbisiklet vb. motorlu taşıtların ayrı ayrı olması yarışmaya uymadığından dolayı hepsinin motorlu taşıt olarak değiştirilmek için bir algoritma geliştirilmiştir ve 40.000 adet düzenlenmiş veri eğitime hazır hale getirilmiştir.

Oluşturulan veri setindeki sınıf sayıları tablo 1’de gösterilmektedir.

Tablo 1: Veri Setindeki Sınıfların Boyutu

Sınıf	Veri	Boyut	Toplam
Araç	Train	312.740	390.925
	Test	78.185	
Yaya	Train	134.783	168.479
	Test	33.696	
UAP	Train	2.597	3.246
	Test	649	
UAI	Eğitim	2.695	3.369
	Test	674	


Veri setinde az olduğu düşünülen UAP ve AUI görüntüleri artırılmıştır. Bu artırma işlemi “4. Özgünlük” başlığı altında detaylı bir şekilde anlatılmıştır. Tüm veriler eğitmek için tablo 2’de gösterildiği oranda “eğitim” ve “test” verisi olmak üzere ikiye ayrılmıştır. Bu ayrılan veriler ile eğitim başlatılmıştır ve eğitim çıktıları “5. Sonuçlar ve İnceleme” başlığı altında detaylı bir şekilde anlatılmıştır.

Tablo 2: Eğitime Sokulacak “Eğitim” ve “Test” Veri Setlerinin Oranları

Veri	Boyut (%)
Eğitim	24.476 (%80)
Test	6.118 (%20)


3.2 Algoritmalar

Problem çözümünde YOLOv4 algoritması kullanılmıştır. YOLOv4 algoritmasının tercih edilme nedenlerinden en önemlisi Şekil 3’de gösterildiği gibi performansı türevlerine göre oldukça yüksek olmasıdır.




Şekil 3: YOLOv4 ve Türev Modellerinin Karşılaştırılması [4]

Yolo (You Look Only Once) son zamanlarda ortaya çıkmış, nesne tespitinde kullanılan bir algoritma olup gerçek zamanlı görüntü işleme için kullanılan bir nesne algılama(object detection) algoritmasıdır ve genel yapısı Şekil 5’de gösterilmiştir. Yolo Algoritması diğer algoritmalarla oranla hızlı tahmin yapabilmektedir. Bu işlemi ise Yolo, resme bir ESA (Evrişimsel Sinir Ağları , Convolutional Neural Network) uygulayıp, resmi ızgaralara böler, sınırlayıcı kutular ve ilgili güven puanının tahminini her ızgara için hesaplar, sınırlayıcı kutular tahmin edilen güven puanı ile hesaplayarak yapmaktadır [4]. Şekil 4’de Yolo algoritmasının kurallarının, bir görüntüdeki nesnelerin algılanmasını nasıl sınırlandığını göstermektedir. Bu sınırlar, tespit edilen nesneler arasındaki dikdörtgenler ile gösterilir[5].



Şekil 4: Yolo Algoritmasının Izgara Hücresinde Çalışma Prensipleri

Yolo algoritması görüntüleri yaklaşık 40-90 FPS (Frames per second, saniye başına kare)'de işleyebilir. Bundan dolayı diğer yöntemlere göre oldukça hızlıdır. Bu bir videonun gerçek zamanlı olarak birkaç milisaniye gecikme ile Yolo Algoritması tarafından işlenebileceğini gösterir[4]. Diğer bir nesne tespiti yöntemi olan R-CNN ile karşılaştırıldığında Yolo, R-CNN'den 1000 kat daha, Faster R-CNN ile karşılaştırıldığında ise 100 daha hızlı olduğunu söylenmektedir[4].



Şekil 5: YOLOv4 Yapısı [7]

4. Özgünlük

UAP ve UAI alan verilerinin az olduğu tespit edilmiştir ve bunların çoğaltılması için bu alanların olmadığı görüntülere montaj yöntemleri ile UAP ve UAI alan eklemeleri yapılmıştır. Şekil 6'da örnek montajlı görüntüler gösterilmektedir.



Şekil 6: Örnek Montajlı Görüntüler

Ayrıca oluşturulan veri seti görüntü işleme teknikleri ile blur ekleme, gürültü ekleme gibi deformasyonlara uğratarak modelin zor şartlarda bile daha iyi performans sergilenmesi sağlanmıştır. Bununla beraber yatay da aynalama (flip) işlemi uygulanmıştır.

Derin öğrenme de verinin çok büyük bir etken olduğu bilindiğinden olabildiğince veri toplanmaya çalışılmıştır. Bu sebepten dolayı farklı veri setleri elde edilerek çalışmada kullanılmıştır. Bu veri setlerinden biri olan VisDrone [3], veri setinde bulunan görüntü etiketleri format olarak YOLO'ya uygun değildir ve bu formata uyması için algoritma geliştirilmiştir. Ayrıca VisDrone veri setindeki sınıf etiketlerinin içerisinde kamyon, motorbisiklet v.b motorlu taşıtların ayrı ayrı olması yarışmaya uymadığından dolayı hepsinin motorlu taşıt olarak değiştirilmek için bir algoritma geliştirilmiştir.

Toplanan verilerde insan verisinin az olması ve VisDrone veri setinde insan verilerinin mesafe olarak uzaktan seçilmesi modeli olumsuz yönde etkilemektedir. Bu yüzden şahsi drone ile toplu alanlarda (Cuma camii çıkışı, şehir merkezi v.b) insan görüntüleri toplanmıştır.

Geçen sene yarışma oturumlarında yarışmacılara verilen verileri kayıt edip, yarışmada kullandığımız model ile test ettik. Test kısmında oluşturulan sınırlayıcı kutuların koordinatlarını ve sınıflarını YOLO formatına uygun olarak .txt formatında kayıt ettik. Bu kayıt edilen etiketleri düzenleyerek (etiketlenmeyen görüntüler etiketlendi) yeni bir veri seti olarak eklenmiştir.

Yarışma kapsamında verilen verilerin görüntü boyutları yüksek olmaktadır. Eğitim sırasında kullanılan modellerin giriş boyutu küçük olduğundan verileri model içerisine eklediğinde piksel kaybı yaşanmaktadır. Bu sorunu ortadan kaldırmak için model öncesi görüntülerin şekil 7'deki gibi kırılması ve modele uygun hale getirilmesi planlanmaktadır.

Bu sayede model başarımının artırılması hedeflenmektedir.



Şekil 7: Oluşturulan Algoritma Yapısı

Geliştirilen modelin test aşamasında başarımlarını arttırmak ve görüntüdeki küçük objelerin tespit edilmesi için geliştirilen sahi[6] algoritmasından yararlanılacaktır. Şekil 8'görüldüğü gibi aradaki başarımların farkı önemli oranda değişmektedir.

Sahi + YOLO



YOLO



Şekil 8: Sahi Algoritma Yapısı

5. Sonuçlar ve İnceleme

Yarışma kapsamında YOLOv4, YOLOv4-Tiny ve YOLOv4-P5 algoritmaları kullanılmıştır ve en iyi sonuç YOLOv4-P5 modelinden elde edilmiştir. Bu modelde girdi olarak 896x896 çözünürlüğünde görseller kullanılmıştır. Eğitim 16.000 eğitim tur (epoch) sayısında tamamlanmıştır. Eğitim neticesinde çıkan tüm doğruluk (accuracy), doğrulama doğruluğu(validation accuracy), kayıp(loss) ve doğrulama kaybı(validation loss) sonuçları tablo 3'de gösterilmektedir.

Tablo 3: Eğitim Sonuçları

Model	Doğruluk	Doğrulama Doğruluğu	Kayıp	Doğrulama Kaybı
YOLOv4-P5	0.9624	0.9689	0.7856	0.7256

Değerlendirme kriterleri olarak, karışıklık matrisi(confusion matrix), duyarlılık(recall), hassasiyet(precision), f-1 puanı (f-1 score) ve kesişim bölgeleri(IoU) kullanılmıştır.

Karışıklık matrisi, gerçek değerlerin bilindiği bir dizi test verisi üzerinde, modelin tahminleri ile karşılaştırıldıktan sonra modelin performansını değerlendirmek için kullanılan bir tablodur.

TP (True Positive) : Gerçek değer 1 olduğu gibi tahmin değer de 1 olduğu durumlardır.

TF (True False) : Gerçek değer 0 olduğu gibi tahmin değer de 0 olmadığı durumlardır.

Doğruluk, sınıfların ortalama hassasiyet(AP) değerlerinin aritmetik ortalaması(mAP) alınarak bulunmaktadır. Denklem 1'de formüller gösterilmektedir.

$$AP = \left(\frac{1}{n} \right) \sum_{Recall_i} Precision(Recall_i) = 1$$

$$mAp = \frac{1}{|classes|} \sum_{c \in classes} \frac{\#TP(c)}{\#TP(c) + \#FP(c)}$$

(1)

Duyarlılık, isabet oranı olarak bilinmektedir ve yüksek olması beklenmektedir. Sınıflayıcının ne kadar TP ya da TN değeri doğru tahmin ettiğinin bir ölçüsüdür. Denklem 2'de duyarlılığın nasıl hesaplandığı gösterilmiştir.

$$Duyarlılık = \frac{TP}{TP + FN}$$

(2)

Hassasiyet, tüm sınıflardan, doğru ve yanlış olarak ne kadar tahmin edildiğinin bir ölçüsüdür. Duyarlılık gibi hassasiyetin de yüksek olması beklenmektedir. Denklem 3'de hassasiyetin nasıl hesaplandığı gösterilmiştir.


$$Hassasiyet = \frac{TP}{TP + FP}$$

(3)

f-1 puanı, sınıflandırıcının ne kadar iyi performans gösterdiğinin bir ölçüsüdür. Duyarlılık ve hassasiyetin harmonik ortalamasıdır. Denklem 4'de f-1 puanının nasıl hesaplandığı gösterilmiştir.

$$F1 = 2 \times \frac{\text{Hassasiyet} \times \text{Duyarlılık}}{\text{Hassasiyet} + \text{Duyarlılık}} \quad (4)$$

IoU, her bir sınırlayıcı kutu için, tahmin edilen sınırlayıcı kutu ile gerçek sınırlayıcı kutu arasındaki örtüşmeyi ölçmek için kullanılır. Şekil 9'de yapı gösterilmektedir.



Şekil 9: IoU Yapısı

Değerlendirme sonuçları, tablo 4'de modelinin karışıklık matrisi gösterilmektedir. Tablo 5'de ise eğitilen modellerin sınıflandırma raporları gösterilmektedir.


Tablo 4: Karışıklık Matrisi

Modeller	Sınıflar	TP	TF	AP(%)
YOLOv4-Tiny	Arac	91.272	21.800	84
	Yaya	15.530	9.420	50
	UAP	1.756	300	98
	UAİ	2.159	450	96
YOLOv4	Arac	106.360	6.480	98
	Yaya	16.813	8.958	64
	UAP	1.909	35	99
	UAİ	2.386	151	99
YOLOv4-P5	Arac	106.020	1.939	99
	Yaya	12.365	1.465	67
	UAP	1.901	11	99
	UAİ	2.376	9	99

Tablo 5: Eğitilen Modelin Sınıflandırma Raporu


Model	Hassasiyet	Duyarlılık	F1	IoU(%)	mAP(%)
YOLOv4-Tiny	0.93	0.62	0.75	78.95	82.77
YOLOv4	0.89	0.92	0.91	77.42	90.62
YOLOv4-P5	0.97	0.89	0.93	87.83	91.14

Yarışmacılara verilen örnek veri seti içerisinde alınan test görüntüleri eğitilmiş modele sokulmuştur ve çıkan sonuçlar Şekil 10'de gösterilmektedir.



Şekil 10: Modelin Test Sonuçları

Şekil 11'da UAP ve UAİ için oluşturulan algoritmanın çıktıları gösterilmektedir.



Şekil 11: UAP ve UAİ İçin Oluşturulan Algoritmanın Çıktısı

Genel olarak, oluşturulan modelin başarımlı performansı oldukça iyi olduğu görülmektedir. Yarışma süresine kadar sürekli yeni veriler toplanarak modelin daha iyi seviyeye getirilmesi sağlanacaktır.

6. Referans

- [1] "Life cycle of Machine Learning - Javatpoint." <https://www.javatpoint.com/machine-learning-life-cycle> (accessed Apr. 10, 2021).
- [2] M. J. Shafiee, B. Chywl, F. Li, and A. Wong, "Fast YOLO: A Fast You Only Look Once System for Real-time Embedded Object Detection in Video," *J. Comput. Vis. Imaging Syst.*, vol. 3, no. 1, Sep. 2017, Accessed: Jun. 28, 2021. [Online]. Available: <http://arxiv.org/abs/1709.05943>.
- [3] "VisDrone – Vision Meets Drones: A Challenge." <http://aiskyeye.com/> (accessed Jun. 28, 2021).
- [4] S. Shinde, A. Kothari, and V. Gupta, "YOLO based Human Action Recognition and Localization," in *Procedia Computer Science*, Jan. 2018, vol. 133, pp. 831–838, doi: 10.1016/j.procs.2018.07.112.
- [5] Hendry and R. C. Chen, "Automatic License Plate Recognition via sliding-window darknet-YOLO deep learning," *Image Vis. Comput.*, vol. 87, pp. 47–56, Jul. 2019, doi: 10.1016/j.imavis.2019.04.007.
- [6] F. C. Akyon, S. O. Altinuc, and A. Temizel, "Slicing Aided Hyper Inference and Fine-tuning for Small Object Detection," Feb. 2022, doi: 10.48550/arxiv.2202.06934.

