

TEKNOFEST
HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

ULAŞIMDA YAPAY ZEKA YARIŞMASI
KRİTİK TASARIM RAPORU



LUNAI
Artificial Intelligence Solutions

İçindekiler

1. Takım Şeması.....	3
2. Proje Mevcut Durum Değerlendirmesi.....	3
3. Algoritmalar ve Sistem Mimarisi	4
3.1. Veri Setleri.....	4
3.2. Algoritmalar	4
3.2.1. SimOTA	5
3.3. Sistem Mimarisi	6
4. Özgünlük.....	7
4.1. Sample Dataset.....	7
4.2. Imbalanced Dataset	7
4.3. Crop Frames	8
4.4. Test Data Augmentation.....	8
5. Sonuçlar ve İnceleme.....	9
6. Kaynakça	10



1. Takım Şeması

LunAI takımı 5 üyeden oluşmaktadır. Üyelerin hepsi Mühendislik bölümlerinden mezun olmuş, kimi yüksek lisans mezunudur. Takım üyeleri geçmiş yıllarda TEKNOFEST'in çeşitli yarışmalarından birincilik ve ikincilik almışlardır. Takım içerisindeki bütün üyeler verilen görevler üzerine beraber çalışmaktadır fakat belirli görevler yetkinliklere göre dağıtılmıştır, dağıtımlar aşağıda mevcuttur;

Ayberk İmir (Takım Kaptanı): Ekip koordinasyonu ve yönetiminin yapılması, Ekibin genel görev dağılımlarının belirlenmesi, model seçimi model tasarımı Kafa(head)Omurga(backbone) İmplementasyonu ve Optimizasyonunun yapılmasından sorumludur.

Berk Karabıllıoğlu (İletişim Sorumlusu): Takımın TEKNOFEST ekibi ile iletişiminden sorumludur. Proje takviminin tasarlanması ve Raporlanması, Proje senaryosu hakkında bilimsel araştırma yapılması, data labeling (veri etiketleme) ve Data Augmentation (veri çoklama) işlemlerinden sorumludur.

Dorukhan Afacan: Model seçimi, Proje senaryosu hakkında bilimsel araştırma yapılması, veri dağılımı (eğitim, test, validasyon) , Kafa(head)-Omurga(backbone) İmplementasyonundan sorumludur.

Askar Bozcan: Ekibin Yazılım Mühendisidir, Algoritma doğruluğu, yazılacak olan API'dan ve Performans optimizasyonundan sorumludur.

Onat Yapıcı: Model seçimi, Kafa(head)-Omurga(backbone) İmplementasyonu, veri dağılımı(train,test,validation), Yazılan API'nın tasarımından ve yazılımından sorumludur.

Ayberk İmir	MCBÜ	Mekatronik Müh.	BSc.
Berk KARABİLLİOĞLU	MCBÜ/AÖF	Mekatronik Müh. - Yönetim Bilişim	BSc.
Dorukhan Afacan	University Of Sheffield	Hesaplamalı Zeka ve Robotik	MSc.
Askar Bozcan	METU KKTC	Bilgisayar Müh.	BSc.
Onat Yapıcı	Koç Üniversitesi	Elektrik Elektronik Müh. Bilgisayar Müh.	BSc. ÇAP

2. Proje Mevcut Durum Değerlendirmesi

- Ön tasarımda kullanılması planlanan MASK-RCNN ve Yolov4 modellerinde değişiklikler yapılmıştır. Bunların başlıca sebepleri birlikte kullanıldığı zaman gösterim hızının istenildiği düzeyden çok daha üstüne çıkması ve elimizdeki donanımda sorun çıkarmasıdır.
- Uygulanması düşünülen ensemble methodu iki farklı mimarinin sonuçlarını ensemble etmek yerine tek farklı mimari kullanılarak verilecek olan frame üzerinde transformasyonlar uygulanarak farklı sonuçlar elde edilip bu sonuçların ensemble şeklinde alacak biçimde değiştirilmiştir.
- Veri setlerinde yarışma şartlarına uygun olmayan kareler çıkarılmış veya düzeltilmiştir.
- Patch-level Augmentation[5] sample dataset üzerinde istenilen sonuçları vermemiş olup tüm deneyler bittikten sonra daha büyük bir data üzerinde tekrardan denenip sonuçlarına göre pipeline'dan çıkarılıp çıkarılmamasına karar verilecektir.
- Pipeline'da ki ön işleme aşamasına ekstra olarak karelerin kırılması eklenmiştir. Bunun APsmall üzerindeki etkisi olumlu gözlenmiştir.

- Training aşaması karelerin kırılmış halleriyle gerçekleşmiş olduğundan dolayı inference aşamasında frameleer croplanarak predict alınacak ve bu predictler aynı obje için birden fazla bounding box içerebileceği için post process aşamasına NMS eklenmiştir.

3. Algoritmalar ve Sistem Mimarisi

3.1. Veri Setleri

- TEKNOFEST Ulaşımında Yapay Zeka Veri Seti (2019-2021-2022): T3 Vakfının yayınladığı 2019-2020-2021 ve 2022 yarışmalarının veri setleri 2022 Ağustos ayında yapılacak olan TEKNOFEST 2022 Kuralları, amacı ve şartnamesine uygun olarak düzenlenmiştir.
- VISDRONE (aiskyeye): Her yıl Aiskyeye tarafından düzenlenen Visdrone yarışmasının 3 ana kategorisi vardır;

1-Object Detection(Nesne tespiti)

2-Multi-Object Detection(Çoklu nesne tespiti)

3-Crowd Counting(kalabalık sayımı)

- Stanford Drone Dataset: Stanford üniversitesinin açık kaynak olarak vermiş bulunduğu veri setidir


Teknofest tarafından sağlanan datasetlerde istenilen derecede insan objesi olmadığı için dataset arayışımızdaki en önemli etken datasetin insan objesi içerip içermemesiydi.

Modelin eksik olduğu insan tahminleri eklenen VISDRONE ve Stanford Drone Datasetleri ile önemli ölçüde iyileştirilmiştir.

3.2. Algoritmalar

Kullanılacak model Yolov4 modelinden YOLOX modeline geçilmiştir.YOLOX, geleneksel YOLO'nun çapa içermeyen bir versiyonu olan ve ayrıştırılmış kafa ve SimOTA'yı tanıtan bir nesne algılama modelidir. Bu model, CVPR2021 Otomatik Sürüş Atölyesinde Streaming Perception Challenge'da birincilik ödülüne layık görüldü.

Mevcut YOLOv4 ve YOLOv5 pipelineleri, çapaların kullanımı için aşırı optimize edildiğinden, YOLOX, temel olarak YOLOv3-SPP ile geliştirilmiştir. YOLOv3-SPP, gelişmiş bir CSPNet omurgasını ve ek bir PAN kafasını benimseyen gelişmiş YOLOv5 mimarisini kullanacak şekilde güncellenmiştir. Nesne algılama modellerinde, çakışmalara neden olduğu ve doğruluğu azalttığı bilinen sınıflandırma ve regresyon (sınırlayıcı kutu konumlarının hesaplanması) görevleri aynı anda gerçekleştirilir. Bu sorunu çözmek için, ayrıştırılmış kafa kavramı tanıtıldı. Geleneksel YOLO serisi omurga ve özellik piramitleri hala klasik bir ayrıştırılmamış kafa kullanır, ancak YOLOX ayrıştırılmış bir kafa kullanacak ve daha yüksek doğruluk elde edecek şekilde güncellendi. YOLOX ayrıca, kaybı optimize etmek için OTA'nın değiştirilmiş bir versiyonu olan gelişmiş etiket ataması SimOTA'yı kullanır.[1] Şekil 1-de ayrıştırılmış ve ayrıştırılmamış kafa arasındaki farklar gösterilmiştir.




Şekil 1

3.2.1. SimOTA

Etiket ataması, her ground truth için pozitif/negatif eğitim örneklerini tanımlar. YOLOX, atama stratejileri arasında en gelişmiş performansı elde etmek için atama prosedürünü bir Optimal Transport(OT) problemi olarak formüle eder.

OT probleminde, her ground truth, belirli sayıda etiket sağlayan bir tedarikçidir ve her çapa, bir birim etikete ihtiyaç duyan bir talepçidir. Bir çapa belirli bir ground truth'dan yeterli miktarda pozitif etiket alırsa, bu çapa o ground truth için bir pozitif çapa olur.[1]

Yeni özelliklerin Yolov3 baselinesına COCO validation setindeki etkileri Şekil-3 üzerinde hesaplanmıştır.




Şekil 2

Methods	AP (%)	Parameters	GFLOPs	Latency	FPS
YOLOv3-ultralytics ²	44.3	63.00 M	157.3	10.5 ms	95.2
YOLOv3 baseline	38.5	63.00 M	157.3	10.5 ms	95.2
+decoupled head	39.6 (+1.1)	63.86 M	186.0	11.6 ms	86.2
+strong augmentation	42.0 (+2.4)	63.86 M	186.0	11.6 ms	86.2
+anchor-free	42.9 (+0.9)	63.72 M	185.3	11.1 ms	90.1
+multi positives	45.0 (+2.1)	63.72 M	185.3	11.1 ms	90.1
+SimOTA	47.3 (+2.3)	63.72 M	185.3	11.1 ms	90.1
+NMS free (optional)	46.5 (-0.8)	67.27 M	205.1	13.5 ms	74.1

Şekil 3

3.3. Sistem Mimarisi



- Eğitim için verilen video python scripti sayesinde framelere ayrılmıştır.
- Frameler Labellmg API yardımıyla etiketlenmiştir.
- Kaydedilen bu framerler üzerinde kırpma işlemi gerçekleştirilip modelin küçük objeleri daha doğru bir şekilde tahmin etmesi planlanmıştır.
- Google Drive bulut sistemine yollamadan önce yapılması planlanan ön işleme işlemleri gerçekleşmiştir.
- Google Drive bulut sistemi üzerinde toplanan kareler OpenMMDetection API'na göre hazırlanmıştır.[11]
- Modelin config dosyası(learning rate scheduler, optimizer, bbox_head, neck, augmentations, log, evaluation configleri) hazırlanmıştır.
- Modelin checkpoint dosyaları hem en eski hem de eğitim sırasında mAP.5 metriği kullanılarak yapılan değerlendirmeler sonucu en yüksek performans gösteren checkpointler tutulmuştur. Bunun nedeni eğitim sırasında oluşan bottleneck'leri mümkün olduğunca çabuk düzelterek eğitime devam etmektir.
- Eğitim sırasında WANDB üzerinden performans takibi yapılmaktadır.[10]
- Inference aşamasında ise alınan frame tekrardan kırpma işleminden geçirilip kırılan kareler üzerindeki tahminleri Test Data Augmentationdan geçirilerek alınan sonuçlar Veya metodu ile birleştirilecek ve toplanan sonuçlar orijinal frame büyüklüğüne scale edilecektir.

- Inference aşaması 386-464 ms arasında değişmektedir.

4. Özgünlük

4.1. Sample Dataset

Deneylerin daha hızlı tamamlanabilmesi için oluşturduğumuz datasetin istatistiksel özelliklerine en uygun subsample seçimi.

4.2. Imbalanced Dataset

Dataset içerisinde yer alan bazı classlar diğer classlardan sayıca çok üstünler bu durumu Focal Loss bir yere kadar çözebiliyor fakat bunu daha iyi hale getirebilmek adına aşağıda görselde örneği gösterilen şekile benzer şekilde preprocess işlemleri gerçekleştirilmektedir.



Şekil 4

HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALI


4.3. Crop Frames

Frameleri sol üst, sol alt, sağ üst, sağ alt şekilde 4 kesite ayırarak küçük sayılabilecek objeleri daha iyi tespit edilmesi sağlanacaktır. Aşağıdaki görselde örnek olarak gösterilmiştir.



4.4. Test Data Augmentation

Test Data Augmentation farklı augmentation teknikleriyle çoğaltılarak prediction almamızı ve var olan frame üzerinde daha genel, doğru sonuç çıkarmamıza yarayan bir tekniktir. Aşağıdaki görselde örnek olarak test data augmentationın aşamalarından bahsedilmektedir. Daha açıklayıcı olduğu için yarışma datasetinden ziyade bu görselin seçilmesi daha uygun bulunmuştur.[4]



Şekil 5

5. Sonular ve İnceleme

Test datalarında yapılan karşılařtırmalar sonucu kırpma kullanılmadan yapılan tahminlerde FPlerin(False Positive) ok sayıda olduėu, bunları bahsedilen kırpma yntemi kullanılarak dřrlebildiėi gzlemlenmiřtir. řekil-5 ve řekil-6 zerinde fark aıka grlmektedir.

n tasarım raporunda bahsedilen MASK-RCNN ve YOLOv4 ensemble'nda donanımsal bir hata ile karşılařıldı bu hata image sizerarı dřrerek ařması denendi fakat karşılařılan mAP dřř bu methodun iře yaramaz olduėunun gstergesiydi o yzden pipelinedan ıkarıldı.

Vazgeilen ensemble metodu yerine kullanacaėımız Test Data Augmentation yani gsterim sırasında frame zerinde yapılacak olan transformların predictlerini seilecek ensemble metodunun Veya metodu olmasına karar kılınmıřtır. Veya metodu False Positiveleri arttırmasına raėmen yarıřmada kullanılacak olan mAP.5 metriėi zerindeki olumlu etkisi yznden seilmiřtir. [4]

řuanki gsterim hızımız yeterince hızlı olduėu iin deneylere devam edip modelimize olumlu etkisi olduėu gzlemlenen algoritmalar pipeline ierisine eklenecektir.



řekil 6



řekil 7

6. Kaynakça

- [1] Zheng Ge, Songtao Liu, Feng Wang, Zeming Li, Jian Sun (2021) , YOLOX: Exceeding YOLO Series in 2021 arXiv
- [2] <https://github.com/WongKinYiu/CrossStagePartialNetworks>
- [3] LunAI TEKNOFEST 2021 Ulaşımında Yapay Zeka ÖTR & KTR
- [4] Angela Casado-Garc Jonathan Heras Ensemble Methods for Object Detection (2020)
- [5] Sungeun Hong* SK T-Brain Sungil Kang* SK T-Brain Donghyeon Cho SK TBrain Patch-level Augmentation for Object Detection in Aerial Images ICCVW_2019
- [6] Ren, S., He, K., Girshick, R., & Sun, J. (2017). Faster R-CNN: towards real-time object detection with region proposal networks. IEEE Transactions on Pattern Analysis & Machine Intelligence, 6, 1137-1149.
- [7] <https://github.com/albumentations-team/albumentations>
- [8] Chen, X., Xiang, S., Liu, C. L., & Pan, C. H. (2014). Vehicle detection in satellite images by hybrid deep convolutional neural networks. IEEE Geoscience and Remote Sensing Letters
- [9] K. He, G. Gkioxari, P. Dollár , R. Girshick, "Mask R-CNN", ", in Proc. IEEE Conference on Computer Vision and Pattern Recognition, 2014, p. 2380-750
- [10] <https://docs.wandb.ai/>
- [11] <https://github.com/open-mmlab/mmdetection>

