

TEKNOFEST

**HAVACILIK, UZAY VE TEKNOLOJİ
FESTİVALİ**

**ULAŞIMDA YAPAY ZEKA YARIŞMASI
KRİTİK TASARIM RAPORU**

Ai Lab - Horizon

372425

Takım Üyeleri: Fatih ACIROĞLU, Alperen ADALAR, Kadir ÖZTÜRK, Eray
DEVELİOĞLU, Hilal KARTAL

Danışman: Dr. Öğr. Üyesi Sait Ali UYMAZ

İÇİNDEKİLER

İÇİNDEKİLER	2
ŞEKİL LİSTESİ.....	3
TABLO LİSTESİ.....	3
KISALTMALAR	4
1. TAKİM ŞEMASI	5
2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ	6
3. ALGORİTMALAR VE SİSTEM MİMARİSİ.....	6
3.1. Veri Setleri	6
3.2. Algoritmalar	7
3.2.1. TPH-YOLOv5.....	7
3.2.2. YOLOR.....	8
3.2.3. Weighted Boxes Fusion	8
4. ÖZGÜNLÜK	9
5. SONUÇLAR VE İNCELEME.....	10
6. KAYNAKÇA.....	12



ŞEKİL LİSTESİ

<u>Şekil 3.1</u>	<u>Veri setimizden örnekler.....</u>	<u>7</u>
<u>Şekil 3.2</u>	<u>YOLOR algoritmasının bilgiyi nasıl kullandığını gösteren şema.....</u>	<u>7</u>
<u>Şekil 4.1</u>	<u>Örnek simülasyon görüntüsü.....</u>	<u>9</u>
<u>Şekil 5.1</u>	<u>WBF ve Ensemble algoritmalarının üst üste binme sorununa getirdiği çözüm.....</u>	<u>10</u>
<u>Şekil 5.2</u>	<u>Çoklu model kullanımının nesne tespiti başarımı üzerindeki etkisi.....</u>	<u>10</u>

TABLO LİSTESİ

<u>Tablo 1.1</u>	<u>Takım üyeleri ve görev dağılımları.....</u>	<u>6</u>
<u>Tablo 3.1</u>	<u>VisDrone 2021 Challenge başarı sıralaması.....</u>	<u>7</u>



KISALTMALAR

FPS	Frames Per Second
RAGE	Rockstar Advanced Game Engine
SSI	Single System Image
TPH	Transformer Prediction Head
WBF	Weighted Boxes Fusion
NMS	Non-maximum Suppression
NMW	Non-maximum Weighted
Soft-NMS	Soft Non-maximum Suppression
YOLOR	You Only Learn One Representation
YOLO	You Only Look Once



1. TAKIM ŞEMASI

Ai Lab – Horizon takımı Konya Teknik Üniversitesi Bilgisayar Mühendisliği ve Yazılım Mühendisliği bölümü öğrencilerinden ve bir danışmandan oluşmaktadır. Takım üyelerimizin görev dağılımları aşağıdaki gibidir.

Danışman	Konya Teknik Üniversite Bilgisayar Mühendisliği bölümünde Dr. Öğr. Üyesi olarak görev yapmaktadır. Takım üyelerine yapay zekâ ve görüntü işleme konularında yardımcı olmaktadır.
Takım Kaptanı	Algoritma optimizasyonu ve WBF algoritması ile ilgili çalışmaları yürütüp sistemimizi çoklu model kullanımına daha uygun hale getirmeye yönelik yazılım geliştirmektedir. Ensemble gibi çoklu model kullanımı esnasında oluşan sorunları azaltan algoritmaları da sistemimize uyarlamaktadır.
Takım Üyesi 1	Kullanacağımız algoritmaların model eğitimi ve optimizasyonlarını yaparak sistemimize entegre etme görevini üstlenmiştir. Aynı zamanda görüntü işleme algoritmalarının parametrelerini ve mimarilerini düzenleyerek tespit doğruluğunu arttırmaya yönelik çalışmalar yapmaktadır.
Takım Üyesi 2	Veri seti optimizasyon ve veri artırımı yazılımı geliştirme ve algoritmamıza entegre etme hakkında çalışmaktadır. Aynı zamanda linux tabanlı işletim sistemlerinde model eğitimi için birden çok bilgisayarın eşzamanlı ve paralel bağlantılı olarak çalışabilmesi için SSI Cluster sistemleri oluşturmaktadır.
Takım Üyesi 3	Veri seti toplama, düzenleme, kontrol ve etiketleme görevlerini üstlenmiştir. Aynı zamanda eğitim optimizasyonu için etiket sınıflarını düzenlemektedir.
Takım Üyesi 4	Veri seti özgünlüğü için simülasyon ortamında ve aynı zamanda gerçek ortamda yarışma şartlarına uygun görüntü çekimi ve düzenlemesi görevini üstlenmiştir.

Tablo 1.1 Takım üyeleri ve görev dağılımları

2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ

Ön tasarım raporunda bahsettiğimiz algoritmalarla gerekli eğitim ve testleri gerçekleştirdikten ve bize uygun parametreleri belirledikten sonra algoritmalar arasında gerçekleştirdiğimiz aynı veri setini ve aynı test videolarını kullanarak yaptığımız denemeler sonucunda kullanmaya karar verdiğimiz ana algoritma gerek yüksek başarımlı oranı gerekse kaynakları verimli kullanması sebebiyle TPH-YOLOv5 oldu. YOLOR da geleneksel YOLO modellerine göre daha yüksek doğruluk değerine ulaştığı için onu da destek algoritması olarak kullanma kararı aldık.

İki modeli eşzamanlı olarak çalıştırmak için kullanacağımız fusion algoritmasıyla ilgili araştırmalar yaparken bulduğumuz ve yaptığımız testler sonucunda çok daha kesin sonuçlar verdiğini ama geleneksel fusion algoritmalarına kıyasla daha hantal olduğunu fark ettiğimiz WBF algoritmasını sistemimizi hedeflediğimiz fps değerinin altına düşürmediği için kullanma kararı aldık.

Sisli, karlı veya kapalı havaların olduğu çekimlerde kullanmayı düşündüğümüz dehaze filtresini tespit doğruluğunu iyileştirmediğini gördüğümüz için kullanmaktan vazgeçtik. Bunun yerine frameleri fazla değiştirmeyecek gibi hafif parametreler girdiğimiz bir histogram equalization algoritması kullanmayı deniyoruz.


Yaptığımız testlerde fark ettiğimiz üzere Stanford veri seti içerdiği kalitesiz görüntüler nedeniyle özellikle insanları tespit etmemizi zorlaştırdığından bu veri setini kullanmaktan vazgeçtik.

3. ALGORİTMALAR VE SİSTEM MİMARİSİ

3.1. Veri Setleri

Kullandığımız nesne tespit algoritmalarından biri olan YOLOR algoritmasının yapısı gereği aynı nesneleri farklı ortam ve şartlarda görerek eğitilmesi algoritmanın kararlılığını oldukça arttırdığı için halihazırda yeterince iyi olan veri setimizi olabildiğince zenginleştirme kararı aldık. Hem kendi droneumuz ile çektiğimiz görüntüleri hem de pexels gibi üçüncü parti kaynaklardan bulduğumuz görüntüleri kullanarak 30 farklı videodan elde ettiğimiz 30.000'den fazla frame içeren ve etiket ağırlık dağılımı çok dengeli olan bir veri seti oluşturduk. Oluşturduğumuz veri setinin tamamı 4K çözünürlükte görüntülerden oluştuğu için doğruluğu artırmak adına eğitimde de 4K çözünürlüğe çıktık.

Ön tasarım raporumuzda belirttiğimiz ve false-positive durumların önüne geçmek için kullandığımız görüntülerin çok faydasını gördüğümüz için daha fazla veri bulma ve kullanma kararı aldık.



Şekil 3.1 Veri setimizden örnekler

3.2. Algoritmalar

3.2.1. TPH-YOLOv5

Ana tespit algoritmamız olan TPH-YOLOv5 [1] algoritmasının en can alıcı özelliği adında da geçen TPH algoritmasının özellikle drone görüntüleri için geliştirilmiş özgün bir sürümünü kullanarak nesne bazlı ve dinamik olarak değişen bir kafa yapısı ile çalışıyor olması. Bu sayede geleneksel YOLO modellerindeki drone irtifası artınca doğruluğun düşmesi ve küçük nesnelerin eğitimi ve tespiti sırasında gereksiz kaynak kullanımı gibi dezavantajları ortadan kaldırmayı amaçlayan TPH-YOLOv5 ile diğer modellere kıyasla çok daha verimli sonuçlar elde edebiliyoruz [1].

TPH-YOLOv5 içerisinde temel düzeyde veri çoğaltma algoritmaları barındırmakta. Bu sayede eğitim sırasında veri setimizi alıp bu temel algoritmaları kullanarak daha büyük bir veri seti oluşturuyor ve bu sayede daha iyi bir model elde etmiş oluyoruz.


Method	AP[%]	AP50[%]	AP75[%]	AR1[%]	AR10[%]	AR100[%]	AR500[%]
DBNet(A.1)	39.43	65.34	41.07	0.29	2.03	12.13	55.36
SOLOer (A.2)	39.42	63.91	40.87	1.75	10.94	44.69	55.91
Swin-T(A.3)	39.40	63.91	40.87	1.76	10.96	44.65	56,83
TPH-YOLOv5(A.4)	39.18	62.83	41.34	2.61	13.63	45.62	56.88
VistrongerDet(A.5)	38.77	64.28	40.24	0.77	8.10	43.23	55.12
cascade++(A.6)	38.72	62.92	41.05	1.04	6.69	43.36	43.36
DNEFS(A.7)	38.53	62.86	40.19	1.42	9.38	43.10	54.87
EfficientDet(A.8)	38.51	63.25	39.54	1.82	11.12	43.89	55.12
DPNet-ensemble	37.37	62.05	39.10	0.85	7.96	42.03	53.78
DroneEye2020	34.57	58.21	35.74	0.28	1.92	6.93	52.37
Cascade R-CNN	16.09	31.91	15.01	0.28	2.79	21.37	28.43

Tablo 3.1 VisDrone 2021 Challenge başarı sıralaması [1]

VisDrone 2021 veri setinde diğer mimariler ile TPH-YOLOv5'in karşılaştırmasına baktığımız zaman performans faktörünü hesaba katınca en iyi sonucu verdiğini görebilirsiniz.

3.2.2. YOLOR

YOLOR [2], YOLO mimarisinin tespit algoritmasına sınıflara ve nesnelere nitelik ekleyen derin öğrenme katmanları eklenerek geliştirilen bir nesne tespit algoritmasıdır. Bu özelliği sayesinde özellikle farklı sınıflardaki nesneleri farklı katmanlarda algılayarak karışık görüntüler içerisinde bu nesneleri tespit ederken çok daha başarılı sonuçlar elde etmektedir. YOLOR, “örtülü bilgiyi ve açık bilgiyi birlikte kodlamak için birleşik bir ağ” olarak geliştirilmiştir. Açık bilgi somut verilerle elde edilebilen, sözlü veya yazılı biçimde aktarılabilen bilgiye denir. Örtük bilgi ise daha çok tecrübelerle elde edilen ve somut bir biçimde aktarılamayan ya da tarif edilemeyen bilgidir. YOLOR, içerisindeki derin öğrenme katmanları sayesinde veri seti eğitimi sırasında aldığı veriler ile önce açık bilgiyi öğrenir, sonrasında ise daha alt katmanlarda örtük bilgi denilen nesne detaylarını öğrenir. Bu sayede sadece eğitimde verilen görüntülerle değil de bir nevi bilinçaltı oluşturarak kendi tecrübeleriyle de nesneleri tespit edebilmektedir [3].




Şekil 3.2 YOLOR algoritmasının bilgiyi nasıl kullandığını gösteren şema [4]

3.2.3. Weighted Boxes Fusion

Nesne tespit algoritmalarında özellikle birden fazla model kullanırken tespitlerin karışmaması veya üst üste binmemesi için filtreleme algoritmaları kullanılması gerekir. NMS, NMW ve Soft-NMS gibi alternatiflerine kıyasla daha yavaş çalışmasına rağmen yine bu alternatiflerinden farklı olarak kullanmayacağı sınırlayıcı kutuları tamamen göz ardı etmek yerine bulunan nesnelerin tamamının güven değerlerini kullanıp daha kapsamlı bir analiz çıkararak çok daha doğru sonuçlar verdiği için bu algoritmayı kullanmayı tercih ettik [5].

WBF, birleştirilen tüm modellerin yanlış tahminler yaptığı durumlarda bile güven skorlarını kullanarak doğru veya doğruya daha yakın sonuçlar üretebilmektedir. Bu sayede modellerimizin yetersiz kaldığı durumlarda bile doğruya yakın çıktılar alabilmekteyiz [6].




Şekil 3.2 WBF ve NMS algoritmalarının çalışma mantıklarının kıyaslanması [6]

4. ÖZGÜNLÜK

Eğitim verimini ve model başarımını artırdığını gözlemlediğimiz için veri setini etiketlerken teknik şartnamede olmayan sınıflar da kullandık, mesela taşıtların tamamına taşıt demek yerine her bir taşıt cinsini ayrı ayrı sınıflandırdık. Bu sayede model çok daha kesin sonuçlar vermeye başladı. En son çıktıyı alırken sınıfları teknik şartnameye uygun şekilde birleştirip tekrar kategorize eden bir algoritmayla sonuç olarak sistemin çıktısını yarışmaya uygun hale getirdik.

Örnek videoyu eğitimde kullanma kararı aldık fakat görüntüler veri setimize kıyasla daha az kaliteli olduğundan özellikle UAP ve UAI alanlarını içeren frameler başta olmak üzere bazı kısımlarda interpolasyon yaparak görüntü kalitesini artırdık.

UAP ve UAİ verilerinin eksikliği nedeniyle RAGE oyun motoru kullanarak gerçekçi sahneler simule ettik ve içerisine gerçek boyutlarına göre ölçeklediğimiz UAP ve UAİ alanları yerleştirdik. Bu sayede çok daha fazla UAP ve UAİ verisi üretmiş olduk.



Şekil 4.1 Örnek simülasyon görüntüsü


WBF algoritmasına ek olarak kendi kontrol algoritmamızı oluşturduk. Bu algoritma ile Fusion algoritmasından aldığımız verileri yaptığımız testlerden elde ettiğimiz sonuçlara göre hazırladığımız parametrelerden geçirerek özellikle yanlış tespit edilen ve alanı olması gerekenden çok büyük ya da küçük olan nesneleri filtrelemeyi amaçladık.

5. SONUÇLAR VE İNCELEME

Kullandığımız algoritmaları test ederken hem Teknofest örnek videolarını hem de kendi veri setimizden ayırdığımız test videolarını kullandık. Nesne tespit algoritmalarının parametrelerini optimize ederken farklı sahneler kullanmaya özen gösterdik, bu sayede her koşulda optimize çalışan bir model oluşturmuş olduk. Farklı algoritmaları kıyaslarken ise aynı görüntüleri kullandık, bu sayede algoritmaların farklarını ve birbirinden üstün olduğu durumları belirlemiş olduk.

TPH-YOLOv5 ile YOLOR algoritmalarının parametrelerini örnek videoda en iyi sonucu aldığımız şekilde ayarladık. İki modeli filtreleyerek birleştirmek için kullandığımız WBF ve Ensemble algoritmalarının parametrelerini ise güven skorlarına ve sınıf sınıf ayarladığımız model öncelik skorlarına göre ayarladık. Mesela insanlarda YOLOR modelinin önceliği daha yüksekken taşıtlarda ise TPH-YOLOv5 modelinin skorunu daha yüksek

belirledik çünkü iki modelin bu sınıflarda birbirine üstünlüğünü en iyi bu şekilde kullanılabiliyordu.



Şekil 5.1 WBF ve Ensemble algoritmalarının üst üste binme sorununa getirdiği çözüm



Şekil 5.2 Çoklu model kullanımının nesne tespiti başarımını üzerindeki etkisi

6. KAYNAKÇA

- [1] <https://github.com/cv516Buaa/tph-yolov5>
- [2] <https://github.com/WongKinYiu/yolor>
- [3] <https://medium.com/@yasarniyazz/yolor-nedir-ve-nas%C4%B1l-e%C4%9Ftilir-ba37a0381e01>
- [4] <https://paperswithcode.com/paper/you-only-learn-one-representation-unified>
- [5] <https://github.com/ZFTurbo/Weighted-Boxes-Fusion>
- [6] <https://medium.com/inspiredbrilliance/object-detection-through-ensemble-of-models-fed015bc1ee0>
- [7] <https://medium.com/analytics-vidhya/weighted-boxes-fusion-86fad2c6be16>

