

**TEKNOFEST**  
**HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ**

**ULAŞIMDA YAPAY ZEKA YARIŞMASI**  
**KRİTİK TASARIM RAPORU**

**ZeroAlpha**  
**366429**

**İSTANBUL 2022**

## İÇİNDEKİLER


|                                             |    |
|---------------------------------------------|----|
| İÇİNDEKİLER .....                           | 2  |
| ŞEKİL LİSTESİ .....                         | 3  |
| 1. TAKIM ŞEMASI .....                       | 4  |
| 2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ ..... | 4  |
| 3. ALGORİTMALAR VE SİSTEM MİMARİSİ.....     | 4  |
| 3.1. Veri Setleri.....                      | 4  |
| 3.2. Algoritmalar .....                     | 5  |
| 3.2.1. Faster R-CNN.....                    | 5  |
| 3.2.2. Detectron2.....                      | 5  |
| 3.2.3. YOLOv5.....                          | 5  |
| 3.2.4. Akış Şeması .....                    | 6  |
| 4. ÖZGÜNLÜK.....                            | 7  |
| 5. SONUÇLAR VE İNCELEME .....               | 8  |
| 6. KAYNAKÇA .....                           | 11 |

## ŞEKİL LİSTESİ

|                                                   |    |
|---------------------------------------------------|----|
| Şekil 1.1 Takım Şeması.....                       | 4  |
| Şekil 3.1 Eğitim Akış Şeması.....                 | 6  |
| Şekil 3.2 Yarışma Akış Şeması .....               | 7  |
| Şekil 5.1 mAP 0.5 ve mAP 0.5:0.99 Metrikleri..... | 9  |
| Şekil 5.2 Score Metriği.....                      | 9  |
| Şekil 5.3 Eğitim Sonuçları.....                   | 10 |
| Şekil 5.4 Tespit Sonuçları - 1.....               | 10 |
| Şekil 5.5 Tespit Sonuçları - 2.....               | 11 |
| Şekil 5.6 Tespit Sonuçları - 3.....               | 11 |

## 1. TAKIM ŞEMASI

Bu bölümde takım organizasyon şeması, takım ve takım üyeleri hakkında tanıtıcı bilgiler verilmiştir. ZeroAlpha takımına ait takım şeması Şekil 1.1'deki gibidir.



Şekil 1.1 Takım Şeması

ZeroAlpha takımı, 2017 yılında kurulmuş, kurulduğu yıldan itibaren çeşitli alanlarda faaliyet göstermiş ve göstermeye devam eden bir teknoloji takımıdır. Ekip üç kişiden oluşmaktadır. Takım lideri Yasin Baykal, BUÜ Elektrik-Elektronik Mühendisliği (EEM) lisans mezunudur ve şu anda İTÜ Savunma Teknolojileri yüksek lisans öğrencisidir. Emre Tavukçu ve Tunahan Kaya, BUÜ EEM lisans son sınıf öğrencileridir. Takım geçmiş yıllarda farklı yarışmalara katılmış üyelerden oluşmaktadır. Takım üyesinin azlığından dolayı takım içerisinde herhangi bir birim oluşturulmamıştır. Tüm üyeler yarışmanın her aşamasına belli oranda katılım göstermektedir.

## 2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ

Ön tasarım raporu (ÖTR) sonrası genel sistem mimarisinde bir değişiklik yapılmamıştır. Yarışmada kullanılacak nesne tespit algoritması ve veri arttırma teknikleri (data augmentation) nihai olarak belli olmadığı için, ÖTR sonrası ilk iş olarak algoritma ve veri arttırma teknikleri belirlenmiştir.

Algoritma seçiminin ilk aşamasında ÖTR'de ve Bölüm 3.2'de bahsedilen algoritmalar yarışmada kullanılacak takım bilgisayarına kurulmuş ve değişik yapılandırmalarla (örneğin farklı görüntü çözünürlükleri ile) bu bilgisayar üzerindeki görüntü işleme hızları karşılaştırılmıştır. Bu testler sonucunda YOLOv5 algoritmasının l6 modelinin 1280 çözünürlük ile yarışmadaki süre gereksinimlerini karşılayarak en yüksek doğruluk oranına ulaştığı görülmüştür. Bu nedenle nihai algoritma ve model olarak YOLOv5l6 1280 seçilmiştir.

Çalışmaların sonraki aşamalarında farklı veri arttırma teknikleri ile Bölüm 3'te verilen veri setleri kullanılarak eğitimler yapılmıştır ve yapılmaya devam etmektedir. Bu eğitimler Google Colab üzerinde Nvidia P100 ekran kartları kullanılarak yapılmaktadır. Çünkü takım bilgisayarları görüntü işleme tarafında oldukça yavaş kalmaktadır. Şu aşamada yapılan eğitimlerde takım açısından yarışmaya yönelik oldukça güzel ve daha iyisi için umut vadeden sonuçlar elde edilmektedir.

Bölüm 5'te burada anlatılan testlerin önemli görülen sonuçlarına ve grafiklerine yer verilmiştir.

## 3. ALGORİTMALAR VE SİSTEM MİMARİSİ

Bu bölümde yarışmada dahilindeki makine öğrenmesi probleminin çözümünde kullanılan sistemin genel şeması, makine öğrenmesi algoritmaları ve bu algoritmaları eğitiminde faydalanan veri setleri hakkında bilgiler verilmiştir.

### 3.1. Veri Setleri

Yapılan kaynak araştırmaları ve literatür taramalarında yarışmada tespit edilecek nesneleri içeren ve yarışmadaki resimlerle benzer arka plana sahip olan dört adet veri seti bulunmuştur. Bu veri setleri kendi içerisinde etiketli bir yapıda eğitim yapmaya hazırdır ve bu özelliklerinin yarışmaya hazırlık sürecini hızlandırması beklenmektedir. Eğitim esnasında bu veri setlerinin haricinde Teknofest 2019 Yapay Zeka yarışmasında paylaşılan veri setleri de kullanılmıştır.

[1], insanların kalabalık sokaklardaki yürüme şekillerini öğrenmek ve bu sayede insanları takip etme veya insanların hareket yörüngesini tahmin etme problemlerini makine öğrenmesi ile iyileştirmeyi amaçlayan bir çalışmadır. [13] ise bu çalışmada kullanılmış veri setidir ve içerisinde yaya, otobüs, araba sınıfları da dahil altı sınıf bulunan resimler bulunmaktadır. [14], kentsel ortamda yapılan drone uçuşlarının ve iniş prosedürlerinin güvenliğini arttırmaya yönelik makine öğrenmesi çalışmalarında kullanılan bir veri setidir. [2], farklı coğrafyadaki farklı kentsel yerleşim görünümelerini makine öğrenmesi ile etiketlemeyi amaçlayan bir çalışmadır. [15], bu çalışmada kullanılan veri setidir ve içerisinde kentsel bölgelerin havadan çekilmiş fotoğrafları bulunmaktadır. [16], içerisinde farklı kara, hava, deniz araçları ile farklı bina ve yapı türleri içeren onlarca sınıflandırma alanı bulunan geniş bir veri setidir. CycloMedia ve Google Earth çevrimiçi sitelerle birlikte GF-2 ve JL-1 isimli uydulardan alınmış görüntüler içermektedir. [3],[4] ve [5] bu veri seti ile yapılmış çalışmalardır.

Yukarıda bahsedilen kaynaklar ve Teknofest 2019 Yapay Zeka veri seti birleştirildiğinde toplamda yaklaşık 200 GB sıkıştırılmış veri içeren bir eğitim seti oluşmaktadır. Bu veri setleri, veri artırma teknikleri ile de çoğaltılmıştır. Bu konuda daha detay bilgi özgünlük kısmında verilmiştir. Toplanan bu görüntülerin yarışmadaki problemin çözümünde yeterli olacağı düşünülmektedir.

### **3.2. Algoritmalar**

Bu bölümde ÖTR aşamasında araştırılan ve yarışmada kullanılması planlanan makine öğrenmesi algoritmalarından bahsedilmiştir. Yapılan araştırmalar sonucunda dört farklı algoritma üzerinde karar kılınmıştır. Bunlar Faster R-CNN, Detectron2 ve YOLOv5 algoritmalarıdır. Faster R-CNN ve Detectron2 yüksek doğruluk, YOLOv5 algoritması ise yüksek çalışma hızı ile ön plana çıkmaktadır. ÖTR sonrası yapılan eğitimlerde YOLOv5 algoritmasının FPS/Doğruluk açısından yarışmaya en uygun algoritma olduğu sonucuna ulaşılmıştır.

#### **3.2.1. Faster R-CNN**

Faster R-CNN[6] ve [17], iki katmandan oluşan bir nesne tespit algoritmasıdır. İlk katmanı nesnelerin olabileceği bölgeleri bulan bir evrişimli ağdan oluşmaktadır. İkinci katman ise üst katmandan gelen bölgeler içindeki nesneleri tespit eden Fast R-CNN [7] detektörüdür. R-CNN [8] algoritmaları yüksek doğruluğu amaçlamaktadır. Yüksek doğruluğa ulaşmak ise görüntü işleme hızını düşürmektedir fakat bu bakımdan Faster R-CNN önceki versiyonlarına göre ; R-CNN'den 200 kat, Fast R-CNN'den 10 kat daha hızlıdır. Bu iyileştirmeler ile Faster R-CNN seleflerine göre gerçek zamanlı nesne tespitinde kullanılabilecek bir hıza ulaşmıştır[12].

#### **3.2.2. Detectron2**


Detectron2 [20], Facebook AI Research tarafından geliştirilen ve içerisinde son teknoloji tespit ve segmentasyon algoritmaları bulunduran bir makine öğrenmesi kütüphanesidir. Yine Facebook AI Research tarafından geliştirilmiş Detectron [21] ve Mask R-CNN Benchmark [22] kütüphanelerinin tek çatı altında toplanmış yeni nesil versiyonudur. Çokça bilgisayarla görü araştırma projesini ve üretim uygulamasını desteklemektedir.

#### **3.2.3. YOLOv5**

YOLOv5 [19] algoritması, YOLOv4 [9] 'ün PyTorch ortamına aktarılmış halidir. YOLOv4 ise YOLO ailesinin en son versiyonudur [18]. Backbone olarak CSPDarknet53 [9], [11] kullanmaktadır. Bu sayede yüksek görüntü işleme hızlarında yüksek doğruluk değerlerine ulaşabilmektedir. Birçok araştırma ve çalışma YOLO ailesinin resim içerisindeki küçük nesneleri tespit etmede başarısız olduğunu ortaya koymaktadır fakat bu problemlerin üstesinden gelebilmek için yeni öznetelik çıkarıcıları eklenmektedir. Bunların en önemlilerinden biri SPP(Spatial Pyramid Pooling) [10] katmanıdır. YOLOv4 içerisinde bu SPP katmanı hazır olarak bulunmaktadır. Ayrıca [23] adresindeki Tensorflow Great Barrier Reef isimli Kaggle yarışması incelendiğinde YOLOv4'ün küçük nesnelerin tespitinde yüksek doğruluklara ulaşabildiği görülmektedir. Bu çıkarımın nedeni yarışmada derece yapan ilk üç takımın [24], [25] ve [26] YOLOv5 kullanmasıdır.


### 3.2.4. Akış Şeması

Eğitim sırasında kullanılan sistemin akış şeması Şekil 3.1'deki gibidir.



Şekil 3.1 Eğitim Akış Şeması

Şekil 3.2’de ise sistemin yarışma esnasındaki akış şeması verilmiştir.



Şekil 3.2 Yarışma Akış Şeması

#### 4. ÖZGÜNLÜK

Takımın özgünlüğe katkısı çoğunlukla; Bölüm 3’te bahsedilen algoritmalara sunulan verilerin ön işlemlerden geçirilmesi ve bu algoritmaların parametrelerinin ayarlanması şeklinde olacaktır. Çünkü yarışmadaki diğer takımların benzer algoritmalar kullanacağı düşünüldüğünde geriye sadece veri setlerinin iyileştirilmesi ve algoritmaların en iyi performansı verecek şekilde ayarlanması kalmaktadır. Hazır veri setlerinde Uçan Araba Park (UAP) ve Uçan Ambulans İniş (UAI) alanları bulunmadığı için bunların veri setlerine dahil edilmesi gerekmektedir. Bu işlem de takım tarafında uygun resimlere uygun açılarla UAP ve UAI alanlarının eklenmesiyle yapılacaktır.

Eğitim sırasında ve yarışmada kullanılacak ön işlemler değişiklik gösterecektir. Eğitim sırasında [29]’daki kütüphane içerisinde bulunan veri artırma tekniklerden faydalanılmaktadır. Kullanılan teknikler aşağıda sıralı bir şekilde verilmiş ve kısaca açıklanmıştır:

**HueSaturationValue:** Giriş görüntüsünün, rastgele olarak renk tonunu (Hue), renk doygunluğunu (Saturation) ve ışık değerini (Value) değiştirmektedir.

**GaussianBlur:** Giriş görüntüsüne rastgele bir Gauss filtresi uygulamaktadır.

**GaussNoise:** Giriş görüntüsüne rastgele olarak Gauss gürültüsü uygulamaktadır.

**RandomBrightnessContrast:** Giriş görüntüsünün, rastgele olarak parlaklığını (Brightness) ve kontrastını değiştirmektedir.

**CLAHE:** Giriş görüntüsüne sınırlı uyarlanabilir histogram eşitleme (Limited Adaptive Histogram Equalization) uygulamaktadır.

Yukarıdaki veri arttırma teknikleri dışında YOLOv5 [19] içinde hazır bir şekilde bulunan veri arttırma teknikleri de vardır. Bunlar arasında eğitim sırasında kullanılanlar şöyledir:

**hsv\_h:** Görüntünün renk tonu üzerinde değişiklik yapar.

**hsv\_s:** Görüntünün renk doygunluğu üzerinde değişiklik yapar.

**hsv\_v:** Görüntünün renk ışık değeri üzerinde değişiklik yapar.

**degrees:** Görüntünün açısını değiştirir.

**translate:** Görüntünün piksellerini kaydırır.

**scale:** Görüntüyü yeniden boyutlandırır.

**flipud:** Görüntüyü yukarı-aşağı yönde çevirir.


**fliplr:** Görüntüyü sağ-sol yönde çevirir.

**mosaic:** Görüntü parçalara ayırıp bu parçaları tekrar rastgele bir şekilde birleştirir.


Yarışmaya yönelik paylaşılan örnek videoda nesnelerin, özellikler insanların, yüzde olarak oldukça az yer kapladığı görülmektedir. Bu sorunu çözmek için [24]'tekine benzer bir çözüm stratejisi izlenecektir. Buradaki çözümde nesnelerin olduğu bölgeler resimlerden kesilerek alınmış ve ayrı birer resim olarak eğitime dahil edilmiştir. Bu sayede eğitilen modelin resim üzerinde yüzde olarak az yer kaplayan nesneleri daha iyi tanıması sağlanmıştır.

## 5. SONUÇLAR VE İNCELEME

Bölüm 2'de bahsedilen FPS testleri sonucunda, yarışma süresini verimli bir şekilde kullanarak takım bilgisayarında çalıştırılacak YOLOv5 modelleri ve yapılandırmaları sınırlıdır. Nihai modele ve yapılandırmasına karar verebilmek için bu seçenekler kısa süreli eğitimlere sokulmuştur. Eğitimler sırasında da Bölüm 2'de verilen veri setlerinden seçilmiş küçük parçalar kullanılmıştır. Bu eğitimlerin sonucunda Şekil 5.1 ve Şekil 5.2'deki grafikler elde edilmiştir. Şekil 5.1'de mavi yatay sütunlar "mAP 0.5" metriğinin ve turuncu olanlar "mAP 0.5:0.95" metriğinin değerini göstermektedir. Şekil 5.2'deki mavi yatay sütunlar ise  $(0.1 * \text{mAP } 0.5 + 0.9 * \text{mAP } 0.5:0.95)$  şeklinde hesaplanan "score" metriğinin değerlerini göstermektedir. Grafiklerin sol tarafında ise ilgili satırdaki sonucun hangi modele ve yapılandırmaya ait olduğu görülmektedir. Örneğin birinci satırdaki "5l6, 1536, True", o satırdaki sonuçların YOLOv5l6 modeli ile 1536 \* 1536 çözünürlükte ve veri arttırma ile yapılan (True yazması veri arttırma kullanıldığını göstermektedir. False yazanlarda veri arttırma yoktur.) eğitime ait olduğunu göstermektedir. İki grafikten de açıkça görüldüğü üzere YOLOv5l6 modeli ile 1280\*1280 çözünürlük ve veri arttırma kullanılarak yapılan eğitimlerin elde ettiği doğruluk değerleri daha yüksektir. Bu nedenle yarışmada bu model ve yapılandırma kullanılacaktır.




**Şekil 5.1 mAP 0.5 ve mAP 0.5:0.99 Metrikleri**




**Şekil 5.2 Score Metriği**

Nihai model ve yapılandırmaya (model) karar verildikten sonra, bu model üzerinde farklı veri artırma tekniklerinin parametreleri değiştirilerek çeşitli eğitimler yapılmıştır. Şekil 5.3'te bu eğitimlerin sonuçları gösterilmiştir. Yatay eksen epoch sayısını göstermektedir. Grafikte de görüldüğü üzere sonuçlar birbiriyle ne kadar benzer olsa da açık mavi (ya da grafikte en çok örneğe sahip çizgi) ile gösterilen yapılandırma daha kararlı ve doğru sonuç vermektedir. Bu neden şu anki eğitimler bu yapılandırma ile devam etmektedir. Şekil 5.4, 5.5 ve 5.6'da eğitilmiş modelin farklı görüntüler üzerinde yapmış olduğu tespitler verilmiştir.

Eğitim aşamasında karşılaşılan en büyük sorun tüm veri setleri içerisindeki “insan” sınıfındaki nesne sayısının yetersiz oluşu ve bir görüntü içerisinde insanların kapladığı alanların çok küçük oluşuydu. Bu sorunun çözümüne yönelik içerisinde çokça insan olan farklı veri seti arayışları ve insan nesnesi özelinde farklı veri artırma yöntemleri deneme şeklinde devam etmektedir.



**Şekil 5.3 Eğitim Sonuçları**



**Şekil 5.4 Tespit Sonuçları - 1**



**Şekil 5.5 Tespit Sonuçları - 2**



**Şekil 5.6 Tespit Sonuçları - 3**

## 6. KAYNAKÇA

[1] A. Robicquet, A. Sadeghian, A. Alahi, S. Savarese, “Learning Social Etiquette: Human Trajectory Prediction In Crowded Scenes” , European Conference on Computer Vision (ECCV), 2016.

[2] Emmanuel Maggiori, Yuliya Tarabalka, Guillaume Charpiat and Pierre Alliez. “Can Semantic Labeling Methods Generalize to Any City? The Inria Aerial Image Labeling Benchmark”. IEEE International Geoscience and Remote Sensing Symposium (IGARSS). 2017.

- [3] Ding, Jian and Xue, Nan and Xia, Gui-Song and Bai, Xiang and Yang, Wen and Yang, Michael and Belongie, Serge and Luo, Jiebo and Datcu, Mihai and Pelillo, Marcello and Zhang, Liangpei, "Object Detection in Aerial Images: A Large-Scale Benchmark and Challenges", IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021
- [4] Xia, Gui-Song and Bai, Xiang and Ding, Jian and Zhu, Zhen and Belongie, Serge and Luo, Jiebo and Datcu, Mihai and Pelillo, Marcello and Zhang, Liangpei, "DOTA: A Large-Scale Dataset for Object Detection in Aerial Images", The IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2018
- [5] Jian Ding, Nan Xue, Yang Long, Gui-Song Xia, Qikai Lu, "Learning RoI Transformer for Detecting Oriented Objects in Aerial Images", The IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2019
- [6] Shaoqing Ren, Kaiming He, Ross Girshick, Jian Sun, "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks", 2015
- [7] Ross Girshick, "Fast R-CNN", 2015
- [8] Ross Girshick, Jeff Donahue, Trevor Darrell, Jitendra Malik, "Rich feature hierarchies for accurate object detection and semantic segmentation", 2013
- [9] Alexey Bochkovskiy, Chien-Yao Wang, Hong-Yuan Mark Liao, "YOLOv4: Optimal Speed and Accuracy of Object Detection", 2020
- [10] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun, "Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition", 2015
- [11] <https://it-qa.com/what-is-cspdarknet-53/> (Eriřim 15 Haziran 2022)
- [12] <https://towardsdatascience.com/r-cnn-fast-r-cnn-faster-r-cnn-yolo-object-detectionalgorithms-36d53571365e> (Eriřim 15 Haziran 2022)
- [13] [https://cvgl.stanford.edu/projects/uav\\_data/](https://cvgl.stanford.edu/projects/uav_data/) (Eriřim 15 Haziran 2022)
- [14] <http://dronedataset.icg.tugraz.at/> (Eriřim 15 Haziran 2022)
- [15] <https://project.inria.fr/aerialimagelabeling/> (Eriřim 15 Haziran 2022)
- [16] <https://captain-whu.github.io/DOTA/dataset.html> (Eriřim 15 Haziran 2022)
- [17] <https://github.com/rbgirshick/py-faster-rcnn> (Eriřim 15 Haziran 2022)
- [18] <https://docs.ultralytics.com/> (Eriřim 15 Haziran 2022)
- [19] <https://github.com/ultralytics/yolov5> (Eriřim 15 Haziran 2022)
- [20] <https://github.com/facebookresearch/detectron2> (Eriřim 15 Haziran 2022)
- [21] <https://github.com/facebookresearch/Detectron/> (Eriřim 15 Haziran 2022)
- [22] <https://github.com/facebookresearch/maskrcnn-benchmark/> (Eriřim 15 Haziran 2022)
- [23] <https://www.kaggle.com/competitions/tensorflow-great-barrier-reef> (Eriřim 15 Haziran 2022)
- [24] <https://www.kaggle.com/c/tensorflow-great-barrier-reef/discussion/307878> (Eriřim 15 Haziran 2022)
- [25] <https://www.kaggle.com/c/tensorflow-great-barrier-reef/discussion/307760> (Eriřim 15 Haziran 2022)
- [26] <https://www.kaggle.com/c/tensorflow-great-barrier-reef/discussion/307707> (Eriřim 15 Haziran 2022)
- [27] <https://chowdera.com/2021/07/20210724150724572z.html> (Eriřim 15 Haziran 2022)
- [28] <https://ashutoshmakone.medium.com/faster-rcnn-502e4a2e1ec6> (Eriřim 15 Haziran 2022)
- [29] <https://github.com/albumentations-team/albumentations> (Eriřim 15 Haziran 2022)