

TEKNOFEST

**HAVACILIK, UZAY VE TEKNOLOJİ
FESTİVALİ**

**ULAŞIMDA YAPAY ZEKA YARIŞMASI
KRİTİK TASARIM RAPORU**

TAKIM ADI: DEEP TEACHING

BAŞVURU ID: 355274

İÇİNDEKİLER

İÇİNDEKİLER.....	2
ŞEKİL LİSTESİ	3
1. TAKİM ŞEMASI (5 PUAN)	4
2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ (15 PUAN).....	5
3. ALGORİTMALAR VE SİSTEM MİMARİSİ (25 PUAN)	6
3.1. Veri Setleri (10 Puan)	6
3.2. Algoritmalar (15 Puan)	7
4. ÖZGÜNLÜK (25 PUAN)	10
5. SONUÇLAR VE İNCELEME (25 PUAN)	11



ŞEKİL LİSTESİ

Şekil 1 - Takım görev dağılımını gösteren şema.....	4
Şekil 2 - İstenilen senaryolara uymayan veriler. [4] (VisDrone Veri Seti).....	6
Şekil 3 - Pix2Seq Tarafından Tespit Edilen Nesneler	9

TABLO LİSTESİ

Tablo 1 - DETR ve Deformable DETR	5
Tablo 2 - Ön İnceleme Karşılaştırma Tablosu	7
Tablo 3 - Ön İnceleme Sonucunda Elde Edilen Modellerin Performansı	7
Tablo 4 - DETR ve Deformable DETR Karşılaştırılması	8
Tablo 5 - Pix2Seq, DETR ve Faster R-CNN Karşılaştırılması.....	9
Tablo 6 – Yarışma Simülasyonu Sonuçları	11


KISALTMALAR

DETR: Detection with TRansformers


CNN: Convolutional neural network

SAHI: Slicing Aided Hyper Inference

AP: Average Precision



1. TAKIM ŞEMASI (5 PUAN)



Takım Kaptanı: Yıldız Teknik Üniversitesi'nde 2.sınıf Bilgisayar Mühendisliği Lisans öğrencisidir. Derin öğrenme ve evrişimli sinir ağları üzerinde çalışmaktadır. Takımımızdaki görevi ise; model seçimi, model eğitimi ve modelin değerlendirilmesidir. Bir diğer görevi ise; modele sağlanacak olan verinin önileme sürecini oluşturmaktır.

Takım Üyesi 1: Kocaeli Üniversitesi'nde Bilişim Sistemleri Mühendisliği 3.Sınıf öğrencisidir. Sistemlerin analizi ve tasarımı üzerine çalışmalar yapmıştır. Takımımızdaki görevi ise; kullanacağımız veri setinin kalitesini artırmak için çeşitli teknikler uygulayacaktır.

Takım Üyesi 2: Yıldız Teknik Üniversitesi'nde Bilgisayar Mühendisliği Yüksek Lisans öğrencisidir. Lisans eğitimi sırasında derin öğrenme ve bilgisayarlı görü alanlarında çalışmalar yapmıştır. Takımımızdaki görevi ise; model seçimi, model eğitimi ve modelin değerlendirilmesidir.

Ayrıca takımımızın tüm üyeleri yapacağı her işlem sırasında yenilikçi teknolojiler kullanmayı hedeflemektedir. Yaratıcılık ve farklı fikirler sayesinde takım ruhunun en üst seviyede olmasını hedeflemekteyiz.

2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ (15 PUAN)

Ön tasarım raporunda hazırlamış olduğumuz proje takvimi kusursuz bir şekilde işlemektedir. T3 Vakfı tarafından verilen örnek eğitim videosunun etiketlenmesi tamamlanmıştır. Ayrıca verilerin ön incelemesi tamamlanmış ve farklı senaryolar için çeşitli önışleme algoritmaları denenmiştir.

Bu deneylerin sonucunda çeşitli senaryoların gerektirdiği farklı önışleme teknikleri nedeniyle yeni bir ön işleme katmanı önerilmiştir. Bu katman öncelikle görüntünün senaryosunu sınıflandıracak daha sonra ise o senaryoya ait ön işleme tekniğini uygulayacaktır. Bu katman henüz projeye eklenmemiştir. Bu katmanın hesaplama maliyeti hesaplanmamıştır. Ayrıca çalışmaların ön işleme algoritmalarından çok Transformers mimarisi yönünde olması gerektiği düşünülmüştür. İlerleyen günlerde ekibimizin bir üyesi daha çok bu katmanın eklenmesi üzerine çalışacaktır.

Tranformers mimarisinin en önemli yapı taşı olan **Attention [1]** katmanlarının sınırları bu mimarinin daha iyi sonuçlar elde etmesini engellemekte idi. Araştırmalarımız sonucunda DETR [2] makalesine oranla 10 kata kadar daha az epochs ile eğitim gerçekleştirebilen bir mimari olan Deformable DETR [3] mimarisini kullanmaya karar verilmiştir. Bu mimarinin model eğitimlerine başlanmadan önce keşfedilmesi ekibimiz için çok kritik bir düzeyde önemli olmuştur.

Ancak ekip merakımıza yenik düşüp DETR ve Deformable DETR arasındaki farkı deneyimlemeye karar verdik. Tablo 1’ de iki mimariye ait kendi veri setimiz üzerindeki eğitim sonuçları gösterilmektedir.

Tablo 1 - DETR ve Deformable DETR

Kullanılan Mimari	Epochs	AP	Eğitim Süresi	FPS
DETR-DC5	10	33.4	60 Saat	5
Deformable DETR	10	41.4	30 Saat	8

Not. Tüm eğitimler Colab Pro üzerinde Tesla T4 16 GB ekran kartı ile MMDetection kütüphanesiyle gerçekleştirilmiştir. Eğitimler eşzamanlı bir şekilde iki farklı Colab Pro hesabı üzerinden gerçekleştirilmiştir. Pre-Trained model olarak FundamentalVision tarafından paylaşılan Deformable DETR (single scale) kullanılmıştır.

3. ALGORİTMALAR VE SİSTEM MİMARİSİ (25 PUAN)

3.1. Veri Setleri (10 Puan)

Daha önceden ön tasarım raporunda belirttiğimiz veri setlerinin saf versiyonlarıyla çeşitli modeller eğitilmiştir. Eğitim sırasındaki analizlerimize göre, kullanmış olduğumuz mimari için veri setinin hazırlığı ve ön işleme algoritmalarını bu veri setleri üzerinde uygulamanın uzun zaman aldığı görülmüştür.



Şekil 2 - İstenilen senaryolara uymayan veriler. [4] (VisDrone Veri Seti)

Bu sonuçlara göre veri seti seçiminde birkaç önemli karar alınması gerekmiştir. Öncelikle birden fazla veri setinin farklı modeller ile eğitimi çok uzun zaman aldığı bilinmektedir. Kullandığımız mimarinin eğitim süresince gerektirdiği hesaplama masrafını ve eğitim süresini azaltmak için yapılan çalışmalar algoritmalar kısmında detaylandırılmıştır. Veri setinin ön incelemesi yapılırken istenmeyen senaryolara sahip veriler ve yarışma standartlarına uymayan görüntülerin veri setinden çıkarılmıştır. Bu ön incelemenin sonuçlara etkisi Tablo 2’de verilmiştir. Ön inceleme 5 gün boyunca 2 takım üyesi tarafından gerçekleştirilmiştir.

Ön inceleme sonucunda elde edilen modellerin performansı, daha önceden etiketlemesi bitirilen T3 Vakfı tarafından paylaşılan örnek videonun üzerinde bir yarışma simülasyonu oluşturularak ölçülmüştür. Bu sonuçlara Tablo 3’te yer verilmiştir.

Yapılan çalışmalar sonucunda VisDrone [4] veri setinin model eğitimleri için temel veri seti olarak seçilmiştir. VisDrone’nin seçilmesinin en önemli sebebi Tablo 3’te aldığımız sonuçlardır. Alınan bu karar tek bir veri seti üzerinde yoğunlaşılması için değil karşılaştırma yapılırken en iyi modeli ve veri setinin birbirini geliştirmesi içindir. Ayrıca birden fazla veri setiyle eğitim gerçekleştirmenin çeşitli sorunları beraberinde getirdiği görülmüştür. Bu sorunlara ve çözümlerine raporun ilerleyen bölümlerinde yer verilmiştir.

Tablo 2 - Ön İnceleme Karşılaştırma Tablosu

Veri Seti	Ön İnceleme	Kullanılan Mimari	Epochs	Box AP
VisDrone	Yok	Deformable DETR	12	44.7
VisDrone	Var	Deformable DETR	12	48.9
Stanford Drone Dataset [5]	Yok	Deformable DETR	12	38.2
Stanford Drone Dataset	Var	Deformable DETR	12	41.3
UAVDT [6]	Yok	Deformable DETR	12	35.5
UAVDT	Var	Deformable DETR	12	39.4

Not. Tüm eğitimler Colab Pro üzerinde Tesla T4 16 GB ekran kartı ile MMDetection kütüphanesiyle gerçekleştirilmiştir. Pre-Trained model olarak FundamentalVision tarafından paylaşılan Deformable DETR (single scale) kullanılmıştır.

Tablo 3 - Ön İnceleme Sonucunda Elde Edilen Modellerin Performansı

Veri Seti	Ön İnceleme	Kullanılan Mimari	FPS	Toplam Puan
VisDrone	Var	Deformable DETR	12	625
Stanford Drone Dataset	Var	Deformable DETR	12	355
UAVDT	Var	Deformable DETR	12	421

Not. T3 Vakfı tarafından sağlanan örnek videodan 221 kare alınmıştır. Bu karelerde toplamda 1871 nesne bulunmaktadır. Tüm tahminlerde Threshold olarak 0.7 seçilmiştir. Tüm tahminler Colab Pro üzerinde Tesla T4 16 GB ekran kartı ile MMDetection kütüphanesiyle gerçekleştirilmiştir. Doğru tahminler için +1, yanlış tahminler için -1 puan yansıtılmıştır.

Tablo 3'te elde edilen sonuçların geliştirilme sürecine ait detaylar raporun ilerleyen bölümlerinde aktarılmıştır.

3.2. Algoritmalar (15 Puan)

Problemin çözümünde kullanılacak algoritmalar açıklanır. Kullanılan algoritmaların hangi sebeplerden dolayı seçildiği anlatılır. Algoritmalar üzerindeki farklılıklardan bahsedilmelidir.

Projede en çok deneyimlediğimiz mimari Transformers mimarisidir. Bu mimarinin ilk kez Facebook tarafından yayınlanan DETR makalesinde Nesne Tespiti problemi için kullanılması araştırmacılar için yeni bir ufuk doğurmuştur. Bu modelinde diğer modellerde olduğu gibi çeşitli avantaj ve dezavantajları bulunmaktadır. Bu model COCO 2017[7] veri setinde yaklaşık olarak 500 epochs için 2000 GPU saatine [3] ihtiyaç duyması çok önemli bir dezavantajdır.

Model eğitimlerimize başlamadan önce eğitim süresi boyunca kiralamamız gereken donanım için hesap yaptığımız sırada eğitim süresini 10 kata kadar düşürebilen yenilikçi bir yaklaşım

sergileyen Deformable DETR makalesi keşfedildi. Ayrıca bu model, temeline dayanan DETR makalesinde çok önemli bir sorun olan küçük boyuta sahip nesneler içinde oldukça iyi performans göstermektedir.

Tablo 4 - DETR ve Deformable DETR Karşılaştırılması

Method	Epochs	AP	AP ₅₀	AP ₇₅	AP _S	AP _M	AP _L	params	FLOPs	Training GPU hours	Inference FPS
Faster R-CNN + FPN	109	42.0	62.1	45.5	26.6	45.4	53.4	42M	180G	380	26
DETR	500	42.0	62.4	44.2	20.5	45.8	61.1	41M	86G	2000	28
DETR-DC5	500	43.3	63.1	45.9	22.5	47.3	61.1	41M	187G	7000	12
DETR-DC5	50	35.3	55.7	36.8	15.2	37.5	53.6	41M	187G	700	12
DETR-DC5 ⁺	50	36.2	57.0	37.4	16.3	39.2	53.9	41M	187G	700	12
Deformable DETR	50	43.8	62.6	47.7	26.4	47.1	58.0	40M	173G	325	19
+ iterative bounding box refinement	50	45.4	64.7	49.0	26.8	48.3	61.7	40M	173G	325	19
++ two-stage Deformable DETR	50	46.2	65.2	50.0	28.8	49.2	61.7	40M	173G	340	19

Not. Tüm eğitimler NVIDIA Tesla V100 GPU ile makale yazarları tarafından gerçekleştirilmiştir. [3]

Sonuç olarak kullanılması planlanan model Two-Stage Deformable DETR'dir. Ancak Transformers mimarisi kullanılarak DETR tabanlı modeller çok hızlı bir şekilde gelişmektedir. Bu gelişim süreci boyunca tek bir modele bağlı kalmak bizler için kabul edilemez bir durumdur. Ekip olarak gelişimini izlediğimiz birden çok Transformers tabanlı Nesne Tespiti algoritması bulunmaktadır. Bunlardan birkaçı aşağıda yer almaktadır.

- Pix2seq: A Language Modeling Framework for Object Detection [8]
- DINO: DETR with Improved DeNoising Anchor Boxes for End-to-End Object Detection [9]
- QueryDet: Cascaded Sparse Query for Accelerating High-Resolution Small Object Detection [10]

Google Brain tarafından 2021 yılında yayınlanan Pix2Seq [8] mimarisi kompleks senaryolara sahip nesne tanıma problemleri için yüksek doğrulukta tahminler sunmaktadır. Bu mimari diğer mimarilere oranla daha çok dikkatimizi çekmektedir. Bu mimariyi özel kılan şey ise geliştirmiş oldukları insan düşüncesine daha çok benzeyen yaklaşımlarıdır. Bu yaklaşım “Eğer bir sinir ağı nesnelerin nerede ve ne olduğunu biliyorsa, ona sadece onları nasıl okuyacağını öğretmemiz gerektiği sezgisidir.”[8].

Tablo 5 - Pix2Seq, DETR ve Faster R-CNN Karşılaştırılması

Method	Backbone	#params	AP	AP ₅₀	AP ₇₅	AP _s	AP _M	AP _L
Faster R-CNN	R50-FPN	42M	40.2	61.0	43.8	24.2	43.5	52.0
Faster R-CNN+	R50-FPN	42M	42.0	62.1	45.5	26.6	45.4	53.4
DETR	R50	41M	42.0	62.4	44.2	20.5	45.8	61.1
Pix2seq	R50	37M	43.0	61.0	45.6	25.1	46.9	59.4
Faster R-CNN	R101-FPN	60M	42.0	62.5	45.9	25.2	45.6	54.6
Faster R-CNN+	R101-FPN	60M	44.0	63.9	47.8	27.2	48.1	56.0
DETR	R101	60M	43.5	63.8	46.4	21.9	48.0	61.8
Pix2seq	R101	56M	44.5	62.8	47.5	26.0	48.2	60.3
Faster R-CNN	R50-DC5	166M	39.0	60.5	42.3	21.4	43.5	52.5
Faster R-CNN+	R50-DC5	166M	41.1	61.4	44.3	22.9	45.9	55.0
DETR	R50-DC5	41M	43.3	63.1	45.9	22.5	47.3	61.1
Pix2seq	R50-DC5	38M	43.2	61.0	46.1	26.6	47.0	58.6
DETR	R101-DC5	60M	44.9	64.7	47.7	23.7	49.5	62.3
Pix2seq	R101-DC5	57M	45.0	63.2	48.6	28.2	48.9	60.4

Not. Tüm eğitimler MS-COCO 2017 veri seti üzerinde makale yazarları tarafından gerçekleştirilmiştir. [8]

Tablo 5’ te de görüldüğü üzere bu mimari şu anda kullanmış olduğumuz DETR mimarisinden bile daha iyi sonuç vermektedir. Ancak Pix2Seq mimarisi nesne tespitlerini serileştirme kullanarak yaptığı için, 1920x1080 çözünürlüğe sahip bir fotoğraftaki nesneleri tespit etmesi NVIDIA Tesla T4 16 GB GPU’da yaklaşık olarak 25 saniye sürmektedir. Oldukça yüksek doğrulukta nesneleri tespit eden bu modeli kullanmamızın en önemli sebebi ise budur. Ancak bu modelin gelişimini çok yakın bir şekilde takip edilmektedir. Çıkarım zamanında gerçekleşecek üst düzey iyileştirme sonucunda ana model olarak seçmeyi planlamaktayız.



Şekil 3 - Pix2Seq Tarafından Tespit Edilen Nesneler

Şekil 3’ te görüldüğü üzere Pix2Seq tüm nesneleri kusursuz bir şekilde 25 saniyede tespit edilmiştir.

4. ÖZGÜNLÜK (25 PUAN)

Ön tasarım raporunda da belirtildiği gibi, veri setleri üzerinde çok önemli bir çalışma yapılmıştır. Bu çalışmada yaklaşık olarak 5 gün boyunca tüm ekip üyeleri ile birlikte diğer veri setlerindeki istenmeyen verilerin temizliği ve senaryolara sınıflandırılması yapılmıştır. Bu sayede sınıf dağılımları ile basit bit hesap yapmak yerine farklı açılardan farklı hava durumlarına ait 15 bin fotoğraf sınıflandırılmıştır. Bu hazırlık sayesinde üzerine yoğunlaştığımız ön işleme teknikleri için en önemli basamağı kolay bir şekilde atmış bulunmaktayız. Ayrıca eğitilen modellerin performansının sadece modelin kalitesine değil eğitilen verinin kalitesine de bağlı olduğu için veri için çeşitli ön işleme katmanları tasarlanmıştır. Ön tasarım raporunda belirtilen katmanlara ek olarak yeni bir katman önerilmiştir. Bu katman, her fotoğrafa aynı ön işleme tekniklerini uygulamanın performansı düşürdüğü yapılan çalışmalarda gözlemlenmiştir. Görüntüleri senaryolarına göre sınıflandırarak çeşitli ön işleme tekniklerini görüntülere uygulayacaktır. Bu katman için ayrıca bir sınıflandırma modelinin eğitilmesi planlamaktadır. Eğitilen modelde hava durumu/ışık/gölge/kamera açısı gibi özellikler sınıflandırılacaktır.

Ancak daha önce belirttiğimiz gibi üzerine en çok çalıştığımız mimari Transformers'dır. Diğer tüm çalışmalarımız bu mimarinin gücünü ortaya çıkarmak için sadece yardımcı bir etkidir. Transformers mimarisinin nesne tespiti alanında yeni bir mimari olması ve mimarinin çeşitli varyantlarının kompleks senaryolarda yüksek doğruluğa sahip olması nedeniyle bu mimari üzerine çalışmalar gerçekleştirmekteyiz. Şu ana kadar kullanmış olduğumuz tüm Transformers mimarisine dayanan modellerdeki en önemli ve kritik sorun hesaplama karmaşıklığı ve eğitim süresidir. Ekibimiz, bu eğitim süresinin azaltılabilmesi için sürekli olarak yenilikçi çalışmalar yapmaktadır. Şu ana kadar yapmış olduğumuz DETR tabanlı mimarilerdeki araştırmaların en önemlisi; eğitim dönemini 10 kata kadar azaltan, “deforme edilebilen evrişimlerden esinlenen” [3] Deformable DETR'dır. Bu makalede önerilen yöntem Transformers mimarisindeki Multi-Head Attention katmanını yerine Şekil 4'te belirtildiği gibi Deformable Attention katmanıdır.

Ekibimiz eğitim süresini ve hesaplama maliyetini azaltmak için çeşitli araştırma ve çalışmalar yapmaya devam edecektir. Yeni bir mimari ile çalışmanın verdiği yenilikçi düşünce ve farklı bakış açıları sayesinde hali hazırda var olan algoritmaları kullanmaktan yerine kendi yaratıcılığımızı konuşturduğumuz özgürlük ile başarıya ulaşacağımıza inanmaktayız.

5. SONUÇLAR VE İNCELEME (25 PUAN)

Ekip olarak yaptığımız çalışmalar sonucunda geliştirdiğimiz modelleri test edebilmek adına kendi yarışma simülasyonumuz oluşturuldu. Bu simülasyon sayesinde herhangi bir modeli değerlendirirken sadece eğitilen veri setindeki performansı değil T3 Vakfı tarafından verilen eğitim videosu örneğindeki performansı izlenebilmektedir.

Tablo 6 – Yarışma Simülasyonu Sonuçları

Veri Seti	Kullanılan Mimari	AP	FPS	Toplam Puan
VisDrone	Deformable DETR	48.9	12	625
VisDrone	Two-Stage Deformable DETR	49.9	12	780
Kendi Veri Setimiz	Deformable DETR	50.1	12	1351
Kendi Veri Setimiz	Two-Stage Deformable DETR	51.5	12	1443

Not. T3 Vakfı tarafından sağlanan örnek videodan 221 kare alınmıştır. Bu karelerde toplamda 1871 nesne bulunmaktadır. Tüm eğitimler Colab Pro üzerinde Tesla T4 16 GB ekran kartı ile MMDetection kütüphanesiyle gerçekleştirilmiştir. Pre-Trained model olarak FundamentalVision tarafından paylaşılan modeller kullanılmıştır. Threshold değeri 0.7 olarak ayarlanmıştır. Kendi veri setimizde diğer tüm veri setlerinden görüntüler alınmıştır.

Tablo 6'daki verilere göre çevrimiçi yarışma simülasyonunda tüm fotoğraflarda tespit edebilmek için yeterli FPS değerine ulaşıldığı görülmektedir. Ancak bu değerlere Colab Pro üzerinde Tesla T4 16 GB ekran kartı ile ulaşılmıştır. Final yarışmasında online platformlara izin verilemediği için hesaplama kapasitesi ve FPS değerlerinin yetersiz kalacağı düşünülmektedir. Bu sorunu çözmek için kullanılacak donanımlarda bir değişiklik söz konusu olacaktır.

Ayrıca sadece T3 Vakfı tarafından sağlanan örnek videolarda değil kendi insansız hava aracımızla çektiğimiz videolarda da eğittiğimiz modelleri test etmekteyiz. Farklı senaryolarda hangi modellerin iyi performans sağladığını gözlemlemekteyiz.

Diğer yandan karşılaştığımız hataları ve çözümlerini detaylı olarak not etmekteyiz. Karşılaştığımız en önemli sorunlardan biri ve çözümü aşağıda verilmiştir.

- Sorun: Eğitim sırasında Ekran Kartı hafızasının yetersiz kalması (Cuda out of Memory)
 - Çözüm: Num of workers ya da batch size parametrelerini düşürmek.

Tüm bu projenin gelişimi boyunca karşılaşılan çoğu hata ekip üyelerinin geçmişteki görüntü işleme alanındaki bilgi ve birikimi sayesinde saniyeler içerisinde çözüme kavuşturulmuştur. Ancak imkanlar dahilinde donanıma bağlı sorunlar devam etmektedir.

Daha da ötesi bu projenin geliştirilmesi, ekip üyelerine çok önemli bir düşünce biçimi olan eleştirel düşünceyi aşılamıştır. Bu düşüncede bir algoritmanın çalışması değil, neden ve nasıl çalıştığı önemlidir. Bu düşüncenin benimsenmesi gelecekteki araştırmacı kimliğimiz için kritik düzeyde öneme sahip olduğunu düşünmekteyiz.

6. KAYNAKÇA

- [1] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, 30.
- [2] Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A., & Zagoruyko, S. (2020, August). End-to-end object detection with transformers. In *European conference on computer vision* (pp. 213-229). Springer, Cham.
- [3] Zhu, X., Su, W., Lu, L., Li, B., Wang, X., & Dai, J. (2020). Deformable detr: Deformable transformers for end-to-end object detection. *arXiv preprint arXiv:2010.04159*.
- [4] Du, D., Zhu, P., Wen, L., Bian, X., Lin, H., Hu, Q., ... & Zhang, L. (2019). VisDrone-DET2019: The vision meets drone object detection in image challenge results. In *Proceedings of the IEEE/CVF international conference on computer vision workshops* (pp. 0-0).
- [5] A. Robicquet, A. Sadeghian, A. Alahi, S. Savarese, Learning Social Etiquette: Human Trajectory Prediction In Crowded Scenes in *European Conference on Computer Vision (ECCV)*, 2016.
- [6] D. Du, Y. Qi, H.g Yu, Y. Yang, K. Duan, G. Li, W.g Zhang, Q. Huang, Q. Tian, " The Unmanned Aerial Vehicle Benchmark: Object Detection and Tracking", *European Conference on Computer Vision (ECCV)*, 2018.
- [7] Lin, T.-Y., Maire, M., Belongie, S., Bourdev, L., Girshick, R., Hays, J., Perona, P., Ramanan, D., Zitnick, C. L. & Dollár, P. (2014). Microsoft COCO: Common Objects in Context (cite arxiv:1405.0312Comment: 1)
- [8] Chen, T., Saxena, S., Li, L., Fleet, D. J., & Hinton, G. (2021). Pix2seq: A language modeling framework for object detection. *arXiv preprint arXiv:2109.10852*.
- [9] Zhang, H., Li, F., Liu, S., Zhang, L., Su, H., Zhu, J., ... & Shum, H. Y. (2022). Dino: Detr with improved denoising anchor boxes for end-to-end object detection. *arXiv preprint arXiv:2203.03605*.
- [10] Yang, C., Huang, Z., & Wang, N. (2022). QueryDet: Cascaded sparse query for accelerating high-resolution small object detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 13668-13677).