

TEKNOFEST

**HAVACILIK, UZAY VE TEKNOLOJİ
FESTİVALİ**

**ULAŞIMDA YAPAY ZEKA YARIŞMASI
KRİTİK TASARIM RAPORU**

TAKIM ADI: WENN

BAŞVURU ID: 354192

İÇİNDEKİLER

İÇİNDEKİLER	2
ŞEKİL LİSTESİ	3
TABLO LİSTESİ	3
KISALTMALAR	5
1. TAKIM ŞEMASI	6
2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ	6
3. ALGORİTMALAR VE SİSTEM MİMARİSİ	8
3.1. Veri Setleri	8
3.2. Algoritmalar	9
4. ÖZGÜNLÜK	10
5. SONUÇLAR VE İNCELEME	11
6. KAYNAKÇA	14



ŞEKİL LİSTESİ

Şekil 1.1. Takım Şeması.....	6
Şekil 3.1. Örnek Veri Seti.....	8
Şekil 3.2. CycleGAN Deneme Sonuçlar.....	8
Şekil 5.1. Yapay Zeka Modelinin Başlangıç ve Bitişini Oluşturan Adımlar.....	11
Şekil 5.2. YoloV5s Modeli Deneme Eğitimi Sonuç Grafikler.....	11
Şekil 5.3. SAHI Algoritmasının Uygulama Durumu.....	12



TABLO LİSTESİ

Tablo 5.1. YOLOv5 Modellerinin Sonuçlarına Göre Karşılaştırılması.....12



KISALTMALAR

ÜÇA: Üretken Çekişmeli Ağlar

ÖTR: Ön Tasarım Raporu

YOLO: You Only Look Once

UAP: Uçan Araba Park Alanı


UAİ: Uçan Ambulans İniş Alanı

ESA: Evrişimli Sinir Ağı



1. TAKIM ŞEMASI

Takımımız, 4 Yazılım ve 1 Elektrik Elektronik Mühendisliği disiplinlerinde öğrenim gören öğrencilerden oluşmaktadır. Takım danışmanlığı, Yazılım Mühendisliği Ana Bilim Dalında öğretim üyesi olarak çalışan bir akademisyen tarafından yürütülmektedir. Takım üyelerinin Teknofest kapsamında düzenlenen Ulaşım, Yapay Zekâ, Tarımsal İnsansız Kara Aracı ve Karma Sürü Simülasyon kategorilerinde daha önce yarışma tecrübeleri bulunmaktadır. Takım şeması Şekil 1.1'de verilmiştir.



2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ

Model geliştirme süreçleri ÖTR yazılırken olabildiğince mümkün tercihler yapılmıştı, bu nedenle ÖTR aşamasında hazırlanan proje takvimi uyarınca hareket edildiğinde büyük bir sorun yaşanmadan hedeflere ulaşılmıştır.

Temel model algoritmaları denenmiş olup verimliliklerine göre YOLOv5 [1] modelinin daha verimli olduğu görülmüştür. YOLOv5, veri seti eğitimi ve testi süresinde tüm imgeyi görmektedir. Böylece sınıflar ve görünüşleriyle ilgili bağlamsal bilgileri örtük olarak kodlamaktadır. YOLO algoritmasının beşinci versiyonunu kullanmamızdaki neden ise, YOLOv5 PyTorch [2] framework üzerinden çalışan ilk YOLO modelidir. Anlaması daha kolay ve basit olan Pythonic yapıda olması sebebiyle Python içerisindeki çeşitli kütüphanelerle daha uyumlu çalışan ve grafik işlem birimi kullanarak daha hızlı deneyim sunan PyTorch ile YOLOv5 daha hızlı çalışmaktadır.

ÖTR'de ayrıyeten belirttiğimiz YoloR [3] ve YoloX [4] nesne tanıma modelleri oluşturuldu, özgün olarak oluşturulan veri seti üzerinde eğitim gerçekleştirildi ve olası zayıflıklar belirlendi. Teknofest tarafından sağlanan örnek video ile testler yapıldı, sonuçlar analiz edildi. Ön ve son işleme algoritmalarının sisteme entegre edilip, test edilmesi kararlaştırıldı.

Alternatif olarak kullanılması planlanan ve temel modellere hibrit olarak entegre edilmesi planlanan SAHI algoritması [5] ile denemeler devam etmektedir.

UAP ve UAİ durumlarını belirleyen model için, ön işleme ile modelin yükünü azaltmaya yönelik çalışmalar yapılarak, deneyler sonucu belirli bir eşik değeri belirlenip sınırlayıcı kutunun en boy oranını kullanarak iniş alanlarının sınıflandırma algoritması kullanılmadan elenme işlemini yapacak bir metod belirlendi, gerekli istatistikler çıkartıldı ve incelendi. Sonuçlar kısmında detaylandırılacak.

Geliştirmekte olduğumuz modelde, eğitim aşamasından sonra Algısal Özet Fonksiyonu (Perceptual Hash) kullanılmıştır. Bu fonksiyonu kullanmadaki amacımız; test doğruluk oranını kabul edilebilir bir oranda tutup çalışma süresini azaltmaktır fakat yarışma alanında paylaşılan verileri test ederken çevrimdışı bir ortam olduğundan Algısal Özet Fonksiyonunun kullanımından vazgeçilmiştir.

Yarışma sırasında kullanılacak donanımlar kararlaştırıldı. Veri setini çeşitlendirmek için dron alınması kararlaştırıldı. Yarışma şartlarına uygun irtifalarda Elâzığ taşıt trafiğinde ve Fırat Üniversitesi kampüsünde çekimler yapılarak özgün veri setine eklemeler yapıldı. Google Colab Pro üyeliği satın alınarak YOLO mimarileri için eğitimler gerçekleştirilmiştir. Yarışma esnasında bilgisayar üzerinde koşturacağımız YOLO mimarisinin ön eğitilmiş halini kullanmak için Monster Tulpur serisi seçilmiştir. Seçilen bilgisayar, Intel® Core™ i7-7700K işlemciye ve 64 GB RAM'a sahiptir. Seçilen bilgisayarın, sahip olduğu NVIDIA GTX 1080 ekran kartı ile kullandığımız nesne tespit algoritmalarını hızlı bir şekilde çalıştırması, yarışma esnasında avantaj sağlayacaktır.

HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

3. ALGORİTMALAR VE SİSTEM MİMARİSİ

3.1. Veri Setleri

Yarışma komitesinin şartnamede belirlemiş olduğu veri seti kriterlerine göre; açı (Kamera açısı 60-90 derece aralığında), yükseklik (hava aracının yerden yüksekliği 25m ile 100 m arasında) şartları baz alınarak; ÖTR’de bahsedilen veri setlerine Vedai [5], Dota [6], VisDrone [7], Bdd100k [8], Voc [9], COCO [10], Dlr [11], Detrac[12], Uavdt [13], Arxiv [14], Pesmod [15] ve Tugraz [16] internet sitelerinden veri toplanmıştır (200 bin dron verisi).

Veri Setlerinin oluşturulması esnasındaki aşamalar aşağıda verilmiştir:

1. Elde edilen veri setleri yarışma şartnamesine göre uygun olarak ayıklanmıştır. Formata uygun toplamda 40 bin resim elde edilmiştir. Ayıklanan veri setinde; güneşli, karlı, sisli, yağmurlu ve gece hava koşullarına ait resimler de mevcuttur. Eğitim için kullandığımız örnek veri seti şekil 2.1’de verilmiştir.



Şekil 2.1. Örnek Veri Seti

2. CycleGAN [17] algoritması kullanılarak farklı hava koşullarını (güneşli, yağmurlu, karlı) içeren veriler üretilmiştir. CycleGAN kullanarak elde edilen sentetik görüntüler şekil 2.2’de verilmiştir.



Gerçek Resim

Sahte Resim

Şekil 2.2 CycleGAN Deneme Sonuçları

3. VQGAN [18] algoritması kullanılarak sentetik görüntüler elde edilmesi de planlanmaktadır.
4. Yarışma şartnamesinde bahsedilen irtifalarda dron uçuşları yapılarak eksik olan nesne sınıfları özgün veri setine eklendi. Dron uçuşları Elâzığ taşıt trafiğinde ve Fırat Üniversitesi Kampüsünde yapıldı. İniş alanlarını branda olarak bastırarak kullanmak için gerekli fizibilite çalışmalarına başlandı.
5. UAP ve UAİ verilerinin yetersizliği nedeniyle boş park alanlarda dron uçuşu yapıldı sonrasında photoshop ile boş alanlara UAP VE UAİ görüntüleri yapıştırılarak veri seti çeşitlendirildi.
6. Davinci Resolve 17 [19] ve GTA V [20] programlarında sanal drone videoları oluşturulup gerçek hayatta olmayan UAP ve UAİ alanlarında veri seti ihtiyacı karşılanmıştır.

3.2. Algoritmalar

Yarışmada kullanacağımız algoritmalar aşağıdaki gibidir.

● YOLOv5

YOLO algoritması [21], gerçek zamanlı nesne tespiti için kullanılmaktadır. Bu algoritma, ileri yayılma ile imgedeki nesneleri kutu şeklinde tespit etmektedir ve son derece hızlı şekilde işlem yapmaktadır. Veri setinin eğitimi ve testi süresinde tüm imgeyi görmektedir. Böylece sınıflar ve görünüşleri ile ilgili bağlamsal bilgileri örtük olarak kodlamaktadır. YOLO algoritmasının beşinci versiyonunu kullanmamızdaki neden ise, YOLOv5 PyTorch framework üzerinden çalışan ilk YOLO modelidir. Anlaması daha kolay ve basit olan Pythonic yapıda olması sebebiyle Python içerisindeki çeşitli kütüphanelerle daha uyumlu çalışan ve grafik işlem birimi kullanarak daha hızlı deneyim sunan PyTorch ile YOLOv5 daha hızlı çalışmaktadır.

● YOLOR

You Only Learn One Representation (YOLOR) genellikle belirli bir amacı yerine getirirken, aynı anda birden fazla sorunu çözmek için eğitilebilen bir modeldir. Evrişimli Sinir Ağları (ESA) [22] genellikle tek bir amaç düşünülerek oluşturulur. ESA'lardan çıktı almak için girdileri nasıl analiz edeceklerini öğrenirken, YOLOR, ESA'ların hem çıktı almayı hem de tüm farklı çıktılarının ne olabileceğini öğrenmesini sağlamaya çalışır. Tek bir çıktı yerine, birçok çıktıya sahip olabilir. İnsanlar tek bir girdi verildiğinde farklı sorulara cevap verebilir. Tek bir veri parçası verildiğinde, insanlar verileri farklı açılardan analiz edebilir. Örneğin, bir şeyin fotoğrafı, gösterilen eylem, konum vb. ile ilgili farklı tepkiler ortaya çıkarabilir. YOLOR, bu yeteneği makine öğrenimi modellerine vermeyi amaçlar. 5 YOLOR yönteminin, yüksek doğruluğu korurken algılama verimliliği açısından son teknoloji yöntemlerinden önemli ölçüde daha iyi performans göstermesi öncelikli model olarak seçilmesine neden olmuştur [23].

● YOLOX

YOLOX, Ağustos 2021'de piyasaya sürülen, YOLOv5'ten daha iyi performans sağlayan ve Apache lisansı ile sunulan son teknoloji bir nesne algılama modelidir [4]. Giriş imgesini tek bir seferde sinir ağından geçirerek, imgedeki tüm nesnelerin sınıfını ve koordinatlarını tahmin edebildiği ve gerçek zamana yakın çıkarım hızına sahip olduğu için tercih edilmiştir.

● SAHI

SAHI, Küçük nesneleri, modeli yeniden eğitmeden ve daha büyük GPU bellek ayırmaya gerek duymadan tespit etmeye yardımcı olarak geliştirilen bir modeldir.[24] Küçük nesneler üzerinde başarılı sonuçlar verdiği gözlemlendiği için tercih edilmiştir. Temel modellere hibrit olarak entegre edilmesi planlanmaktadır.

4. ÖZGÜNLÜK

Yarışma komitesinin belirlemiş olduğu metriklerde özgün veri setimiz oluşturulmuş olup eksik olan veri sınıfları tespit edildikçe veri setimiz zenginleşmeye devam etmektedir.

Kullanılan veri seti sağlığını görüntülemek için Roboflow [25] platformu kullanılmıştır. Bu platform hangi sınıftan ne kadar veri olduğunu, hangi sınıfın eğitim için yeterli miktarda olduğunu, hangi sınıfın veri miktarının eksik olduğunu belirtmektedir. Ayrıca bu platformda veri çoğaltma (Data agumentation) işlemleri de yapılabilmektedir. Bu platform kullanılarak kontrollü bir veri seti hazırlanmıştır.

Ayrıca özgün veri seti oluşturulurken yetersiz bulunan nesne sınıflarının çeşitlendirilmesi için ÜÇA ile sentetik veri üretimi yapılmıştır. ÜÇA, evrişimli sinir ağları gibi derin öğrenme yöntemlerini kullanan üretken modellemeye yönelik bir yaklaşımdır. ÜÇA, gerçek veriler yerine geçebilecek sentetik veri örnekleri oluşturmak için iki sinir ağı kullanan algoritmik mimarilerdir [26]. ÜÇA'ın seçilen iki versiyonu CycleGAN ve VQGAN modelin veri iyileştirmesinde kullanılmıştır. CycleGAN veriler üzerinde mevsim değiştirme efekti uygulayarak, VQGAN ise verileri çoğaltarak (Agumente işlemi) sentetik veri üretiminde önemli ölçüde veri setine katkıda bulunmuştur.

Etiketleme için taşıt olarak bizden istenilen alt sınıfların hepsi (araba, motosiklet, traktör, kamyon vb.) ayrı ayrı modele tanıtılıp eğitimin kolaylaştırılması hedeflenmiştir. En son JSON dosyasında bunların hepsi "Taşıt" etiketi ile sınıflandırılıp, ID numarası "0" olarak yazılmıştır.


Modelin çalışma esnasında ortaya çıkabilen "false pozitif ve false negatif" gibi istenmeyen durumların en aza indirgenmesi için eğitim veri setinin %3'ü, arka plan görüntülerinden oluşturulması sağlanmıştır.

Drone görüntülerinde küçük nesne tespiti oldukça önemlidir. Araştırmalarımız ve hazır modellerde elde ettiğimiz sonuçlara göre küçük nesne tespit oranını artıran SAHI algoritması [27] oldukça fayda sağladığı görülmüştür. Yapılan araştırmaya göre de algoritma diğer modellerdeki sonuçlardan iyi olduğu anlaşılmıştır. Bu durumda nihai eğittiğimiz modeli SAHI algoritması ile küçük nesne tespitini kolaylaştırması hedeflenmektedir [28].



5. SONUÇLAR VE İNCELEME:


Yarışma kapsamında yapılan çalışmaların adımları 8 aşamada verilmiştir. Kullanılan yöntemlerin adımları şekil 5'te verilmiştir.



Şekil 5.1.Yapay Zekâ Modelinin Başlangıç ve Bitişini Oluşturan Adımlar

1. Görüntü üzerinden Yapay Zekâ modellerini eğitirken veri toplama çok önemlidir. İlk aşama olarak birçok açık kaynak tabanlı platformlardan veriler toplandı.
2. Dron çekimleri için ortamlar oluşturulup amaca uygun veriler toplandı
3. Verilerin istenilen miktarda ve çeşitlilikte olmaması nedeniyle veri artırma metotlarından biri olan Roboflow ile veri artırımı yapıldı.
4. Veri hazırlama süreci niyetlendiğinde veri sağlığını Roboflow'dan inceleyerek kontrollü bir veri seti hazırlanmıştır.
5. Make Sense [29] ile etiketlenen verilerden Roboflow'dan sihirbaz olarak etiketleri bulundurulmuştur.
6. Make Sence'den yapay zekâ model eğitimi için txt formatında etiket çıktıları alınmıştır.
7. Elde edilen txt formatından Google Colab Pro üzerinden eğitim gerçekleştirilmiştir.
8. Sonuç olarak eğitilen Yapay Zekâ modelinin test aşaması tamamlanmıştır.

Kullanılması öngörülen algoritmalar etiketlenmiş veriler üzerinden Google Colab Pro kullanılarak eğitilmiştir. YoloR çalıştırılmasında epoch hatası alınmıştır. Hata çözülmesine rağmen GPU hatası devam etmiştir. İlk olarak 100 epoch YOLOv5 daha sonra 100 adım (epoch) YOLOX modelleri eğitilmiştir. Sonuçları Şekil 5.2'de yer almaktadır.



Şekil 5.2. YoloV5s Modeli Deneme Eğitimi Sonuç Grafikler

Kullanılması planlanan alternatif model olan SAHI özgün veri setimiz üzerinde denenmiştir ve sonucunda Şekil 5.3'te görüldüğü üzere küçük nesne algılamada oldukça iyi olduğu görülmüştür.



Şekil 5.3. SAHI Algoritmasının Uygulama Durumu

Eğitilen modellerin performansını yarışma kriterlerine göre değerlendirmek için, şartnamede belirtilen IoU metriği dikkate alınmıştır. Model başarısını ölçmek için kullanılan bir diğer metrik ise Karmaşıklık matrisi (Confusion Matrix)'dir [30]. Karmaşıklık matrisi, gerçek değerlerin bilinmekte olduğu, test veri seti üzerinde, bir sınıflandırma modelinin performansını ölçmek için kullanılan bir tablodur. Karmaşıklık matrisi yardımıyla Gerçek Pozitif (TP), Yanlış Pozitif (FP) ve Yanlış Negatif (FN) durumları incelenmiştir. Yanlış pozitif durumları: IoU oranı 0.5 olan tespitler ve etiketlenmemiş bir objenin işaretlenmesidir. Yanlış negatif durumu ise, etiketli bir nesnenin tespit edilememesidir.

Karmaşıklık matrisinde bulunan TP, FP, FN durumları nesne sınıfları için Accuracy (Doğruluk), Precision (Tahmin), Recall (Duyarlılık), F1-Score (F1-Puanlama) gibi metriklerinin hesaplanmasında kullanılır. Oluşturulan sınıflandırma modeli için sözü geçen metrikler hesaplanmıştır. Şartnamede, nesne tespitinin doğruluğu Kesişimin Birleşime Oranı (Intersection Over Union) (IoU) değerine göre belirlenmiştir. Bu oran tahmin edilen alan ve nesnenin gerçek alanının arasındaki eşleşme miktarını gösterir. mAP (Ortalama hassasiyet), nesne tespitinde kullanılan modellerin doğruluğunu ölçmek için kullanılan popüler bir ölçümdür. Şartnamede belirtilen IoU eşik değerine (0,5) göre mAP metriğinin hesaplanması kararlaştırılmıştır.

mAP metrik değerinin hesaplanabilmesi için, Precision ve Recall değerlerinin hesaplanması gerekmektedir. Precision (Kesinlik), sınıflandırma modelinin yaptığı tahminlerden kaçının gerçekte doğru olduğunu ölçen metrik değeridir.

Precision değeri,

Precision: $\frac{TP}{TP+FP}$ formülü ile hesaplanmıştır [31]. Recall (Duyarlılık) ise pozitif olarak tahmin edilmesi gereken durumların ne kadarının pozitif olarak tahmin edildiğini gösteren bir metriktir.

Recall değeri,

Recall: $\frac{TP}{TP+FN}$ formülü ile hesaplanmıştır [32]. AP (Ortalama Hassasiyet), kesinlik ve duyarlılık eğrisinin altındaki alan bulunarak hesaplanır. mAP metrik değeri ise AP değerinin ortalamasıdır.

Trained Models	Accuracy (0-1)	Precision	Recall	F1-Score	Processing Time (ms)
YOLOv5s	0.37	0.22	0.18	0.29	82
YOLOv5m	0.43	0.38	0.34	0.32	220
YOLOv5l	0.49	0.47	0.44	0.60	430
YOLOv5s6	0.52	0.69	0.22	0.43	356
YOLOv5m6	0.58	0.71	0.57	0.78	885
YOLOv5l6	0.59	0.68	0.55	0.59	1500

Tablo 5.1. YOLOv5 Modellerinin Sonuçlarına Göre Karşılaştırılması

UAP ve UAİ alanlarının tespiti için yazılan algorithmada önce UAP ve UAİ alanlarının tespiti yapıldı sonrasında koordinatları tutuldu. Yarım UAP ve UAİ'ler inişe uygun olmayacak şekilde “y-uap” ve “y-uai” ismiyle etiketlenmiştir. Alanların üzerinde farklı nesneler tespit edilirse, iniş veya park için “uygun değildir” bilgisi döndürülür.



6. KAYNAKÇA

- [1] Wang, J., Chen, Y., Gao, M., & Dong, Z. (2021). Improved YOLOv5 network for real-time multi-scale traffic sign detection. arXiv preprint arXiv:2112.08782.
- [2] PyTorch, A. D. I. (2018). Pytorch.
- [3] Wang, X., Zheng, S., Zhang, C., Li, R., & Gui, L. (2021). R-YOLO: A real-time text detector for natural scenes with arbitrary rotation. *Sensors*, 21(3), 888.
- [4] Cochard, D. (2021, November 1). Yolox: Object detection model exceeding yolov5. Medium. Retrieved March 20, 2020, from <https://medium.com/axinc-ai/yolox-object-detection-model-exceeding-yolov5-d6cea6d3c4bc>
- [5] Cagatay Akyon, F., Onur Altinuc, S., & Temizel, A. (2022). Slicing Aided Hyper Inference and Fine-tuning for Small Object Detection. arXiv e-prints, arXiv-2202.
- [6] Razakarivony, S., & Jurie, F. (2016). Vehicle detection in aerial imagery: A small target detection benchmark. *Journal of Visual Communication and Image Representation*, 34, 187-203.
- [7] Xia, G. S., Bai, X., Ding, J., Zhu, Z., Belongie, S., Luo, J., ... & Zhang, L. (2018). DOTA: A large-scale dataset for object detection in aerial images. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 3974-3983).
- [8] Zhu, P., Du, D., Wen, L., Bian, X., Ling, H., Hu, Q., ... & Liu, Z. (2019). Visdrone-vid2019: The vision meets drone object detection in video challenge results. In *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops* (pp. 0-0).
- [9] Yu, F., Xian, W., Chen, Y., Liu, F., Liao, M., Madhavan, V., & Darrell, T. (2018). Bdd100k: A diverse driving video database with scalable annotation tooling. arXiv preprint arXiv:1805.04687, 2(5), 6.
- [10] Everingham, M., Van Gool, L., Williams, C. K., Winn, J., & Zisserman, A. (2010). The pascal visual object classes (voc) challenge. *International journal of computer vision*, 88(2), 303-338.
- [11] Lin, T. Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., ... & Zitnick, C. L. (2014, September). Microsoft coco: Common objects in context. In *European conference on computer vision* (pp. 740-755). Springer, Cham.
- [12] Igual, R., Medrano, C., & Plaza, I. (2015). A comparison of public datasets for acceleration-based fall detection. *Medical engineering & physics*, 37(9), 870-878.
- [13] Wen, L., Du, D., Cai, Z., Lei, Z., Chang, M. C., Qi, H., ... & Lyu, S. (2020). UA-DETRAC: A new benchmark and protocol for multi-object detection and tracking. *Computer Vision and Image Understanding*, 193, 102907.
- [14] Gibril, M. B. A., Kalantar, B., Al-Ruzouq, R., Ueda, N., Saeidi, V., Shanableh, A., ... & Shafri, H. Z. (2020). Mapping heterogeneous urban landscapes from the fusion of digital surface model and unmanned aerial vehicle-based images using adaptive multiscale image segmentation and classification. *Remote Sensing*, 12(7), 1081.
- [15] Lai, G., Xie, Q., Liu, H., Yang, Y., & Hovy, E. (2017). Race: Large-scale reading comprehension dataset from examinations. arXiv preprint arXiv:1704.04683.
- [16] Mribrahim. (n.d.). *MRIBRAHIM/PESMOD: UAV images dataset for Moving object detection*. GitHub. Retrieved June 15, 2022, from <https://github.com/mribrahim/PESMOD>
- [17] Nedeveschi, S. (2019, September). Semantic segmentation learning for autonomous uavs using simulators and real data. In *2019 IEEE 15th International Conference on Intelligent Computer Communication and Processing (ICCP)* (pp. 303-310). IEEE.

- [18] Chu, C., Zhmoginov, A., & Sandler, M. (2017). Cyclegan, a master of steganography. arXiv preprint arXiv:1712.02950.
- [19] Miranda, L. J. Taming the 'Taming transformers' paper (VQGAN). ljmiranda921. github. io.
- [20] Goch, B. (2021). BLACKMAGIC DESIGN'S DAVINCI RESOLVE SPEED EDITOR: WHAT'S OLD IS NEW AGAIN. Post, 36(1), 30-32.
- [21] Pérez Latorre, Ó. (2015). The social discourse of video games analysis model and case study: GTA IV. Games and Culture, 10(5), 415-437.
- [22] Huang, R., Pedoeem, J., & Chen, C. (2018, December). YOLO-LITE: a real-time object detection algorithm optimized for non-GPU computers. In 2018 IEEE International Conference on Big Data (Big Data) (pp. 2503-2510). IEEE.
- [23] Meel, V. (n.d.). Yolor - you only learn one representation (what's new, 2022). viso.ai. Retrieved 2018, from <https://viso.ai/deep-learning/yolor/>
- [24] Akyon, F. C., Altinuc, S. O., & Temizel, A. (2022). Slicing Aided Hyper Inference and Fine-tuning for Small Object Detection. arXiv preprint arXiv:2202.06934.
- [25] Give your software the power to see objects in images and video. Roboflow. (n.d.). Retrieved April 3, 2020, from <https://roboflow.com/>
- [26] Goodfellow, Ian; Pouget-Abadie, Jean; Mirza, Mehdi; Xu, Bing; Warde-Farley, David; Ozair, Sherjil; Courville, Aaron; Bengio, Yoshua (2014).
- [27] Obss. (n.d.). OBSS/Sahi: A lightweight vision library for performing large scale object detection/instance segmentation. GitHub. Retrieved February 11, 2021, from <https://github.com/obss/sahi>
- [28] Keles, M. C., Salmanoglu, B., Guzel, M. S., Gursoy, B., & Bostanci, G. E. (2022). Evaluation of YOLO Models with Sliced Inference for Small Object Detection. arXiv preprint arXiv:2203.04799.
- [29] Wittmann, M. C., Steinberg, R. N., & Redish, E. F. (1999). Making sense of how students make sense of mechanical waves. *The physics teacher*, 37(1), 15-21.
- [30] Veribilimcisi. (2018, November 28). *Karışıklık matrisi (confusion matrix)*. Veri Bilimcisi-YENİLENİYOR ... Retrieved June 15, 2022, from <https://veribilimcisi.com/2017/07/18/karisiklik-matrisi-nedir/>
- [31] Yohanandan, S. (2020, June 9). *Map (mean average precision) might confuse you!* Medium. Retrieved June 15, 2022, from <https://towardsdatascience.com/map-mean-average-precision-might-confuse-you-5956f1bfa9e2>
- [32] Ögündür, G. (2020, April 22). *Doğruluk (accuracy) , Kesinlik(precision) , Duyarlılık(recall) ya da F1 score ?* Medium. Retrieved June 15, 2022, from <https://medium.com/@gulcanogundur/do%C4%9Fruluk-accuracy-kesinlik-precision-duyarl%C4%B1l%C4%B1k-recall-ya-da-f1-score-300c925feb38>