

TEKNOFEST

HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

ULAŞIMDA YAPAY ZEKA YARIŞMASI

KRİTİK TASARIM RAPORU

BAŞVURU ID: 347392

TAKIM ADI: zekAi



İÇİNDEKİLER

İçindekiler

Şekil Listesi

Tablo Listesi

1. Takım Şeması
2. Proje Mevcut Durum Değerlendirmesi
3. Algoritmalar ve Sistem Mimarisi
 - 3.1. Veri Setleri
 - 3.2. Algoritmalar
 - 3.2.1. Veri Artırma ve Ön İşleme
 - 3.2.2. Dedektör Modeli
 - 3.2.3. Dinamik Başlık Modeli
 - 3.2.4. Eğitim ve Test
4. Özgünlük
5. Sonuçlar ve İnceleme
6. Referanslar

ŞEKİL LİSTESİ

Şekil 1.1: Takım şeması.....	5
Şekil 3.2.1: Algoritma akış şeması.....	6
Şekil 3.2.2.1: SFA (ölçeğe duyarlı özellik toplama) modülü.....	7
Şekil 3.2.2.2: Dedektör modeli (AFF : adaptif özellik füzyonu, SFA: ölçeğe duyarlı özellik toplama, DYH: dinamik başlık).....	7
Şekil 3.2.2.3: AFF modülü (GAP: global ortalama havuzlama).....	8
Şekil 3.2.3.1: Dinamik başlık modeli.....	8
Şekil 5.1: val/box_loss ve train/box_loss çıktısı.....	9
Şekil 5.2: train/cls_loss ve val/cls_loss çıktısı.....	9
Şekil 5.3: precision ve recall metrics çıktısı.....	10
Şekil 5.4: mAP_0.5 ve mAP_0.5:0.95 metrics çıktısı.....	10



TABLO LİSTESİ

Tablo 5.1: TPH-Yolo ve DYH-Yolo validasyon mAP çıktısı.....10

Tablo 5.2: Nesnelere göre TPH-Yolo ve DYH-Yolo mAP çıktısı.....11



KISALTMALAR

TPH: Transformer Prediction Head

AFF: Adaptive Feature Fusion

SFA: Scale-Aware Feature

DYH: Dynamic Head

SAHI: Slicing Aided Hyper Inference

FPN: Feature Pyramid Net

PANet: Path Aggregation Network

TPH-Yolov5: Transformer Prediction Head - You Only Look Once

Yolo: You Only Look Once

ResNet: Residual Network

NMS: Non-maximum Suppression

Ap: Average Precision


mAp: mean Average Precision

IOU: Intersection Over Union



1. Takım Şeması

zekAi takımında görev dağılımı takım üyelerinin çalışma alanlarına ve tecrübelerine göre yapıldı. Takım 5 üyeden oluşmaktadır. Görev dağılımı kullanılacak metot adımlarına göre yapılmıştır. Bu görevler; veri setinin hazırlanması, modelin kodlanması, eğitilmesi ve test edilmesidir.



Şekil 1.1: Takım şeması

2. Proje Mevcut Durum Değerlendirmesi

Ön tasarım raporunda TPH-Yolov5 modeli baz alındı. Bu model üzerinde omurga, boyun ve başlık kısmında değişiklikler yapılarak küçük nesneler üzerinde başarı oranı artırılmaktadır. Omurga kısmında ResNet2 mimarisi kullanılarak küçük nesneler üzerinde sınıflandırma başarıları artırılmakta ve test kısmında kullanılan ekstra sınıflandırıcı kaldırılarak tespit süresi azaltılmaktadır. Boyun kısmında PANet modülü yerine AFF ve SFA modülü kullanılarak yüksek parametre gereksinimi azaltılmaktadır. Başlık kısmında ise dinamik başlık kullanılmaktadır. Projede yarışma için oluşturulan veri seti veri artırma teknikleri kullanılarak artırıldı. Veri seti yolo formatına uygun olacak şekilde etiketlendi. Dedektör modeli olarak baz alınan TPH-Yolov5 modeli üzerinde omurga kısmında CSPDarknet53 mimarisi yerine ResNet2 mimarisi entegre edildi. Boyun kısmında PANet yerine SFA ve AFF modülleri entegre edildi. Ayrıca başlık kısmında TPH modülü yerine DYH modülü kullanıldı. Test kısmında sınıflandırma başarıları artırmak adına kullanılan ek sınıflandırıcı ResNet2 mimarisinin yüksek başarısından dolayı dedektör modelinden kaldırıldı. Ayrıca test kısmında SAHI algoritması eklenerek küçük nesneler üzerinde başarı oranı artırıldı. Değişiklikler yapılmadan ve yapıldıktan sonra iki farklı eğitim gerçekleştirildi. İki farklı sonuçlar incelenerek TPH-Yolov5 modeline göre daha yüksek başarı verdiği ve değişikliklerin sonuçlara göre uyumlu çalışmasından dolayı ön tasarım raporunda belirtilen algoritmalar ve metotlar kullanıldı ve ön tasarım raporu sonrası değişiklik yapılmadı.

3. Algoritmalar ve Sistem Mimarisi


3.1. Veri Setleri

Yarışma şartnamesinde 25m-100m irtifa ve 60-90 derece arasında kamera açısı değerlerine göre veri seti oluşturuldu. Aynı zamanda verilerin distorsiyon olmayan ve kalibre edilmiş kameralardan alınmış olmasına dikkat edildi. Bununla birlikte veri seti sabah, öğlen ve akşam üstü vakitlerinde çekilen 1920x1080 çözünürlüğünde görüntülerden oluşmaktadır. Bu kapsamda TEKNOFEST tarafından 2019, 2021 ve 2022 yıllarında verilen veriler kullanıldı. Aynı zamanda bu veriler çeşitli veri artırma teknikleri ile çoğaltıldı. Bunun yanı sıra literatürde olan veri setleri incelenerek teknik şartnamaya uygun olan Visdrone[1] veriseti kullanıldı. Bu veri setinde yaya ve araç verileri alındı. Bu veriler kullanılan dedektör modeline göre etiketlendi. Bu işlemler sonucunda yaklaşık olarak teknik şartnamaya uygun etiketli 250 bin adet veri elde edildi. Son olarak veri seti %80 eğitim %15 validasyon %5 test olmak üzere 3 gruba bölündü.

3.2. Algoritmalar

Literatürde nesne tespitinde başarıları kanıtlanmış olan ve tek aşamalı olması sebebiyle daha hızlı nesne tespiti yapan YOLOv5 modeli [4] ana model olarak kullanıldı. Bu modelin drone ile çekilen

görüntülerdeki nesnelerin tespit performansını artırmak için, bazı değişiklikler uygulandı. Bu değişiklikler aşağıdaki başlıklarda açıklanmıştır.



Şekil 3.2.1: Algoritma akış şeması

3.2.1. Veri Artırma

Kaliteli ve büyük veriseti modelin başarısında büyük rol oynamaktadır. Bu yüzden, Bölüm 3.1’ de kullanılacak verisetinin büyüklüğünü ve çeşitliliğini artırmak için, farklı irtifa ve açılardan çekilen görüntüleri modellemek için geometrik distorsiyon metotları ve günün farklı saatlerindeki değişen ışık miktarını modellemek için fotometrik distorsiyon metotları kullanılmıştır.


Geometrik distorsiyon metotları, rastgele ölçekleme, kırpma, translasyon ve rotasyonu içermektedir. Fotometrik distorsiyon için görüntünün renk tonu, parlaklığı ve doygunluğu üzerinde rastgele değişiklikler yapılmıştır. Ayrıca, son yıllarda model performansını büyük ölçüde artırdığı gözlemlenmiş olan, MixUp[4] ve mozaik[4] algoritmaları verisetini zenginleştirmek için kullanıldı. Bu algoritmalar, MixUp algoritması eğitim görüntülerinden rastgele iki görüntü seçmekte ve bu görüntülerin etiketleri ağırlıklı toplama (random weighted summation) yöntemi ile birleştirilerek yeni görüntüler oluşturulmaktadır. Bunun yanı sıra, mozaik algoritması, algılanmak istenen nesnenin arka planını üç farklı görüntü ile birleştirerek yeni görüntüler oluşturur. Ayrıca, modelin eğitimi esnasında yapılan bu veri zenginleştirme işlemlerine ek olarak, görüntü boyutunun değiştirilmesi ve yatay eksende çevirme gibi teknikler modelin test aşamasında da kullanılarak, modelin performansının artırılmıştır[2][3].

Son olarak, ters saldırı (adversarial attack) metotları modelin sağlamlığını artırmak ve ezberleme problemine karşı kullanılmıştır. [9]


3.2.2. Nesne Tespiti Modeli

Nesne tespiti için tek katmanlı dedektörlerden YOLOv5 modeli baz alındı[4]. Bu model, omurga (backbone), boyun (neck) ve dinamik başlık olmak üzere üç kısımdan oluşur[4]. YOLOv5 modelinde omurga kısmında CSPDarknet53, boyun kısmında PANet ve başlık (head) kısmında YOLO tespit modeli kullanılmaktadır.

YOLOv5 modelindeki PANet mimarisi, fazla sayıda parametre içerdiği ve elimizdeki eğitim verisinin azlığından dolayı, Feature Pyramid Net (FPN) kullanılmıştır[7]. FPN’ nin performansını artırmak için aşağıdaki değişiklikler yapıldı. Farklı irtifalardan alınan görüntülerde nesne boyutu değişmektedir. Buna ek olarak, aynı görüntüdeki, araba, yaya gibi farklı büyüklükteki nesnelerin tespiti gerekmektedir. Farklı büyüklükteki nesnelerin tespit başarısını artırmak için, FPN mimarisinde, adaptif özellik füzyonu (adaptive feature fusion, AFF) ve ölçeğe duyarlı özellik toplama (scale-aware feature aggregation, SFA) metodu kullanılmıştır[7]. TPH-Yolov5[5] mimarisine benzer şekilde, dinamik başlık sayısı artırılarak, özellikle küçük boyuttaki nesnelerin tespit başarısı artırıldı. SFA, üç farklı kernel büyüklüğüne sahip atrous konvolusyonel katmanlar kullanarak, farklı çözünürlükte featurelar elde eder. Ardışık iki çözünürlük seviyesindeki featurelar birleştirilip, attention modülüne giriş olarak verilir. Bu modülün çıkışı, konvolusyon katmanları ile elde edilen featureların ağırlıklı olarak toplanması için kullanılır.




Şekil 3.2.2.1: SFA (ölçeğe duyarlı özellik toplama) modülü



Şekil 3.2.2.2: Dedektör modeli (AFF : adaptif özellik füzyonu, SFA: ölçeğe duyarlı özellik toplama, DYH: dinamik başlık) [7].

AFF modülü, enkoder ve dekoder featurelarını direk birleştirmek yerine, bu featurelar üzerinden hesaplanan attention ağırlıkları ile dekoder featurelarını çarpıp ve elde edilen dekoder ve enkoder featurelarını toplar. Böylece, dekoder featurelarında bulunan semantik sınıf bilgisi, daha çok konumsal bilgiyi içeren enkoder featurelar ile daha etkin olarak birleştirilmiş olur [7].




Şekil 3.2.2.3: AFF modülü (GAP: global ortalama havuzlama)

Başlık kısmında ise YOLOv5 modeli kullanıldı. YOLOv5 modeli tek katmanlı dedektör olduğu için sınırlayıcı kutu ve nesne sınıfını aynı anda tahmin etmektedir. Tek katmanlı model olan YOLOv5 dört farklı mimariye sahiptir: YOLOv5s, YOLOv5m, YOLOv5l ve YOLOv5x [4]. Eğitim sırasında kayıp değerlerine bakılarak en optimum çalışan model olarak YOLOv5l seçildi.

Boyun kısmında 3 farklı ağ katmanından çıkan çıktı 1x1 evrişimden geçirildikten sonra dinamik başlık modülüne girdi olarak verilir. Üç farklı çıktı yumuşak maksimum olmayan bastırma (Soft-NMS) algoritması ile test aşamasında aday çıktılar üzerinde uygulanmıştır.[7] Test kısmında, küçük nesnelerin tespit edilme doğruluğunu artırmak için, SAHI (slicing aided hyper inference) metodu kullanıldı[8]. SAHI algoritması, orjinal görüntüyü hücrelere böler ve en-boy oranı korunarak her hücre yeniden boyutlandırılır. Bundan sonra nesne algılama ileri geçişi örtüşen her bir hücreye bağımsız olarak uygulanır. Uygulanan algorithmada SAHI algoritması, önerilen modelin farklı çözünürlükteki çıkış katmanlarında kullanıldı.

3.2.3. Dinamik Başlık Modeli

Yukarıda belirtilen değişikliklerin yanısıra, alternatif bir metot olarak, Şekil 3.2.3.1'deki boyun ve çoklu başlık kısmı, Dai ve arkadaşlarının önerdiği dinamik başlık modeli ile değiştirildi[6]. Bu metotta, attention mekanizması, nesnenin büyüklüğüne, konumuna ve yapılacak göreve, sınıflandırma, konum bilgisi öğrenme gibi, üç farklı amaçla kullanılmıştır. Şekil 3.2.3.1'de belirtilen dinamik başlık modeli, TPH-Yolo v5 mimarisindeki çoklu kafa yapısı için kullanılmıştır.



Şekil 3.2.3.1: Dinamik başlık modeli

3.2.4. Eğitim ve Test

Dedektörde kullanılan hiper parametreler (hyperparameters), veri setinin boyutu ve bilgisayar donanımına göre belirlendi. Eğitim sırasında yüksek çözünürlüklü ve hacimli veri setinden dolayı yüksek hafızalı ve hızlı olan NVIDIA 32 GB Tesla V100 ekran kartı ile eğitim gerçekleştirildi. Eğitim sırasında ezberleme, öğrenememe gibi durumları sınıflandırma ve tahmin için eğitim ve validasyon kayıpları incelendi. Ayrıca hiper parametre optimizasyonu için ağaç yapılı parzen tahmin (tree-structured parzen estimator) algoritması kullanıldı. Veri setinde yaya nesnesinin kapsadığı en düşük ve en yüksek alan aralıkları belirlendi. Önceki yarışmalarda, yayaların başarı oranının diğer nesnelere göre daha düşük olduğu gözlemlendiğinden, maksimum olmayan bastırma'nın (NMS) eşik değeri azaltılarak daha fazla tahmin çıktısı verilmesi ve bu çıktının önceden belirlenen yaya nesne aralığına göre eşiklemesi yeniden yapıldı. Bu şekilde yanlış pozitif (false positive) ve yanlış negatif (false negative) değerleri düşürüldü. Test işlemi NVIDIA GTX1080 ekran kartlı bilgisayar ile gerçekleştirildi. Test zamanında performans metriği olarak Ap, mAp ve IOU metrikleri kullanıldı. Eğitim sırasında workers: 8, imgsiz: 1920, batch-size: 4, epochs: 100, lr: 0.0032, momentum: 0.843, weight_decay: 0.00036, box: 0.07, cls: 0.18, obj: 0.15, iou_t: 0.2, anchor_t: 3, fl_gamma: 0.0, hsv_h: 0.4, hsv_s: 0.3, hsv_v: 0.5, degrees: 0.2, scale: 0.4, shear: 0.0, flipud: 0.0, fliplr: 0.5, mosaic: 1.0, mixup: 0.2 hiper parametreleri kullanıldı.


4. Özgünlük

Model eğitimi sırasında kullanılan veri seti yarışma teknik şartnamesine uygun olarak TEKNOFEST tarafından verilen veriler ve Visdrone veriseti baz alınarak veri seti oluşturuldu. Bu veri seti sayısal görüntü işleme tabanlı veri artırma teknikleri ile artırılarak yaklaşık 100 bin etiketli veri içermektedir. YOLOv5 modelinde omurga kısmında CSPDarknet53 yerine Resnet2 mimarisi kullanıldı. TPH-Yolov5 modelinin test kısmında sınıflandırma başarısı düşük olmasından dolayı ekstra sınıflandırıcı kullanılmaktadır. Ekstra sınıflandırıcı kullanmamak için daha küçük nesneler üzerinde CSPDarknet53


mimarisine kıyasla daha yüksek başarı veren ResNet2 mimarisi kullanıldı. Bu şekilde test süresi azaltılıp başarı oranı artırıldı. Dedektör modelinin boyun kısmında PANet yerine, nesne boyutuna ve sınıfına hassasiyeti artıracak yeni modüller, (SFA ve AFF) FPN mimarisi ile birleştirildi. Böylece daha az parametre ile farklı boyuttaki nesnelerin tespitinde daha etkin bir boyun mimarisi elde edilmiştir. Aynı zamanda, YOLOv5 modelindeki başlık sayısı artırılarak, yüksek çözünürlüklü özellikler üzerinde de nesne tespiti yapılmıştır. Böylelikle, yaya gibi küçük boyutlu nesnelerin tespit başarıları artırılmıştır. Bu mimariye alternatif olarak, dikkat mekanizmasının nesne boyutuna, konumuna odaklandığı dinamik kafa yapısı da YOLOv5 mimarisi ile entegre edilip, performans karşılaştırmaları yapılmıştır.

5. Sonuçlar ve İnceleme



Oluşturulan veri seti kullanılarak dedektör modeli NVIDIA 32 GB Tesla V100 ekran kartlı donanımıyla eğitim ve test bölümünde belirtilen hiper parametreler ile 100 epok kadar eğitildi. Eğitim ve validasyon ile alakalı başarımlar grafik formatında çıktı olarak alındı. Eğitim ve validasyonda; nesne koordinat tespiti için şekil 5.1'de gösterilen box_loss çıktısı, nesne sınıflandırma başarıları için şekil 5.2'de belirtilen cls_loss çıktısı, mAP değerindeki hassasiyeti ve kesinliği ölçmek amacıyla şekil 5.3'te belirtilen mAP- precision/recall çıktısı, tahmin edilen nesne koordinat ile gerçek koordinat örtüşmesini ölçmek amacıyla şekil 5.4'te gösterilen mAP çıktısı gösterilmektedir. Verilen grafiklerde eğitim ve validasyon çıktıları karşılaştırılarak ezberleme ve öğrenememe probleminin olmadığı görülmektedir. Eğitim sırasında sınıflandırma başarıları koordinat tespit başarılarından yüksek olmaktadır. Ayrıca mAP değerlerine göre hassasiyet değeri kesinlik değerinden daha yüksektir.



Şekil 5.1: val/box_loss ve train/box_loss çıktısı



Şekil 5.2: train/cls_loss ve val/cls_loss çıktısı



		mAP (0.5)	
		TPH-Yolo	DYH-Yolo (Modelimiz)
Epok	20	0.68	0.77
	40	0.70	0.79
	60	0.75	0.80
	80	0.78	0.82
	100	0.80	0.84

Tablo 5.1: TPH-Yolo ve DYH-Yolo validasyon mAP çıktısı

mAP (0.5)					
TPH-Yolo			DYH-Yolo (Modelimiz)		
Arac	Yaya	UAP-UAİ	Arac	Yaya	UAP-UAİ
0.90	0.70	0.93	0.91	0.76	0.92

Tablo 5.2: Nesnelere göre TPH-Yolo ve DYH-Yolo mAP çıktısı

Tablo 5.1’de iki farklı modelin validasyon mAP çıktıları verilmektedir. Çıktılara bakıldığında eğitim süresince mAP değerleri yükseliş eğilimindedir. Eğitim sonunda modelimiz diğer modele göre mAP metriğinde 0.04 puan yüksek olmaktadır. Bu değer 3 nesnenin (yaya, arac, UAP-UAİ) başarısının ortalamasını temsil etmektedir. Tablo 5.2’de nesnelere göre iki modelin mAP çıktıları verilmektedir. Bu çıktılarda yüksek başarı oranı araç ve UAP-UAİ nesneleri iki modelde de tespit edilmektedir. Ayrıca bu değerler yaklaşık olarak birbirine yakındır. Görüntü üzerinde daha düşük çözünürlükte olan yaya nesnesinin mAP değerine bakıldığında diğer iki nesneye göre daha düşük olmaktadır. Modelimizde küçük nesneler üzerinde başarı artıran metotlar kullanılarak yaya nesnesinde diğer modele göre mAP metriğinde 0.06 puan daha yüksek başarılı sonuç vermektedir. Bu sonuçlara göre TPH-Yolo modeli üzerinde yapılan değişiklikler olumlu sonuç vermiştir.

6. Referanslar

- 1- Pengfei Zhu ve diğerleri (2018), Vision Meets Drones: A Challenge, arXiv:1804.07
- 2- Yiming Wan ve diğerleri (2020), Boosting Image-Based Localization Via Randomly Geometric Data Augmentation, IEEE
- 3- Luke Taylor ve diğerleri (2018), Improving Deep Learning with Generic Data Augmentation, IEEE
- 4- Xingkui Zhu ve diğerleri (2021), TPH-YOLOv5: Improved YOLOv5 Based on Transformer Prediction Head for Object Detection on Drone-captured Scenarios, arXiv:2108.11539
- 5- Shang-Hua Gao ve diğerleri (2019), Res2Net: A New Multi-scale Backbone Architecture, arXiv:1904.01169
- 6- Xiyang Dai ve diğerleri (2021), Dynamic Head: Unifying Object Detection Heads with Attentions, arXiv:2106.08322
- 7- Huisi Wu ve diğerleri (2021), SCS-Net: A Scale and Context-Sensitive Network for Retinal Vessel Segmentation, ELSEVIER:102025
- 8- Fatih Cagatay Akyon ve diğerleri (2022), Slicing Aided Hyper Inference and Fine-tuning for Small Object Detection, arXiv:2202.06934
- 9- Mst. Tasnim Pervin ve diğerleri (2021), Adversarial Attack Driven Data Augmentation for Accurate And Robust Medical Image Segmentation, arXiv:2105.12106