

TEKNOFEST
HAVACILIK, UZAY VE TEKNOLOJİ
FESTİVALİ

ULAŞIMDA YAPAY ZEKA YARIŞMASI
KRİTİK TASARIM RAPORU



SoftWave

345244

İÇİNDEKİLER

İÇİNDEKİLER.....	2
ŞEKİL LİSTESİ.....	3
TABLO LİSTESİ.....	3
KISALTMALAR	4
1. TAKIM ŞEMASI.....	6
2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ.....	6
3. ALGORİTMALAR VE SİSTEM MİMARİSİ	7
3.1. Veri Setleri	7
3.2. Algoritmalar.....	7
3.2.1. Scaled-YOLOv4.....	7
3.2.2. Hatalı Tespitleri Ayıklama Algoritması.....	8
3.2.3. Maksimum Olmayan Bastırma.....	9
3.2.4. Algılama Sonrası İzleme Algoritması.....	9
4. ÖZGÜNLÜK.....	10
4.1. Veri Seti Oluşturma	10
4.2. Veri Artırma.....	10
4.3. K-Fold Cross-Validation.....	10
4.4. Algılama Sonrası İzleme Algoritması.....	11
4.5. Hatalı Tespitleri Ayıklama Algoritması.....	11
5. SONUÇLAR VE İNCELEME.....	11
5.1. Asıl Nesne Tespiti Testleri	11
5.2. Sistem Hız Testleri Ve Optimizasyonlar	12
5.3. Algılama Sonrası İzleme Algoritması Testleri	13
5.4. Hatalı Tespitleri Ayıklama Algoritması Karışanlar Tespiti	14
6. KAYNAKÇA.....	15

ŞEKİL LİSTESİ

ŞEKİL 1. SCALED-YOLOV4 ALGORİTMASI	8
ŞEKİL 2. NESNE TESPİTİ TEST ÖRNEĞİ.....	12
ŞEKİL 3. NESNE TESPİTİ TEST ÖRNEĞİ.....	12
ŞEKİL 4. İZLEME TEST SONUÇLARI	13
ŞEKİL 5. İNTERPOLASYON TEST SONUÇLARI	14
ŞEKİL 6. TAŞIT KONTEYNER KARIŞMA ÖRNEĞİ	14
ŞEKİL 7. TAŞIT PENCERE KARIŞMA ÖRNEĞİ	14
ŞEKİL 8. İNSAN ÇALI KARIŞMA ÖRNEĞİ	14
ŞEKİL 9. İNSAN DİREK KARIŞMA ÖRNEĞİ.....	14



TABLO LİSTESİ

TABLO 1. İZLEME ALGORİTMASI ÖRNEK BAŞARI PUANI MATRİSİ 8

TABLO 2. ÇÖZÜNÜRLÜK TESTLERİ SONUÇLARI TABLOSU 12



KISALTMALAR



1. TAKIM ŞEMASI

SoftWave Takımı 2021 yılında, Mehmet İlker Çoban danışmanlığında, eski StarTech Drone Ekibi Üyeleri Burak Yılmaz Zor ve Tuna Ekici tarafından kurulmuştur. Takım aynı sene ilk defa katıldığı TEKNOFEST Ulaşımda Yapay Zeka Yarışmasında ÖTR ve KTR aşamalarını geçmiş, İstanbul Atatürk Havalimanında gerçekleştirilmiş olan finale kalmaya hak kazanmış ve final aşamasını da sorunsuz biçimde tamamlamıştır. Takım, yarışmaya 2022 yılında da aşağıda görevleri belirtilen aynı üyeler ile katılmaktadır. Takım organizasyonu aşağıdaki gibidir:

Tuna Ekici – Takım Kaptanı

- Nesibe Aydın Fen Lisesinde 11. sınıf öğrencisidir.
- Takım organizasyonu ve proje planlamasında görevlidir.
- Yarışma ve test yazılımının oluşturulması ile veri seti toplanmasında görevlidir.

Burak Yılmaz Zor – Takım Üyesi

- Nesibe Aydın Fen Lisesinde 11. sınıf öğrencisidir.
- Yarışma yazılımının oluşturulması, eğitim sisteminin oluşturulması, eğitim işleminin takip edilmesi ve veri seti toplanması aşamalarında görevlidir.

Mehmet İlker Çoban – Danışman

- Nesibe Aydın Fen Lisesinde matematik öğretmenidir.
- Takımın destek alınan kurum ve kişilerle iletişimini sağlama, takıma çalışma ortamı oluşturma ve proje boyunca rehberlik yapma görevindedir.

2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ

Bu bölümde projenin mevcut durumu ve takımın ÖTR aşamasından beri gerçekleştirdiği çalışmalara yer verilmiştir.

ÖTR aşamasının ardından, ÖTR’de verilmiş olan proje takvimi uyarınca hareket edilmiş ve hedeflerin büyük bölümü öngörülen süre içerisinde tamamlanmıştır. İlk olarak ÖTR aşamasında belirtilen tüm veri setleri büyük oranda eğitime uygun hale getirilmiş ve bu veri setleri temel alınarak test amaçlı, daha küçük boyutlu veri setleri oluşturulmuştur. Ardından bu test setleri kullanılarak her bir nesne tipi için hem asıl tespitleri gerçekleştirecek hem de hatalı tespitleri algılayacak test modellerinin eğitimi tamamlanmıştır. Son olarak testler “Sonuçlar ve İnceleme” kısmına işlenen biçimde gerçekleştirilmiştir. Bu testler sonucunda her bir nesne tespit modeli için uygun çözünürlük benzeri parametreler de tespit edilmiştir. Bu süreçlerde ÖTR’ye göre en büyük değişiklikler, nesne tespit algoritmasının “Algoritmalar” bölümünde belirtilen sebeple YOLOR[0] yerine Scaled-YOLOv4[1] olarak belirlenmesi ve takımın eğitim platformu olarak Google COLABORATORY PRO[2]’ya geçmesidir.

Yarışmada kullanılacak sistemin yapısı ve özellikleri ise ÖTR’deki anlatılar merkeze alınarak detaylandırılmış, ardından ÖTR’de belirtildiği üzere Python dili kullanılarak tamamen işlevsel olacak biçimde oluşturulmuştur. “Algılama Sonrası İzleme” algoritması hariç ÖTR’de belirtilen tüm algoritmalar, yine ÖTR’deki sistem akışına ve algoritma tanımlarına sadık kalacak biçimde yazılımsal olarak sisteme entegre edilmiştir. İzleme algoritması ise “Algoritmalar” bölümünde belirtilmiş olan gerekli değişikliklere tabii tutulduktan sonra yine tam işlevsel biçimde sisteme eklenmiş, böylece yarışma sistemi yazılımsal olarak yarışmaya hazır hale getirilmiştir.

Bu noktadan itibaren test sonuçları da göz önünde bulundurularak yarışmada kullanılacak olan asıl nesne tespit algoritmalarının eğitimine ve bu algoritmaların eğitiminde kullanılacak olan veri setlerinin, özellikle veri artırma yöntemleri yardımıyla genişletilmesine yoğunlaşılacaktır. Bunlara ek olarak tamamlanmış olan yarışma sistemi de sürekli biçimde hız ve sağlamlık testlerine tabii tutulacak, yarışma simülasyonu ve asıl yarışma sırasında oluşabilecek problemler asgari seviyeye indirilecektir.

3. ALGORİTMALAR VE SİSTEM MİMARİSİ

3.1. Veri Setleri

Bu bölümde Phoneix II'nin eğitim ve test aşamalarında kullanılacak veri setleri açıklanmıştır. Veri setleri belirlenirken modelin üstün başarılı olması göz önünde bulundurulmuş, bu doğrultuda verilerin niteliği ve niceliğinde çeşitlilik olması dikkate alınarak veri seti oluşturulmuştur.

- **VisDrone 2020 ve 2021 Crowd Counting [3] Veri Setleri:** Bu veri setleri nesne tespiti yapacak yapay zeka modellerinin kullanabilmesi için insansız hava araçlarının kuşbakışı çektiği videolarla oluşturulmuştur. Phoneix II'nin amacı nesne tespiti olduğu için bu veri setleri seçilmiştir. Videoları çeken insansız hava aracının yerden yüksekliği değişkenlik gösterse de TEKNOFEST Ulaşımda Yapay Zeka yarışmasına uygun görüntüler ayıklanmış, etiketlerinde gerekli düzenlemeler yapılmış ve Phoneix II'nin esas veri setine eklenmiştir.
- **Stanford Drone [4] Veri Seti:** Stanford Üniversitesi kampüsü üzerinde şartnameye uygun yüksekliklerde insansız hava aracı ile çekilmiş görüntülerden oluşan veri seti oldukça çeşitli sınıflara sahip bir veri setidir. Aynı zamanda yaklaşık 70 GB boyutunda alternatiflerine kıyasla nicelik açısından zengin veriler içeren bir veri setidir. Bu nedenlerden dolayı veri setindeki etiketlerin düzenlenip kullanılmasına karar verilmiştir.
- **VCI – CİTR [5] Veri Seti:** Ohio State Üniversitesi tarafından oluşturulan veri seti insan ve taşıt arasındaki etkileşimi incelemek amacıyla oluşturulmuştur, bu amaç doğrultusunda yoğun miktarda insan ve taşıt içeren görüntülere sahiptir. Veri setindeki görüntülerin çekim açısı ve görüntülerdeki nesnelerin boyutları yarışma şartnamesine uygundur. Sözü edilen sebeplerden dolayı veriler esas veri setine dahil edilmiştir. Veri setindeki etiketler sistem mimarisine uygun formata getirilerek kullanıma hazır hale getirilmiştir.
- **PKLot [6] Veri Seti:** Park alanlarında bulunan araçların güvenlik kameraları sayesinde çekilmesiyle oluşturulmuş bir veri setidir. Verilerin çok sayıda taşıt nesnesi içerdiği görülmüş ve veri setinde çeşitlilik sağlanacağı düşünülmüştür. Bu nedenle veri setinin yapay zekanın eğitim ve test aşamalarında kullanılmasına karar verilmiştir. Veri setindeki görüntülerden çekim açısının yarışmaya uygun olmayanları ayıklanmış ve Phoneix II'nin muazzam veri setine eklenmiştir.
- **Cars Overhead With Context (COWC) [7] Veri Seti:** Nesne tespiti yapması istenilen yapay zeka modellerinin eğitim ve test aşamalarında kullanılması için oluşturulmuş veri seti 6 farklı konumdan toplam 32,716 farklı araba içermekle nitelik ve nicelik açısından son derece iyi veriler sunmaktadır. Veri setindeki görüntülerin boyutları ve çekim açıları yarışmaya oldukça uygundur. Bu nedenle verilerin etiketleri Phoneix II'nin kullanabileceği şekilde düzenlenmiş ve esas veri setine ilave edilmiştir.

3.2. Algoritmalar

3.2.1. Scaled-YOLOv4


Üstün başarılı Phoneix II yapay zeka modelinin eğitiminde kullanılan Scaled-YOLOv4 algoritması seçilme nedenleriyle birlikte açıklanmış ve yapılan testlerin sonuçlarıyla takımın hedefi olan birinciliğe ulaşabileceği somut verilerle açıklanmıştır.

Ön tasarım raporu aşamasında YOLOR algoritmasının kullanılacağı belirtilmiş fakat kritik tasarım raporu aşamasında yapılan literatür taramaları sayesinde güncel bir algoritma olan YOLOR'u konu alan makale ya da kaynakların yeterli sayıda olmadığı görülmüştür. SoftWave takımı ileride karşılaşılabilecek problemlerin çözümü için yeterli kaynağın olmaması durumunu da göz önünde bulundurarak projenin geleceğini riske atmamış, YOLOR algoritmasının alternatiflerini incelemiştir. Bu doğrultuda Scaled-YOLOv4, EfficientDet [8], Faster RCNN [9] algoritmalarının karşılaştırılmasına karar verilmiştir. Yapılan literatür taramaları ve karşılaştırmalar sonucu Scaled-YOLOv4 algoritmasının EfficientDet ve Faster RCNN algoritmalarına göre hatırı sayılır miktarda tutarlı ve hızlı olduğu görülmüştür. Ardından Scaled-YOLOv4 algoritması üzerine yoğunlaşmış, algoritmanın YOLOR

algoritmasına göre tutarlılığı daha yüksek fakat hızı göz ardı edilebilecek miktarda yavaş olduğu sonucuna ulaşılmıştır. Scaled-YOLOv4 algoritması hakkında yazılan makalelerin, oluşturulan kaynakların sayısının YOLOR'a göre oldukça fazla olduğu görülmüştür. Scaled-YOLOv4 algoritmasının Phoneix II'nin sistem mimarisine uygunluğu gözetilmiş, bu doğrultuda testler yapılmış ve hızının, tutarlılığının yeterli düzeyde olduğu görülmüştür. (Sözü edilen testler bu bölümde paylaşılacaktır.) Bu nedenlerden dolayı hedefi birincilik olan SoftWave takımı tarafından yapay zekanın eğitimi ve testlerinde Scaled-YOLOv4 algoritmasının kullanılmasına karar verilmiştir.

Scaled-YOLOv4 algoritması, açılımı "You Only Look Once" olan YOLO algoritmasının geliştirilmiş ve güncellenmiş versiyonlarından biri olan YOLOv4 ağının derinliği, genişliği, çözünürlüğü ve yapısı düzenlenerek oluşturulmuştur. Scaled-YOLOv4, CSPNet[10] ağ yapısını temele alarak bulut GPU için tasarlanmış bir algoritmadır. Açılımı "Cross Stage Partial Network" olan CSPNet, tutarlılık gözetilirken karmaşıklığın önlenmesi ve kendi içindeki gradyan bilgilerinin çoğaltılması için oluşturulmuş bir ağ yapısıdır. Scaled-YOLOv4 algoritmasının ağ mimarisi yukarıda sunulmuştur.

Algoritma Microsoft COCO[11] veri seti ile yapılan testlerden %55,8 ortalama hassasiyet değerine sahiptir. Bu durum Scaled-YOLOv4'ün son derece tutarlı olduğunu gözler önüne sermektedir. Aynı zamanda algoritma her bir saniyede 15 ile 1774 kare arasında tespit yapmaktadır, bu sayede oldukça hızlı bir algoritma olarak dikkat çekmektedir.



Şekil 1. Scaled-YOLOv4 Algoritması

3.2.2. Hatalı Tespitleri Ayıklama Algoritması

Bu bölümde hatalı tespitlerin yani "false positive" durumlarının ayıklanması için kullanılacak olan algoritmanın detaylarına yer verilmiştir.

Hatalı tespitleri ayıklama algoritması olarak isimlendirilen bu algoritma; standart bir nesne tespit modeline ek olarak özellikle insan ve taşıt sınıfları için asıl sınıflarla karıştığı tespit edilen her türlü hatalı tespitin ayıklanmasında kullanılacak ikincil birer nesne tespit modelinin kullanılması prensibine dayanmaktadır. Bu ikincil modeller, testler sonucu asıl sınıflarla karıştığı tespit edilen nesneleri bulacak şekilde eğitilecektir. Algoritma, asıl nesne tespit algoritması işini tamamladıktan sonra devreye girecek şekilde tasarlanmıştır. Çalışma mantığı adım adım şu şekildedir: İlk olarak üzerindeki asıl nesne tespiti işlemi tamamlanmış olan mevcut kare, karışan sınıfları ayıklamak için eğitilmiş olan nesne tespit algoritmasına verilir. Ardından bu algortmadan elde edilen nesne tespit çıktılarına ait kutuların, asıl nesne tespit algoritmasından gelen kutularla kesişimlerinin birleşimlerine oranı hesaplanır. Son olarak hatalı tespitlere ait olan kutularla yapılan bu hesaplamaları önceden belirlenmiş bir eşik değerine eşit veya bu değerin üzerinde olan asıl nesne tespitlerine ait kutular, "false positive" olarak işaretlenir ve sitem tarafından sonraki aşamalarda ihmal edilecek biçimde ayıklanır.

3.2.3. Maksimum Olmayan Bastırma [12]

Yapay zeka modelinin çıktıları incelendiğinde bir nesne için birden fazla sınırlayıcı kutu çizebildiği ve bu durumun takıma puan kaybettirebileceği fark edilmiştir. Bu ihtimalin ortadan kaldırılabilmesi ve takımın hedeflediği birinciliğe ulaşabilmesi için yapay zekanın çıktılarına maksimum olmayan bastırma algoritmasının uygulanmasına karar verilmiştir. Algoritmanın ilk adımı, bir kare içindeki en yüksek yüksek güven puanına sahip olan sınırlayıcı kutunun seçilmesidir. Ardından bu sınırlayıcı kutu ile bunun dışındaki aynı sınıflı en yüksek güven puanına sahip olan sınırlayıcı kutunun kesişime birleşimi oranı hesaplanır. Hesaplanan kesişimin birleşime oranı, yapılan testler sonucu belirlenen bir eşik değeri ile karşılaştırılır. Bu karşılaştırma sonucu kesişimin birleşime oranının daha büyük olması durumunda oranın hesaplandığı sınırlayıcı kutulardan daha düşük güven puanına sahip olan sınırlayıcı kutu, yüksek güven puanlı sınırlayıcı kutu ile aynı nesneye ait olduğu için yapay zekanın çıktılarından çıkarılır ve yarışma komitesine gönderilmez. Bu işlemler ilk başta seçilen nesne ile aynı sınıflı olan her bir sınırlayıcı kutu için, aynı sınıflı başka sınırlayıcı kutu kalmayana kadar uygulanır. Daha sonrasında algoritmanın adımları karedeki bütün farklı sınıflı sınırlayıcı kutular için uygulanır. Maksimum olmayan bastırma algoritması yarışma komitesine gönderilen çıktılarda her nesne için yalnızca bir sınırlayıcı kutu olmasını ve bu sınırlayıcı kutunun güven puanının en yüksek olmasını sağlayarak Phoneix II'nin genel başarısını bir üst düzeye taşır.

3.2.4. Algılama Sonrası İzleme Algoritması

Bu bölümde takım tarafından özgün biçimde tasarlanmış olan “Algılama Sonrası İzleme Algoritması”nın detayların yer verilmiştir. Bu algoritmanın sisteme entegre edilmesindeki temel amaç yarışma sırasında meydana gelebilecek “False Negative” durumlarını önlemektir.

Algoritma; temelde 80 karede bir, bu 80 karede tespit edilmiş olan nesnelerin nesne takip yöntemleri yoluyla eşleştirilmesi, ardından bu karelerdeki eksik tespitlerin, halihazırda yapılan tespitlere ait sınırlayıcı kutuların konumları üzerinde interpolasyon uygulanması yoluyla belirlenmesi ve belirlenen bu alanlarda yeniden nesne tespit işleminin yapılması yoluyla tespit eksikliğinin giderilmesi prensibine dayanmaktadır. İşlemin daha fazla ya da daha az kare yerine 80 karede bir uygulanacak şekilde tasarlanmasındaki amaç hem algoritmanın çalışma sıklığının düşürülmesini sağlama yoluyla sistemin genel hızını artırmak hem de genel sistem işleyişinin belirlenen süre içerisinde tamamlanamaması durumunda hasarı asgari düzeyde tutmaktır. Algoritma nesne tespiti sonucu elde edilen sınırlayıcı kutular ve sunucudan alınan kareler temelinde çalışmakta olduğu için nesne tespit işlemi süresince hem kareler hem de kutular ayrı birer listeye kaydedilmektedir. Algoritma 80. ve 80'nin katlarındaki sıralarda bulunan karelere standart tespit işlemi uygulandıktan hemen sonra devreye girecek şekilde tasarlanmıştır. Algoritmanın devreye girdikten sonraki işleyişi aşağıda adım adım verilmiştir:

Algoritma öncelikle kutuların kaydedildiği listede bulunan tüm kutuları, kendisinden önce gelen karelerde bulunan kutulardan en uygun olanı ile eşleştirmeye çalışır. Bu eşleştirme için bir “izleme listesi” kullanılır. Bu liste temelde aynı özgül nesneye ait olan ancak farklı karelerde bulunan sınırlayıcı kutuların bulunduğu dizileri içerir. Algoritma, her bir sınırlayıcı kutuyu bu dizilerin son elemanları ile eşleştirilmeye çalışır. Bu eşleştirme için öncelikle daha yeni olan karede bulunan sınırlayıcı kutulardan birinin belirlediği alan kareden kesilir. Ardından tek tek daha eski olan kareye ait olan sınırlayıcı kutuların belirlediği alanlar kesilir. Daha yeni olan karede kesilmiş olan alan ve daha eski olan karede kesilmiş olan alanlar, aralarındaki benzerlik miktarının tespit edilmesi amacıyla tek tek “feature matching”[13] ve “histogram”[14] karşılaştırma işlemlerine tabii tutulur. Bu noktada arka arkaya gelen kareler üzerinden bir hesaplama yerine biri diğerinden yeni olan herhangi iki karede bulunan alanlar arasındaki görsel benzerlik miktarı üzerinden bir takip yöntemi kullanılmasıdaki amaç, özgül bir nesnenin tespit edilemediği kare aralığının fazla olması durumunda bile sınırlayıcı kutuların başarılı biçimde eşleşmesini ve özgül nesneye ait dizinin eksiksiz biçimde oluşturulmasını sağlamaktır. Bu işlemler sonucunda iki alandaki görsellerin uyumuna göre bir başarı puanı elde edilir. Bu başarı puanı daha yeni olan karedeki tüm sınırlayıcı kutular için hesaplanır ve aşağıda verilene benzer bir “Başarı Puanı Matrisi” elde edilir.

Bu matriste satırlar daha yeni karedeki sınırlayıcı kutuları, sütunlar ise daha eski karedeki sınırlayıcı kutuları ifade eder. Kesişimleri ise bu iki sınırlayıcı kutunun sınırladığı alanların benzerliğini veren başarı puanıdır. Bu matris yardımıyla daha yeni olan karedeki tüm sınırlayıcı kutular daha eski karedeki kutulardan; başarı puanı önceden belirlenmiş bir eşik değerine eşit veya üzerinde olan, en uygun kutu ile eşleştirilir. Ardından daha yeni karedeki kutu, eşleştirilen eski kareye ait kutunun izleme listesinde bulunduğu dizinin en sonuna, aynı özgül nesnenin daha yeni bir karedeki devamı olarak

eklenir. Daha yeni olan karedeki sınırlayıcı kutulardan, daha eski karede bulunan tüm sınırlayıcı kutulara göre hesaplanan başarı puanları eşik değerinin altında olanlar ise daha önceki karelerde bulunmayan yeni bir özgül nesne olarak belirlenir ve izleme listesine yeni bir dizinin ilk elemanı olarak eklenir. Bu işlemin 80 kare için de tamamlanmasıyla interpolasyona uygun, nihai bir izleme listesi elde edilir.

	Daha Eski Karedeki 1. Kutu	Daha Eski Karedeki 2. Kutu
Daha Yeni Karedeki 1. Kutu	5123.7	12.1
Daha Yeni Karedeki 2. Kutu	127.5	12657.9
Daha Yeni Karedeki 3. Kutu	0.0	322

Tablo 1. İzleme Algoritması Örnek Başarı Puanı Matrisi

Bu aşamadan sonra algoritma interpolasyon aşamasına geçer. Bu aşamada öncelikle izleme listesinde bulunan dizilerden içerisinde kare atlama olan, yani art arda gelen elemanlarından bazılarının karelerinin ardışık olmadığı durumlar içerenler interpolasyona tabii tutulmak üzere belirlenir. Ardından belirlenen dizilerdeki sınırlayıcı kutuların başlangıç ve bitiş noktalarının koordinatları tek tek “küçük” interpolasyona tabii tutulur. Bu interpolasyon işlemi sonucunda tespit edilememiş nesnelere ait olası sınırlayıcı kutu koordinatları belirlenmiş olur. Belirlenen bu olası kutuların öncelikle, kendisiyle aynı karede bulunan halihazırda tespit edilmiş nesnelere ait sınırlayıcı kutularla kesişiminin birleşimine oranı hesaplanır. Bu hesaplama sonucu elde edilen değerin belirli bir değerin üzerinde olduğu kutular, izleme işlemi sonucunda eksik olduğu belirlenen bu kutunun aslında halihazırda tespit edilmiş kutular içerisinde olduğunu ifade eder. Dolayısıyla bu tahmini kutu aynı nesne için birden fazla tahmin yapılmasını engellemek amacıyla algoritmanın sonraki aşamalarında ihmal edilir. Belirlenen bu koordinatların uygun karelerde sınırladığı alanların kesilip algılamayı kolaylaştırabilecek ön işlemlere tabii tutulduktan sonra yeniden nesne tespit algoritmasına verilmesi sonucu yapılan yeni tespitler de sonuçlar listesine eklenir ve algoritma tamamlanır.

4. ÖZGÜNLÜK

4.1. Veri Seti Oluşturma

Phoneix II'nin eğitim ve test aşamalarında kullanılacak esas veri setine, “Veri Setleri” kısmında açıklananlar dışında takımın kendi topladığı ve her bir nesnesini etiketlediği veri seti ilave edilmiştir. Sözü edilen özgün veri seti herhangi bir kişi veya topluluk tarafından oluşturulmamış, etiketlenmemiştir. Bu sayede esas veri setinde üst düzey çeşitlilik sağlanmış ve yapay zeka modellerinin farklı senaryolarla eğitimi, testleri yapılmıştır.

4.2. Veri Artırma

Birinciliği hedefleyen takımın kendi oluşturduğu ve çeşitli kaynaklardan topladığı veri setlerinin bir araya getirilmesi ile oluşan esas veri setinin niceliği, niteliği detaylı bir şekilde incelenmiştir. Veri sayısı yeterli olduğu görülmüş fakat verilerin sahip olduğu senaryoların çeşitlendirilebileceği fark edilmiştir. İncelemenin sonuçlarına göre esas veri seti belirli veri gruplarına ayrılmış, bu gruplara özel aşağıda açıklanan veri artırma işlemleri uygulanmıştır. Renk değiştirme, esas veri setindeki taşıt nesnelerinin renklerinin çeşitliliğinin artırılması amacıyla taşıt yoğunluklu veri gruplarına uygulanmıştır. Döndürme, yarışma esnasında verilecek görüntülerdeki taşıt ve insan sınıflı nesnelerin görünüş açılarının değişebileceği düşünüldüğünden bu nesnelerinin öne çıktığı veri setlerine uygulanmıştır. Kar veya yağmur yağışlı hava durumu ekleme, Phoneix II'nin tespit yapması gereken görüntülerde hava durumu şartları değişkenlik gösterebileceği için uygulanmıştır. Parlaklık değiştirme ise yarışma sırasında sunucudan alınan verilerde ışık açısı, miktarı farklılık gösterebileceğinden çeşitlilik amaçlanmıştır. Açıklanan her veri artırma işlemi takım tarafından yazılan kodlar sayesinde uygulanmıştır.

4.3. K-Fold Cross-Validation[15]

Esas veri setinin eğitim-test verileri olarak bölünmesi için son derece başarılı olan K-Fold Cross-Validation yöntemi kullanılmıştır. Bu validasyon yönteminde veri seti $k = 10$ veri grubuna ayrılmış ve bu veri grupları “Dataset_1, Dataset_2... Dataset_10” olarak isimlendirilmiştir. Ardından bir veri grubu (örneğin: Dataset_1) dışındaki bütün veri grupları ($k - 1 = 9$ adet veri grubu) ile yapay zeka eğitilmiştir.

Sonrasında eğitim veri setine katılmayan (Dataset_1) veri grubu ile yapay zeka modeli test edilmiştir ve modelin başarısı hesaplanmıştır. Bu işlemler her bir veri grubunun Dataset_1 yerine seçilmesi ile tekrarlanmış ve hesaplanan başarı değerleri karşılaştırılmıştır. Son olarak karşılaştırma sonucu en tutarlı çıktıları sağlayan modelin eğitiminde ve testinde kullanılan veri grupları belirlenmiştir. Bu sayede en başarılı eğitim-test kombinasyonu bulunmuştur.

4.4. Algılama Sonrası İzleme Algoritması

Bu bölümde “Algoritmalar” bölümünde detaylı biçimde açıklanmış olan algılama sonrası izleme algoritmasının özgün yanlarından bahsedilmektedir.

Bu algoritmanın en önemli yönü nesne tespit algoritmalarının en büyük sorunlarından biri olan “False Negative” durumlarını, makine öğrenmesinin önemli bir dalı olan nesne takip işlemi yardımıyla gidermesidir. Bu anlamda nesne takip işleminin yarışma sistemine entegrasyonu yönünde önemli bir özgünlük sunmaktadır. Dahası yaygın nesne takip metotları yerine yarışma gereksinimleri özelinde yeni metotlar geliştirilmiştir. Bunlardan en önemlisi kareler arasında aynı özgül nesnelere ait ana nesne tespitlerinin eşleştirilmesi amacıyla kullanılan ve aradaki kare sayısından bağımsız biçimde, art arda gelmeyen karelerdeki tespitlerin de eşleştirilebilmesini sağlayan görsele dayalı bir alan eşleştirme yönteminin kullanılmasıdır. “Feature matching” ve histogram eşleştirme işlemlerine dayanan bu yöntem sayesinde her bir özgül nesne için ana nesne tespit işlemi sonucu tespit edilemedikleri karelerin bulunabilmesi sağlanmıştır. Bu özgün çözüm de yine “Algoritmalar” bölümünde detaylıca açıklanmıştır.

Algoritmanın yarışma konseptine entegrasyonu anlamında sunduğu en göze çarpan yeniliklerden biri ise ana nesne tespit işlemleri sonucu tespit edilemeyen karelerin tahmini konumlarının oldukça tutarlı biçimde elde edilebilmesini sağlayan ve “Algoritmalar” bölümünde detaylı biçimde açıklanmış olan interpolasyon işleminin kullanılmasıdır. Bu tahmini kutuların veri artırma yöntemleri ile bir daha nesne tespit işlemine tabii tutulmasıyla sonlanan algoritma görüldüğü gibi tamamen yenilikçi ve mantıklı temeller üzerine inşa edilmiştir.

4.5. Hatalı Tespitleri Ayıklama Algoritması

Bu bölümde “Algoritmalar” bölümünde detaylıca açıklanmış olan hatalı tespitleri ayıklama algoritmasının özgün yanlarından bahsedilmektedir.

Bilindiği gibi nesne tespit algoritmalarının karşılaştığı en büyük problemlerden biri “False Positive” algılamalardır. Algoritma, bu hatalı tespitlerin giderilmesi için çok sayıda nesne tespit işleminin kullanılmasına dayanan ve “Algoritmalar” kısmında detaylı biçimde yer verilen özgün bir anlayış benimsenerek geliştirilmiştir. Bu birden fazla algoritma kullanımı elde edilen nesne tespit çıktılarının kullanım biçimini de içeren algoritma yapısı da tamamen takım tarafından tasarlanmıştır.

Bu algoritma ve bir önceki bölümde yer verilmiş olan “Algılama Sonrası İzleme” algoritmasının en çarpıcı yanı ise, birlikte kullanıldıklarında bir nesne tespit algoritmasının temel problemleri olan “False Positive” ve “False Negative” durumlarının ikisinin de büyük oranda giderilmesini sağlamalarıdır.

5. SONUÇLAR VE İNCELEME

5.1. Asıl Nesne Tespiti Testleri

SoftWave takımı tarafından tasarlanan sistem mimarisi birçok sayıda özgün modüller ve dosyalardan oluşturulmuştur. Bu dosya ve modüllerin senkronize bir şekilde çalıştığının, hedeflenen süreler içinde hedeflenen görevlerin gerçekleştirilmesinin teyit edilmesi ve gerekli iyileştirmelerin yapılması için testler yapılmıştır. Söz edilen testler takımın belirlediği bir sunucu üzerinden veriler alınarak gerçekleştirilmiştir. Alınan veriler raporda detaylıca açıklanan tüm algoritmalara girdi olarak verilmiştir. Ardından bütün algoritmalar sorunsuz bir şekilde çalışmış ve bunun doğrulanması için gerekli belirteçler kontrol edilmiştir. Sonrasında istenilen format olan JSON dosyası biçimindeki çıktı yine takım tarafından belirlenen bir sunucuya gönderilmiştir. JSON dosyasının içeriği kontrol edilmiş ve şartnameye uygun olduğu görülmüştür.

Sistem mimarisini oluşturan bileşenlerin senkronize bir şekilde çalıştığı teyit edildikten sonra Scaled-YOLOv4 algoritması ile farklı çözünürlüklü verilerle eğitilen yapay zeka modellerinin tutarlılığı ve hızları test edilmiştir. Bu testlerdeki amaç hangi çözünürlüklü modellerin Phoneix II'nin sistem mimarisi için en uygun olduğunu bulmaktır. Sözü edilen çözünürlükler şunlardır: 896, 608, 512, 416. Testler yapılırken test veri setinden rastgele seçilen 80 karelik veri grupları kullanılmıştır. Aşağıda testlerin yapıldığı verilerden birkaç örnek verilmiştir.



Şekil 2. Asıl Nesne Tespiti Test Sonuçları



Şekil 3. Asıl Nesne Tespiti Test Sonuçları

Yapılan test sonuçları aşağıdaki tabloda sunulmuştur.

Test Edilen Modelin Çözünürlüğü	Saniye Başına Tespit Yapılan Kare	Taşıt Nesneleri için mAP	İnsan Nesneleri için mAP
896	1,848	%78	%73
608	1,893	%73	%64
512	2,049	%65	%60
416	2,114	%59	%55

Yukarıda verilen test sonuçları incelendiğinde saniye başına tespit yapılan kare sayıları arasında çok fazla fark olmadığı görülmüş fakat mAP verileri incelendiğinde hatırı sayılır farklara rastlanmıştır. Farklı çözünürlüklü modellerin tamamının saniye başı tespit yaptığı kare sayıları sistem mimarisinin başarısı için hedeflenen 1,80 değeri ile örtüşmektedir. Diğer yandan mAP verileri incelendiğinde hedeflenen %71 değerinin altındaki modeller seçenekler arasından kaldırılmıştır. Bu eleme sonuçlarına göre insan nesnelerinin tespitini yapacak olan modelin 896 çözünürlüklü verilerle eğitilmesine, taşıt tespitini yapacak olan modelin (hız faktörü de göz önünde bulundurularak) 608 çözünürlüklü verilerle eğitilmesine karar verilmiştir. İnış alanı tespiti için ise 320 çözünürlüklü verilerle eğitilen modele yapılan testlere göre son derece başarılı sonuçlar elde edildiği görülmüş ve inış alanı tespitini yapacak olan modelin 320 çözünürlüklü verilerle test edileceği kararlaştırılmıştır.

5.2. Sistem Hız Testleri ve Optimizasyonlar

Phoenix II sistemi maksimum performans ve tutarlılık için tasarlanmıştır ve kareler üzerinde gerçekleştirdiği işlem sayısı görece fazladır. Bu durum yarışma süresi de göz önüne alındığında belli başlı alanlarda hız testlerini mecburi kılmış ve bu testler sonucunda bu alanlarda optimizasyon ihtiyaçları ortaya çıkmıştır. Bu testler ve optimizasyonlar, aşağıda detaylıca açıklanmış olan ve sistemin çalışma süresine yüksek miktarda etki ettiği gözlemlenen alanlar üzerine yoğunlaşmış olup bu bölümde bu testlerden ve optimizasyonlardan bahsedilecektir. Testlerin tamamı yarışma sırasında da kullanılacak olan MONSTER TULPAR T5 V19.1 laptop üzerinde gerçekleştirilmiştir. Bu cihaz NVIDIA GEFORCE GTX 1660ti ekran kartı, INTEL CORE I7-9750H işlemci ve 16GB DDR4 RAM ihtiva etmektedir.

Üzerinde testler ve optimizasyonlar gerçekleştirilen ilk alan asıl nesne tespiti bölümüdür. Bu bölüm 3'ü temel, 2'si ise ayıklamada kullanılacak olan toplam 5 adet nesne tespit algoritmasının çalıştırılması ile başlamakta olup bu kısmın 1000 kare ile yapılan testlerde ortalama çalışma süresinin 0.24 saniye olduğu tespit edilmiştir. Bu noktada temel hız optimizasyonu Scaled-YOLOv4 algoritmasının kullanımı ile olmuştur. Asıl nesne tespit alanında temelde optimizasyona tabii tutulan bölüm ise nesne

tespit algoritmasının çıktılarından güven puanı belli bir eşik değerine eşit veya eşik değerinin üzerinde olan algılamaların seçilmesini sağlayan kod parçasıdır. Bu kısmın optimizasyona tabii tutulmadan önce 1000 kare ile yapılan testlerinde, kare başına ortalama 0.087 saniyelik bir çalışma süresine sahip olduğu görülmüştür. Bu kısım hem normal Python listelerinden çok daha hızlı biçimde çalışan “Numpy Array” yapıları kullanılarak yeniden yazılmış hem de Python fonksiyonlarının “C” dilinde derlenmesini sağlayarak hızlarını artıran “Numba” kütüphanesi ile hızlandırılmış, sonuçta çalışma süresi etkileyici bir süre olan ortalama 0.014 saniyeye düşürülmüştür. Asıl nesne tespit bölümünün son kısmı olan maksimum olmayan bastırma kısmı ise zaten yeterince hızlı bir süre olan ortalama 0.000044 saniyede çalışması sebebiyle herhangi bir hız optimizasyonuna tabii tutulmamıştır. Bu optimizasyonlar sonucunda asıl nesne tespitleri bölümünün tüm işlemleriyle kare başına ortalama çalışma hızının, ortalama 0.386 saniyeden yaklaşık %35’lik bir iyileşme oranı ile 0.254 saniyeye düştüğü görülmüştür.

Testlere ihtiyaç duyulan diğer bir alan ise “Algılama Sonrası İzleme” algoritmasını ihtiva eden kod parçasıdır. Bu bölüm “Feature Matching”, histogram çıkarma, izleme listesi oluşturma, interpolasyon gibi birçok aşamadan oluşmaktadır ve dolayısıyla herhangi bir optimizasyona tabii tutulmadan önce, kare başına ortalama 0.22 saniye gibi uzun bir sürede çalıştığı görülmüştür. Bu sürenin azaltılması amacıyla standart Python listeleri yerine daha hızlı çalışan “Numpy Array”leri kullanılmıştır, algoritma her bir sınıf için ayrı ayrı çalıştırılacak şekilde düzenlenmiş, böylece kutu kombinasyonu sayısı azaltılmıştır. Ek olarak, işlemin en uzun süren kısmı olan “feature matching”in daha kısa sürmesi amacıyla görseller, çözünürlükleri istenen başarıyı sağlayabilecek kadar düşürülerek (En ideal değer 40 x 40 piksel olduğu görülmüştür.) işleminden geçirilmiştir. Yapılan testlerde optimizasyon sonrası sadece izleme listesi çıkarma işleminin, tek bir kare için ortalama 0.07 saniye, toplam 4500 kare için ortalama 315 saniye sürdüğü görülmüştür. İnterpolasyon işlemi ile birlikte ise tüm algılama sonrası izleme işleminin tek bir kare için yaklaşık ortalama 0.11 saniye, 4500 kare için ise interpolasyon sonrası gerçekleştirilecek nesne tespitleri hariç ortalama 512 saniye sürdüğü görülmüş, böylece işlemin belirlenen zaman diliminde sorunsuz biçimde tamamlanabileceği kanıtlanmıştır. Tüm testler sonucunda ise tek bir kareye uygulanan tüm işlemlerin ortalama kare başına 0.365 saniye, 4500 kare için ise ortalama 1642 saniye olduğu görülmüştür. Bu süre ortaya çıkabilecek gecikmeler ve kare alım gönderim işlemleri dikkate alındığında oldukça iyi bir süredir.

5.3. Algılama Sonrası İzleme Algoritması Testleri


Algılama sonrası izleme algoritması yazılımsal olarak çok sayıda bileşenden oluşmaktadır. Bu nedenle tüm bileşenlerin uyumlu ve sorunsuz bir biçimde çalışacağından emin olmak için algoritma üzerinde bölüm bölüm olacak şekilde işleyiş testleri gerçekleştirilmiştir. Testler ilk olarak sadece nesne takip kısmının işleyişi üzerine, ikinci olarak sadece interpolasyon kısmının işleyişi üzerine yöneltilenektir. Bu bölümde bu testlere ve sonuçlarına yer verilmiştir.

Nesne takip kısmında kullanılan “Feature Matching” ve histogram eşleştirme yöntemleri görselden görsele değişebilen niteliktedir ve dolayısıyla takip işleminin farklı senaryolarla testini zorunlu hale getirmektedir. Kameranın düz ilerlediği ve kameranın dönme durumu gösterdiği iki farklı video ile testler yapılmıştır. Testler “Algoritmalar” bölümünde bahsedildiği gibi 40x40’lık görsellerle yapılmıştır.



Şekil 4. İzleme Test Sonuçları


Yukarıda verilen sonuçlarda görsellerin kenarındaki numaralar kare sırasını göstermektedir. Art arda gelen görsellerdeki aynı renkli sınırlayıcı kutular aynı özgül nesneleri belirtmektedir. Görülebileceği gibi sistem son derece başarılıdır. İnterpolasyon testleri ise aşağıda verilmiş olan test amaçlı etiketlenmiş kareler üzerinde gerçekleştirilmiştir. Çizilen mavi kutular zaten mevcut olan etiketlemeleri ifade etmekte olup kırmızı kutular, atlama durumunda çizilen oldukça başarılı tahminleri göstermektedir.




Şekil 5. İnterpolasyon Test Sonuçları

5.4. Hatalı Tespitleri Ayıklama Algoritması Karışanlar Tespiti


Hatalı tespitleri ayıklama algoritmasında kullanılacak olan ve “Algoritmalar” kısmında detaylı biçimde belirtilmiş olan ikinci modellerin eğitimi için hangi sınıfların kullanılacağı aşağıda verilen testler sonucu belirlenmiştir. Bu testler insan ve taşıt yoğunluğu fazla olan veri setleri ile gerçekleştirilmiştir. Sonucunda aşağıda verilen şekillerde de görülebileceği gibi taşıt sınıfı için “Pencere” ve “Konteyner” nesnelerinin, insan sınıfı için ise özellikle “Çalı” ve “Direk” nesnelerinin karışma sebebi olduğu tespit edilmiştir. Test sonuçları sadece belirtilen sınıfa ait sonuçları içermektedir.



Şekil 6. Taşıt Konteyner Karışma Örneği



Şekil 7. Taşıt Pencere Karışma Örneği



Şekil 8. İnsan Çalı Karışma Örneği



Şekil 9. İnsan Direk Karışma Örneği

6. KAYNAKÇA

0. Chien-Yao Wang, I-Hau Yeh, & Hong-Yuan Mark Liao (2021). You Only Learn One Representation: Unified Network for Multiple Tasks. *CoRR*, *abs/2105.04206*.
1. Chien-Yao Wang, Alexey Bochkovskiy, & Hong-Yuan Mark Liao (2020). Scaled-YOLOv4: Scaling Cross Stage Partial Network. *CoRR*, *abs/2011.08036*.
2. Google COLABORATORY PRO, <https://colab.research.google.com>
3. Dawei Du, Longyin Wen, Pengfei Zhu, Heng Fan, Zhiwei Wei, & Zhiyuan Zhao (2021). VisDrone-CC2020: The Vision Meets Drone Crowd Counting Challenge Results. *CoRR*, *abs/2107.08766*.
4. Stanford Dataset, <https://snap.stanford.edu/data/>
5. VCI – CTR Dataset, <https://github.com/dongfang-steven-yang/vci-dataset-citr>
6. PKLot Dataset, <https://public.roboflow.com/object-detection/pklot>
7. COWC Dataset, <https://gdo152.llnl.gov/cowc/>
8. Mingxing Tan, Ruoming Pang, & Quoc V. Le. (2020). EfficientDet: Scalable and Efficient Object Detection.
9. Shaoqing Ren, Kaiming He, Ross Girshick, & Jian Sun. (2016). Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks.
10. Chien-Yao Wang, Hong-Yuan Mark Liao, I-Hau Yeh, Yueh-Hua Wu, Ping-Yang Chen, & Jun-Wei Hsieh. (2019). CSPNet: A New Backbone that can Enhance Learning Capability of CNN.
11. Tsung-Yi Lin, Michael Maire, Serge Belongie, Lubomir Bourdev, Ross Girshick, James Hays, Pietro Perona, Deva Ramanan, C. Lawrence Zitnick, & Piotr Dollár. (2015). Microsoft COCO: Common Objects in Context.
12. Non-Max Suppression, <https://paperswithcode.com/method/non-maximum-suppression>
13. Ana Huaman. (2022). Feature Matching with FLANN: https://docs.opencv.org/4.x/d5/d6f/tutorial_feature_flann_matcher.html
14. OpenCV. (2022). Histograms - 1: https://docs.opencv.org/4.x/d1/db7/tutorial_py_histogram_begins.html
15. Berrar, Daniel. (2018). Cross-Validation. 10.1016/B978-0-12-809633-8.20349-X.