

TEKNOFEST
HAVACILIK, UZAY VE TEKNOLOJİ
FESTİVALİ
ULAŞIMDA YAPAY ZEKA YARIŞMASI
KRİTİK TASARIM RAPORU

TAKIM ADI: FEZA
BAŞVURU ID: 320512



İÇİNDEKİLER

1. TAKIM ŞEMASI	3
2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ	3
3. ALGORİTMALAR VE SİSTEM MİMARİSİ	4
3.1. Veri Setleri.....	4
3.2. Algoritmalar	4
4. ÖZGÜNLÜK	7
5. SONUÇLAR VE İNCELEME	7
6. KAYNAKÇA.....	10

ŞEKİL LİSTESİ

Şekil 1: Yarışmada kullanılacak olan algoritmanın tasarımı	6
Şekil 2:Tasarlanan algoritmanın yarışma tarafından paylaşılan örnek videodan alınmış görüntüde gösterdiği nesne tespit başarısı örneği	9
Şekil 3: Tasarlanan algoritmanın yarışma tarafından paylaşılan örnek videodan alınmış görüntüde gösterdiği nesne ve pist tespit başarısı örneği.....	10
Şekil 4: Şekil 3’de tespit edilen UAİ ve UAP alanlarının PADIM-UAİ ve PADIM-UAP ile gerçekleştirilmiş iniş durum tespiti çıktıları	10

TABLO LİSTESİ

Tablo 1: Takım şeması.....	3
Tablo 2: Nesne ve pist tespiti için tasarlanan ve kullanılan algoritmaların özellikleri.....	5
Tablo 3: Pist iniş durum tespiti için eğitilen modelin özellikleri.....	6
Tablo 4: Nesne ve pist tespiti için tasarlanan algoritma kombinasyonlarının eğitim başarı testi sonuçları.....	7
Tablo 5: Nesne ve pist tespiti için eğitilen modellerin test başarıları sonuçları.....	8
Tablo 6: Pist iniş durum tespiti için eğitilen modellerin test başarı sonuçları	9

KISALTMALAR

KISALTMALAR	AÇILIMI
TPH-YOLOV5	Transformer Prediction Head You Only Look Once Version 5
UAV	Unmanned Aerial Vehicle
AFO	Aerial Floating Objects
VAN	Visual Attention Network
BiFPN	Bidirectional Feature Pyramid Network
PANet	Path Aggregation Network
FPN	Feature Pyramid Network
TOOD	Task-aligned One-stage Object Detection
YOLO-head	You Only Look Once Head
WBF	Weighted Boxes Fusion
PADIM	Patch Disribution Modeling
T-head	Task-aligned One-stage Object Detection Head
UAP	Uçan Araba Park
UAİ	Uçan Ambulans İniş
AUROC	Area Under the Receiver Operating Characteristic Curve
bbox-mAP	Bounding Box Mean Average Precision
Mb	Megabyte
dk	Dakika
sn	Saniye
İt/s	Iterations/ Second

1. TAKIM ŞEMASI

Takım Üyeleri	Görev
Takım Kaptanı	Koordinatörlük, Rapor Hazırlama, Yapay Zeka Algoritma Tasarımı
İletişim Sorumlusu	İletişim Sorumlusu, Görev Takip, Etiketleme, Rapor Denetleme
Üye 1	Etiketleme, literatür Araştırması, Veri Seti Araştırması
Üye 2	Etiketleme, Yapay Zeka Algoritma Tasarım Desteği, Algoritma Testi
Üye 3	Etiketleme, Rapor Denetleme, Algoritma Testi

Tablo 1: Takım şeması

2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ

Ulaşımda yapay zeka yarışması kapsamına uygun olarak başarılı bir nesne tespit algoritması tasarlayabilmek için ön tasarım raporundaki hedeflere ulaşıldı ve testler yapıldı.

İlk hedef, eğitimde kullanılacak olan veri setini oluşturmaktır. Veri seti oluşturulurken yarışmaya uygun verilerin seçilmesine özen gösterildi. İnsan ve taşıt sınıflarından oluşan ve drone ile çekilmiş görüntülere sahip olan VisDrone [1] veri seti hazır etiketleriyle birlikte eğitim verisi olarak, yarışma kapsamında paylaşılan örnek video görüntülere bölünerek test verisi olarak veri setine eklendi. Test verisinin etiketi yapılırken TPH-YOLOV5 [2] modelinden yararlanıldı. TPH-YOLOV5, Visdrone veri setiyle eğitilmiş açık kaynaklı hazır bir modeldir. Test verilerinin el ile etiketi öncesinde görüntüler bu modele verilerek nesne tespit tahminleri elde edildi ve yalancı etiketleme yapılmış oldu. Daha sonra, etiketleme programı yardımıyla model tarafından yanlış etiketlenmiş nesneler düzeltildi ve modelin görüntülerde tespit edemediği nesneler el ile etiketlendi. Bu sayede zamandan oldukça tasarruf edildi. Ön tasarım raporunda da belirtilen bu veri setlerine ek olarak Unmanned Aerial Vehicle (UAV) [3], Aerial Dataset [4], Aerial Floating Objects (AFO) [5] veri setleri eğitim veri setine eklendi. UAV, drone ile çekilen ve şehir trafiğindeki araçları içeren veri setidir. Diğer bahsedilen veri setleri ise drone ile çekilmiş insan görüntülerinden oluşan veri setleridir. Fazladan eklenen bu veri setleri ile amaçlanan, modelin eğitim başarısını ve genelleme performansını artırmaktır.

Diğer hedef, kullanılacak olan algoritmaların oluşturulmasıydı. Bizim yaklaşımımız görev odaklı olduğu için nesnelerin ve pistlerin tespiti ön tasarım raporunda belirtildiği üzere birbirinden ayrıldı. Nesne tespit algoritması backbone, neck ve head olarak 3 temel parçaya incelendi. Hazır modeller kullanmaktan kaçınıldı ve denenecek algoritmalar MMDetection [6] aracı ile oluşturuldu. MMDetection, birçok güncel nesne tespit algoritmalarını içeren, bu algoritmalar üzerinde özgürce değişiklik yapılabilen ve yeni algoritmalar eklenebilen açık kaynaklı bir araçtır. Ön tasarım raporunda backbone olarak iki adaydan bahsedildi; bunlar Visual Attention Network (VAN) [7] ve ConvNeXt [8] algoritmalarıydı. Açık kaynaklı olan her iki algoritma da MMDetection sistemine entegre edilebilecek şekilde düzenlendi ve MMDetection sistemine backbone olarak eklendi. Backbone karşılaştırmasının daha sağlıklı bir şekilde tamamlanması amacıyla ön tasarım raporunda bahsedilen backbone adaylarından farklı olarak Swin [9] algoritması da kullanıldı. Swin, son yıllarda başarısını kanıtlamış bir backbone'dur. Aday olarak kullandığımız algoritmaların Swin karşısında nasıl performans gösterdiğini inceleyerek tercihlerimizin doğruluğu hakkında daha geniş bilgi sahibi olduk. Oluşturulacak olan modelin neck adaylarından olan Bidirectional Feature Pyramid Network'de [9] sisteme neck olarak eklendi. Path Aggregation Network (PANet) [10] MMDetection aracında bulunduğu için hazır olarak kullanıldı. Backbone karşılaştırmasında olduğu gibi daha sağlıklı bir neck karşılaştırması yapabilmek için bahsedilen neck adaylarından farklı olarak FPN [11] algoritması da kullanıldı. Hem BiFPN hem de PANet algoritmaları FPN'den türetilmiş tasarımlardır. Neck adaylarının FPN'e karşı gösterdikleri performansla ne kadar geliştirilmiş olduklarını görmek istedik. Modelin head adayları olan T-head [12] ve YOLO-head [13] algoritmaları PANet algoritmasına benzer olarak MMDetection sisteminde bulunduğu için hazır olarak kullanıldı. Ön tasarım

raporunda belirtilen bu algoritmalar kullanıma hazır hale getirildikten sonra backbone, neck ve head olarak çeşitli kombinasyonlarda, birbirlerine uyumlu bir şekilde MMDetection ortamında birleştirildi. Örnek olarak ConvNeXt, PANet ve T-head birleştirilerek yeni bir nesne tespit algoritması tasarlandı. TPH-YOLOV5, sadece yalancı etiketlemede kullanılacak ancak etiketleme sırasında gösterdiği başarı neticesinde nesne tespit algoritmasına eklenmesi kararlaştırıldı. Böylece ensemble model fikrine geçildi ve tasarlanan yeni model ile TPH-YOLOV5 çıktıları WBF[14] metodu ile birleştirilerek daha doğru sonuçlar elde etme yoluna gidildi.

Pistlerin tespitinde ise seçilen aynı algoritma adaylarının daha az derin ve parametre sayısı daha düşük versiyonları denendi. Pistlerin inilebilir ya da inilemez olduklarını tespit edebilmek için anomali tespit sistemleri kullanıldı. Ön tasarım raporunda belirtilen Fastflow [15] yerine PADIM [16] anomali tespit algoritması tercih edildi. Fastflow'un çok güncel olması sebebiyle birçok hatasının olduğu ve resmi olarak yayınlanmış sürümünün olmadığı tespit edildi. Bu yüzden algoritmada değişiklik tercihinde bulunduk. Ayrıca ön tasarım raporunda belirtilmesi de sınıflandırma algoritmaları bu problemin çözümünde denendi. Böylece tüm ihtimalleri deneyip en doğru sonuca ulaşmak hedeflendi. Aday olarak belirlediğimiz VAN ve ConvNeXt backbone algoritmaları, sınıflandırma algoritmalarına çevrilerek bu problem kapsamında anomali tespit algoritmalarına karşı başarıları sınandı.

3. ALGORİTMALAR VE SİSTEM MİMARİSİ

3.1. Veri Setleri

Model başarısını en çok etkileyen faktörlerden biri veri setinin kalitesidir. Veri seti probleme uygun olarak seçilmelidir. Problem, drone görüntülerindeki insan, taşıt ve pist gibi nesnelerin tespiti olduğu için bu kapsamda veri setleri seçilmiştir.

İlk olarak ön tasarım raporunda da bahsedildiği üzere Visdrone veri seti, eğitim veri setine eklenmiştir. Bu veri setinin tamamı drone ile çekilmiştir ve şehirdeki araç ve insanların görüntülerinden oluşur. Yaklaşık 10209 görüntüye sahiptir ve bu görüntüler farklı yüksekliklerde ve açılarda çekilmiştir. Görüntülerin neredeyse tamamı etiketlidir. Yarışma tarafından verilen probleme çok uygun bir veri setidir. Visdrone, model eğitiminde kullanılarak modelin genelleme performansı artırılmak istendi.

Diğer kullanılan veri seti UAV'dır. Tamamı drone görüntülerinden oluşan bu veri seti, trafikteki araçların tespit problemi üzerine oluşturulmuştur. Yaklaşık 80000 etiketli görüntülerden oluşur. Visdrone'dan farklı olarak tamamen araçlara odaklanmıştır ve yağmurlu, güneşli ve gece gibi hava koşulları düşünülerek hazırlanmıştır. UAV, eğitim veri setinin çeşitliliğini artırmak ve modelin farklı araç tiplerine ve hava koşullarına hazır olmasını sağlamak amacıyla kullanılmıştır.

Aerial Dataset, Kaggle sitesinden alınmış açık kaynaklı bir veri setidir. Drone görüntülerinden oluşur ve insanların tespitine odaklanmıştır. Yaklaşık 1200 görüntüden oluşur ve görüntüler insanların farklı şekillerde olduğu parklarda çekilmiştir. Oturan, spor yapan, yürüyen ve koşan insanların bulunduğu bu veri seti modelin insanları tanımasını kolaylaştıracaktır.

AFO, yine Kaggle sitesinden alınmış açık kaynaklı bir veri setidir. Plajdaki insanların ve deniz araçlarının tespitine odaklanmış bir veri setidir. Yaklaşık 3647 etiketli görüntülerden oluşur. Tüm görüntüler yarışmaya uygun bir şekilde drone ile çekilmiştir. İnsanlar yüzerken, yatarken ve eğlenirken çekilmiş görüntülerdir. Ayrıca denizde bulunan taşıtları içermesiyle çeşitliliği artırmaktadır.

Pist tespitinde kullanmak üzere, yarışma komitesinin sağladığı png verilerinden yararlanılmıştır. UAP ve UAİ png verileri çeşitli görüntülere eklenerek yeni bir veri seti oluşturulmuştur. Buna ek olarak yarışmanın paylaştığı videolardan alınan pist içeren görüntüler de kullanılmıştır. Yine de pist veri sayısı istenilen düzeye gelmediği için döndürme, canlılık, parlaklık ve bulanıklık gibi çeşitli veri çoğaltma adımları uygulanarak pist verileri çoğaltılmıştır. Veriler çoğaltılmadan önce 541 görüntüden oluşuyordu. Çoğaltma işleminden sonra yaklaşık 1381 görüntüye ulaşıldı. Toplam UAP ve UAİ nesne sayılarının eşit olmasına dikkat edildi. Böylece eğitilen modelin bir pist çeşidine odaklanması önlenmiştir.

3.2. Algoritmalar

Yarışma kapsamında kullanılacak algoritmalar tasarlanırken özgünlüğe ve görev odaklı olmalarına özen gösterildi. Problemin çözümünde kullanılacak algoritma 3 ana parçadan oluşuyor; bunlar nesne tespiti, pist tespiti ve pist iniş durumu tespitidir. Tasarlanan algoritmanın bu şekilde parçalardan oluşmasındaki en büyük sebep pist tespitine ayrı önem veriliyor olmasıdır. Pist ve nesnelerin tespiti farklı modeller ile gerçekleştirilerek algoritma başarısı artırıldı. Buna ek olarak görev odaklı modeller tasarlanmış oldu.

Nesne tespiti bölümündeki amaç insan ve taşıtların doğru bir şekilde sınıflandırılıp görüntüye göre koordinatlarının saptanmasıdır. Güncel nesne tespiti modelleri 3 bölümden oluşur; bunlar backbone, neck ve head'dir. Daha önce belirtildiği üzere Backbone adaylarımız VAN ve ConvNeXt, neck adaylarımız BiFPN ve PANet, head adaylarımız ise T-head ve YOLO-head algoritmalarıydı. Bu algoritmalar çeşitli kombinasyonlarda MMDetection ortamında birleştirildi ve denendi. Denemeler sonucunda nesne tespiti için en başarılı backbone ConvNext, neck FPN ve head T-head olarak tespit edildi. Neck bölümünde adaylarımızdan farklı olan bir algoritma tercih edildi çünkü FPN daha başarılı bir performans gösterdi. Tasarladığımız bu nesne tespit modelinin literatürde bir örneği olmadığı için ismi Feza modeli olarak belirlendi. Tasarlanan Feza modeli ile TPH-YOLOV5 birleştirilerek ensemble bir nesne tespit modeli ortaya çıkarıldı. Her iki modelin çıktıları WBF metodu ile birleştirildi. WBF, gelen çıktıları analiz eder ve belirlenen threshold değerinin üstündeki çıktıları birleştirir. Böylece daha doğru sonuçlar elde edilmesine olanak sağlar.

Backbone olarak tercih edilen ConvNext, çok güncel bir algoritmadır. Nesne tespitinde sıklıkla kullanılan ResNet [17] algoritmasının modernize edilmiş halidir. ResNet'in blok sayıları değiştirildi, depth-wise konvolüsyon blokları eklendi ve darboğaz hücrelerinin yerine ters yönlü darboğaz hücreleri tercih edildi. Böylece ResNet geliştirilerek ConvNext algoritmasına dönüştürüldü. Yapılan araştırmalar sonucunda bu algoritma muadilleri arasında çok daha başarılı olduğu saptandı ve backbone adayı olarak tercih edilmişti. Aday algoritma olan VAN'ı da başarı anlamında geride bırakarak nesne tespit modelimizin backboneu olarak tercih edildi. ConvNeXt, normalde sınıflandırma algoritmasıdır. MMDetection sisteminde backbone olarak kullanabilmek için tam bağlantılı katmanı kullanım dışı bırakıldı ve birden fazla çıkış alınabilecek şekilde düzenlendi.

Birçok nesne tespit algoritmalarında neck olarak kullanılan FPN diğer neck adaylarımızdan daha yüksek performans gösterdiği için tercih edildi. FPN sadece aday neck algoritmalarımızın başarısını ölçmek için kullanılması planlanıyordu ancak aday algoritmalarımızdan sürpriz bir şekilde daha başarılı olduğu için nesne tespit algoritmamıza neck olarak seçildi. FPN yukarıdan aşağıya ve aşağıdan yukarıya doğru katmanlardan oluşur ve öznitelik kaybını azaltır. Özellikle küçük nesnelerin tespitini kolaylaştırır. Bu avantajları sayesinde nesne tespit modelimize eklendi.

Nesne tespit modellerinin karar verici bölümü head algoritmalarıdır. Sınıflandırma ve koordinat tahminleri backbone ve neck'ten gelen verilere göre bu kısımda belirlenir. Aday algoritmalarımızdan T-head, YOLO-head'e karşı daha başarılı bir sonuç verdiği için nesne tespit algoritmasına seçildi. T-head, metot olarak TOOD [12] yolunu izler; en önemli özellikleri anchor-free olması ve görev odaklı tasarlanmış olmasıdır. Tek aşamalı olan T-head ayrıca sınıflandırma ve koordinat çıktıları arasında ilişki kurar ve daha doğru sonuçlar üretir. Hem hız hem de performans açısından daha başarılı olduğu testlerde görülmüş ve Feza nesne tespit algoritmasına head olarak eklenmiştir.

TPH-YOLOV5, sonradan nesne tespit algoritmasına eklenmesi kararlaştırıldı çünkü yalancı etiketleme sırasında gösterdiği başarı ile nesne tespit algoritmasına yararlı olacağını kanıtladı. Bu algoritma normal YOLOV5'den farklı olarak transformer blokları içerir ve Visdrone yarışmasında kullanmak üzere geliştirilmiştir. Tamamen açık kaynaklıdır. Probleme uyumluluğu açısından ve gösterdiği başarılı performanstan dolayı nesne tespit algoritmasında kullanılması kararlaştırıldı. Feza ve TPH-YOLOV5, WBF metoduyla birleştirildi ve güçlü, probleme uygun nesne tespit algoritması geliştirildi.

Model	Backbone	Neck	Head	Derinlik	Filtre	Metot	Hedef
Feza-Base	ConvNeXt	FPN	T-head	(3, 3, 27, 3)	(96, 192, 384, 768)	TOOD	Nesne Tespiti
Feza-Small	ConvNeXt	FPN	T-head	(3, 3, 9, 3)	(96, 192, 384, 768)	TOOD	Pist Tespiti
TPH-YOLOV5	CSPDarknet53	BiFPN	YOLO-head	(3, 6, 9, 3)	(128, 256, 512, 1024)	YOLO	Nesne Tespiti

Tablo 3: Nesne ve pist tespiti için tasarlanan ve kullanılan algoritmaların özellikleri


Pist tespiti için Feza modelinin daha az parametrelili, daha hızlı ve daha az derin versiyonu kullanıldı. Nesne tespiti için tasarlanan Feza modelinin backbonedaki her katmanı için derinlik sayıları (3, 3, 27, 3) olarak ayarlanmışken pist için oluşturulan Feza modelinin backbonedaki her katmanı için derinlik sayıları (3, 3, 9, 3) olarak belirlenmiştir. Aradaki bu farktan dolayı nesne tespiti için oluşturulan Feza modeline Feza-Base modeli, pist için tasarlanan versiyonuna Feza-Small modeli denmesi tercih edildi.

Nesne tespiti ve pist tespiti modellerinin eğitimindeki bir diğer fark ise görüntü çözünürlüğüdür. Feza-Base 1280X466 çözünürlüklü görüntüler ile eğitilirken Feza-Small modeli için 640X360 boyutlu görüntüler kullanılmıştır. Bunlar dışında Feza-Base ve Feza-Small model özellikleri aynıdır. Böylece ön tasarım raporuna sadık kalınarak pist tespiti için Feza-Base modelinin daha hafif versiyonu Feza-Small modeli tasarlandı ve nesne ve pist tespiti birbirinden ayrılmış oldu. Burada amaçlanan görev odaklı ve daha başarılı bir algoritma çıkarmaktır.

Pist iniş durumu tespiti içinse anomali tespit sistemleri kullanılması tercih edildi. Anomali tespit sistemleri normalde seri üretimlerdeki ürünlerin normal olmayanlarını veya istenmeyen özelliklerde olanlarını tespit etmek için tasarlanan algoritmalar. İniş durum tespitine de uygun olduğu varsayılarak denendi ve çok başarılı oldu. Bu problem için PADIM algoritması tercih edildi. PADIM'in en büyük avantajları çok az veri istiyor, çok hızlı eğitilebiliyor ve çok hızlı ve doğru sonuçlar alınabiliyor olmasıdır. PADIM öznetelik çıkarımı için ResNet-18 algoritmasının önceden ImageNet [18] ile eğitilmiş versiyonunu kullanıyor. Böylece kısa süren eğitimlerde bile doğru öznetelik çıkarımı yapabiliyor. Çıkarılan öznetelikler Gauss dağılımına göre hesaplanarak modele verilen nesnenin normal olduğu ya da anomali içerdiği tahmin ediliyor. Daha önce de belirtildiği üzere pistler hazırlanan veri setinde diğer nesnelere göre çok daha az bulunuyor. PADIM, anormal (inilemez) pist görüntülerine gerek kalmadan sadece normal (inilebilir) pist görüntüleri ile eğitilebiliyor. Daha doğru sonuçlar elde edebilmek adına UAP ve UAİ için 2 ayrı ama aynı özellikteki PADIM modelleri eğitildi. Pist tespiti için eğitilen Feza-Small modelinin çıktısı pist iniş durumu tespiti algoritmasına verilir. Çıktı, sınıfına göre UAP ya da UAİ için eğitilen PADIM modeline gönderilir. PADIM verilen pist görüntüsünün, eğitim sırasında öğrendiği gauss dağılımındaki benzerliğine göre normal (inilebilir) veya anormal (inilemez) olduğu tahminini çıktı olarak sunar. Pist tahmini olmadığı müddetçe çalışmaz.

Model	Özellik Çıkarıcı	Benzerlik Ölçüm Tipi	Hedef
PADIM	ResNet-18	Gauss Dağılımı	Pist İniş Durumu Tespiti

Tablo 5: Pist iniş durum tespiti için eğitilen modelin özellikleri



Şekil 1: Yarışmada kullanılacak olan algoritmanın tasarımı

Yukarıdaki figür algoritmamızın çalışma mantığıdır. Yarışma sırasında verilen test verileri nesne ve pist tespiti modellerine uygun hale getirilmek üzere ön işlemden geçirilir. Pksel değerleri normalleştirilir ve çözünürlük ayarlanır. Nesne tespiti için görüntü Feza-Base ve TPH-YOLOV5 modellerinden geçirilir ve her iki modelden çıkan tahminler WBF algoritmasıyla analiz edilerek belirlenen şartlarda birleştirilir. Pist tespiti için aynı görüntü Feza-Small modelinden geçirilir. Eğer pist tespiti yapıldıysa pist sınıfına uygun olarak PADIM modeline verilir. PADIM modeli pistlerin inilebilir veya inilemez olduğunu tahmin eder. Feza-Small modelinden çıkan pist tahmini WBF çıktısıyla toplanır ve elde edilen sınıflandırma ve koordinat tahminleri ile pist iniş durumu tahminleri JSON halinde raporlanarak yarışma tarafından beklenen formata çevrilir.

4. ÖZGÜNLÜK

Probleme çözüm aranırken tamamen özgün olmak hedeflendi. Özellikle hazır modeller kullanmaktan kaçınıldı ve daha önce yapılmış çözümler yerine onları geliştirmeye veya daha doğru yeni çözümler getirmeye uğraşıldı.

Özgünlük hedefi doğrultusunda problemin çözümünde kullanmak üzere literatürde olmayan yeni modeller tasarlandı. Nesne tespitinde kullanılan Feza-Base ve pist tespitinde kullanılan Feza-Small modelleri tasarlanarak literatüre kazandırılmış oldu. Bu modeller tasarlanırken en güncel, en başarılı ve göreve en uygun algoritmaların kullanılmasına özen gösterildi.

Ayrıca pist iniş durumu tespiti çok farklı bir yöntem ile gerçekleştirildi. Normalde seri üretimdeki ürünleri denetlemek amacıyla oluşturulan anomali tespit algoritmaları bu problem için kullanıldı. Bu problem için daha sık kullanılan sınıflandırma algoritmaları yerine yeni bir bakış açısı getirilmiş oldu. Daha önce iniş durumu tespitinde kullanılmadığı için risk alındı ancak başarılı sonuçlar elde edilerek bu problemin çözümünde kullanılacak yeni bir yaklaşım kazandırılmış oldu. Anomali tespit algoritmalarının daha farklı problemlerde de kullanılabileceği kanıtlanmış oldu.

Veri setinin büyüklüğü yüzünden etiketsiz verileri etiketlemek çok zaman alıcı bir işlemdir. Buna çözüm getirmek üzere Visdrone veri seti için eğitilmiş olan TPH-YOLOV5 modeli kullanıldı. Etiketsiz görüntüler ilk önce bu modelden geçirilerek yalancı etiketleme yapıldı. Yanlış etiketlenen veya etiketlenmeyen diğer nesneler el ile etiketlendi. Yapılan bu yöntemle büyük bir zaman tasarrufu sağlandı. Pistlerin etiketlenmesinde ise daha farklı bir yöntem uygulandı. OpenCV kütüphanesi yardımıyla klasik şekil ve renk bulma yöntemleriyle pistlerin yalancı etiketlenmesi yapıldı. Hatalar daha sonra el ile giderildi. Bu sayede pist etiketleme işleminde de çok büyük zaman tasarrufu sağlandı.

Nesne ve pist tespitinde backbone olarak denenen açık kaynaklı VAN ve ConvNeXt normalde sınıflandırma algoritmalarıdır. Probleme uygun hale getirebilmek için tam bağlantılı katmanları silindi ve çeşitli düzenlemeler yapılarak MMDetection sistemine entegre edilebilecek hale çevrildi. Böylece her iki algoritma da nesne tespit algoritmalarında kullanılabilecek backbone algoritmasına dönüştürüldü.

Nesne tespitinde ensemble model kullanıldı. Feza-Base ve TPH-YOLOV5 modellerinden elde edilen çıktılar son dönemde nesne tespit algoritmalarında başarıyı artırdığı kanıtlanan WBF yöntemiyle birleştirildi. Böylece ensemble modellerde WBF kullanılarak literatüre yeni bir bakış açısı kazandırılmış oldu.

Son olarak yarışma tarafından belirlenen problemin çözümünde kullanılacak olan algoritma tamamen görev odaklı tasarlandı. Hazır sistemler yerine göreve uygun şekilde özgün olarak tasarlanan bu algoritmayla başarılı sonuçlar elde edildi.

5. SONUÇLAR VE İNCELEME

Yeni, özgün ve görev odaklı bir tasarım yapılmaya çalışıldığı için birçok testler gerçekleştirildi. Bunlardan en önemlisi nesne ve pist tespitinde kullanılacak olan modelin seçilmesi için yapılan testlerdi.

Backbone	Neck	Head	Hafıza Kullanım (Mb)	Sınıf Kayıp (%)	Bbox Kayıp (%)	Eğitim Süresi (dk)	Test Süresi (sn)	bbox-mAP 50	bbox-mAP
VAN	PANet	T-head	1660	0.29	0.34	45	55	0.431	0.21
Swin	PANet	T-head	1279	0.28	0.37	42	52	0.672	0.311
ConvNeXt	PANet	T-head	1265	0.12	0.30	38	52	0.663	0.317
ConvNeXt	BiFPN	T-head	3127	0.82	0.80	119	142	0.002	0.001
ConvNeXt	FPN	YOLO-head	1775	0.26	0.52	37	27	0.391	0.15
ConvNeXt	FPN	T-head	1185	0.09	0.30	25	17	0.728	0.355

Tablo 7: Nesne ve pist tespiti için tasarlanan algoritma kombinasyonlarının eğitim başarı testi sonuçları

Yukarıdaki tabloda backbone, neck ve head sütunları aday algoritmaları belirtir. Hafıza kullanımı; eğitim sırasında harcanan GPU belleğini, sınıf kayıp; eğitim sırasında yanlış sınıflandırılan nesnelerin

yüzdesel oranını, Bbox kayıp; eğitim sırasında yanlış belirlenen koordinat yüzdesini, eğitim süresi; dakika cinsinden eğitim süresini, test süresi; saniye cinsinden test süresini, bbox-mAP 50; IOU threshold 0.5 olduğu zaman gerçek koordinatlar ile tahmin edilen koordinatların arasındaki doğruluk oranını, bbox-map gerçek koordinatlar ile tahmin edilen koordinatlar arasındaki doğruluk oranını gösterir.

Daha önce de belirtildiği üzere nesne ve pist tespiti için aday olarak belirlenen algoritmalar belirli kombinasyonlarda birleştirilerek denendi. Yukarıdaki tabloda tasarlanan kombinasyonlar ve onların test sonuçları gösterilmiştir. Testler MMDetection ortamında yapıldı. Bu testte veri seti olarak drone görüntülerinden oluşan ve yarışma tarafından tespit edilmesi beklenen nesneleri içeren görüntüler kullanıldı. Test edilecek algoritma sayısı fazlalığından zamandan tasarruf edebilmek için eğitim veri setinden 371 eğitim ve 137 test verisi olmak üzere görüntüler seçildi. Eğitim ve test boyunca görüntü çözünürlüğü 512X512 olarak ayarlandı. Testler olabildiğince aynı şartlarda yapıldı. Örnek olarak Backbone karşılaştırması yapılırken, ilk 3 satırda da görüldüğü gibi, diğer algoritmalar sabit tutuldu. Tabloda görüldüğü üzere ConvNeXt, diğer test edilen backbonelara göre daha az hafıza kullanıyor, daha hızlı ve başarısı daha yüksek. Neck adayları arasında yapılan testlerde şaşırtıcı sonuçlar elde edildi. BiFPN, beklenmedik şekilde çok kötü bir sonuç elde etti. Rakibi PANet daha iyi olmasına rağmen sonradan test için eklenen neck algoritması FPN, en iyi sonucu gösterdi. Rakiplerine göre daha hızlı, az hafıza kullanan ve doğruluğu daha yüksek olduğu belirlendi. Head karşılaştırmasında ise tabloda görüldüğü üzere T-head çok daha iyi sonuçlar verdi. Böylece nesne ve pist tespit algoritması yapılan testlere göre seçilmiş oldu. ConvNeXt, FPN, T-head algoritmalarından oluşan model problemin çözümünde kullanılmak üzere seçildi.

Model	Veri Seti	Hız (it/s)	bbox-mAP 50	bbox-mAP
Feza-Small	Pist Tespit	6.10	1.0	0.876
Feza-Base	Nesne Tespit	1.91	0.33	0.25
TPH-YOLOV5	Nesne Tespit	1.90	0.50	0.43

Tablo 9: Nesne ve pist tespiti için eğitilen modellerin test başarıları sonuçları

Yukarıdaki tabloda Model; nesne ve pist tespitinde kullanılan modelleri, Veri Seti; modellerin hangi veri seti ile test edildiğini, Hız; modelin saniyede kaç görüntü işleyebildiğini, bbox-mAP sütunları ise daha önce belirtildiği üzere gerçek koordinatlar ile tahmin edilen koordinatlar arasındaki yüzdesel doğruluk oranını belirtir.

Seçilen algoritmalarla tasarlanan modeller, oluşturulan eğitim veri seti ile eğitildi. Eğitim veri seti daha önce bahsedilen VisDrone, UAV, AFO ve pist veri seti görüntülerinden oluşuyor. Nesne ve pist tespiti birbirinden ayrıldığı için eğitimleri ayrı ayrı yapıldı. Nesne tespiti için bu görüntüler arasından 5000 eğitim verisi seçildi. Bu seçim, nesne sayıları gerçek durumlara uygun olacak şekilde yapıldı. Eğitim sırasındaki test içinse 5000 eğitim verisi dışında 1000 görüntü daha seçildi. Bu görüntülerde pist verileri bulunmuyor, sadece yarışma kapsamında belirlenen diğer nesneler bulunuyor. Feza-Base modeli, eğitim veri setinden seçilen bu görüntülerle eğitildi. Feza-Small ise sadece pistlerin etiketlendiği görüntüler ile eğitildi. Eğitim verisi 1068, eğitim sırasındaki test verisi 195 görüntüden oluşuyor. Eğitilen bu modeller gerçeğe en yakın doğruluk oranlarını elde etmek için yarışma tarafından takımlara sunulan test videosundan alınan görüntüler ile sınılandı. Test videosundan seçilen 500 farklı görüntü ile yapılan test sonuçları yukarıda belirtilen tablodaki gibidir. Doğruluk oranları ölçülürken Feza-Small için sadece pist etiketleri, diğer modeller için yarışma kapsamında belirlenen diğer nesneler baz alındı.

Pist iniş durumu tespiti için PADIM modeli eğitildi. Daha doğru sonuçlar için UAİ ve UAP sınıfları birbirinden ayrıldı, böylece 2 farklı ama aynı özellikte modeller elde edilmiş oldu. PADIM-UAİ, 246 inilebilir UAİ pist görüntüleri ile eğitildi. Testte ise 404 inilemez ve 27 inilebilir UAİ pist görüntüleri kullanıldı. PADIM-UAP, 211 inilebilir UAP pist görüntüleri ile eğitildi. Testte ise 334 inilemez ve 23 inilebilir UAP pist görüntüleri kullanıldı. Bu pist görüntüleri tamamen Feza-Small algoritmasından doğru tahmin olarak elde edilen pist koordinatları ve sınıfları kullanılarak kesilen görüntülerden oluşur. Görüntülerin sadece pist koordinatları içeren bölgeleri sınıfına göre PADIM-UAİ veya PADIM-UAP

modeline verilir ve inilebilir veya inilemez sonucu elde edilir. Yapılan testlerde de görüldüğü üzere getirilen yeni yaklaşım yüzde 99 başarı elde etmiştir; ayrıca hafif ve çok hızlı bir çözüm yoludur.

Model	Veri Seti	Hız (it/s)	AUROC	F1
PADIM-UAİ	Pist İniş Durum Tespit	6.78	0.999	0.995
PADIM-UAP	Pist İniş Durum Tespit	7.47	0.998	0.993


Tablo 11: Pist iniş durum tespiti için eğitilen modellerin test başarı sonuçları

Yukarıdaki tabloda Model; eğitilen algoritmaları, Veri Seti; test yapılan verileri, Hız; saniyedeki görüntü işleme sayısını, AUROC; sınıflandırma ayırımının ne kadar iyi yapıldığını, F1; precision ve recall değerlerinin harmonik ortalamasını belirtir.


Yarışma kapsamında belirlenen problemi çözüme ulaştırma yolunda birçok zorluklarla karşılaşıldı. Kullanılan modellerin özgün olması için literatürde olmayan yeni algoritmalar tasarlandı. Bazı seçilen aday algoritmalar model tasarımına uygun değildi. Birbirleri arasında uyum sorunu olduğu için algoritmaları birleştirmede problem yaşandı. Uyumsuz olan tüm aday algoritmalar açık kaynaklı olduğu için kodları yeniden düzenlendi ve tasarlanan algoritmaya uygun hale getirildi. Ayrıca MMDetection sistemine, doğru bir şekilde entegre edebilmek için bu durum da dikkate alınarak algoritmalar yeniden düzenlendi. Karşılaşılan bir diğer problem, eğitim donanımının tasarlanan algoritma için yeterli olmamasıydı. Ekran kartı olarak Nvidia GTX 1650 4GB kullanıldı ve eğitim sırasında CUDA bellek yetersizliği sorunu ile karşılaşıldı. Bu durumu çözmek için tasarlanan algoritmanın parametre sayısı düşürüldü, derinliği azaltıldı ve eğitim sırasındaki görüntü çözünürlüğü donanımın sınırlarına uygun şekilde seçildi. Bu çözüme ek olarak TPH-YOLOV5 modelinin de kullanılmasına karar verildi; çünkü bu model hem yüksek çözünürlükte hem de daha derin ve yüksek parametre sayısı ile eğitilmiş olduğu belirtildi. Model eğitimlerini COCO [19] standartlarına göre gerçekleştirdik çünkü MMDetection sistemi bu standartlara uyulmasını bekliyordu. Veri setini bu standartlara göre oluştururken bir hata yapıldı. Gerçek etiket dosyalarında sınıflar index olarak 0'dan başlanarak sıralandırıldı. Bu şekilde eğitim yapıldığında çok kötü sonuçlar elde ediliyordu. Daha sonra fark edildiği üzere COCO standartlarında sınıf indexleri 0'dan değil 1'den başlamalıymış. Bu hata giderildikten sonra sağlıklı eğitimler yapılabilirdi. Yarışma kapsamında verilen problemi en doğru şekilde çözüme ulaştırmak için birçok yöntem ve algoritma en güncel şekilde araştırılarak ve test edilerek büyük bilgi birikimi sağlandı. Literatürde olmayan yeni modeller geliştirilerek ve problemin çözümünde kullanmak üzere anomali tespit algoritmaları gibi yeni yöntemler belirlenerek ve uygulanarak büyük tecrübeler kazanıldı.



Şekil 2: Tasarlanan algoritmanın yarışma tarafından paylaşılan örnek videodan alınmış görüntüde gösterdiği nesne tespit başarıları örneği



Şekil 3: Tasarlanan algoritmanın yarışma tarafından paylaşılan örnek videodan alınmış görüntüde gösterdiği nesne ve pist tespit başarısı örneği



Şekil 4: Şekil 3'de tespit edilen UAİ ve UAP alanlarının PADIM-UAİ ve PADIM-UAP ile gerçekleştirilmiş iniş durum tespiti çıktıları

6. KAYNAKÇA

- 1) Du, D., Zhu, P., Wen, L., Bian, X., Lin, H., Hu, Q., ... & Zhang, L. (2019). VisDrone-DET2019: The vision meets drone object detection in image challenge results. In *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops* (pp. 0-0).
- 2) Zhu, X., Lyu, S., Wang, X., & Zhao, Q. (2021). TPH-YOLOv5: Improved YOLOv5 Based on Transformer Prediction Head for Object Detection on Drone-captured Scenarios. In *Proceedings of the IEEE/CVF International Conference on Computer Vision* (pp. 2778-2788).
- 3) Zeng, Y., Duan, Q., Chen, X., Peng, D., Mao, Y., & Yang, K. (2021). UAVData: A dataset for unmanned aerial vehicle detection. *Soft Computing*, 25(7), 5385-5393.
- 4) <https://www.kaggle.com/datasets/mysteryprsm/aerial-dataset>
- 5) <https://www.kaggle.com/datasets/jangsienicajzkowy/afo-aerial-dataset-of-floating-objects>
- 6) Chen, K., Wang, J., Pang, J., Cao, Y., Xiong, Y., Li, X., ... & Lin, D. (2019). MMDetection: Open mmlab detection toolbox and benchmark. *arXiv preprint arXiv:1906.07155*.
- 7) Guo, M. H., Lu, C. Z., Liu, Z. N., Cheng, M. M., & Hu, S. M. (2022). Visual attention network. *arXiv preprint arXiv:2202.09741*.
- 8) Liu, Z., Mao, H., Wu, C. Y., Feichtenhofer, C., Darrell, T., & Xie, S. (2022). A ConvNet for the 2020s. *arXiv preprint arXiv:2201.03545*.
- 9) Tan, M., Pang, R., & Le, Q. V. (2020). Efficientdet: Scalable and efficient object detection. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 10781-10790).
- 10) Liu, S., Qi, L., Qin, H., Shi, J., & Jia, J. (2018). Path aggregation network for instance segmentation. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 8759-8768).

- 11) Lin, T. Y., Dollár, P., Girshick, R., He, K., Hariharan, B., & Belongie, S. (2017). Feature pyramid networks for object detection. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 2117-2125).
- 12) Feng, C., Zhong, Y., Gao, Y., Scott, M. R., & Huang, W. (2021, October). Toood: Task-aligned one-stage object detection. In *2021 IEEE/CVF International Conference on Computer Vision (ICCV)* (pp. 3490-3499). IEEE Computer Society.
- 13) Redmon, J., & Farhadi, A. (2018). Yolov3: An incremental improvement. *arXiv preprint arXiv:1804.02767*.
- 14) Solovyev, R., Wang, W., & Gabruseva, T. (2021). Weighted boxes fusion: Ensembling boxes from different object detection models. *Image and Vision Computing*, 107, 104117.
- 15) Yu, J., Zheng, Y., Wang, X., Li, W., Wu, Y., Zhao, R., & Wu, L. (2021). FastFlow: Unsupervised Anomaly Detection and Localization via 2D Normalizing Flows. *arXiv preprint arXiv:2111.07677*.
- 16) Defard, T., Setkov, A., Loesch, A., & Audigier, R. (2021, January). Padim: a patch distribution modeling framework for anomaly detection and localization. In *International Conference on Pattern Recognition* (pp. 475-489). Springer, Cham.
- 17) Wu, Z., Shen, C., & Van Den Hengel, A. (2019). Wider or deeper: Revisiting the resnet model for visual recognition. *Pattern Recognition*, 90, 119-133.
- 18) Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. *Advances in neural information processing systems*, 25.
- 19) Lin, T. Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., ... & Zitnick, C. L. (2014, September). Microsoft coco: Common objects in context. In *European conference on computer vision* (pp. 740-755). Springer, Cham.