

**TEKNOFEST**

**HAVACILIK, UZAY VE TEKNOLOJİ  
FESTİVALİ**

**ULAŞIMDA YAPAY ZEKA YARIŞMASI  
KRİTİK TASARIM RAPORU**

**MüZEYyenHan**

**319322**

## İÇİNDEKİLER

|                                                  |    |
|--------------------------------------------------|----|
| İÇİNDEKİLER .....                                | 2  |
| ŞEKİL LİSTESİ .....                              | 3  |
| TABLO LİSTESİ .....                              | 4  |
| KISALTMALAR .....                                | 4  |
| 1. TAKIM ŞEMASI.....                             | 6  |
| 1.1. Kurucu Takım Lideri .....                   | 6  |
| 1.2. Takım Üyesi-1 .....                         | 6  |
| 1.3. Takım Üyesi-2.....                          | 6  |
| 2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ.....       | 7  |
| 3. ALGORİTMALAR VE SİSTEM MİMARİSİ.....          | 8  |
| 3.1. Veri Setleri.....                           | 8  |
| 3.1.1. UA-P/İ Veri Seti .....                    | 8  |
| 3.1.2. MKT Objelerini İçeren Veri Setleri .....  | 8  |
| 3.1.3. İnsan Objelerini İçeren Veri Setleri..... | 9  |
| 3.2. Algoritmalar.....                           | 9  |
| 3.2.1. Faster R-CNN .....                        | 10 |
| 3.2.2. YOLO.....                                 | 10 |
| 4. ÖZGÜNLÜK .....                                | 11 |
| 5. SONUÇLAR VE İNCELEME .....                    | 14 |
| 6. KAYNAKÇA.....                                 | 15 |



## ŞEKİL LİSTESİ

|                                                      |    |
|------------------------------------------------------|----|
| Şekil 1.1 Takım Organizasyon Şeması.....             | 6  |
| Şekil 3.1 UA-P/İ Veri Seti Örnekleri .....           | 8  |
| Şekil 3.2 Roundabout Veri Seti Örnekleri.....        | 9  |
| Şekil 3.3 SDD Veri Seti Örnekleri.....               | 9  |
| Şekil 3.4 Faster R-CNN Mimarisi .....                | 10 |
| Şekil 3.5 YOLO Tabanlı Mimari.....                   | 10 |
| Şekil 4.1 Önerilen Algoritma Adımları .....          | 11 |
| Şekil 4.2 Ön İşlem Adımları Uygulanmış Örnekler..... | 12 |
| Şekil 4.3 Görüntü Parçalama Fonksiyonu Kurgusu ..... | 12 |
| Şekil 4.4 Dolgulama Yöntemi.....                     | 12 |
| Şekil 4.5 Filtreye Takılan Görüntüler.....           | 13 |
| Şekil 4.6 İniş Durumu Belirleme Algoritması .....    | 13 |
| Şekil 5.1 Test Görüntüleri ve Sonuçları.....         | 14 |



## TABLO LİSTESİ

|                                                                 |    |
|-----------------------------------------------------------------|----|
| Tablo 2.1 Kullanılması Planlanan Bilgisayarın Özellikleri ..... | 7  |
| Tablo 3.1 MKT Objelerini İçeren Veri Setleri.....               | 8  |
| Tablo 5.1 YOLOv5 Eğitim Değerleri.....                          | 14 |




## KISALTMALAR

|        |                                                                 |
|--------|-----------------------------------------------------------------|
| A.B.D: | Anabilim Dalı                                                   |
| NT:    | Nesne Tespiti                                                   |
| ÖTR:   | Ön Tasarım Raporu                                               |
| YOLO:  | You Only Look Once                                              |
| CPU:   | Merkezi İşlem Birimi                                            |
| GPU:   | Grafik İşlem Birimi                                             |
| RAM:   | Rastgele Erişimli Hafıza                                        |
| UAP:   | Uçan Araba Park                                                 |
| UAİ:   | Uçan Ambulans İniş                                              |
| MKT:   | Motorlu Karayolu Taşıtları                                      |
| VAID:  | Vehicle Aerial Imaging from Drone                               |
| UAVDT: | Unmanned Aerial Vehicle Benchmark Object Detection and Tracking |
| LSM:   | Lab of Sensors and Modelling                                    |
| JPEG:  | Joint Photographic Experts Group                                |
| SDD:   | Stanford Drone Dataset                                          |
| RPN:   | Region Proposal Network                                         |



## 1. TAKIM ŞEMASI

2022 Teknofest Ulaşımında Yapay Zeka yarışması özelinde kurulan MüZEYyenHan takımı, bir adet takım lideri ve iki adet üye olmak üzere toplamda üç farklı kişiden oluşmaktadır. Şekil 1.1'de MüZEYyenHan takımının organizasyon şeması verilmiştir.



Şekil 1.1. Takım Organizasyon Şeması

Bu kişilerin görev tanımları ve sorumlulukları uzmanlık alanlarına göre belirlenmiş olup detayları aşağıdaki gibidir.

### 1.1. Kurucu Takım Lideri

MüZEYyenHan takımının kurucusu ve aynı zamanda lideri, Ulaştırma Anabilim Dalı'nda (A.B.D.) lisansüstü eğitimine devam etmektedir. Bu süreçte elde ettiği teorik bilgiler yardımıyla yapay zeka tabanlı bir sistemin ulaştırma sektörüne entegrasyonunda gerekli bilimsel ve akademik altyapıyı, MüZEYyenHan takımı için oluşturmaktadır. Raporlama ve dokümantasyon aşamalarının etkin bir şekilde kurgulanmasında ve etik süreçlerin yönetiminde sorumluluk almaktadır. Literatürde yer alan benzer çalışmaların incelenerek içerik analizlerinin yapılması sonucunda projenin ilerleyişi için gereksinimlerin belirlenmesi ve proje takvimin oluşturulmasında yetkilidir. Takım üyelerinin çalışmalarının koordine edilmesi ve proje takvimine uygunluğunun denetlenmesinde görev üstlenmektedir. Belirtilen tüm bu sorumluluklara ek olarak veri seti örneklerinin etiketlenmesinde aktif olarak görev almaktadır.

### 1.2. Takım Üyesi-1

MüZEYyenHan takımı üyesi-1, yapay zeka ve veri bilimi alanında çalışmalar yapmaktadır. Veri setlerinin araştırılması, irdelenmesi ve projeye uygunluğunun belirlenmesinde görev almaktadır. Halka açık veri setlerinin Nesne Tespiti (NT) çalışmalarında kullanılabilir bir hale getirilmesinde gerekli yöntemlerin araştırılması ve projede uygulanmasından sorumludur. Veri seti örneklerinin yetersiz kaldığı senaryolar için sentetik görüntülerin üretilmesi ve üretilen görüntülerin ilgili veri setinde gözetilen standartlara uygun olarak dahil edilmesi gibi uygulamalar gerçekleştirmektedir. Görüntülerin içerisinde yer alan ve yarışma kapsamında bilgisayar tarafından otomatik olarak tespit edilmesi gereken objelerinin yapay zeka modelinin eğitiminde kullanılmak üzere etiketlenilmesi süreçlerini yürütmektedir.

### 1.3. Takım Üyesi-2

MüZEYyenHan takımı üyesi-2, yapay zeka ve görüntü işleme alanında çalışmalar yapmaktadır. Proje kapsamında kullanılacak algoritmalarının araştırılması, karşılaştırılması ve belirlenmesinde yetkilidir. Etiketlendirilmiş veri seti örnekleri yardımıyla ilgili yapay zeka modellerinin eğitilmesi süreçlerini gerçekleştirmektedir. Eğitim süreçleri sonrasında yapay zeka modellerinin performanslarının irdelenmesi için test aşamalarını da yürütmektedir. Bu test aşamaları sayesinde elde edilen sonuçlar neticesinde yarışma esnasında kullanılacak en başarılı modeli belirlemektedir. Yarışma gününe kadar modelin daha iyi sonuçlar üretebilmesi için ilgili optimizasyon çalışmalarından sorumludur.

## 2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ

Ön Tasarım Raporunun (ÖTR) hakemler tarafından değerlendirilmesinin ardından projemizin planlamasında çeşitli düzenlemeler gerçekleştirilmiştir. Bu düzenlemelerde, hakemler tarafından zayıf yönlerimiz olarak yorumlanan maddeler ön planda tutulmuştur. ÖTR'de zayıf noktalarımız olarak belirtilen spesifik maddeler aşağıdaki gibidir.

1. Projenin gerçekleştirileceği platform veya donanım hakkında bilginin bulunmaması.
2. NT görevini gerçekleştirecek algoritma olarak yalnızca You Only Look Once (YOLO) kullanımının planlanması.

Belirtilen hakem değerlendirmelerinde yer alan 1. maddeye istinaden; projede kullanılacak modelin eğitimi Google Colab ortamında gerçekleştirilecek olup yarışma konseptini içinde barındıran test aşamaları ise kişisel bilgisayarımızda yürütülecektir. Tablo 2.1'de yarışma esnasında kullanılması planlanan bilgisayarın özellikleri verilmiştir.

**Tablo 2.1. Kullanılması Planlanan Bilgisayarın Özellikleri**

| Model       | Çip | CPU          | GPU          | RAM   |
|-------------|-----|--------------|--------------|-------|
| MacBook Pro | M1  | 8 Çekirdekli | 8 Çekirdekli | 16 GB |

Belirtilen hakem değerlendirmelerinde yer alan 2. maddeye istinaden; YOLO ve türevleri olan algoritmalara ek olarak Faster R-CNN tabanlı modelleri eğiterek en başarılı modelin seçimi için karşılaştırmaya dayalı bir yapı oluşturulmuştur. ÖTR'de belirtilen zayıf noktalarımızın yanı sıra güçlü yönlerimizin etkilerini arttırabilmek için proje takvimine de uygun olacak bir şekilde çalışmalar gerçekleştirilmiştir. Bu çalışmalar hakkında detaylı bilgiler aşağıda yer almaktadır.

1. NT çalışmalarında kullanılan halka açık veri setleri detaylıca irdelenmiştir ve özel izinler sayesinde paylaşılan veri setleri için gerekli başvurular tarafımızca yapılmıştır.
2. Halka açık veri setlerinde yer alan ve yarışma esnasında tespiti gerçekleştirilmesi gereken objelerin etiketlenmemiş durumları için online platformlar kullanılarak manuel işaretleme yapılmıştır.
3. Uçan Araba Park (UAP) ve Uçan Ambulans İniş (UAI) objelerinin yalnızca bu yarışma kapsamında yer almasından ötürü ilgili objeleri içeren kaynak sayısı sınırlıdır. Bu sebeple görüntü çoklama yöntemleri kullanılarak UAP ve UAI alanlarını içeren görüntüler sentetik olarak üretilmiştir.
4. Nihai veri setinin oluşturulması aşamasında baskınlığın oluşmaması için işaretlenmiş obje sayısının sınıf bazlı olarak benzer sayıda olmasına özen gösterilmiştir.
5. Yapay zeka tabanlı modellerin eğitiminde kullanılan adım sayısı (epoch), parti boyutu (batch size) ve giriş boyutu (input size) gibi hiper-parametrelerin en uygununun seçimi için çokça sayıda eğitim aşaması gerçekleştirilmiştir.
6. Model eğitimlerinde her adımdaki ağırlıklar sıralı bir şekilde kaydedilmiştir. Ek olarak performans metrikleri referans alınarak tespit etme yeteneği en fazla olan adım belirlenmiş ve test aşamasında kullanılmak üzere ayrılmıştır.
7. Test aşamaları sonucunda 1920×1080 piksel çözünürlüğüne sahip görüntülerde yer alan küçük objelerin yapay zeka modeli tarafından tespit edilmesinin oldukça zor bir görev olduğu anlaşılmıştır. Bu sebeple görüntüler 416×416 piksellik alt görüntülere parçalanmıştır. 416×416 piksel değerini tamamlayamayan görüntüler doldurma (padding) yöntemleriyle ilgili piksel değerine ulaştırılmıştır. Belirtilen ön işlem adımları sonucunda eğitim aşamaları tekrarlanmıştır.

ÖTR'de belirttiğimiz üzere, raylı taşıtlar kategorisinde yer alacak örnek görüntülere erişimdeki kısıtlamalar sebebiyle drone yardımıyla bu yarışma kapsamında kullanılmak üzere özel bir veri setinin oluşturulması planlandırılmıştı. Ancak gerekli idari izin süreçlerinin belirtilen zaman aralığında sonuçlandırılmaması sebebiyle özel veri setimiz yalnızca halka açık video karelerinden elde edilmiş ve tarafımızca işaretlenmiş görüntülerden oluşmaktadır.



### 3. ALGORİTMALAR VE SİSTEM MİMARİSİ

#### 3.1. Veri Setleri

Teknofest Ulaşım'da Yapay Zeka yarışmasının yayınlanan teknik şartnamesinde taşıt, insan, UAP ve UAİ olmak üzere dört adet objenin bilgisayar tarafından otomatik olarak tespit edilmesi beklenmektedir. Halka açık veri setlerinde NT çalışmalarına uygun olarak Motorlu Karayolu Taşıtları (MKT) ve insan objelerini içeren görüntülerin sayısı oldukça fazladır. Bu sebeple belirtilen sınıflar için sıfırdan özel bir veri seti oluşturulması kaynak yönetimi açısından verimli değildir. Ancak UAP ve UAİ objeleri bu yarışma özelinde oluşturulduğu için halka açık olarak paylaşılan veri setleri arasında örneklerine rastlamak mümkün değildir. Bu sebeple UAP ve UAİ objelerini içeren özel veri seti oluşturulması gerekmektedir.

##### 3.1.1. UA-P/İ Veri Seti

'Örnek Eğitim Videosu' başlığıyla tüm yarışmacılara iletilen işaretlenmemiş ve 2 dakika 48 saniyeden oluşan video dosyasında UAP ve UAİ objelerine ait kesitler bulunmaktadır. İlgili video dosyası, OpenCV [1] kütüphanesi yardımıyla her bir saniyesi 1920×1080 piksel çözünürlüğüne sahip 30 alt görüntüye bölünecek şekilde '.jpg' uzantılı resim dosyalarına dönüştürülmüştür. Bu işlem sonrasında elde edilen 5040 adet görüntünün 1230 tanesinde UAP veya UAİ objeleri görülmektedir. Veri setine veri çoklama teknikleri uygulanarak 850 adet UAP objesinin ve 850 adet UAİ objesinin yer aldığı görüntü yardımıyla nihai veri seti yaratılmıştır. İnsan objelerinin mor, UAP objelerinin pembe ve UAİ objelerinin kırmızı renkteki sınırlayıcı kutularla işaretlendiği UA-P/İ veri seti örnekleri Şekil 3.1'de verilmiştir.



Şekil 3.1. UA-P/İ Veri Seti Örnekleri

##### 3.1.2. MKT Objelerini İçeren Veri Setleri

NT çalışmaları için halka açık olarak paylaşılan veri setleri irdelendiğinde MKT objelerini içeren halka açık veri setleri aşağıdaki gibidir.

1. Roundabout [2]
2. Vehicle Aerial Imaging from Drone (VAID) [3]
3. Unmanned Aerial Vehicle Benchmark Object Detection and Tracking (UAVDT) [4]
4. Lab of Sensors and Modelling (LSM) [5]

MKT objelerini içeren ve drone yardımıyla çekilen görüntülerin sınıf bazlı işaretlenmesi sonucunda oluşturulan halka açık veri setleri hakkında detaylı bilgiler Tablo 3.1.'de verilmiştir.

Tablo 3.1. MKT Objelerini İçeren Veri Setleri

| Veri Seti  | Görüntü Formatı | Görüntü Sayısı | Sınıf Sayısı | Görüntü Çözünürlükleri |
|------------|-----------------|----------------|--------------|------------------------|
| Roundabout | JPEG            | 15474          | 4            | 1920×1080              |
| VAID       | JPEG            | 4788           | 7            | 1280×720               |
| UAVDT      | JPEG            | 1685           | 3            | 1080×540               |
| LSM        | JPEG            | 501            | 4            | 4000×3000              |



Veri seti örneklerinin çekim açıları ve görüntü çözünürlükleri referans alınarak belirtilen halka açık veri setleri karşılaştırıldığında bu proje kapsamında Roundabout veri setinin kullanılması diğer veri setlerine kıyasla daha uygun olacağı tespit edilmiştir. Şekil 3.2'de Roundabout veri setinde yer alan örnekler ve içerdiği MKT objeleri turkuaz renkteki sınırlayıcı kutularla belirtilmiştir.



Şekil 3.2. Roundabout Veri Seti Örnekleri

### 3.1.3. İnsan Objelerini İçeren Veri Setleri

İnsan objelerini içeren halka açık veri setleri arasında en popüler veri seti Stanford Drone Dataset [6] (SDD)'dir. 2016 yılında paylaşılan ve dronelar sayesinde sekiz farklı lokasyonda gerçekleştirilen video kayıtlarıyla oluşturulan veri setinde yayalar, bisikletli kişiler, kaykaycılar, arabalar, otobüsler ve golf arabaları olmak üzere altı benzersiz sınıf işaretlenmiştir. SDD'ye ek olarak Roundabout ve 'Örnek Eğitim Videosu' başlığıyla tüm yarışmacılara iletilen video karelerinde yer alan insan objeleri de manuel olarak tarafımızca işaretlenmiştir. Şekil 3.3'de SDD'de yer alan örnekler ve içerdiği insan objeleri mor çerçevelerle belirtilmiştir.



Şekil 3.3. SDD Veri Seti Örnekleri


## 3.2. Algoritmalar

Derin öğrenme alanında yaşanan teknolojik gelişmeler sayesinde 2014 yılından sonraki süreçte iki aşamalı ve tek aşamalı algoritmalar NT problemlerinde sıkça kullanılmaya başlanmıştır. Genel olarak derin öğrenme tabanlı NT algoritmaları, giriş görüntüsünden veya video karesinden özellikler çıkarmaktadır. İki aşamalı NT algoritması; bulunması istenen sayıda nesnenin tespiti ve sınıflandırmasının ardından bir sınırlayıcı kutu ile boyutunu tahmin etmektedir. Tek aşamalı algoritmalar ise daha yüksek performans elde etmek için doğruluk değerindeki düşüş pahasına her iki görevi tek bir

adımda birleştirmektedir. Projemizde kullanılması planlanan iki aşamalı ve tek aşamalı NT algoritmaları mevcuttur. Bunlar Faster R-CNN ve YOLO tabanlı modellerdir.

### 3.2.1. Faster R-CNN


Faster R-CNN, RPN ile Fast R-CNN modellerinin birleştirilmiş halidir. RPN'in getirdiği yenilik, doğrudan örnekleme katmanına bağlanılabilesidir. Böylece Faster R-CNN, güçlü yapısı ile görüntülerde baştan sona nesne tespitini gerçekleştirmek için bir çalışma ortamı sunar. RPN tam olarak evrimsel bir sinir ağıdır. Girdisi bir görüntü olan önerilen bölgeleri çıkartmak için kullanılır ve önerilen bölgelere aynı zamanda skorlar verilir. Önerilen bölgelerin sınıflama katmanı ve skor değerlerini tahmin katmanı aşamasında Fast R-CNN ağına birleştirilir. Fast R-CNN ağına da iki çıkış katmanı bulunmaktadır. Bunlardan ilki Softmax sınıflayıcı katmanı diğeri ise tespit edilen bölgenin tespit edilme doğruluğunu veren regresyon katmanıdır. Faster R-CNN ile giriş görüntüsü sınıflandırma süreci boyunca sadece bir kez hesaplanır ve daha sonra tespit edilmesi gereken bölgelerin bulundukları yeri belirleyen kutuların sınırlarını düzeltir. Daha da fazlası, evrimsel katmanların paylaşılması sayesinde, nesne tespitinin performansını geliştirmek için derin bir evrimsel ağ eğitilebilir. Şekil 3.4'de Faster R-CNN mimarisinin blok gösterimi verilmiştir.



Şekil 3.4. Faster R-CNN Mimarisi [7]

### 3.2.2. YOLO

YOLO konvolüsyonel sinir ağları kullanarak nesne tespiti yapan bir algoritmadır. Gerçek zamanlı bir nesne algılama sistemi olarak YOLO, tek bir sinir ağı kullanır. Bu sebeple diğer nesne tespit algoritmalarından daha hızlıdır. YOLO mimarisi Şekil 3.5'de verilmiştir.




Şekil 3.5. YOLO Tabanlı Mimari [8]

YOLO algoritması görüntüler üzerinde tespit ettiği nesnelerin çevresini sınırlayıcı kutu ile çevreler. Kendisine girdi olarak verilen görüntüyü  $N \times N$ 'lik ızgaralara böler. Her ızgara kendi içerisinde nesne olup olmadığını ve nesne var olduğunu düşünüyorsa merkez noktasının kendi alanında olup olmadığını düşünür. Nesnenin merkez noktasına sahip olduğuna karar veren ızgara o nesnenin sınıfını, yüksekliğini ve genişliğini bulup o nesnenin çevresine sınırlayıcı kutu çizmelidir. Birden fazla ızgara, nesnenin kendi içerisinde olduğunu düşünebilir. Bu durumda ekranda gereksiz sınırlayıcı kutular oluşur. Ancak Non-max Suppression algoritması görüntü üzerinde tespit edilen nesneler için çizilen sınırlayıcı kutulardan güven değeri en yüksek olanı ekrana çizmektedir. [9]

#### 4. ÖZGÜNLÜK

NT için geliştirilen modeller eğitim aşamasında sınırlayıcı kutuları saf doğru olarak kabul ettiği için işaretleme süreci büyük bir hassasiyetle yürütülmelidir. Bu özelliğinden dolayı yüksek çözünürlüklü görüntülerde sınırlayıcı kutuları oluşturmak zaman ve kaynak açısından oldukça maliyetli bir görevdir. Sınırlayıcı kutuların oluşturulması sürecinde farklı bir lisansüstü çalışmamızda oluşturduğumuz ve anlamsal bölütleme yöntemine uygun olarak çalışan algoritmamızdan yararlanılmıştır. Yüksek çözünürlükteki görüntüler için yüksek hassasiyette sınırlayıcı kutuların oluşturulmasını zaman maliyetini arttırmadan gerçekleştirilmesini sağlayan algoritmamızın detayları aşağıdaki gibidir.

1. Sınırlayıcı kutuların oluşturulması istenilen görüntü, farklı bir lisansüstü çalışmamız için eğitilmiş U-Net modeline girdi olarak verilir.
2. U-Net modelinin çıkışında ilgili sınıfa ait objelerin yer aldığı pikseller önceden belirtilmiş değerlere göre piksel bazlı olarak sınıflandırılır ve tahmin maskesi üretilir.
3. Sınırlayıcı kutuların oluşturulması istenilen görüntü üzerinde hassasiyete çok fazla özen gösterilmeden manuel olarak işaretleme gerçek kişi tarafından yapılır.
4. U-Net modeli tarafından üretilen maske görüntüsündeki objelerin yer aldığı pikseller arasında, hassasiyete dikkat edilmeden işaretlenen alanlar içerisinde olacak şekilde  $x_{max}$ ,  $y_{max}$ ,  $x_{min}$  ve  $y_{min}$  pikselleri otomatik olarak tanımlanır.
5. Sınırlayıcı kutunun kenarları, otomatik olarak tanımlanan  $x_{max}$ ,  $y_{max}$ ,  $x_{min}$  ve  $y_{min}$  piksellerine teğet olacak şekilde bilgisayar tarafından indirgenir.



Şekil 4.1. Önerilen Algoritma Adımları




Veri seti örneklerinde bulunan objelerin sınırlayıcı kutu içerisinde işaretlenmesinin ardından çeşitli ön işlem adımları uygulanmaktadır. Bu ön işlem adımlarında ilk olarak görüntü üzerinde parlaklık ve döndürme gibi işlemler uygulanmıştır. Bu sayede farklı alternatifler oluşturularak modelin öğrenmeden ziyade örüntüleri ezberleme olasılığı azaltılmıştır. Şekil 4.2'de ön işlem adımı uygulanmış veri seti örneği verilmiştir.




Şekil 4.2. Ön İşlem Adımları Uygulanmış Örnekler

Görüntü işleme teknikleri uygulandıktan sonra yüksek çözünürlükteki görüntülerde küçük yer kaplayan objelerin tespitinin kolaylaştırılması ve donanımsal sınırlamalar göz önüne alındığında eğitim aşamasının daha verimli gerçekleşebilmesi için veri seti örnekleri 416×416 piksellik alt parçalara bölünmüştür. Görüntü parçalama fonksiyonunun görsel kurgusu Şekil 4.3'de verilmiştir.



Şekil 4.3. Görüntü Parçalama Fonksiyonu Kurgusu

Şekil 4.3'de yeşil renkle belirtilen kareler başarılı bir şekilde parçalanmış 416×416 piksellik alt görüntüleri temsil etmektedir. Ancak kırmızı renkle belirtilen kareler ise 416×416 piksel boyutuna tamamlanamayan alt görüntülere karşılık gelmektedir. Bu görüntüleri 416×416 piksellik boyuta tamamlamak için dolgulama yöntemi kullanılmaktadır. Şekil 4.4'de dolgulama yöntemi uygulanmış bir örnek çıktı verilmiştir.



Şekil 4.4. Dolgulama Yöntemi

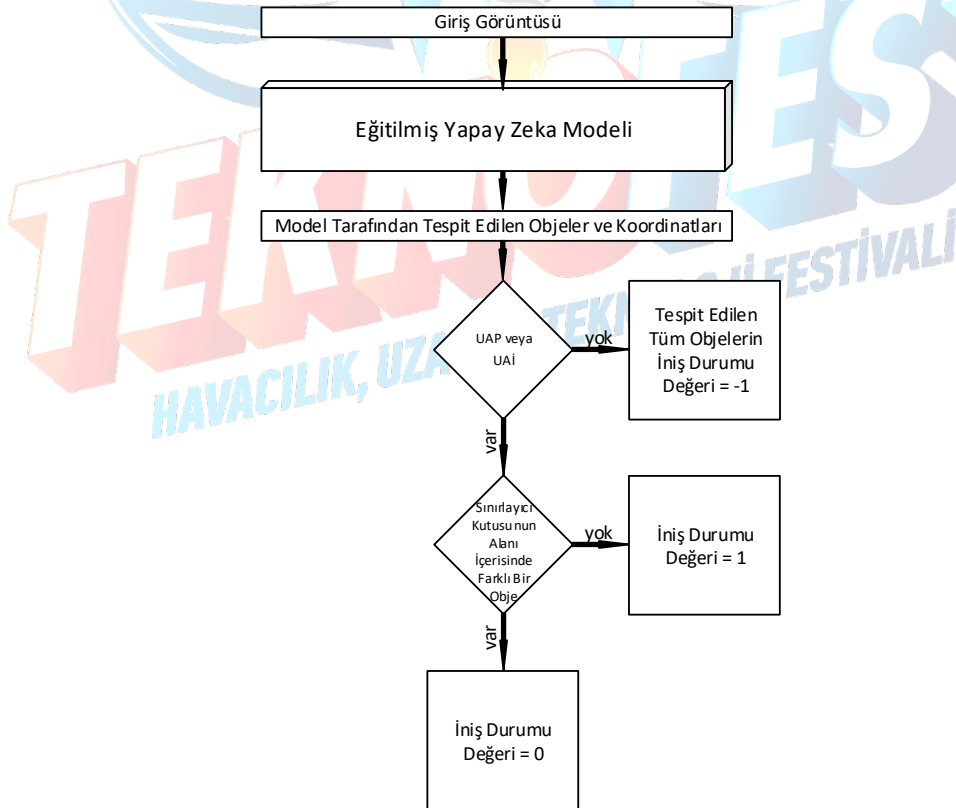
Veri seti örneklerinin tamamı belirtilen yöntem kullanılarak alt görüntülere parçalandıktan sonra bir adet 1920×1080 piksellik görüntüden 15 adet alt görüntü elde edilmiştir. Artan görüntü sayısının fazlalılığı sebebiyle eğitim aşamasının karmaşıklığı ve donanım ihtiyacı artmaktadır. Bu olumsuzluğun önüne

geçebilmek için alt görüntülerde yarışma kapsamında tespitinin yapılması istenen objelerden hiç birinin yer almadığı görüntüler var ise bu görüntüler filtre yardımıyla veri setinden kaldırılmıştır. Çünkü bu görüntüler modelimiz için herhangi bir anlamlı bilgi içermemektedir. Şekil 4.5'de filtre fonksiyonumuza takılan ve eğitim aşamasından önce veri setinden çıkarılan örnekler arasından rastgele seçilen görüntüler verilmiştir.



Şekil 4.5. Filtreye Takılan Görüntüler

Veri seti örnekleri üzerinde gerçekleştirilecek işlemler tamamlandıktan sonra model eğitimi süreci başlatılmıştır. Model eğitimi sürecinde hiper-parametreler her bir eğitimde değiştirilerek en uygun değerlere ulaşmak hedeflenmiştir. Uygun hiper-parametrelerin deneme yanılma yöntemiyle elde edilmesinin ardından eğitim esnasında her bir adımda oluşan ağırlıkların kaydedilmesi sağlanmıştır. Daha sonra ağırlıklar ve performans metriklerinin incelenmesi sonucunda belirlenen en başarılı modelin ağırlıkları test aşamasında kullanılmak üzere tercih edilmiştir. Yarışma esnasında dikkat edilmesi gereken diğer bir kıstas 'İniş Durumu' değerinin başarılı olarak belirtilebilmesidir. İniş Durumu değerinin belirlenmesinde yalnızca UAP ve UAI objeleri için ek bir işleme gerek duyulmaktadır. Çünkü taşıt ve insan sınıfına ait bir objenin İniş Durumunun mutlaka '-1' değerinde olması teknik şartnamede belirtilmiştir. Bu sebeple ilgili statik tanımlarında yer aldığı iniş durumu değerinin belirlenmesi için önerdiğimiz algoritmanın akış şeması Şekil 4.6'da verilmiştir.



Şekil 4.6. İniş Durumu Belirleme Algoritması



## 5. SONUÇLAR VE İNCELEME

YOLOv3, YOLOv4, YOLOv5, YOLOR ve Faster R-CNN modelleri 16 batch size, maksimum 300 adım sayısı ve 416×416 giriş boyutu parametreleri kullanılarak Google Colab ortamında aynı veri seti kullanılarak eğitilmiştir. Eğitim sonuçları irdelendiğinde en yüksek mAP@[.5,.95] değerine ulaşan modelin YOLOv5 olduğu gözlemlenmiştir. İlgili modelin sınıf bazlı mAP@[.5,.95] değerleri Tablo 5.1'de verilmiştir.

Tablo 5.1. YOLOv5 Eğitim Değerleri

| Sınıf  | Görüntü Sayısı | Obje Sayısı | mAP@[.5,.95] |
|--------|----------------|-------------|--------------|
| Tamamı | 8000           | 24179       | 0.653        |
| İnsan  | 8000           | 6225        | 0.443        |
| Taşıt  | 8000           | 16254       | 0.646        |
| UAİ    | 8000           | 850         | 0.778        |
| UAP    | 8000           | 850         | 0.744        |

YOLOv5 modelinin eğitim aşamasından önce test kategorisi için ayrılan ve daha önce hiç görmediği görüntüleri giriş olarak aldığı anda çıkışta üretmiş olduğu sonuç örnekleri Şekil 5.1'de verilmiştir.



Şekil 5.1. Test Görüntüleri ve Sonuçları



YOLOv5 modelinin test sonuçları detaylı olarak incelendiğinde yapılabilecek çıkarımlar sırasıyla aşağıdaki gibidir.

1. Model en düşük tespit başarısını insan sınıfına ait objeler için gerçekleştirmektedir.
2. Model taşıt objelerinde özellikle panelvan ve yük taşıma kapasitesine sahip örnekler için hatalı sonuçlar üretebilmektedir.
3. Model gölge alanlarının fazla olduğu alanlarda karar verirken zorlanmaktadır.
4. Model UAİ ve UAP alanlarının tespitinde oldukça başarılı sonuçlar üretmektedir.

Eğitimi tamamlanan YOLOv5 modelinin performansının iyileştirilmesi için planlanan süreç ve adımlar aşağıdaki gibidir.

1. Taşıt sınıfında sedan benzeri araç tiplerinin örnek sayısının azaltılarak bunların yerine panelvan ve kasalı taşıt içeren örnek sayısı artırılacaktır.
2. İnsan objelerinin tespitinin daha iyi yapılabilmesi için veri çoklama yöntemleriyle ve görüntü işleme metotlarıyla sentetik görüntüler üretilecektir.
3. YOLOv5 modeline alternatif olarak YOLOX ve diğer benzer mimariler üzerinde çeşitli katman değişikliği ve varyasyonlar kullanarak daha performanslı bir modele ulaşmak hedeflenmektedir.

Devam eden projemizde bu aşamaya kadar bizleri en fazla zorlayan etmenlerin başında donanım yetersizliği sebebiyle eğitim süreçlerinin oldukça uzun süreler almasıdır. Bu süreler ön işleme adımları sayesinde minimize edilmiş olsada yeterli düzeyde değildir. Ek olarak veri seti örneklerinin sınırlayıcı kutu yöntemiyle işaretlenmesi sürecinde personel yetersizliği beklenen performans seviyesine ulaşmamızı geciktirmektedir.

## 6. KAYNAKÇA

- [1] Jour Bradski, G., ve Kaehler, A. (2000). OpenCV. Dr. Dobb's journal of software tools, 3, 120.
- [2] Puertas, Enrique, Gonzalo De-Las-Heras, Javier Fernández-Andrés, and Javier SánchezSoriano. 2022. "Dataset: Roundabout Aerial Images for Vehicle Detection" Data 7, no. 4: 47. <https://doi.org/10.3390/data7040047>
- [3] H. -Y. Lin, K. -C. Tu and C. -Y. Li, "VAID: An Aerial Image Dataset for Vehicle Detection and Classification," in *IEEE Access*, vol. 8, pp. 212209-212219, 2020, doi: 10.1109/ACCESS.2020.3040290
- [4] Du, D., Qi, Y., Yu, H., Yang, Y., Duan, K., Li, G. ve Tian, Q. (2018). The unmanned aerial vehicle benchmark: Object detection and tracking. In *Proceedings of the European conference on computer vision (ECCV)* (pp. 370-386)
- [5] Omar, W., Oh, Y., Chung, J. ve Lee, I. (2021). Aerial Dataset Integration For Vehicle Detection Based on YOLOv4. *Korean Journal of Remote Sensing*, 37(4), 747-761.
- [6] Robicquet, A., Sadeghian, A., Alahi, A. ve Savarese, S. (2016). Learning social etiquette: Human trajectory understanding in crowded scenes. In *European conference on computer vision* (pp. 549-565). Springer, Cham
- [7] İnternet Adresi: <https://towardsdatascience.com/faster-rcnn-object-detection-f865e5ed7fc4> Erişim: 13.06.2022
- [8] Jeny, A. A., Junayed, M. S. ve Islam, M. B. (2021). PoseTED: a Novel Regression-Based Technique for Recognizing Multiple Pose Instances. In *International Symposium on Visual Computing* (pp. 573-585). Springer, Cham.
- [9] Redmon, J., Divvala, S., Girshick, R. ve Farhadi, A. (2016). You only look once: Unified, real-time object detection. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 779-788).