

TEKNOFEST

HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

ULAŞIMDA YAPAY ZEKÂ YARIŞMASI

KRİTİK TASARIM RAPORU

SPATIUM Vision

438534



İÇİNDEKİLER

1. TAKIM ŞEMASI	3
2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ	3
3. ALGORİTMALAR VE SİSTEM MİMARİSİ.....	3
3.1. Veri Setleri.....	3
3.1.1. Bounding Box Etiketli:	3
3.1.2. Segmente Etiketli:	4
3.1.3. Özel Veri Setleri:	4
3.2. Algoritmalar	4
3.2.1. Temel Tespit Algoritmaları	4
3.2.2. DAB-Transformers	5
3.2.3. SparseInst	5
3.2.4. maYOLACT	6
4. ÖZGÜNLÜK.....	6
4.1. Özgün Veri Seti.....	6
4.2. Eğitim Verisinin Çoğaltılması (Albumentations, AutoAugment).....	7
4.3. Sentetik Görüntülerden Veri Üretimi	7
5. SONUÇLAR VE İNCELEME	8
5.1. Nesne Tespiti Örnekleri, Eğitimi ve Skorları	8
5.2. Tecrübe ve Sonuçlar	8
6. KAYNAKÇA	9



1. TAKIM ŞEMASI

Kaptanımız, genel proje yürütücüsüdür. İşlerin organize edilmesi ve proje iş planını takip eder. Ayrıca yapay zekâ mimarisinin dizayn edilmesi, literatür taramasının yapılması, verilerin analizi, pipeline oluşturulması ve proje yönetimi ile ilgilenmektedir. Üye1 pipeline oluşturulmasında ve görüntülerin özellikleri üzerinde performans iyileştirme yaklaşımlarında görev alır. Üye2 yapay zekâ mimarisinin dizayn edilmesi ve hyper parametrelerin optimizasyonunda görev alır. Üye3 ve Üye4 verilerin analizi, ek verilerin bulunması, göreve uygun şekilde filtreden geçirilmesi ve verilerin etiketlenmesinden sorumludur.

2. PROJE MEVCUT DURUM DEĞERLENDİRMESİ

Takım çalışmalarımıza, ön tasarım raporunda düşünülen YOLOR[1], YOLOX[2], DAB-Transformers [3], UNet++[4] modelleri ile rapor sonrasında SparseInst[5] ve maYOLACT[6] modellerinin implementasyonu üzerinde çalışıldı. Erken aşamada küçük homojen bir veri seti dizayn edilmesi ile başlandı. Bu veri seti hem bounding box hem de segmente örneklerden oluşan iki farklı yapı olarak nitelenebilir. Bounding box etiketli verilerimizi öncelikle YOLOR üzerinde eğitildi. Segmente etiketli veriler öncelikle UNet++ üzerinden test edilirken yavaşlığı sebebi ile yeni modeller incelenmeye başlandı. Ön tasarım raporunda düşünülen ilk fikirler, birkaç baseline model üzerinde ince ayar olmaksızın direkt olarak eğitim ve sonuç alma şeklinde test edilmiştir. Ulaşılan skorlar not edilerek gelişme kayıt altına alınmaya çalışılmıştır. Bahsi geçen modeller üzerinde Öğrenme Aktarımı ve eniyileme yöntemleri ile performans ölçümleri yapılmıştır. End-to-End yaklaşımını ele alan modeller üzerinde karar kılınmıştır. Bu modellere ön tasarımda özgünlük olarak belirttiğimiz "Sentetik Görüntülerden Veri Üretimi" başlığı altında GTA V üzerinden sentetik veri üretimi son aşamaya gelmiştir. Örnek çıkarımları tamamlanmış sadece senaryo ve kayıt süreçleri projeye dahil edilecektir. UAP, UAİ tespitinde başarılı, iniş kontrolünde ise ORB[7], AKAZE[8] ve BRISK[9] algoritmaları özelleştirilerek test edilmeye başlanmıştır.

3. ALGORİTMALAR VE SİSTEM MİMARİSİ

3.1. Veri Setleri

3.1.1. Bounding Box Etiketli:

- Cezeri Veri Seti: Verilen örnek video ve görüntülerden frameler çıkartılarak hem bounding box hem de poligon etiketleme yapılarak veri setine eklenmiştir.
- VisDrone[10]: Veri seti yaklaşımımıza ve yarışmaya uygun özelliklere göre incelenerek yaklaşık %7'lik bir kısmı alındı. Veri sitenin çeşitli adına analiz edilmiştir.
- UAVDT[11]: Veri seti yaklaşımımıza ve yarışmaya uygun özelliklere göre incelenerek yaklaşık %3'lük bir kısmı alındı.

3.1.2. Segmente Etiketli:

- Cezeri Veri Seti: Verilen örnek video ve görüntülerden framerler çıkartılarak hem bounding box hem de poligon etiketleme yapılarak veri setine eklenmiştir.
- UAVID[12]: Veri seti Human ve Moving Car etiketleri alınarak genel veri setine dahil edilmiştir. Deneyisel bir yaklaşım olarak insan tespitinde başarımların artışı beklenmektedir.
- GTA V: Sentetik Görüntülerden Veri Üretimi başlığı altında otonom etiketle yapıma aşamasına gelinmiştir.

3.1.3. Özel Veri Setleri:


- PeopleOnGrass(POG)[13]: Veri seti deneyisel aşamadır. Modele entegrasyonu sonrasında insan tespitinde başarımların artışı beklenmektedir.

3.2. Algoritmalar


Ön Tasarım raporunda bahsedilen bounding box etiketlemelerinde kullanılacak modeller yarışmada kullanılacak şekilde seçilmiştir. Örnek segmentasyonu için kullanılacak modellerde ise ön tasarım raporundan sonra yapılan denemeler sonucunda yavaşlık sebebiyle yeni bir literatür taramasına gidilmiştir. Sonuç olarak örnek segmentasyonunu yapmayı planladığımız nihai modeller SparseInst ve maYOLACT ile oluşturulan bir yapı dizayn edilecektir. Tüm bu yapılar ensemble çalışıp, çoklu karşılaştırma ve analiz metotlarını içeren bir yapı dizayn edilecektir.

3.2.1. Temel Tespit Algoritmaları

YOLOR ve YOLOX yaklaşımları base alınarak E2E bir yapı oluşturulacaktır. Bu algoritmaların seçilmesinin ana amacı takım olarak sahada uygulanabilirliği olduğu için hız ve doğruluk konusunda başarılı olmalarıdır. Daha iyi doğruluk için özgünlük aşamasındaki ek yaklaşımlar düşünülmektedir.




Şekil-2: YOLOR Algoritması – (doi.org/10.48550/arXiv.2105.04206)



Şekil-3: YOLOX Algoritma Mimarisi – (doi.org/10.48550/arXiv.2107.08430)

3.2.2. DAB-Transformers

DE:TR[14], nesne algılamada elle tasarlanmış birçok bileşene olan ihtiyacı ortadan kaldırmak için yakın zamanda önerilmiştir. Ancak, görüntü özellik haritalarının işlenmesinde Transformer dikkat modüllerinin sınırlaması nedeniyle yavaş yakınsama konusunda zayıftır. DAB-Deformable-DETR, çapraz dikkat hesaplamasını iyileştirmek için hem bir referans sorgu noktası (x, y) hem de bir referans çapa boyutu (w, h) sağlamak için doğrudan dinamik olarak güncellenen bağlantı kutularını kullanır.




Şekil-4: DAB-DETR yapısının farkları - (doi.org/10.48550/arXiv.2203.03605)

3.2.3. SparseInst

SparseInst, gerçek zamanlı örnek segmentasyonu için kavramsal olarak yeni, verimli ve tamamen evrimsel bir çerçevedir. Bölge kutuları veya çapaların (merkezlerin) aksine, SparseInst, her ön plan nesnesi için bilgilendirici bölgeleri vurgulamak için nesne temsili olarak seyrek bir örnek etkinleştirme haritaları kümesini benimser. Ardından, tanıma ve segmentasyon için vurgulanan bölgelere göre özellikleri toplayarak örnek düzeyindeki özellikleri elde eder. İki parçalı eşleştirme,

örnek etkinleştirme haritalarını nesneleri bire bir tarzda tahmin etmeye zorlar, böylece işlem sonrası maksimum olmayan bastırmayı (NMS) önler.



Şekil-5: SparseInst Model Mimarisi - (doi.org/10.48550/arXiv.2203.12827)

3.2.4. maYOLACT

YOLACT[15] üzerine inşa edilen model Mask-aware IoU hesaplama metriğini kullanır. Mask-aware IoU: Mask-aware IoU (maIoU), örnek segmentasyon yöntemlerini denetlemek için daha iyi bağlantı ataması için bir IoU çeşididir. Standart IoU'nun aksine, Mask-aware IoU, bir çapa için bir yakınlık puanı atarken temel gerçeği maskelerini de dikkate alır.

Algorithm 1 The algorithm for efficiently calculating mask-Aware IoU.

- 1: **procedure** MASKAWAREIOU($\hat{B}, B, M$)
- 2: Compute $|B|$, $|\hat{B} \cup B|$ and Θ^M as integral image of M such that $\Theta_{i,j}^M$ is $(i, j)^{th}$ element of Θ^M
- 3: Set $|M| = \Theta_{m+1, n+1}^M$ and $|\hat{B} \cap M| = \Theta_{x_2+1, y_2+1}^M + \Theta_{x_1, y_1}^M - \Theta_{x_2+1, y_1}^M - \Theta_{x_1, y_2+1}^M$.
- 4: Compute $MOB(B, M) = |M|/|B|$ for ground truth B
- 5: **return** maIoU($\hat{B}, B, M$) (Eq. 5)
- 6: **end procedure**

Şekil-6: maYOLACT Model Mimarisi - (doi.org/10.48550/arXiv.2110.09734)

4. ÖZGÜNLÜK

4.1. Özgün Veri Seti

Takım Dronu ile beraber üniversite içerisinde görüntü alınmaya başlandı. Takip eden günlerde özel çekimler yapılarak veri setinin eksik yanları giderilmeye çalışılacaktır. Veri seti teknik şartnamede belirtilen özelliklere uygun şekilde üretiləcəktir. Bu veri setleri takım üyeleri tarafından hem sınırlayıcı kutu etiketlenmesi hem de bir kısmına piksel tabanlı segmentasyona uygun etiketlenme yapılacaktır.

4.2. Eğitim Verisinin Çoğaltılması (Albumentations, AutoAugment)

Veri büyütme, modern görüntü sınıflandırıcılarının doğruluğunu artırmak için etkili bir tekniktir. Biz de bu yüzden özellikle eğitim aşamasında küçülen pixellere sıkışan objelerin tespitinde modellerin başarısını artıran, veri setinin yapısına göre augmentation stratejileri geliştiren AutoAugment[16] modülü ve Albumentations[17] kütüphanesi ile verilerimizi çoğaltmayı planlamaktayız.

4.3. Sentetik Görüntülerden Veri Üretimi

Video oyun sektörünün gelişmesi ile birlikte sentetik görüntü üretiminde artan yüksek kaliteli görüntüler veri oluşturma konusunda yardımcı bir etmen olarak literatüre dahil olmuştur. Biz de Grand Theft Auto 5 (GTA V) adlı oyuna drone sistemini entegre ederek ve UAP, UAİ görsellerini oyunun farklı bölgelerine ekleyerek sentetik olarak bir veri kümesi oluşturulacaktır. Ayrıca bu yaklaşımın eğitim aşamasına katkısını deneyimlemeyi planlamaktayız. Ayrıca oyun yapımının bir ana ögesi olarak ayrı ayrı modellerle oluşturulan nesneler hızlıca segmente edilebildiği için etiketleme konusunda sentetik görüntüler ile avantaj sağlanacaktır.



5. SONUÇLAR VE İNCELEME

5.1. Nesne Tespiti Örnekleri, Eğitimi ve Skorları



(Test Seti üzerinden Nesne Tespiti örnekleri)

Yarışma üstlenicileri tarafından sağlanan Cezeri Veri Seti örnek videosu framelere ayrılarak veri seti eklemiştir ayrılmıştır. VisDrone ve UAVDT görüntülerinden görev benzerliğine uygun görüntüler eklenerek veri seti genişletilmiştir. CVAT[18], LabelImg[19] etiketleme aracı ile sadece sınırlayıcı kutular ile etiketlenmiştir. Örnek segmentasyonu için UAvId ve GTA V'ten gelecek verilerin yanı sıra labelların oranını bakılarak veri dengesi oluşturmaya yönelik olarak Cezeri Veri Seti videosundan ek segmente etiketli veriler üretilecektir.

5.2. Tecrübe ve Sonuçlar

Eğitim sonrası ortaya çıkan eksiklikler tespit edilmiştir. Bunlardan başlıcaları; UAP, UAİ iniş alanları tespit olarak iyi olmasına rağmen iniş kontrolü istenilen seviyede değildir. Bu nedenle modele ile eş zamanlı çalışacak ORB, AKAZE ve BRISK algoritmaları ile daha iyi sonuçlar beklenmektedir. İnsan tespitindeki başarımın daha da artırılması için veri setine örnek segmentasyon etiketleri ile ek yardımcı yaklaşım sunmak amaçlanmaktadır.

Mevcut bounding box veri seti ile YOLOR modeli üzerinde gerçekleştirilen 200 epoch'luk eğitim aşaması sonrası elde edilen sonuçlar şu şekildedir

Model	Kernel	Precision	Recall	mAP .5	mAP .95	val_GIoU	val_Object.	val_Classif.
YOLOR	1600	0.7912	0.9658	0.9555	0.8073	0.008022	0.01029	0.002447

Mevcut bounding box veri seti ile YOLOX modeli üzerinde gerçekleştirilen 300 epoch'luk eğitim aşaması sonrası elde edilen sonuçlar şu şekildedir

Model	Kernel	Precision	Recall	mAP .5	mAP .95	val_GIoU	val_Object.	val_Classif.
YOLOX	1200	0.8347	0.9481	0.9234	0.8157	0.01109	0.00929	0.003447

6. KAYNAKÇA

- [1] Chien-Yao Wang, I-Hau Yeh, Hong-Yuan Mark Liao. You Only Learn One Representation: Unified Network for Multiple Tasks. arXiv preprint arXiv:2105.04206, 2021.
- [2] Zheng Ge, Songtao Liu, Feng Wang, Zeming Li, Jian Sun. YOLOX: Exceeding YOLO Series in 2021. arXiv preprint arXiv:2107.08430v2, 2021.
- [3] Shilong Liu, Feng Li, Hao Zhang, Xiao Yang, Xianbiao Qi, Hang Su, Jun Zhu, Lei Zhang. DAB-DETR: Dynamic Anchor Boxes are Better Queries for DETR. arXiv preprint arXiv:2201.12329v4, 2022.
- [4] Zongwei Zhou, Md. Mahfuzur Rahman Siddiquee, Nima Tajbakhsh, Jianming Liang. UNet++: A Nested U-Net Architecture for Medical Image Segmentation. arXiv preprint arXiv:1807.10165v1, 2018.
- [5] Tianheng Cheng, Xinggang Wang, Shaoyu Chen, Wenqiang Zhang, Qian Zhang, Chang Huang, Zhaoxiang Zhang, Wenyu Liu. Sparse Instance Activation for Real-Time Instance Segmentation. arXiv:2203.12827v1, 2022.
- [6] Kemal Oksuz, Baris Can Cam, Fehmi Kahraman, Zeynep Sonat Baltaci, Sinan Kalkan, Emre Akbas. Mask-aware IoU for Anchor Assignment in Real-time Instance Segmentation. arXiv:2110.09734v1, 2021.
- [7] ORB (Oriented FAST and Rotated BRIEF). https://docs.opencv.org/3.4/d1/d89/tutorial_py_orb.html
- [8] AKAZE local features matching. https://docs.opencv.org/4.x/db/d70/tutorial_akaze_matching.html
- [9] cv::BRISK Class Reference. https://docs.opencv.org/3.4/de/dbf/classcv_1_1BRISK.html
- [10] VisDrone2021 Object Detection Dataset. aiskyeye.com/challenge_2021/object-detection-2/
- [11] UAVDT Dataset. <https://sites.google.com/view/grli-uavdt/>
- [12] UAVid Dataset. <https://uavid.nl/>
- [13] POG (People On Grass) Dataset. <https://uni-tuebingen.de/fakultaeten/mathematisch-naturwissenschaftliche-fakultaet/fachbereiche/informatik/lehrstuehle/kognitive-systeme/projects/avalon/>
- [14] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, Sergey Zagoruyko. End-to-End Object Detection with Transformers. arXiv preprint arXiv:2005.12872v3, 2020.
- [15] Daniel Bolya, Chong Zhou, Fanyi Xiao, Yong Jae Lee. YOLACT++: Better Real-time Instance Segmentation. arXiv preprint arXiv:1912.06218v2, 2020.
- [16] Ekin D. Cubuk, Barret Zoph, Dandelion Mane, Vijay Vasudevan, Quoc V. Le. AutoAugment: Learning Augmentation Policies from Data. arXiv preprint arXiv:1805.09501v3, 2019.
- [17] Alexander Buslaev, Alex Parinov, Eugene Khvedchenya, Vladimir I. Iglovikov, Alexandr A. Kalinin. Albumentations: fast and flexible image augmentations. arXiv preprint arXiv:1809.06839v1, 2018.