

TEKNOFEST

HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

SAĞLIKTA YAPAY ZEKÂ YARIŞMALARI

(Bilgisayarlı Görüyle Abdomen (Karın) Bölgesi için
Hastalık Tespiti Kategorisi)

PROJE DETAY RAPORU

ABDOMEN (KARIN) BÖLGESİ HASTALIKLARININ
TESPİTİ İÇİN DERİN ÖĞRENME TABANLI BİR
YAKLAŞIM

TAKIM ADI: ZEBOT-E1

TAKIM ID: 410880



İÇİNDEKİLER

1. Proje Mevcut Durum Değerlendirmesi:	3
1.1. Ön İşleme:	3
1.2. Veri Artırma:	3
1.3. Derin Öğrenme Modelinin Kullanılması:	5
1.4. Performans Değerlendirme:	7
2. Özgünlük:	7
3. Sonuçlar ve İnceleme:	8
4. Deney ve Eğitim Aşamalarında Kullanılan Veri Setleri:	11
7. Referanslar:	11



1. Proje Mevcut Durum Değerlendirmesi:

Ön rapor teslimi yapıldıktan sonra derin öğrenme mimarileri, bu mimarilerin ve bileşenlerinin kullanım amaçları, mimarilerin tasarlanması ve simülasyon ortamında gerçekleşmesi için kullanılabilecek programlar araştırılmıştır. Bu amaçla, Sakarya Üniversitesi Mühendislik Fakültesi Elektrik Elektronik Mühendisliği ve Sakarya Üniversitesi Bilgisayar ve Bilişim bilimleri Fakültesi Yazılım Mühendisliği Bölümleri ilgili öğretim üyelerinden destek alınmıştır.


Ön rapor aşamasında öğrencisi olduğum Adapazarı Özel Şahin Okulları bünyesinde Biyoloji Öğretmeni olan danışmanın Hakan Gülçiçek yerine kendisinin talebi ve tavsiyeleri ile Sakarya Üniversitesi Mühendislik Fakültesi Elektrik Elektronik Mühendisliği Bölümü öğretim üyesi Doç. Dr. Gökçen ÇETİNEL çalışmamıza dahil olmuştur.

Sakarya Üniversitesi Matlab programı kullanım lisansına sahip olduğundan ve Matlab programının derin öğrenme (Deep Learning Toolbox), makine öğrenmesi (Machine Learning Toolbox), görüntü işleme (Image Processing Toolbox) gibi gelişmiş araç kutularına sahip olmasından dolayı çalışma Matlab programı üzerinden yürütülmüştür. Çalışmaya ait uygulamalar her ne kadar Matlab üzerinden yürütülse de Phyton programı, kütüphaneleri ve açık kaynak kodları da incelenmiştir.

Sunulan ön raporda verilen problemin çözümü için şu temel adımlar önerilmiştir: i) Ön işleme, ii) Veri artırma, iii) Derin öğrenme modelinin kullanılması ve iv) Performans değerlendirme. Ön rapor kabulünden sonra geçen sürede her bir adım için literatür analizi yapılmış ve denemeler yapılmıştır.

1.1.Ön İşleme

Ön işleme adımında kontrast iyileştirme teknikleri incelenmiştir. Orijinal dicom uzantılı görüntülere Matlab programı kullanılarak kontrast artırma ve histogram eşitleme gibi basit işlemler uygulanmıştır. Kontrast artırma ya da ayarlama işleminde giriş görüntüsündeki intensity (yeğnlik) değerleri yeni intensity değerlerine haritalanır ve bu sayede görüntü kontrastı artırılır. Histogram eşitleme görüntüdeki intensity değerlerini, çıkış görüntüsünün histogramı önceden belirlenmiş bir histogram dağılımına yaklaşık olarak uygun olacak şekilde değiştirir. Şekil 1'de sırasıyla Matlab dicomread fonksiyonu ile okunmuş örnek bir görüntü, kontrast ayarlama, histogram eşitleme ve adaptif histogram eşitleme işlemleri uygulanmış görüntüler verilmiştir.



Şekil 1. Basit ön işleme adımları uygulanmış görüntüler.

1.2.Veri Artırma

Veri artırma adımında ilk etapta geometrik dönüşümler gibi klasik veri artırma teknikleri ele

Yönteme ilişkin detaylar [2, 3] numaralı referanslarda mevcuttur.

1.3. Derin Öğrenme Mimarisi


Ön işleme ve veri artırma adımlarından sonraki adım, verilen problemi çözmede en etkin sonuçları sağlayacak derin öğrenme mimarisinin belirlenmesidir. Çalışmanın en zaman alıcı ve önemli adımı bu adımdır. Ön raporda Faster R-CNN yapısının kullanılmasının başarılı sonuçlar vereceği ön görülmüştü. Ancak ön rapor tesliminden sonra veri tabanının da paylaşımı ile beraber bazı farklı mimariler de analiz edilmiştir. Sonuç olarak sağladığı yararlar nedeniyle YOLO V3 mimarisi dikkat çekmiştir.

Nesne algılama amacıyla kullanılan Faster R-CNN, YOLO, YOLO V2, SSD gibi çeşitli derin öğrenme mimarileri mevcuttur. YOLO V3, küçük nesnelerin algılanmasını sağlamak amacıyla YOLO V2 mimarisine eklenen çoklu ölçekli algılama özelliğine sahiptir. YOLO V3'te nesne algılama doğruluğunu artırmak amacıyla eğitim için kullanılan kayıp fonksiyonu, sınırlayıcı kutu regresyonu için ortalama karesel hata ve nesne sınıflandırma için iki-seviyeli çapraz entropi şeklinde ikiye ayrılmıştır.

YOLO V3 mimarisinin girişi için bazı ön ayarlamaların yapılması gerekmektedir. Çalışmada çok sayıda sınıf olduğundan üç sütunlu veri organizasyonu yapılmalıdır. İlk sütunda .dcm uzantılı görüntü numaraları, ikinci sütunda sınıf etiketleri ve son sütunda mimariye uygun şekilde verilen sınırlayıcı kutu (bounding box) koordinatları bulunmaktadır. Sınırlayıcı kutu için sol üst köşenin x ve y koordinatları, kutu genişliği ve yüksekliği verilmektedir.

Veri, ağı eğitmek için eğitim kümesi ve ağı değerlendirmek için test kümesi şeklinde ayrıştırılır. Ayrıştırma oranları önceden belirlenir. Sonuçların güvenilirliğini artırmak amacıyla çalışmada on kat çapraz doğrulama da yapılmıştır. Görüntüleri yüklemek için bir görüntü deposu ve gerçek doğru (ground truth) sınırlayıcı kutular için bir veri deposu oluşturulur. Görüntü ve kutu etiketi veri depoları bir araya getirilir. Geçersiz görüntüler, sınırlayıcı kutular veya etiketleri belirlemek için Matlab "validateInputData" fonksiyonu kullanılarak doğrulama işlemi yapılmıştır. Eğitim verilerini artırmada YOLO V3 için hazırlanmış yardımcı fonksiyonlar ile HSV uzayında renk titreşim artırımı, rastgele yatay döndürme ve ölçekleme (%10) işlemleri yapılabilmektedir. Ölçekleme ve döndürme işlemleri hem görüntülere hem de sınırlayıcı kutulara uygulanmıştır [7, 8].

YOLO, daha önce geliştirilmiş mimarilere göre daha yüksek mAP değeri sağlamaktadır (Şekil 4). R-CNN gibi bölge tabanlı nesne tespit algoritmaları ilk adımda nesne bulunma olasılığı olan aday bölgeleri tespit ederek her bir bölgeye ayrı ayrı CNN uygulamaktadır. Bu yöntem iyi sonuç verse de hesap yükü oldukça yüksektir. R-CNN'den sonra geliştirilen Fast R-CNN ve Faster R-CNN mimarileri tüm görüntüye tek seferde CNN uygular. R-CNN 1 FPS ile çalışırken Faster R-CNN 7 FPS ile çalışır. YOLO ise resmi tek seferde ağıdan geçirerek tüm nesnelerin sınıfını ve koordinatlarını sınırlayıcı kutular içerisinde belirler. Bu amaçla giriş görüntüleri 3x3, 5x5 ve 19x19 vb. boyutlu ızgaralara bölünür. Her ızgara kendi içinde nesne olup olmadığını, varsa orta noktasının ızgara içinde olup olmadığını, orta nokta içindeyse uzunluğunu, yüksekliğini ve hangi sınıfta olduğunu belirler. YOLO her ızgara için ayrı tahmin vektörü oluşturur. Sınıflandırma kaybı, konum kaybı ve güven kaybı değerler hesaplanarak en doğru sonuçlar elde edilmeye çalışılır.




Şekil 4. YOLO V3 için performans kıyaslaması [5].

YOLO V3 ile hem sınıf etiketleri belirlenip hem de nesnelerin bulunduğu bölgeler sınırlayıcı kutular vasıtasıyla işaretlenebilmektedir. Mimari ile ilgili olarak: YOLO V3, orijinal olarak Imagenet üzerinde eğitilmiş 53 katmanlı ağı sahip olan bir Darknet türevi kullanır. Algılama görevi için, üzerine 53 katman daha eklenir ve bize YOLO v3 için 106 katman tamamen evrimsel bir temel mimari verir.

YOLO V3'te algılama, ağıdaki üç farklı yerde üç farklı boyuttaki özellik haritalarına 1×1 algılama çekirdeği uygulanarak yapılır. Algılama çekirdeğinin $1 \times 1 \times (B \times (5 + C))$ formundadır. Burada B, özellik haritasındaki bir hücrenin tahmin edebileceği sınırlayıcı kutu sayısıdır, '5' sayısı 4 sınırlayıcı kutu niteliği ve bir nesne güveni içindir ve C sınıf sayısıdır. YOLO V3'te, nesne güveni ve sınıf tahminleri lojistik regresyon yoluyla tahmin edilirken, her etiket için sınıflandırma kaybını hesaplamada daha önce de belirtildiği gibi ikili çapraz entropi kullanılır. YOLO v3 mimarisinde, Darknet-53 özellik çıkarıcı olarak kullanılır. Darknet-53, ResNet'teki artık ağı gibi atlama bağlantılarına sahip temel olarak 3×3 ve 1×1 filtrelerden oluşur. Son geliştirilen Darknet-53 mimarisi Şekil 5'te verilmiştir [4, 5, 6].

Type	Filters	Size	Output
Convolutional	32	3×3	256×256
Convolutional	64	$3 \times 3 / 2$	128×128
Convolutional	32	1×1	
Convolutional	64	3×3	
Residual			128×128
Convolutional	128	$3 \times 3 / 2$	64×64
Convolutional	64	1×1	
Convolutional	128	3×3	
Residual			64×64
Convolutional	256	$3 \times 3 / 2$	32×32
Convolutional	128	1×1	
Convolutional	256	3×3	
Residual			32×32
Convolutional	512	$3 \times 3 / 2$	16×16
Convolutional	256	1×1	
Convolutional	512	3×3	
Residual			16×16
Convolutional	1024	$3 \times 3 / 2$	8×8
Convolutional	512	1×1	
Convolutional	1024	3×3	
Residual			8×8
Avgpool		Global	
Connected		1000	
Softmax			



Şekil 5. Darknet-53 [7].

1.4. Performans Değerlendirme

Önerilen sistemin performansını değerlendirmek amacıyla ortalama kesinlik değerlerinin ortalaması (mean Average Precision, mAP) ve kesiştirilmiş bölgeler (Intersection over Union, IoU) ölçütleri kullanılacaktır [4].

Yarışma öncesinde ve esnasında beklenen düzeyde performans sağlayabilecek “İşlemci: Intel (R) Core (TM) i7-8750H CPU @ 2.20GHz, RAM: 16 GB ve 64 bit işletim sistemi” özelliklerine sahip dizüstü bilgisayar kullanılacaktır. Ayrıca ön rapordan sonraki aşamada Sakarya Üniversitesi Bilgisayar ve Bilişim Bilimleri Fakültesi Öğretim Üyesi Doç. Dr. Devrim AKGÜN tarafından eğitim süreçlerinin tamamlanması için destek sağlanmıştır.

2. Özgünlük:

Sunulan çalışmanın özgün yönleri kısaca şu şekilde özetlenebilir:


- i) TEKNOFEST ekibi tarafından paylaşılan veriler ile işlemlere başlamadan önce veri tabanı üzerinde incelemeler yapılmıştır. Bu incelemede veri setinde etiketlenen ancak bizden tespiti istenmeyen safra kesesi taşı gibi etiketler olduğu görülmüştür. Ayrıca aynı görüntü üzerinde birden fazla tespitin de yapılması gerektiği anlaşılmıştır. Bu bağlamda veri seti üzerinde mimariye girmeden bazı düzenlemeler yapılmıştır. Bu işlem yapılırken iki farklı yol izlenmiştir. İlk sette tüm etiketler taranarak sadece abdomen bölgesinde tespit edilmesi istenen altı sınıf ve bir de bulgu yok sınıfı olmak üzere yedi sınıfa göre veriler kümelendirilmiştir. Burada, aslında bizden tespiti istenmeyen etiketler veri seti haricinde tutulmuştur. İkinci sette ise ilkinden farklı olarak bizden istenmeyen etiketler de bulgu yok sınıfına dahil edilmiştir. Ayrıca her iki sette de birden fazla bulgu olan görüntüler her bulguya ayrı ayrı dahil edilmiştir.
- ii) Ön işleme adımında yukarıda bahsedilen işlemler görüntülere uygulanmıştır.
- iii) Veri artırma adımında eğitim seti üzerinde yukarıda bahsedilen yaygın veri çoğaltma teknikleri uygulanarak performanslar değerlendirilmiştir. Ayrıca DCGAN yapısı da analiz edilmiştir.
- iv) Verilen problemi çözmek için hem sınıflandırma hem de nesne algılama işlemlerini yürütebilen hız açısından etkin YOLO V3 mimarisi kullanılmıştır. Mimaride özellik çıkarma görevini yerine getirmek amacıyla Darknet-53 evrişimli sinir ağı bulunmaktadır. Bu ağ, 1000 nesne kategorisi ve 1 milyondan fazla görüntü içeren Imagenet veri tabanı üzerinde eğitilmiş ön eğitilmiş (pretrained) bir ağıdır. Çalışmada Darknet-19, SqueezeNet, MobileNet-V2, ResNet-18 gibi ön eğitilmiş ağların performansları da araştırılmıştır.
- v) YOLO mimarilerinde hâlihazırda kullanılan çapa kutusu (anchor box) için tahminler oluşturulmuş ve sayıları, genişlik ve yükseklikleri tahminlenmiştir. Çapa kutuları sayesinde hızlı bir şekilde çok sayıda farklı ölçekte nesnenin algılanması sağlanmıştır. Çapa kutularının kestiriminde ortalama IoU değeri 0.5 değerinin

altında olan çapalar kaldırılmıştır. Ortalama IoU değerinin 0.5'in üzerinde olması eğitim verisindeki kutularla çapa kutularının güzel örtüştüğünü gösterir.

- vi) Bilindiği gibi YOLO ile sınırlayıcı kutular ve sınıf etiketleri belirlenmektedir. Son işleme adımı olarak sınırlayıcı kutuların bir nesne içerip içermediğini belirlenmesi için sınıf olasılıkları çekilerek 0.3'ün altında olan nesneler ihmal edilmiştir. Aynı nesneyi tanımlayan nadiren birden fazla sınırlayıcı kutu olması durumunda bir eşik belirlenerek (Non-max Suppression, 0.5) tek sınırlayıcı kutu seçilmiştir.
- vii) YOLO V3'ten sonra geliştirilen YOLO V4 ve V5 mimarileri de araştırılmış bu mimarilerin gerçek zaman uygulamalarda hız yönünden katkı sağladığı sonucuna ulaşılmıştır. Bu nedenle YOLO V3 üzerinden devam edilmiştir.
- viii) Darknet-53 ağına ilave katmanlar eklenerek performansın artırılması amacıyla yapılan çalışmalar devam etmektedir.

3. Sonuçlar ve İnceleme:

Çalışmanın ilk sonuçlarını elde etmek için Şekil 6'da verilen basit CNN yapısı kurulmuştur. Bu yapı sadece sınıflandırma amacıyla kullanılmıştır. Böylece oluşturulan veri tabanları üzerinde sadece sınıf etiketlerinin hangi doğrulukla elde edildiği analiz edilmiş, veri çoğaltma tekniklerinin eğitim doğruluğu üzerindeki etkileri de bu basit ağ ile ilk aşamada incelenmiştir.




Şekil 6. İlk denemeler için oluşturulan CNN mimarisi.

Daha önce de bahsedildiği gibi iki farklı yolla veri tabanı düzenlemesi yapılmıştır. İlkinde tüm etiketler taranarak sadece abdomen bölgesinde tespit edilmesi istenen altı sınıf ve bir de bulgu yok sınıfı olmak üzere yedi sınıfa göre veriler kümelendirilmiştir. Burada, aslında bizden tespiti istenmeyen etiketler veri seti haricinde tutulmuştur. İkinci veri setinde ise ilkinden farklı olarak bizden istenmeyen etiketler de bulgu yok sınıfına dahil edilmiştir. Sınıflandırma sonuçları ön işleme ve veri çoğaltma adımları olmaksızın ilk sette %93,21 ikinci sette %89,96 olarak elde edilmiştir. Veri çoğaltma teknikleri arasında yeniden boyutlandırma, çarpıtma, kırpma işlemleri doğruluğu yaklaşık olarak %1,28-1,74 oranında artırmıştır. Görüntü döndürme işleminin uygulandığı durumlarda ise doğruluk yaklaşık %2-2,5 oranlarında artmıştır. Sentetik gürültü ekleme ile veri çoğaltma durumunda ise doğruluk %0,5-1 oranlarında azalmaktadır. Buna göre


veri artırmada geometrik çoğaltma tekniklerinin genel olarak eğitim performansını bir miktar artırdığı sonucuna ulaşılmıştır. Gürültülü veri gelmesi durumunda karşılaşılabilecek performans düşüşünü önlemek amacıyla da araştırmalar yapılmıştır. Matlab derin öğrenme örnekleri arasında görüntüden gürültü temizlemek amacıyla oluşturulmuş mimariler bulunmuş ve incelenmiştir. Böylece gürültü durumu için de alternatif bir çözüm üretilebileceği sonucuna ulaşılmıştır.

CNN ile sınıflandırma tabanlı ön çalışma adımlarından sonra, önerilen YOLO V3 mimarisi ile hem sınıflandırma hem de istenildiği gibi minimum sınırlayıcı kutu belirleme görevini yerine getirmek amacıyla çalışmalar yapılmıştır. Yapılan çalışmalarda özellik çıkarma adımı daha önce de bahsedilen DarkNet-53, Darknet-19, SqueezeNet, MobileNet-V2, ResNet-18 ağlarının performansları kıyaslanmıştır. En iyi performans DarkNet-53 mimarisi ile elde edilmiştir.


YOLO V3 ile tüm veri seti üzerinden sınıflandırma performansı test aşaması için %84,21 olarak elde edilmiştir. Minimum sınırlayıcı kutular için bizden istenildiği gibi hesaplanan ortalama IoU değeri %76,89 olarak hesaplanmıştır. Bazı bulgular için minimum sınırlayıcı kutular Şekil 7, Şekil 8 ve Şekil 9'da gösterilmiştir.



Şekil 7. Böbrek/Üreter Taşı Bulgusu için Elde Edilen Minimum Sınırlayıcı Kutu (Olgu Numarası: 16265, Sınıf: 4, Kutu Koordinatları: 312,322-331,342 / YOLO V3 ile Tespit Edilen Sınıf: 4, Elde Edilen Koordinatlar: 313,325-328,340).



Şekil 8. Akut Pankreatit Bulgusu için Elde Edilen Minimum Sınırlayıcı Kutu (Olgu Numarası: 21922, Sınıf: 3, Kutu Koordinatları: 201,232-251,261 / YOLO V3 ile Tespit Edilen Sınıf: 3, Elde Edilen Koordinatlar: 202,227-249,233).



Şekil 9. Akut Kolesistit Bulgusu için Elde Edilen Minimum Sınırlayıcı Kutu (Olgu Numarası: 16558, Sınıf: 2, Kutu Koordinatları: 181,198-229,240 / YOLO V3 ile Tespit Edilen Sınıf: 3, Elde Edilen Koordinatlar: 183,197-227,239).

4. Deney ve Eğitim Aşamalarında Kullanılan Veri Setleri:

Çalışmada TEKNOFEST tarafından sağlanan veriler kullanılmıştır. Ancak kullanılan mimari ön eğitilmiş ağ içerdiğinden COCO veri tabanı ve ImageNet veri tabanı ön eğitilmiş ağlarda kullanılmaktadır.

5. Referanslar:

[1] Radford, A., Metz, L., & Chintala, S. (2015). Unsupervised representation learning with deep convolutional generative adversarial networks. ArXiv Preprint ArXiv:1511.06434.

[2] Hammami, M., Friboulet, D., & Kéchichian, R. (2020, October). Cycle GAN-based data augmentation for multi-organ detection in CT images via Yolo. In 2020 IEEE International Conference on Image Processing (ICIP) (pp. 390-393). IEEE.

[3] J.-Y. Zhu, T. Park, P. Isola, and A.A Efros, "Unpaired image-to-image translation using cycle-consistent adversarial networks," in Proceedings of the IEEE international conference on computer vision, 2017, pp. 2223–2232.

[4] Rani, S., Singh, B. K., Koundal, D., & Athavale, V. A. (2022). Localization of Stroke Lesion in MRI Images Using Object Detection Techniques: A Comprehensive Review. Neuroscience Informatics, 100070.

[5] Redmon, J., & Farhadi, A. (2018). YOLOv3: An incremental improvement. arXiv preprint arXiv:1804.02767.

[6] Salman, M. E., Çakar, G. Ç., Azimjonov, J., Kösem, M., & Cedimoğlu, İ. H. (2022). Automated prostate cancer grading and diagnosis system using deep learning-based Yolo object detection algorithm. Expert Systems with Applications, 201, 117148.

[7] <https://www.analyticsvidhya.com/blog/2018/12/practical-guide-object-detection-yolo-framework-python/>

[8] <https://www.mathworks.com/help/vision/ug/object-detection-using-yolo-v3-deep-learning.html>